

Peso de ações nos fundos de investimento brasileiros

Um modelo de fator dinâmico com correção logística e ajuste parcial

João Paulo Zangrandi

Escola de Economia de São Paulo, Fundação Getulio Vargas

Orientador: Prof. Maurício Ferraresi Junior

2026

A pergunta, e a base para respondê-la

A carteira divulgada de um fundo é demanda revelada. Olhando todos os fundos que carregam a mesma ação no mesmo mês, o preço é comum a todos, e o que resta para explicar a diferença entre eles são características dos próprios fundos.

Duas perguntas: o que explica o peso, e esse peso é previsível fora da amostra.

	Fundos	Ativos	Gestoras
Universo bruto CVM com posição em ações, 2016 a 2021	3.254	n.a.	41
Com ao menos uma posição direta em ação	3.228	536	41
Amostra final, com as seis características completas	2.507	512	41

8.212.294 observações de fundo por ativo e por mês, em 59 meses. Dado inteiramente público da CVM, e o universo inteiro, não um recorte de uma gestora ou de um papel.

Referência: Kojen e Yogo (2019). O trabalho fica do lado das quantidades, não dos preços.

Onde o trabalho entra na literatura

Três correntes sustentam o desenho, e cada uma para num ponto diferente.

Corrente	Referências	Até onde ela vai
Precificação baseada em demanda	Koijen e Yogo (2019); Gabaix e Koijen (2021)	Estima o sistema de demanda a partir de carteiras e mostra que o rebalanceamento institucional move o preço. O objeto final é o preço, com investidor americano.
Fluxo e negociação institucional	Lakonishok, Shleifer e Vishny (1992); Coval e Stafford (2007); Lou (2012)	Documenta que a negociação do fundo move o preço e que o fluxo prevê retorno. Mede fluxo e retorno, não o peso de cada posição.
Ajuste parcial	Fama e French (2002); Flannery e Rangan (2006); Calvet, Campbell e Sodini (2009)	Mede a velocidade de convergência a um alvo, em alavancagem de firma e em carteira de pessoa física. O alvo é tomado como dado.

Nenhuma delas percorre sozinha a cadeia que vai da característica do fundo ao peso previsto, deste à velocidade de ajuste e desta ao desempenho fora da amostra. É essa cadeia que o trabalho monta, com o alvo estimado dentro do próprio modelo, num painel brasileiro de base pública onde a evidência é escassa.

Etapa 1: o corte transversal

Para cada ativo n e cada mês t , uma regressão logística do peso nas características do fundo i , estimada separadamente em cada célula:

$$\text{peso}_{i,n,t} = g(x'_{i,n,t}\theta_{n,t}) + e_{i,n,t}, \quad g(z) = \frac{1}{1 + e^{-z}}, \quad e_{i,n,t} = \text{peso}_{i,n,t} - g(x'_{i,n,t}\theta_{n,t})$$

Seis características em $x_{i,n,t}$: tamanho, cotistas, fundo de cotas, fluxo sobre patrimônio, beta da cota e a concentração do restante da carteira, definida como

$$\text{HHI}_{\text{resto},i,n,t} = \text{HHI}_{\text{total},i,t-1} - \text{peso}_{i,n,t-1}^2, \quad \text{HHI}_{\text{total},i,t-1} = \sum_m \text{peso}_{i,m,t-1}^2$$

Subtrair $\text{peso}_{i,n,t-1}^2$ retira o próprio ativo-alvo do índice, o que evita explicar o peso com uma medida que já o contém. Defasar para $t - 1$ mantém a mesma disciplina de predeterminação das outras cinco características.

A forma logística é escolhida porque o peso vive em $[0, 1]$: nenhuma das 8,2 milhões de previsões caiu fora do intervalo.

Etapas 2 e 3: dinâmica e teste fora da amostra

Etapas 2. O fundo não salta para o alvo $w_{i,n,t}^* = g(x'_{i,n,t}\theta_{n,t})$. Fecha uma fração λ da distância por mês:

$$w_{i,n,t+1} - w_{i,n,t} = \lambda d_{i,n,t} + u_{i,n,t+1}, \quad d_{i,n,t} \equiv w_{i,n,t}^* - w_{i,n,t}$$

Etapas 3. λ_h estimado apenas com $t < \text{jan}/2020$, congelado e aplicado ao período seguinte, contra a regra ingênua:

$$\hat{w}_{i,n,t+h}^{\text{PA}} = w_{i,n,t} + \hat{\lambda}_{h,\text{treino}} d_{i,n,t}, \quad \hat{w}_{i,n,t+h}^{\text{ing}} = w_{i,n,t}$$

$$\text{erro}_{i,n,t+h} = (w_{i,n,t+h} - w_{i,n,t}) - \hat{\lambda}_{h,\text{treino}} d_{i,n,t}, \quad \text{margem}_h = 1 - \frac{\text{RMSE}_h^{\text{PA}}}{\text{RMSE}_h^{\text{ing}}}$$

A previsão ingênua é um adversário duro: peso de carteira é muito persistente, e repetir o último valor já acerta quase tudo.

Etapa 1: o que explica o peso

Característica	Mediana do coeficiente	Mediana do efeito marginal médio	Células com sinal positivo
Beta da cota	0,7830	0,1401 p.p.	88,2%
Concentração do resto	0,4220	0,0562 p.p.	87,6%
Cotistas	0,1254	0,0141 p.p.	72,8%
Fluxo sobre patrimônio	0,0372	0,0027 p.p.	53,0%
Fundo de cotas	-0,0244	-0,0005 p.p.	48,3%
Tamanho	-0,0283	-0,0007 p.p.	44,5%

Estimado em 13.723 células de ativo e mês, com pseudo- R^2 médio de 0,531. A concentração do resto é significativa em 74,4% das células, e nessas o sinal é positivo em 95,7%.

Duas características dominam. Fundo mais exposto ao mercado carrega mais de qualquer ação, e quem já concentrava no mês anterior concentra de novo. Concentrar é um traço de estilo da casa, não uma decisão tomada ativo por ativo.


Etapas 2 e 3: ajuste lento, mas que ajuda a prever

$\hat{\lambda} = 0,0690$ ao mês. O fundo fecha só 6,9% da distância até o alvo por mês, o que dá meia-vida de 9,7 meses. Ajuste real, porém lento, e é essa lentidão que faz o peso parecer um passeio aleatório no curto prazo.

	$h = 1$	$h = 3$	$h = 6$	$h = 12$
RMSE do ajuste parcial	0,004033	0,005850	0,007097	0,008546
RMSE da previsão ingênua	0,004095	0,006040	0,007454	0,009198
Razão entre os dois	0,9848	0,9686	0,9522	0,9291
$\hat{\lambda}_h$ estimado no treino	0,0704	0,1473	0,2205	0,3382

Vence a ingênua nos quatro horizontes, com margem crescendo de 1,5% a 7,1%, e em 23 dos 23 meses de teste. O λ_h cresce com o horizonte, que é o previsto: mais tempo, mais da distância percorrida.

O achado: a dificuldade de prever tem dono



Erro médio mensal fora da amostra, $h = 1$. À esquerda, as três gestoras mais difíceis de prever; à direita, as três mais previsíveis, na mesma escala.

Entre as 40 gestoras, o erro varia quase trinta vezes, de 0,00050 a 0,01424.

E não é ruído. Dividindo o teste ao meio, cada gestora se parece consigo mesma, com correlação de 0,85 na dispersão do erro. Quem é difícil em 2020 continua difícil em 2021.

O viés, ao contrário, quase não importa: responde por menos de 0,5% do erro quadrático, e corrigi-lo melhora o RMSE em 0,04%. É a variância que precisa ser explicada.

Erro e margem por gestora, nos quatro horizontes

Gestora	Fundos	RMSE fora da amostra				Margem sobre a ingênua (%)			
		$h=1$	$h=3$	$h=6$	$h=12$	$h=1$	$h=3$	$h=6$	$h=12$
Guepardo	11	0,01424	0,02305	0,03358	0,05649	1,2	1,0	-0,1	-1,3
Ibiuna	7	0,01331	0,02131	0,02492	0,02848	3,1	6,8	8,2	14,3
AZ Quest	22	0,01092	0,01461	0,01650	0,01871	3,1	6,7	9,5	15,1
Squadra	15	0,01069	0,01588	0,02090	0,03058	-5,4	-13,7	-24,3	-45,6
Núcleo Capital	22	0,01037	0,01810	0,02468	0,03538	-1,0	-2,1	-2,0	-5,7
<i>trinta gestoras intermediárias omitidas</i>									
Itaú	466	0,00261	0,00385	0,00473	0,00559	1,9	4,2	6,2	8,1
Dahlia Capital	18	0,00245	0,00422	0,00549	0,00631	2,4	5,3	8,0	10,2
TNA	29	0,00150	0,00216	0,00278	0,00384	0,1	-0,8	-0,8	2,3
Gávea	17	0,00144	0,00265	0,00365	0,00472	2,2	4,2	7,9	10,4
Plural	1	0,00050	0,00079	0,00104	0,00134	-2,4	-3,7	-2,8	-6,1

As cinco mais difíceis e as cinco mais previsíveis, de 40 grupos de gestora, ordenadas por RMSE em $h = 1$. Erro alto e margem baixa não são a mesma coisa: a AZ Quest é das mais difíceis e ainda assim o modelo ajuda 15,1% nela em $h = 12$, enquanto a Squadra é o único caso em que o modelo piora de forma expressiva e crescente com o horizonte.

O que explica a variância: concentração

Uma regressão entre as 40 gestoras, com a dependente medida só no teste e as explicativas só no treino:

$$\begin{aligned} \text{dp}(\text{erro})_g = & \alpha + \beta_1 \overline{\text{beta}}_g + \beta_2 \overline{\log(\text{PL})}_g + \beta_3 \overline{\log(\text{cotistas})}_g \\ & + \beta_4 \overline{\text{FIC}}_g + \beta_5 \overline{\text{fluxo}}_g + \beta_6 \overline{\text{HHI}}_g + \varepsilon_g \end{aligned}$$

Variável	Coef.	t	Sig.
Intercepto	-0,0122	-1,07	n.s.
Beta médio da cota	0,0015	0,55	n.s.
Tamanho médio	0,0009	1,34	n.s.
Cotistas médio	0,0001	0,18	n.s.
Proporção de fundos de cotas	-0,0006	-0,31	n.s.
Fluxo médio sobre patrimônio	-0,0092	-1,38	n.s.
Concentração média da carteira	0,0736	3,76	1%
R^2		0,496	
R^2 ajustado		0,405	

Correlação entre concentração e erro, agora no nível de fundo e mês:

Contemporânea	0,48
Defasada em um mês	0,49
Dentro do mesmo fundo	0,07

As duas primeiras quase iguais afastam coincidência de mês. A terceira, perto de zero, mostra que a concentração separa fundos, e não meses de um mesmo fundo.

Conclusão

- Beta da cota e concentração do resto da carteira explicam o peso de forma consistente. Tamanho e fluxo, quase nada.
- O ajuste ao alvo é positivo mas lento, com meia-vida de dez meses, e ainda assim bate a previsão ingênua nos quatro horizontes testados.
- A dificuldade de prever é heterogênea, persistente e explicada pela concentração da carteira. Essa é a regularidade nova do trabalho.

Limitações

- Metade da variância do erro entre gestoras segue sem explicação.
- O beta é medido no próprio mês, e não defasado como as demais características.
- $d_{i,n,t}$ e Δw compartilham $-w_{i,n,t}$, o que favorece mecanicamente $\hat{\lambda} > 0$.
- A amostra termina em 2021.