

Explicação completa e didática — modelagem do peso de VALE3 nos fundos Itaú

TCC — FGV EESP
Orientador: Prof. Maurício Ferraresi Jr.

26 de junho de 2026

Este documento explica, em profundidade e em linguagem acessível, todo o raciocínio: *o que* fazemos, *por que* cada modelo e cada escolha, *as equações* e *como interpretar*. O companheiro `results.pdf` traz as tabelas com os números.

Sumário

1	O problema e a motivação	1
2	A estrutura: o peso como função de demanda e a ideia de dois passos	1
3	As variáveis e por que cada transformação	2
4	Passo 1A — a cross-section mês a mês	2
5	Por que preço e beta NÃO entram na cross-section	3
6	Passo 1B — a regressão <i>pooled</i>	3
7	Como o beta é calculado, e por quê	3
8	Cuidado com <i>look-ahead</i> e por que preço nominal	3
9	Passo 2 — a dinâmica dos fatores θ_t	4
10	Passo 2 — previsão do peso e a matriz de erros	4
11	O filtro de Kalman (estado-espço) — o próximo passo	4
12	Rigor: validação e parsing	5
13	Síntese	5

1 O problema e a motivação

Cada fundo de investimento decide quanto do seu patrimônio coloca em cada ação. A fração investida na ação j pelo fundo i é o **peso** $w_{i,t}^{(j)}$. Aqui fixamos $j = \text{VALE3}$ e olhamos os fundos da gestora

Itaú, mês a mês. Queremos responder: *quais características dos fundos explicam o peso?* e, depois, *conseguimos prever o peso do mês seguinte?*

A motivação teórica é o *demand-based asset pricing* (Kojien–Yogo): em vez de tratar preços como dados por um “investidor representativo”, modela-se a **demanda** de cada investidor por um ativo como função das *características* de quem investe. O peso de um fundo é, nessa visão, uma **função de demanda**.

2 A estrutura: o peso como função de demanda e a ideia de dois passos

Postulamos que o peso é, a cada mês, uma função (linear) das características do fundo:

$$w_{i,t} = \alpha_t + \underbrace{\sum_k \beta_t^k x_{i,t}^k}_{\text{parte explicada}} + \varepsilon_{i,t}, \quad (1)$$

onde $x_{i,t}^k$ são características (tamanho, cotistas, etc.) e $\varepsilon_{i,t}$ é a parte idiossincrática (o que o modelo não captura). O ponto central, proposto pelo orientador, é que o vetor de coeficientes

$$\theta_t = (\alpha_t, \beta_t^1, \dots, \beta_t^K)$$

resume como as posições dependem das características naquele mês. Em vez de acompanhar o peso de centenas de fundos, acompanhamos esses poucos números: θ_t é um **fator latente** que *reduz um problema de alta dimensão a uma dimensão pequena*. A modelagem tem **dois passos**:

- **Passo 1 (transversal)**: para cada mês, estimar θ_t por uma regressão entre fundos.
- **Passo 2 (temporal)**: modelar como θ_t evolui no tempo e usar isso para prever.

3 As variáveis e por que cada transformação

Alvo $w_{i,t}$ (peso) — **em nível**. É uma fração em $[0, 1]$. Usamos em nível porque é o que o orientador pediu (o coeficiente de MQO é o fator) e é direto de ler.

AUM e n^o de cotistas — **em logaritmo**. São muito assimétricos (fundos de R\$1 milhão e de R\$18 bilhões). Em nível, um fundo gigante dominaria. O log *comprime* a escala e capta efeitos *proporcionais*: como $\ln(2X) - \ln(X) = \ln 2$ independe de X , dobrar de 10 para 20 milhões “pesa” como dobrar de 100 para 200. Formalmente, o coeficiente de $\ln(\text{AUM})$ é o efeito de uma *variação percentual* no tamanho.

FIC vs. FI — **variável binária**. Um FIC (Fundo de Investimento em Cotas) investe em cotas de outros fundos; um FI investe direto. Isso afeta a posição *direta* em ações. Detectamos FIC pelo nome (a classificação ANBIMA é de estratégia, não distingue FIC/FI).

Fluxo líquido — **como fluxo/AUM**. O fluxo é (captação – resgate) do mês. Dividir pelo patrimônio dá uma medida *comparável* entre fundos de tamanhos diferentes (fluxo como % do tamanho) e que *preserva o sinal* (entrada +, saída –). Não dá para usar log porque o fluxo pode ser negativo.

4 Passo 1A — a cross-section mês a mês

Para *cada mês* t , estimamos por MQO:

$$w_{i,t} = \alpha_t + \beta_t^1 \ln(\text{AUM}_{i,t}) + \beta_t^2 \ln(\text{Cot}_{i,t}) + \beta_t^3 \text{FIC}_i + \beta_t^4 \left(\frac{\text{Fluxo}}{\text{AUM}} \right)_{i,t} + \varepsilon_{i,t}. \quad (2)$$

Cada mês gera um θ_t . Com 72 meses (2016–2021), temos 72 vetores.

Por que Fama–MacBeth. Como os coeficientes mudam mês a mês, o jeito estatístico correto de resumi-los é o procedimento de **Fama–MacBeth**: a estimativa final é a *média no tempo*, e o erro-padrão vem da *variação entre os meses*:

$$\hat{\beta}^k = \frac{1}{T} \sum_{t=1}^T \beta_t^k, \quad \text{ep}(\hat{\beta}^k) = \frac{\text{dp}(\beta_t^k)}{\sqrt{T}}, \quad t = \frac{\hat{\beta}^k}{\text{ep}(\hat{\beta}^k)}. \quad (3)$$

O teste t assim construído pergunta: *o efeito médio é robusto ao longo dos meses?*

O que achamos. Tamanho (–), cotistas (+) e FIC (–) têm o *mesmo sinal nos 72 meses* e são altamente significativos; o fluxo não explica o *nível*. Em palavras: fundos maiores diversificam mais (menos VALE3); fundos com mais cotistas têm mais; FICs têm menos posição direta.

5 Por que preço e beta NÃO entram na cross-section

Dentro de um mesmo mês, o preço e o beta da VALE3 são *iguais para todos os fundos* — são características do *ativo*, não do fundo. Na equação (2), uma variável constante entre os i é colinear com o intercepto α_t : não há variação *entre fundos* para identificar seu efeito (ele seria absorvido por α_t). Logo, preço e beta são variáveis **agregadas**: explicam o nível *médio* ao longo do *tempo*, não as diferenças entre fundos. Por isso entram (i) na regressão *pooled* e (ii) no Passo 2.

6 Passo 1B — a regressão *pooled*

Empilhando todos os fundos-meses, o preço e o beta passam a variar (entre os 72 meses) e ficam identificados:

$$w_{i,t} = \alpha + \beta^1 \ln \text{AUM} + \beta^2 \ln \text{Cot} + \beta^3 \text{FIC} + \beta^4 \frac{\text{Fluxo}}{\text{AUM}} + \beta^5 \text{Preço}_t + \beta^6 \text{Beta}_t + \varepsilon_{i,t}. \quad (4)$$

Achamos **preço** + e **beta** –, ambos significativos: em meses de VALE3 mais cara, o peso médio sobe; em meses de VALE3 mais arriscada (beta alto), cai (aversão a risco). *Lição metodológica*: no piloto de só 2016 (12 meses) o beta saía positivo e fraco; com 72 meses ele é claramente negativo. Doze pontos no tempo eram poucos para identificar variáveis agregadas — por isso estendemos para 6 anos.

7 Como o beta é calculado, e por quê

Beta mede **quanto a ação se move quando o mercado se move** — é a inclinação da regressão dos retornos da VALE3 sobre os do Ibovespa (modelo de mercado / CAPM):

$$r_t^{VALE} = a + \beta r_t^{Ibov} + u_t \implies \beta = \frac{\text{Cov}(r_t^{VALE}, r_t^{Ibov})}{\text{Var}(r_t^{Ibov})} = \rho_{VALE, Ibov} \cdot \frac{\sigma_{VALE}}{\sigma_{Ibov}}. \quad (5)$$

A segunda igualdade é instrutiva: o beta é a *correlação* com o mercado vezes a *razão de volatilidades*. Calculamos *nós mesmos* (não pegamos o “beta” pronto do Yahoo, que é de 5 anos contra índice americano e estático), com retornos diários simples $r_s = P_s/P_{s-1} - 1$ (VALE3 pelo preço ajustado; Ibovespa pelo fechamento), em **janela móvel de 252 pregões**, lido no **último pregão do mês anterior** a cada competência. $\beta > 1$: amplifica o mercado (cíclica/arriscada); $\beta < 1$: amortece. Conferimos o cálculo por três caminhos idênticos (fórmula covariância/variação, função **cov/var**, e o coeficiente de uma regressão).

8 Cuidado com *look-ahead* e por que preço nominal

Look-ahead (viés de antecipação) é usar informação do futuro — erro grave em previsão. Garantimos que cada característica olha só para trás: a janela do beta termina na data de medição, e preço/beta vêm do mês *anterior*. Detalhe fino: o preço *ajustado* (adjclose) é recalculado para trás usando dividendos *futuros*, então seu nível numa data passada “sabe” de proventos posteriores. Por isso, como característica usamos o **preço nominal** (o preço de fato negociado, imune a isso); o ajustado serve só para os *retornos*/beta, que são limpos (a constante de ajuste cancela na razão P_s/P_{s-1}).

9 Passo 2 — a dinâmica dos fatores θ_t

Como cada coeficiente evolui no tempo? Comparamos dois modelos:

$$\text{AR}(1): \theta_{k,t} = c_k + \phi_k \theta_{k,t-1} + \eta_{k,t}; \quad \text{Random walk: } \theta_{k,t} = \theta_{k,t-1} + \eta_{k,t}. \quad (6)$$

O AR(1) “puxa” o coeficiente de volta a uma média de longo prazo quando $|\phi| < 1$ (reversão à média); o random walk ($\phi = 1$) deixa-o vagar sem âncora. Para distinguir, usamos um teste tipo **Dickey–Fuller**: regredimos $\Delta\theta_t = a + \rho\theta_{t-1} + e_t$ e testamos $\rho = 0$ (raiz unitária $\Leftrightarrow$ random walk); um $t < -2,9$ rejeita a raiz unitária ($\approx 5\%$) em favor da reversão.

O que achamos. Os fatores estruturais (intercepto, tamanho, cotistas, FIC) são **persistentes mas estacionários** ($\phi \approx 0,7-0,84$, não ≈ 1 ; DF rejeita raiz unitária): *oscilam em torno de um nível estável e reverterem à média*. O coeficiente do fluxo é quase ruído. Ou seja, a proposta de random walk do orientador é refinada pelos dados para **reversão à média**; na prática, na previsão dos fatores, AR(1) e random walk dão erro parecido (a posição “âncora”).

10 Passo 2 — previsão do peso e a matriz de erros

Prevemos o peso um mês à frente aplicando o *vetor de coeficientes previsto* às características do fundo:

$$\hat{w}_{i,t} = \hat{\theta}_t' x_{i,t}, \quad \hat{\theta}_t = \begin{cases} \theta_{t-1}, & \text{random walk,} \\ \hat{c} + \hat{\phi} \theta_{t-1}, & \text{AR}(1), \end{cases} \quad (7)$$

e comparamos com o **benchmark ingênuo** $\hat{w}_{i,t} = w_{i,t-1}$ (o peso do próprio fundo no mês anterior). A **matriz de erros** é $e_{i,t} = w_{i,t} - \hat{w}_{i,t}$ (uma matriz fundo $\times$ mês).

Resultado (e por que importa). O **benchmark ingênuo vence** (erro $\approx$ metade do modelo de fator). Isso é economicamente esperado: o peso é **muito persistente no nível do fundo** — quem tem 5% em VALE3 este mês terá $\approx 5\%$ no próximo. O modelo de fator é forte para **explicar** a seção transversal (quais características importam), mas não bate a inércia do próprio fundo para **prever**.

A matriz de erros tem média ≈ 0 e é estacionária (DF $t = -7,6$) — propriedades que o orientador queria verificar. O **refino natural** é combinar os dois: adicionar um *efeito-fixo de fundo* μ_i (o nível próprio de cada fundo) à dinâmica do fator, modelando $w_{i,t} = \mu_i + \theta'_t x_{i,t} + \varepsilon_{i,t}$, ou prever a *variação* Δw .

11 O filtro de Kalman (estado-espço) — o próximo passo

As estimativas mensais θ_t vêm de regressões com ~ 130 fundos cada: têm *ruído amostral*. O filtro de Kalman trata isso com um modelo de **estado-espço**, separando o *estado verdadeiro* (oculto) da *medida ruidosa*:

$$\text{medida: } \hat{\theta}_t^{\text{MQO}} = \theta_t + v_t, \quad v_t \sim (0, R) \quad (\text{ruído amostral da cross-section}), \quad (8)$$

$$\text{estado: } \theta_t = c + \phi \theta_{t-1} + \eta_t, \quad \eta_t \sim (0, Q) \quad (\text{evolução AR}(1)). \quad (9)$$

O filtro combina, de forma *ótima* (mínimo erro quadrático), a **inércia do estado** (o que esperávamos por (6)) e a **informação nova** de cada mês, pesando-as pela confiança relativa (Q vs. R). O resultado é uma trajetória de θ_t mais limpa e uma previsão $\theta_{t+1|t}$ — e, daí, do peso. É o que implementaremos a seguir, possivelmente já com o efeito-fixo de fundo.

12 Rigor: validação e parsing

As bases da CVM têm armadilhas: números em “R\$x.xxx,xx”, vírgula decimal, notação científica; datas em formatos diferentes; linhas duplicadas; mudança de layout em 2021 (coluna extra). Tratamos e **auditamos** cada uma. Em particular: 0 duplicados fundo-mês, 0 pesos negativos, 0 NAs indevidos; a captação da SH bate com o Informe Diário da CVM em **99,4–99,8% ao centavo** nos 6 anos; o preço bate com o fechamento oficial da B3; o beta confere por três métodos; e o recorte de 2016 do painel de 6 anos é *idêntico* ao painel de 2016 validado isoladamente.

13 Síntese

O **nível** do peso de VALE3 é explicado por características *estruturais* do fundo (tamanho –, cotistas +, FIC –), de forma estável e forte ao longo de 6 anos; o “clima de mercado” da VALE (preço +, beta –) desloca o nível médio no tempo; o fluxo não explica o nível. Para *prever*, a inércia do próprio fundo é o forte baseline — o que motiva combinar o modelo de fator (que *explica*) com um efeito-fixo de fundo e a dinâmica via Kalman (que devem *prever* melhor). O produto final é a matriz de erros, cuja média ≈ 0 e estacionariedade medem o ajuste do modelo.