

Explicação didática — modelagem do peso de VALE3 nos fundos Itaú

TCC — FGV EESP

Orientador: Prof. Maurício Ferraresi Jr.

26 de junho de 2026

Este documento explica, passo a passo e em linguagem acessível, *o que* estamos fazendo, *por que* cada modelo e cada escolha, e *como* interpretar os resultados. O companheiro `results.pdf` traz as tabelas.

1 O problema

Queremos entender e, no fim, **prever** quanto cada fundo da gestora Itaú investe na ação **VALE3** — ou seja, o **peso** de VALE3 na carteira de cada fundo, mês a mês. A pergunta de fundo é: *quais características dos fundos explicam essas posições?* Isso se conecta à literatura de *demand-based asset pricing* (Kojien–Yogo), em que a demanda por um ativo é vista como função de características de quem investe.

2 A ideia central: o peso como “função de demanda”

Para um fundo i no mês t , modelamos:

$$\text{peso}_{i,t} = \alpha_t + \beta_t^1 x_{i,t}^1 + \dots + \beta_t^k x_{i,t}^k + \varepsilon_{i,t},$$

onde os x são características do fundo (tamanho, nº de cotistas, etc.). Os coeficientes $\theta_t = (\alpha_t, \beta_t^1, \dots)$ dizem *como* as características se traduzem em posição naquele mês. A sacada do orientador: em vez de acompanhar o peso de centenas de fundos, acompanhamos esses poucos coeficientes — eles são um **fator latente** que *reduz um problema de alta dimensão a uma dimensão pequena*.

3 Por que “regressão em dois passos”

Passo 1 (transversal / cross-section): para *cada mês*, uma regressão separada do peso contra as características dos fundos. Isso produz uma série de coeficientes θ_t ao longo do tempo.

Passo 2 (temporal / dinâmico): modelar como esses θ_t *evoluem no tempo*. O orientador propõe que evoluam como um *passeio aleatório* (random walk): $\theta_t = \theta_{t-1} + \text{choque}$, estimável pelo *filtro de Kalman*. É o “modelo de fator dinâmico”. A previsão vive aqui: prevendo θ_{t+1} e conhecendo as características do fundo, reconstruímos o peso previsto. (Este documento cobre o Passo 1; o Passo 2 é o próximo.)

4 As variáveis e por que cada tratamento

Alvo: peso (nível). É uma fração em $[0, 1]$. Usamos em nível porque é o que o orientador pediu (o coeficiente OLS vira o fator) e é direto de interpretar.

AUM e nº de cotistas: usamos log. Essas variáveis são muito assimétricas — há fundos de R\$ 1 milhão e de R\$ 18 bilhões. Em nível, um fundo gigante dominaria a regressão. O logaritmo comprime a escala e capta efeitos *proporcionais*: ir de 10 para 20 milhões “pesa” como ir de 100 para 200.

FIC vs. FI: variável binária (dummy). Um FIC (Fundo de Investimento em Cotas) investe em cotas de outros fundos; um FI investe direto. Isso muda a posição *direta* em ações. Detectamos FIC pelo nome do fundo (a classificação ANBIMA não distingue FIC/FI).

Fluxo líquido: usamos fluxo/AUM. O fluxo é (captação – resgate) do mês, em reais. Dividir pelo tamanho do fundo dá o fluxo como *proporção do patrimônio* — comparável entre fundos grandes e pequenos, e preserva o sinal (entrada positiva, saída negativa). O fluxo líquido “de verdade” (com a perna de resgate) só existe no *Informe Diário* da CVM, não na base SH.

5 Passo 1A: a cross-section mês a mês (e por que Fama–MacBeth)

Rodamos 72 regressões (uma por mês, 2016–2021). Cada uma dá um θ_t . Para resumir, usamos o procedimento de **Fama–MacBeth**: a estimativa final de cada coeficiente é a *média* dos 72 valores mensais, e o erro-padrão vem da *variação entre os meses* (não de uma única regressão). É o jeito estatístico correto de tratar coeficientes que mudam mês a mês — e o teste t resultante diz se o efeito médio é robusto no tempo.

Resultado: tamanho (–), cotistas (+) e FIC (–) têm sinal idêntico *em todos os 72 meses* e são altamente significativos. O fluxo não é significativo para o *nível* do peso.

6 Por que preço e beta NÃO entram na cross-section

Dentro de um mesmo mês, o preço da VALE3 e o beta da VALE3 são *iguais para todos os fundos* (são variáveis “de mercado”, do ativo, não do fundo). Logo, eles não conseguem explicar por que um fundo difere de outro *naquele mês* — seriam absorvidos pelo intercepto. São variáveis *agregadas*: explicam como o nível *médio* das posições se move *ao longo do tempo*. Por isso entram (i) na regressão *pooled* e (ii) no Passo 2 (a dinâmica do nível médio).

7 Passo 1B: a regressão *pooled*

Empilhando todos os fundos-meses numa só regressão, o preço e o beta passam a ter variação (entre os 72 meses) e ficam identificados. Achamos: **preço** + e **beta** –, ambos significativos. Ou seja, em meses de VALE3 mais cara, o peso médio sobe; em meses de VALE3 mais arriscada (beta alto), o peso médio cai (aversão a risco). *Importante:* no piloto de só 2016 (12 meses), o beta saía positivo e fraco; com 72 meses ele vira claramente negativo. Isso ensina uma lição metodológica: 12 pontos no tempo eram poucos para identificar variáveis agregadas — por isso estendemos para 6 anos.

8 Como o beta é calculado (e por quê)

Beta mede **quanto a ação se move quando o mercado se move**. É a inclinação da regressão dos retornos da VALE3 sobre os do Ibovespa:

$$\beta = \frac{\text{Cov}(r_{VALE}, r_{Ibov})}{\text{Var}(r_{Ibov})}.$$

Calculamos *nós mesmos* (não pegamos o “beta” pronto do Yahoo, que é de 5 anos contra índice americano e estático). Usamos **retornos diários simples** e uma **janela móvel de 252 pregões** (≈ 1 ano), lendo o beta no **último pregão do mês anterior** a cada competência. $\beta > 1$ significa que a ação amplifica o mercado (mais cíclica/arriscada); $\beta < 1$, que amortece. A VALE, mineradora, tem beta tipicamente alto.

9 Cuidado com *look-ahead* e por que preço *nominal*

Look-ahead é usar informação do futuro para prever o passado — um erro grave. Garantimos que cada característica olha só para trás (a janela do beta termina na data de medição; o preço/beta vêm do mês *anterior*). Um detalhe fino: o preço *ajustado* (adjclose) é recalculado para trás usando dividendos *futuros*, então o nível dele numa data passada “sabe” de proventos posteriores. Por isso, na regressão usamos o **preço nominal** (o preço de fato negociado, imune a esse problema); o ajustado serve só para os retornos/beta, que são limpos.

10 O que os resultados dizem (em palavras)

O **nível** do peso de VALE3 é explicado por características **estruturais** do fundo: fundos maiores diversificam mais (menos VALE3); fundos com mais cotistas têm mais; FICs têm menos posição direta. O fluxo do mês não explica o nível (deve explicar a *variação*). E o “clima de mercado” da VALE (preço e risco) desloca o nível médio de alocação no tempo. Tudo isso é estável e forte ao longo de 6 anos.

11 Rigor: validação e parsing

As bases da CVM têm armadilhas (formatos de número com “R\$”, vírgula decimal, notação científica; datas em formatos diferentes; linhas duplicadas; mudança de layout em 2021). Tratamos e **auditamos** cada uma: 0 duplicados, 0 NAs indevidos; a captação da SH bate com o Informe Diário da CVM em 99,4–99,8% ao centavo nos 6 anos; o preço bate com o fechamento oficial da B3; o beta confere por três métodos independentes. O recorte de 2016 do painel de 6 anos é idêntico ao painel de 2016 validado isoladamente.

12 Passo 2: a dinâmica dos fatores θ_t

Com os 72 vetores θ_t em mãos, perguntamos: *como cada coeficiente se comporta no tempo?* Isso decide o modelo dinâmico.

O que achamos. Os fatores estruturais (intercepto, tamanho, cotistas, FIC) são **persistentes mas estacionários**: o coeficiente AR(1) é $\phi \approx 0,7\text{--}0,84$ (não ≈ 1), e um teste tipo Dickey–Fuller rejeita a hipótese de passeio aleatório. Em palavras: eles **oscilam em torno de um nível estável**

e reverterem à média, em vez de vagar sem rumo. O coeficiente do fluxo é quase ruído (baixa persistência).

Random walk ou reversão à média? O orientador sugeriu, como ponto de partida, o passeio aleatório ($\theta_t = \theta_{t-1} + \text{choque}$). Os dados refinam isso: a dinâmica é de **reversão à média** (AR(1) com ϕ moderado). Na prática, para prever os fatores estruturais, AR(1) e random walk dão erro parecido (ambos bons, AR(1) um pouco melhor); o fluxo, por ser ruidoso, é melhor previsto pela própria média. Ou seja: a posição não “foge”; ela ancora.

Por que então um filtro de Kalman? As estimativas mensais θ_t vêm de regressões com ~ 130 fundos cada — têm *ruído amostral*. O filtro de Kalman trata θ_t como um *estado oculto* que evolui suavemente (AR(1)) e que “enxergamos” com ruído a cada mês. Ele combina, de forma ótima, (i) a inércia do estado e (ii) a informação nova de cada mês, produzindo uma trajetória mais limpa e uma previsão dos θ_{t+1} — e, daí, do peso de cada fundo. É o passo seguinte.

O produto final é uma *matriz de erros* (resíduos fundo $\times$ mês), cujas propriedades (média zero, estabilidade, variância) dizem o quão bem o modelo captura as posições — exatamente o que o orientador descreveu.