

Explicação completa e didática

Modelagem do peso de VALE3 nas carteiras dos fundos Itaú (2016–2021)

TCC — FGV EESP

Orientador: Prof. Maurício Ferraresi Jr.

26 de junho de 2026

Resumo

Este documento explica, do zero e em profundidade, todo o trabalho: a pergunta de pesquisa, a base de dados e seus tratamentos, os modelos (com as equações), os resultados (com os números), suas interpretações econômicas, o rigor da validação e os próximos passos. É escrito para ser lido por quem não acompanhou a construção — com intuição, exemplos numéricos e um glossário ao final.

Sumário

1	A pergunta e a motivação	2
2	Visão geral em palavras (antes da matemática)	2
3	A base de dados	2
4	As variáveis e por que cada transformação	3
5	Alinhamento temporal — quando cada variável é medida	3
6	Retrato dos dados (estatísticas descritivas)	4
7	Modelo 1 — a “fotografia” de cada mês (cross-section)	4
8	Por que preço e beta NÃO entram na “fotografia”	5
9	Modelo 2 — juntando tudo (pooled)	6
10	O beta: o que é e como calculamos	6
11	Cuidado com <i>look-ahead</i> e por que “preço nominal”	7
12	Passo 2A — a dinâmica dos fatores θ_t	7
13	Passo 2B — previsão do peso e a matriz de erros	8
14	O filtro de Kalman — o que é e por que o usamos	9
15	Exemplo resolvido — como a previsão é montada	9

16 A opacidade de 90 dias — prever a 3 meses	10
17 As duas margens: ter ou não ter, e quanto	10
18 Rigor: validação e parsing	11
19 Limitações e cuidados	11
20 Síntese	12
Glossário	12

1 A pergunta e a motivação

Todo fundo de investimento decide *quanto* do seu patrimônio coloca em cada ação. A fração do patrimônio que o fundo i tem na ação j , no mês t , é o que chamamos de **peso**, $w_{i,t}^{(j)}$. Por exemplo, se um fundo de R\$ 100 milhões tem R\$ 5 milhões em VALE3, seu peso em VALE3 é 0,05 (ou 5%).

Neste trabalho fixamos a ação $j = \mathbf{VALE3}$ e olhamos todos os fundos da gestora **Itaú**, mês a mês, de 2016 a 2021. Duas perguntas guiam tudo:

1. **Explicação:** quais *características dos fundos* determinam o peso de VALE3? (Fundos grandes investem mais ou menos? Fundos com muitos cotistas? etc.)
2. **Previsão:** conseguimos *prever* o peso do mês seguinte?

Por que isso é interessante (a teoria). A finança tradicional costuma explicar preços a partir de um “investidor representativo”. A literatura de *demand-based asset pricing* (Kojien e Yogo) inverte a lente: olha a **demanda** de cada investidor pelo ativo como função das *características* de quem investe. Nessa visão, o peso de um fundo é uma **função de demanda**. Entender essa função — e como ela muda no tempo — é a contribuição central.

2 Visão geral em palavras (antes da matemática)

A ideia, proposta pelo orientador, tem duas etapas:

Passo 1 — “fotografia” de cada mês. A cada mês, rodamos uma regressão que relaciona o peso de VALE3 de cada fundo às suas características. Os coeficientes dessa regressão (quanto cada característica “puxa” o peso) formam um pequeno conjunto de números, θ_t . Em vez de acompanhar o peso de centenas de fundos, acompanhamos esses poucos coeficientes: eles são um **fator latente** que resume tudo. É como trocar uma planilha gigante por um retrato de baixa resolução, mas que guarda o essencial.

Passo 2 — “filme” ao longo do tempo. Pegamos a sequência desses retratos (θ_t ao longo de 72 meses) e modelamos como ela *evolui*. Se soubermos prever o próximo retrato, prevemos o peso de cada fundo.

3 A base de dados

Usamos quatro fontes, todas públicas:

CONS (CVM) — mensal. Composição consolidada das carteiras: qual ativo cada fundo tem e em que *participação* (peso). É de onde sai o nosso alvo.

SH (CVM) — diária. Série histórica dos fundos: gestora, patrimônio líquido, número de cotistas, etc. De onde saem as características de fundo.

Informe Diário (CVM) — diário. Captação e resgate diários de cada fundo. De onde sai o *fluxo líquido* verdadeiro (a SH só tem a captação, não o resgate).

Yahoo Finance. Cotações diárias de VALE3 e do Ibovespa, para calcular preço e beta.

Uma observação = um fundo num mês. O painel final tem **26.123 observações** (fundo-mês), **623 fundos** distintos e **72 meses**. Distribuição por ano:

Ano	2016	2017	2018	2019	2020	2021
Observações	4.062	3.983	4.011	4.124	4.724	5.219
Fundos	388	363	376	395	435	473

As armadilhas das bases (e por que tratamos cada uma). As bases da CVM têm formatos traiçoeiros: números como “R\$ 1.234,56” (com cifrão, ponto de milhar e vírgula decimal), mas também em notação científica; datas em formatos diferentes entre bases (a SH usa DD/MM/AAAA, a CONS AAAA-MM-DD); *linhas duplicadas* (a CVM às vezes repete a mesma posição); e até mudança de *layout* em 2021 (uma coluna extra no Informe Diário). Cada uma foi tratada e auditada (Seção 18).

4 As variáveis e por que cada transformação

Alvo: o peso $w_{i,t}$ — em nível. É uma fração em $[0, 1]$. Usamos como está, porque é isso que o orientador pede (o coeficiente de mínimos quadrados é o “fator”) e é direto de interpretar.

AUM (tamanho) e n^o de cotistas — em logaritmo. Essas variáveis são muito *assimétricas*: há fundos de R\$ 1 milhão e de R\$ 18 bilhões. Se usadas em nível, um único fundo gigante dominaria a conta. O logaritmo *comprime* a escala e capta efeitos *proporcionais*. A razão matemática: como $\ln(2X) - \ln(X) = \ln 2$ não depende de X , dobrar de 10 para 20 milhões “pesa” igual a dobrar de 100 para 200. O coeficiente de $\ln(\text{AUM})$ é, então, o efeito de uma *variação percentual* do tamanho sobre o peso.

FIC vs. FI — variável binária (0/1). Um **FIC** (Fundo de Investimento em Cotas) investe em cotas de *outros* fundos; um **FI** investe direto em ativos. Isso muda a posição *direta* em ações. A variável vale 1 se o fundo é FIC. (Detectamos pelo nome do fundo; a classificação ANBIMA é de estratégia e não distingue FIC/FI.)

Fluxo líquido — como fluxo/AUM. O fluxo é (captação – resgate) do mês, em reais. Dividimos pelo patrimônio para obter o fluxo como *proporção do tamanho* — comparável entre fundos grandes e pequenos, e que *preserva o sinal* (entrada +, saída –). Não dá para usar logaritmo, pois o fluxo pode ser negativo.

5 Alinhamento temporal — quando cada variável é medida

Um ponto sutil e importante: as bases têm *frequências diferentes* (CONS é mensal; SH e Informe Diário são diários; Yahoo é diário), então é preciso definir, para o peso do mês t , *de quando* vem cada

característica.

Variável	Fonte	Frequência	Quando medimos (para o mês t)
Peso de VALE3 (alvo)	CONS	mensal	fim do mês t (competência = último dia útil)
AUM, n ^o cotistas	SH	diária	mesmo dia da competência (fim de t)
Fluxo líquido	Inf. Diário	diária	soma de todo o mês t
Preço, beta VALE3	Yahoo	diária	média do mês t (explicação); fim de $t - 1$ (previsão)

A escolha-chave de timing: preço e beta são variáveis de *mercado* e têm **dois papéis distintos**. Na **explicação** (Modelos 1–2) usamos a **média do mês t** — é a melhor medida do que o gestor *observou ao longo do mês* ao dimensionar a posição; afinal ele não olha um único dia, acompanha o preço e o risco da ação durante o mês inteiro. Já na **previsão** (Modelo 3) usamos o **fim do mês $t - 1$** (último pregão anterior): para prever o peso de t sem *look-ahead*, só vale informação *anterior* a t — foi o que o orientador pediu (“último dia do mês anterior”). Já o AUM e o n^o de cotistas são características *estruturais* do fundo, medidas no *mesmo* retrato da carteira (fim de t); e o fluxo, por ser um fluxo, é *somado* ao longo do mês.

6 Retrato dos dados (estatísticas descritivas)

Antes dos modelos, um retrato numérico da amostra de regressão (margem intensiva, fundos com mais de 3 cotistas, com fluxo): **11.413** observações fundo-mês, **307** fundos. **75,7%** são FICs.

Variável	Média	DP	Mín	P25	Mediana	P75	Máx
Peso VALE3 (%)	2,87	3,52	0,00	0,21	1,22	4,77	23,55
AUM (R\$ milhões)	399	1.079	0,04	25,6	68,3	256	17.866
N ^o de cotistas	10.202	72.039	4	7	105	1.161	696.013
Fluxo líq. (R\$ mi)	5,7	74,1	−1.522	−0,9	0,0	0,6	1.636
Fluxo/AUM (%)	0,19	89,9	−6.399	−1,44	0,00	0,91	144,6
Preço VALE3 (R\$)	54,6	27,2	9,94	33,7	50,9	67,5	114,1
Beta VALE3	1,04	0,30	0,68	0,81	0,97	1,06	1,73

Leia assim: o fundo *típico* tem $\approx 1,2\%$ em VALE3 (mediana), mas há fundos com até 23,6%. O AUM e o n^o de cotistas têm **média muito maior que a mediana** (poucos fundos gigantes) — é o que justifica usar o log. O preço da VALE3 (média do mês) varia de R\$ 9,94 a R\$ 114,06 no período (a recuperação da ação), e o beta, de 0,68 a 1,73. Um detalhe importante: **preço e beta são bem correlacionados** (−0,71) — quando a ação está cara, seu beta tende a ser baixo. Para referência, o painel completo tem 26.123 observações (623 fundos) e o painel da margem extensiva (fundos de Ações, com zeros) tem 10.286.

7 Modelo 1 — a “fotografia” de cada mês (cross-section)

Para *cada mês t* , estimamos por mínimos quadrados ordinários (MQO):

$$w_{i,t} = \alpha_t + \beta_t^1 \ln(\text{AUM}_{i,t}) + \beta_t^2 \ln(\text{Cot}_{i,t}) + \beta_t^3 \text{FIC}_i + \beta_t^4 \left(\frac{\text{Fluxo}}{\text{AUM}} \right)_{i,t} + \varepsilon_{i,t}. \quad (1)$$

Aqui α_t é o intercepto (nível “base”) e cada β_t^k diz *quanto* aquela característica empurra o peso, naquele mês. O conjunto $\theta_t = (\alpha_t, \beta_t^1, \dots, \beta_t^4)$ é o nosso **fator latente**. Com 72 meses, obtemos 72 desses vetores.

Como ler um coeficiente (exemplo numérico). O coeficiente médio de $\ln(\text{AUM})$ é $-0,00376$. Como “dobrar o tamanho” é $\Delta \ln(\text{AUM}) = \ln 2 \approx 0,69$, dobrar o AUM muda o peso em $-0,00376 \times 0,69 \approx -0,0026$, isto é, **cai $\approx 0,26$ ponto percentual**. Para a FIC, o coeficiente $-0,017$ significa que um FIC tem, em média, **1,7 ponto percentual a menos** de VALE3 direto que um FI parecido.

Por que Fama–MacBeth. Como os coeficientes mudam mês a mês, resumimos as 72 estimativas pelo procedimento de **Fama–MacBeth**: a estimativa final é a *média no tempo* e o erro-padrão vem da *variação entre os meses*:

$$\hat{\beta}^k = \frac{1}{T} \sum_{t=1}^T \beta_t^k, \quad \text{ep}(\hat{\beta}^k) = \frac{\text{dp}(\beta_t^k)}{\sqrt{T}}, \quad t = \frac{\hat{\beta}^k}{\text{ep}(\hat{\beta}^k)}. \quad (2)$$

O teste t assim construído pergunta: *o efeito médio é robusto ao longo dos meses?* (Um $|t|$ grande $\Rightarrow$ sim.)

Variável	Coef. médio	t	p	Meses +	Sig.
Intercepto	0,08939	21,6	$< 0,001$	72/72	***
$\ln(\text{AUM})$	$-0,00376$	$-19,3$	$< 0,001$	0/72	***
$\ln(\text{cotistas})$	0,00387	19,8	$< 0,001$	72/72	***
FIC	$-0,01697$	$-19,2$	$< 0,001$	0/72	***
Fluxo/AUM	$-0,00044$	$-0,14$	0,886	39/72	n.s.

Resultados (72 meses). (R^2 médio mensal = 0,152; “Meses +” = em quantos dos 72 meses o sinal foi positivo.)

Interpretação.

- **Tamanho (–):** fundos maiores carregam *menos* VALE3 — são mais diversificados, então cada ação isolada pesa menos.
- **Cotistas (+):** fundos com mais cotistas têm *mais* VALE3.
- **FIC (–):** fundos de cotas têm *menos* posição direta na ação (investem via cotas de outros fundos).
- **Fluxo (não significativo):** o fluxo do mês não explica o *nível* do peso — ele deve explicar a *variação* (assunto do Passo 2).
- **Estabilidade impressionante:** os três fatores estruturais têm o *mesmo sinal nos 72 meses*. Isso justifica modelá-los como fatores que mudam *devagar* no tempo (Passo 2).

8 Por que preço e beta NÃO entram na “fotografia”

Dentro de um mesmo mês, o preço e o beta da VALE3 são *iguais para todos os fundos* — são características do *ativo*, não do fundo. Na equação (1), uma variável que não varia entre os fundos é *colinear* com o intercepto α_t : não há como separar o efeito dela do nível-base. Em palavras: preço e beta não explicam por que um fundo difere de outro *naquele mês*. Eles são variáveis **agregadas** (de tempo): explicam como o nível *médio* se move *ao longo dos meses*. Por isso vão para a regressão *pooled* e para o Passo 2.

9 Modelo 2 — juntando tudo (pooled)

Empilhando os 72 meses numa só regressão, o preço e o beta (aqui, a **média de cada mês** t) passam a variar entre os meses e ficam identificados:

$$w_{i,t} = \alpha + \beta^1 \ln \text{AUM} + \beta^2 \ln \text{Cot} + \beta^3 \text{FIC} + \beta^4 \frac{\text{Fluxo}}{\text{AUM}} + \beta^5 \text{Preço}_t + \beta^6 \text{Beta}_t + \varepsilon_{i,t}. \quad (3)$$

Variável	Estimativa	t	p	Sig.
Intercepto	0,09937	24,5	< 0,001	***
$\ln(\text{AUM})$	-0,00354	-19,0	< 0,001	***
$\ln(\text{cotistas})$	0,00388	30,9	< 0,001	***
FIC	-0,01682	-21,3	< 0,001	***
Fluxo/AUM	-0,00030	-0,91	0,365	n.s.
Preço VALE3	0,000182	11,5	< 0,001	***
Beta VALE3	-0,02141	-15,1	< 0,001	***

($R^2 = 0,166$; $n = 11.413$. Preço e beta são a **média do mês** t .) **Preço +:** em meses de VALE3 mais cara, o peso médio sobe — mas atenção: parte disso é *mecânica* (se o preço da ação sobe, sua fração na carteira cresce sozinha, mesmo sem o gestor negociar), não só decisão ativa. **Beta -:** em meses de VALE3 mais arriscada (beta alto), o peso médio cai (aversão a risco).

Uma lição metodológica importante. No piloto de só 2016 (12 meses), o beta saía *positivo e fraco*; com os 72 meses, ele é claramente *negativo* e fortemente significativo. Doze pontos no tempo eram *poucos* para identificar variáveis agregadas (que só variam mês a mês). Foi exatamente por isso que estendemos a amostra de 2016 para 2016–2021.

10 O beta: o que é e como calculamos

Beta mede quanto a ação se move quando o mercado se move. É a inclinação da reta que relaciona o retorno da VALE3 ao retorno do Ibovespa (o “modelo de mercado” / CAPM):

$$r_t^{VALE} = a + \beta r_t^{Ibov} + u_t \implies \beta = \frac{\text{Cov}(r^{VALE}, r^{Ibov})}{\text{Var}(r^{Ibov})} = \underbrace{\rho_{VALE, Ibov}}_{\text{correlação}} \cdot \underbrace{\frac{\sigma_{VALE}}{\sigma_{Ibov}}}_{\text{razão de vol.}}. \quad (4)$$

A segunda forma é instrutiva: o beta é a *correlação* com o mercado vezes a *razão de volatilidades*. $\beta > 1$ amplifica o mercado (ação cíclica/arriscada); $\beta < 1$ amortece. A VALE, mineradora, costuma ter beta alto.

Exemplo numérico real (fim de dez/2015, janela de 252 pregões). $\sigma_{VALE} = 3,63\%$ /dia, $\sigma_{Ibov} = 1,47\%$ /dia, correlação = 0,609. Então

$$\beta = 0,609 \times \frac{3,63}{1,47} = 0,609 \times 2,47 = \mathbf{1,505}.$$

Ou seja: naquele período, para cada +1% do Ibovespa a VALE3 andava $\approx +1,5\%$.

Detalhes do cálculo. Usamos retornos diários *simples* $r_s = P_s/P_{s-1} - 1$ (VALE3 pelo preço *ajustado*; Ibovespa pelo fechamento), em **janela móvel de 252 pregões** (≈ 1 ano). Para a *explicação* lemos o beta como **média do mês t** ; para a *previsão*, no **último pregão do mês anterior** (predeterminado). Não usamos o “beta” pronto do Yahoo (que é de 5 anos, contra índice americano, e estático). A média do beta por ano: 1,66 (2016), 1,23 (2017), 0,86 (2018), 0,85 (2019), 1,00 (2020), 0,82 (2021) — coerente com a recuperação da ação no período (o preço subiu de $\approx$ R\$ 17 para $\approx$ R\$ 94).

11 Cuidado com *look-ahead* e por que “preço nominal”

Look-ahead (viés de antecipação) é usar informação do *futuro* para “prever” o passado — um erro grave. Na **previsão** (Modelo 3) garantimos que cada característica olha só para trás: a janela do beta termina na data de medição, e preço/beta vêm do mês *anterior* à competência (predeterminados). Já na *explicação* (Modelos 1–2), que é contemporânea por construção — descreve, não prevê —, usamos a média do próprio mês t .

Há um detalhe fino. O **preço ajustado** (que corrige por dividendos e desdobramentos) é recalculado “para trás”: o nível dele numa data passada depende de proventos pagos *depois*. Logo, ele carrega, no nível, uma pitada de informação futura. Por isso, como *característica* usamos o **preço nominal** (o preço de fato negociado, imune a isso); o ajustado serve só para os *retornos* (e o beta), onde a constante de ajuste se cancela na divisão P_s/P_{s-1} e não há viés.

12 Passo 2A — a dinâmica dos fatores θ_t

Agora olhamos a *sequência* de cada coeficiente ao longo dos 72 meses e perguntamos: ela “vagueia” sem rumo, ou oscila em torno de um nível? Comparamos dois modelos:

$$\text{AR}(1): \theta_{k,t} = c_k + \phi_k \theta_{k,t-1} + \eta_{k,t}; \quad \text{Random walk: } \theta_{k,t} = \theta_{k,t-1} + \eta_{k,t}. \quad (5)$$

No AR(1), quando $|\phi| < 1$ o coeficiente é “puxado” de volta a uma média de longo prazo (**reversão à média**); no random walk ($\phi = 1$) ele vagueia sem âncora. Para distinguir, usamos um teste tipo **Dickey–Fuller**: regredimos $\Delta\theta_t = a + \rho\theta_{t-1} + e_t$ e testamos $\rho = 0$ (raiz unitária $\Leftrightarrow$ random walk). Um $t < -2,9$ rejeita a raiz unitária (a $\approx 5\%$) em favor da reversão à média.

Série (θ_t)	autocorr.(1)	ϕ (AR1)	DF t	Leitura
Intercepto	0,77	0,77	−3,07	reverte à média
ln(AUM)	0,76	0,76	−3,11	reverte à média
ln(cotistas)	0,84	0,83	−2,70	quase random walk
FIC	0,70	0,70	−3,57	reverte à média
Fluxo/AUM	0,37	0,38	−5,59	quase ruído

O que isso diz. Os fatores estruturais são **persistentes mas estacionários** ($\phi \approx 0,7\text{--}0,84$, não ≈ 1): oscilam em torno de um nível estável e *revertem à média*. A proposta inicial do orientador (random walk) é, assim, refinada pelos dados para *reversão à média*. O coeficiente do fluxo é quase ruído (pouca persistência). A Figura no **results.pdf** mostra as cinco séries.

13 Passo 2B — previsão do peso e a matriz de erros

Pre vemos o peso um mês à frente aplicando o *vetor de coeficientes previsto* às características do fundo:

$$\widehat{w}_{i,t} = \widehat{\theta}_t' x_{i,t}, \quad \widehat{\theta}_t = \begin{cases} \theta_{t-1}, & \text{(random walk)} \\ \widehat{c} + \widehat{\phi} \theta_{t-1}, & \text{(AR(1))} \end{cases} \quad (6)$$

e comparamos com um **benchmark ingênuo**: prever que o peso do mês que vem é igual ao do mês passado, $\widehat{w}_{i,t} = w_{i,t-1}$. A **matriz de erros** é $e_{i,t} = w_{i,t} - \widehat{w}_{i,t}$ (uma tabela fundo $\times$ mês). Avaliação pseudo-fora-da-amostra (9.804 previsões):

Método	RMSE	MAE
Fator + random walk	0,0340	0,0256
Fator + AR(1)	0,0337	0,0253
Ingênuo (peso defasado)	0,0159	0,0083

O resultado — e o que ele ensina. O **benchmark ingênuo vence**: o erro é cerca de *metade* do modelo de fator. Por quê? Porque o peso é **muito persistente no nível do fundo**: quem tem 5% em VALE3 este mês terá $\approx 5\%$ no próximo. A posição “âncora”. Isso *não* invalida o modelo de fator — ele continua excelente para **explicar** a seção transversal (quais características importam). Mas, para **prever**, a inércia do próprio fundo é um adversário difícil de bater.

A matriz de erros (Fator+AR1) tem **média** ≈ 0 (0,0024) e é **estacionária** (Dickey–Fuller $t = -7,6$) — exatamente as propriedades que o orientador queria checar (no cenário ideal, a média do erro é zero).

Por que efeito-fixo e por que Kalman? Dois reforços para dar ao modelo a *melhor chance* contra o ingênuo.

- **Efeito-fixo de fundo μ_i** : o ingênuo vence porque carrega o *nível próprio* de cada fundo (a posição “âncorada”); o modelo de fator puro não tem intercepto por fundo. Adicionar μ_i (a média histórica do fundo) devolve essa âncora — junta a *inércia que prevê* com a *estrutura que explica*.
- **Filtro de Kalman**: os θ_t mensais têm *ruído amostral* (~ 130 fundos cada). O Kalman trata o θ verdadeiro como estado oculto que evolui devagar e a estimativa mensal como medida ruidosa, devolvendo uma trajetória mais limpa e uma previsão (foi também a proposta do orientador).

O modelo combinado é $w_{i,t} = \mu_i + \theta_t' x_{i,t} + \varepsilon_{i,t}$.

Os três modelos (contra o ingênuo M0). Seja $x_{i,t}$ as características do fundo e $\bar{x}_i$ suas médias históricas:

$$\text{M0 Ingênuo: } \widehat{w}_{i,t} = w_{i,t-1}; \quad (7)$$

$$\text{M1 Efeito-fixo: } \widehat{w}_{i,t} = \widehat{\mu}_i; \quad (8)$$

$$\text{M2 FE + Fator/Kalman: } \widehat{w}_{i,t} = \widehat{\mu}_i + \widehat{\theta}_t^{\text{Kal}'} (x_{i,t} - \bar{x}_i); \quad (9)$$

$$\text{M3 Variação } \Delta w : \widehat{w}_{i,t} = w_{i,t-1} + \widehat{\delta}' x_{i,t}. \quad (10)$$

$\widehat{\mu}_i$ = média do peso do fundo (treino); $\widehat{\theta}_t^{\text{Kal}}$ = coeficiente previsto pelo Kalman; $\widehat{\delta}$ = coeficientes de uma regressão da *mudança* Δw nas características. Os resultados (9.532 previsões fora da amostra):

Método	RMSE	MAE
M0 Ingênuo (peso defasado)	0,0159	0,0083
M1 Efeito-fixo (μ_i , média)	0,0247	0,0153
M2 FE + Fator (Kalman)	0,0265	0,0162
M3 Variação Δw (com fluxo)	0,0160	0,0084

O que isso ensina (resultado-chave). O **ingênuo continua vencendo**. E cada linha diz algo preciso: (i) o efeito-fixo de *média* é *pior* que o lag, logo o peso **não reverte à média no nível do fundo** — é persistente, quase um *passeio aleatório* (o último valor prevê melhor que a média histórica); (ii) somar o fator/Kalman não ajuda — a estrutura transversal serve para *explicar*, não para prever um fundo específico; (iii) o modelo da *variação* apenas empata com o ingênuo, ou seja, a mudança do peso é **essencialmente imprevisível** um mês à frente (nem o fluxo a antecipa de forma útil). Em uma frase: o peso de VALE3 é, no nível do fundo, quase um **martingale** — o modelo de fator é ferramenta de *compreensão*, e a inércia do próprio fundo é o teto prático da previsão de curto prazo.

14 O filtro de Kalman — o que é e por que o usamos

As estimativas mensais θ_t vêm de regressões com ~ 130 fundos cada: têm *ruído amostral*. O filtro de Kalman trata isso com um modelo de **estado-espço**, separando o estado *verdadeiro* (oculto) da *medida ruidosa*:

$$\text{medida: } \hat{\theta}_t^{\text{MQO}} = \theta_t + v_t, \quad v_t \sim (0, R) \text{ (ruído da cross-section),} \quad (11)$$

$$\text{estado: } \theta_t = \theta_{t-1} + \eta_t, \quad \eta_t \sim (0, Q) \text{ ("local-level").} \quad (12)$$

O filtro combina, de forma *ótima*, (i) a *inércia* do estado e (ii) a *informação nova* de cada mês, pesando-as pela confiança relativa (Q vs. R , estimadas por máxima verossimilhança). O resultado é uma trajetória de θ_t mais limpa e uma previsão causal $\theta_{t|t-1}$. Implementamos um Kalman local-level manual (sem depender de pacote) e o usamos no modelo M2 acima — mas, como vimos, mesmo o θ suavizado não bate a inércia do próprio fundo para prever.

15 Exemplo resolvido — como a previsão é montada

A previsão é **fora da amostra com janela expansiva**: a cada mês, fingimos estar parados no presente e prevemos o mês seguinte usando *só o passado*. Para o mês-alvo, os dados se dividem em **treino** (tudo *antes* do mês, onde *calibramos* os parâmetros) e **alvo** (o mês, onde prevemos e comparamos com o real). Veja num caso concreto.

Fundo 779, prevendo o peso de junho/2020. No fim de maio/2020 esse fundo tinha **53 meses de histórico** (o treino). O peso real em jun/2020 foi 0,060.

- **M0 Ingênuo** — não calibra nada; repete o último peso (maio/2020): $\hat{w} = 0,06268$.
- **M1 Efeito-fixo** — calibra μ_i = a *média histórica* do peso do fundo nos 53 meses = 0,06116; prevê esse valor.
- **M2 FE + Kalman** — parte de μ_i e corrige pelos desvios das características de hoje em relação à média histórica *do próprio fundo*, com os slopes que o Kalman prevê

para jun/2020 (a partir dos meses anteriores):

$$\hat{w} = \underbrace{0,06116}_{\mu_i} + \underbrace{(-0,0021)}_{\text{slope AUM}} \cdot \underbrace{(+0,023)}_{\Delta \ln \text{AUM}} + \underbrace{(+0,0035)}_{\text{slope cot.}} \cdot \underbrace{(-0,236)}_{\Delta \ln \text{cot.}} + \dots = 0,06027.$$

(O n^o de cotistas estava abaixo da média do fundo, e seu slope é positivo, então puxa a previsão um pouco para baixo.)

Neste fundo-mês, o M2 ficou mais perto (0,06027 vs. real 0,060); mas, na *média* dos 9.532 casos, é o M0 que tem o menor erro.

O que se calibra em cada janela: as médias μ_i (por fundo); as médias das características $\bar{x}_i$; os parâmetros Q, R do Kalman (por máxima verossimilhança), que geram os slopes suavizados; e, no modelo de variação, os coeficientes da regressão de Δw . Tudo só com dados *anteriores* ao mês-alvo.

16 A opacidade de 90 dias — prever a 3 meses

Os fundos divulgam a carteira (o peso) com **defasagem trimestral**: em t , o peso mais recente que se *enxerga* é o de ≈ 90 dias atrás. Saber o peso *atual* equivale, então, a **prever $t + 3$ com informação de t** — um horizonte de 3 meses, em vez de 1. Refizemos a comparação (a parte de *explicação* não muda, pois é contemporânea):

Horizonte	M0 Ingênuo	M1 FE	M2 FE+Kalman	M3 Δw
$h = 1$ (prever $t + 1$)	0,0156	0,0240	0,0255	0,0156
$h = 3$ (opacidade de 90 dias)	0,0207	0,0262	0,0273	0,0210

A 3 meses, o **ingênuo piora bastante** ($0,0156 \rightarrow 0,0207$, +33%), porque o peso “velho” de 3 meses é mais defasado — e a *distância* para os modelos estruturais **encolhe**. Mesmo assim, **o ingênuo ainda vence** a $h = 3$ ($0,0207 < 0,0262$). Conclusão: o peso é *tão persistente* que, mesmo sob a opacidade trimestral, o último valor divulgado bate a média histórica e os fatores. A contribuição segue sendo de **compreensão**, não de previsão.

Robustez (só fundos de Ações). Refizemos a previsão restringindo aos fundos de *Ações* (o universo da margem extensiva, mais “puros” de bolsa). Os erros ficam *maiores* (fundos de Ações têm posições de VALE3 maiores e mais variáveis; os multimercados tinham fatias minúsculas e estáveis), mas o ingênuo vence com folga *ainda maior*, em $h = 1$ e $h = 3$ — a conclusão é robusta.

17 As duas margens: ter ou não ter, e quanto

Até aqui modelamos o peso *dado que* o fundo tem VALE3 — a **margem intensiva**. Mas há uma decisão anterior: *ter ou não ter* VALE3 — a **margem extensiva**. No painel principal, um fundo que não tem VALE3 simplesmente *não aparece* (não é um zero). Para estudar essa decisão, construímos um painel que **inclui os zeros**: pegamos todos os fundo-meses de **Ações** da Itaú (fundos claramente de bolsa, onde “não ter VALE3” é uma escolha real) e marcamos o peso como a participação na CONS, ou **0** se o fundo não detém.

O retrato. São **10.286** fundo-meses (260 fundos de Ações); **86%** têm VALE3 (subindo de 81% em 2016 para 89% em 2021). A posse é *muito grudenta*: muda em apenas **1,3%** dos meses (75 entradas, 100 saídas no total).

O que explica *ter* VALE3. Usamos um modelo **logit** (regressão para uma variável 0/1), $\Pr(\text{tem}) = \Lambda(\gamma_0 + \gamma_1 \ln \text{AUM} + \gamma_2 \ln \text{Cot} + \gamma_3 \text{FIC})$, onde Λ é a curva logística. Ahamos que fundos **maiores** ($\text{AUM}, \gamma_1 > 0$) e **FICs** ($\gamma_3 > 0$) são *mais propensos a ter* VALE3.

O achado bonito: as duas margens se invertem. Compare:

Característica	Ter ou não (extensiva)	Quanto (intensiva)
Tamanho (AUM)	+ mais provável ter	– peso menor
FIC	+ mais provável ter	– peso menor

Fundos grandes e FICs *quase sempre incluem* VALE3, mas com uma *fatia pequena*. É a assinatura da **diversificação**: quem tem muitos ativos provavelmente tem VALE3 entre eles, porém cada ação pesa pouco. Uma decisão (ter) e a outra (quanto) respondem em *sentidos opostos* ao tamanho — algo que o painel só da margem intensiva escondia.

Prever entrar/sair? De novo, a persistência ganha (h=1 e h=3). Prevendo a posse 1 e 3 meses à frente (o de 3 meses é o da opacidade trimestral): o palpite **ingênuo** (“vai ter VALE3 se tem hoje”) acerta **98,7%** (h=1) e **98,3%** (h=3); o logit com características, $\approx 87\%$ nos dois. A posse muda em só 1,3% (h=1) a 1,7% (h=3) dos casos — é grudentíssima. Como na margem intensiva, as características *explicam* bem, mas não batem a pura inércia para *prever*, em nenhum horizonte. Em suma: tanto *ter ou não* quanto *quanto* são quase martingales — o trabalho contribui entendendo *quais fundos* demandam VALE3 e *como*, não prevendo o curto prazo.

18 Rigor: validação e parsing

Como as bases têm armadilhas, **audita**mos tudo:

- **Integridade:** 0 pares (fundo, mês) duplicados; 0 pesos negativos; 0 valores faltantes indevidos (apenas 119 fund-months sem fluxo, por estarem fora do arquivo do Informe Diário).
- **Parsing certificado:** a captação somada da SH bate com a do Informe Diário da CVM em **99,4–99,8% ao centavo** nos seis anos; o **preço** bate com o fechamento *oficial* da B3 (arquivo COTAHIST) ao centavo; o **beta** confere por três métodos independentes (fórmula, função pronta e regressão).
- **Consistência:** o recorte de 2016 do painel de seis anos é *idêntico* ao painel de 2016 construído isoladamente (mesmos valores).

19 Limitações e cuidados

- Modelamos a posição *direta* em VALE3 (não as posições via empréstimo de ações). Estudamos as duas margens: a intensiva (peso | deter) e a extensiva (deter ou não, entre fundos de Ações).
- Removemos fundos com ≤ 3 cotistas (exclusivos), que refletem decisões de um único investidor, não gestão “típica”.
- R^2 em torno de 0,15–0,16: as características explicam uma parte relevante — mas não tudo — da variação entre fundos; o restante é idiossincrático.
- Preço e beta vêm do Yahoo; validamos o preço contra a B3, mas a fonte ideal para um trabalho final poderia ser a própria B3/Economatica.

20 Síntese

O **nível** do peso de VALE3 é explicado por características *estruturais* do fundo — tamanho (–), base de cotistas (+) e estrutura FIC/FI (FIC –) — de forma *estável e forte* ao longo de seis anos. O “clima de mercado” da VALE (preço +, beta –) desloca o nível *médio* no tempo. O fluxo não explica o nível. **Para prever**, porém, testamos efeito-fixo de fundo, filtro de Kalman e um modelo da variação Δw , e *nenhum* supera o **benchmark ingênuo** (o peso defasado do próprio fundo): no nível do fundo, o peso é quase um **martingale** (persistente, com mudança imprevisível um mês à frente). A contribuição do trabalho é, portanto, de **compreensão** — a função de demanda e seus fatores latentes —, mais do que de previsão de curto prazo. A matriz de erros do melhor modelo tem média ≈ 0 e é estacionária, confirmando ausência de viés sistemático.

Glossário

Peso (de uma ação na carteira) fração do patrimônio do fundo investida naquela ação.

AUM *Assets Under Management*; o patrimônio líquido do fundo.

FI / FIC Fundo de Investimento (investe direto) / Fundo de Investimento em Cotas (investe em cotas de outros fundos).

Cross-section análise “transversal”, comparando vários fundos *num mesmo instante* (aqui, num mês).

Pooled regressão que empilha todas as observações (todos os fundos e meses) numa só.

Fator latente variável não observada diretamente que resume muita informação; aqui, o vetor de coeficientes θ_t .

Fama–MacBeth método de resumir regressões transversais repetidas: média dos coeficientes no tempo, com erro-padrão vindo da variação entre os períodos.

Beta sensibilidade do retorno da ação ao retorno do mercado (inclinação do modelo de mercado/CAPM).

Retorno ajustado retorno que considera dividendos/desdobramentos (preço ajustado), medindo o ganho econômico total.

Look-ahead viés de usar informação do futuro indisponível na data da previsão.

Random walk processo $\theta_t = \theta_{t-1} + \text{choque}$; “vagueia” sem âncora.

Reversão à média tendência de uma série voltar a um nível de longo prazo ($\phi < 1$ num AR(1)).

Dickey–Fuller teste para distinguir random walk (raiz unitária) de série estacionária (reverte à média).

Estado-espço / Kalman arcabouço que separa o estado verdadeiro (oculto) da medida ruidosa e estima/prevê o estado de forma ótima.

RMSE / MAE raiz do erro quadrático médio / erro absoluto médio — medidas de erro de previsão (menor é melhor).

Matriz de erros tabela dos erros de previsão $e_{i,t}$ por fundo e mês.