

Explicação

O projeto inteiro, devagar, do jeito que faz sentido de verdade

Peso de VALE3 nos fundos do grupo Itaú — guia completo, com analogias,
exemplos numéricos passo a passo e a resposta de “o quê, por quê e como”
para cada peça do trabalho

João Paulo Zangrandi (FGV–EESP)

documento de apoio ao `tcc I.pdf`; escrito para ler antes ou junto com ele

Resumo

Este documento existe para uma única finalidade: explicar *tudo* que acontece no projeto, do começo ao fim, sem pressa e sem pular etapas. Cada método aparece na mesma ordem: primeiro a pergunta que ele responde, depois uma analogia do dia a dia, depois um exemplo com números inventados (mas realistas) que você pode conferir na calculadora, e só então o que aconteceu de fato nos seus dados. Nada aqui substitui o `tcc I.pdf` — é o texto que fica do lado, para consultar sempre que uma passagem dele parecer rápida demais.

Sumário

1	O mapa da história inteira, antes de qualquer detalhe	4
2	Os dados: o que existe, e por que cada tratamento foi feito	4
2.1	As quatro fontes de informação	4
2.2	Por que tanto cuidado de limpeza	4
2.3	Por que o peso, e não o valor em reais	5
3	A curva em S (logit): por que existe, e como funciona por dentro	5
3.1	Por que uma reta não serve	5
3.2	A curva em S, sem fórmula ainda	5
3.3	A fórmula, com números pequenos para você ver funcionando	6
3.4	De onde vem o “ z ” que entra nessa máquina	6
3.5	Por que as características entram numa escala especial (padronização)	6
3.6	Juntando tudo: um exemplo completo, com um fundo de verdade	7
3.7	Por que essa forma logística é melhor que uma reta, na prática	7
3.8	O efeito parcial médio: traduzindo a nota de volta para pontos percentuais	7
4	Fama–MacBeth: por que rodar 72 regressões separadas	8
4.1	O problema que motiva o método	8
4.2	A solução, em duas etapas	8
4.3	Por que isso é inteligente	9
4.4	A hipótese que precisa valer (e que falha no seu caso)	9
4.5	O resultado, no seu projeto	9
5	Newey–West: por que o erro-padrão simples engana	9
5.1	A correção	10
6	A dinâmica do fator: os coeficientes mudam de mês para mês, e o filtro de Kalman	10
6.1	O que a Etapa 1 do Fama–MacBeth já te deu, sem você perceber	10
6.2	Por que essa série é “barulhenta”	10
6.3	Antes do Kalman: como saber se a série “sempre volta ao mesmo lugar” ou “pode se afastar para sempre”? O teste de Dickey–Fuller	11
6.4	Duas formas diferentes de lidar com essa série barulhenta	12
6.5	Como o filtro decide quanto confiar em cada mês novo	13
6.6	Um exemplo de verdade, passo a passo, com os números do seu projeto	13
7	Previsão: os quatro modelos e por que a ingênua vence	14
7.1	O resultado, e por que ele é revelador	14
8	A margem extensiva: antes de “quanto”, existe “tem ou não tem”	15
8.1	Como se monta essa análise	15
8.2	O achado mais bonito do trabalho	15
8.3	A posse também é bastante persistente	16

9	O modelo de ajuste parcial: o alvo, a distância, e por que o cálculo direto engana	16
9.1	Relembrando o alvo	16
9.2	A equação do ajuste parcial	16
9.3	Por que medir isso diretamente (MQO) não funciona: Problema 1	17
9.4	Por que medir isso diretamente (MQO) não funciona: Problema 2	17
9.5	Os dois problemas competem	18
10	Os quatro métodos de estimar a velocidade de ajuste	18
10.1	Método 1 — Mínimos Quadrados (MQO): a medição direta, sabendo que vem torta	18
10.2	Método 2 — Variável Instrumental: usando “ontem” como pista mais limpa	18
10.3	Uma pausa importante: o $t = 6,6$ da VI é confiável de verdade?	19
10.4	Método 3 — Efeito-fixo de fundo: existe um terceiro problema	20
10.5	Método 4 — Arellano-Bond: o mesmo problema, atacado de outro jeito	21
10.6	Resumo dos quatro métodos	21
11	Como interpretar os números	22
11.1	Da fração para algo intuitivo: a meia-vida	22
11.2	Significativo não é o mesmo que importante	23
11.3	O teste de Diebold–Mariano: a vitória do ajuste parcial é real, ou é sorte?	23
12	As extensões: NEFIN, beta do fundo, e o universo multiativo	24
12.1	Fatores de risco do NEFIN-USP	24
12.2	Beta do próprio fundo	25
12.3	O universo multiativo: o padrão de VALE3 generaliza?	25
13	Juntando tudo: a história completa, em um parágrafo	27

1 O mapa da história inteira, antes de qualquer detalhe

O projeto conta uma história em duas partes, e vale muito a pena ter essa história inteira na cabeça antes de entrar em qualquer fórmula.

Parte 1 — Explicar. Você tem 307 fundos do grupo Itaú, ao longo de 72 meses (2016–2021), e para cada um sabe quanto de VALE3 ele carrega na carteira (o *peso*). Você também sabe algumas características de cada fundo: tamanho, número de cotistas, se é um fundo que investe em outros fundos (FIC) ou direto em ações, e quanto ele captou ou resgatou naquele mês. A primeira pergunta do trabalho é: **essas características explicam o peso?** A resposta, resumidamente, é sim — fundos maiores carregam menos VALE3 em peso, fundos com mais cotistas carregam mais, fundos de cotas carregam menos.

Parte 2 — Prever. Sabendo que as características explicam o peso, a segunda pergunta é: **isso ajuda a prever o peso do mês seguinte?** Aqui a resposta é mais surpreendente: não muito. O peso de cada fundo é tão parecido de um mês para o outro que simplesmente “repetir o valor do mês passado” é uma previsão difícil de bater. O resto do trabalho investiga *por que* isso acontece e se existe, ainda assim, algum sinal de que os fundos caminham devagar em direção a um alvo definido pelas características.

Este documento segue essa mesma ordem: primeiro as ferramentas da Parte 1 (Fama–MacBeth, Newey–West, o modelo logístico), depois as da Parte 2 (dinâmica do fator, teste de Dickey–Fuller, filtro de Kalman, previsão, a margem extensiva de ter ou não ter a ação), e por fim a peça mais elaborada do trabalho, o modelo de ajuste parcial — com os quatro métodos de estimação, a correção do erro-padrão por efeito de tempo, e o teste de Diebold–Mariano — que tenta reconciliar as duas partes. As extensões (fatores NEFIN, beta do fundo, e a generalização para outras ações) fecham o documento.

2 Os dados: o que existe, e por que cada tratamento foi feito

2.1 As quatro fontes de informação

- **A composição das carteiras (CONS, CVM)** — é de onde vem a variável mais importante do trabalho: quanto de VALE3 cada fundo tem, mês a mês, em fração da carteira (o peso). Uma descoberta útil desta versão: esse arquivo já vem filtrado pela CVM só para *ações*, não é a carteira inteira do fundo (que teria também renda fixa, por exemplo).
- **A série histórica dos fundos (SH, CVM)** — de onde vêm as características: o patrimônio do fundo, quantos cotistas ele tem, e se o nome dele indica que é um fundo de cotas (FIC).
- **O Informe Diário (CVM)** — de onde vem a captação líquida (quanto entrou menos quanto saiu do fundo naquele mês). Precisou de uma fonte à parte porque a SH só registra a captação bruta, sem os resgates.
- **Cotações de mercado (Yahoo Finance)** — de onde vêm o preço e o beta de VALE3, conferidos contra a fonte oficial da B3.

2.2 Por que tanto cuidado de limpeza

A pergunta: Por que não simplesmente juntar as bases e rodar a regressão?

Pensa assim: Imagina que você está montando um quebra-cabeça com peças de duas caixas diferentes. Antes de encaixar qualquer peça, você confere se elas realmente são do mesmo quebra-cabeça (mesma data, mesmo fundo) e se não tem peça duplicada ou triplicada por engano. Só depois disso faz sentido começar a montar a imagem.

No seu projeto: cada linha da base de composição (CONS) precisou ser casada com a linha certa da série histórica (SH) — pelo *dia exato*, porque a SH é diária e a CONS é mensal. Linhas duplicadas (a CVM às vezes repete uma linha por engano) foram removidas. Pesos negativos (um resíduo contábil sem sentido de participação de carteira) foram descartados. E, numa correção recente, descobrimos que uma mesma ação pode aparecer em até cinco linhas diferentes na base bruta, dependendo do tipo de custódia (posição direta, ação emprestada, direito de compra de ações novas) — sem isso ser cinco ações diferentes. Filtramos para manter só a posição direta, a mesma convenção usada para VALE3 desde o início.

2.3 Por que o peso, e não o valor em reais

A pergunta: Por que medir “quanto de VALE3” como uma fração da carteira (peso), em vez de em reais?

Pensa assim: Se você quer comparar o quanto duas pessoas de renda muito diferente gastam com lazer, comparar em reais engana — R\$ 500 é muito para quem ganha R\$ 2.000 e pouco para quem ganha R\$ 50.000. Comparar em *porcentagem da renda* resolve isso. O peso faz o mesmo serviço para fundos de tamanhos muito diferentes.

O peso tem uma vantagem e uma complicação. A vantagem: é sempre um número entre 0% e 100%, comparável entre um fundo pequeno e um fundo gigante. A complicação: exatamente por ser limitado entre 0 e 1, uma regressão linear comum (uma reta) pode devolver previsões sem sentido — um peso negativo, ou maior que 100%. É essa complicação que motiva a curva logística, explicada na próxima seção.

3 A curva em S (logit): por que existe, e como funciona por dentro

A pergunta: Como transformar uma combinação de características (tamanho, cotistas, tipo de fundo) num número que *sempre* fica entre 0% e 100%, não importa quão extremas sejam as características?

3.1 Por que uma reta não serve

Se você tentasse escrever “peso = 4% + (ajuste por tamanho) + (ajuste por cotistas) + ...” como uma soma direta, nada impede o resultado de dar, por exemplo, -3% ou 115% — números sem sentido para uma fração de carteira. Precisamos de uma “máquina” que aceite qualquer combinação de entrada e sempre devolva algo dentro do intervalo válido.

3.2 A curva em S, sem fórmula ainda

Existe uma curva com formato de S deitado que faz exatamente isso. O comportamento dela, em palavras, antes de qualquer conta:

- Se você entra com um número **bem negativo**, ela devolve algo **bem perto de 0%** (nunca chega a tocar em 0%, mas fica bem próximo).
- Se você entra com **zero**, ela devolve exatamente **50%**.
- Se você entra com um número **bem positivo**, ela devolve algo **bem perto de 100%**.

Pensa assim: É como um amortecedor de carro: não importa o tamanho do buraco na estrada (a entrada pode ser qualquer número), a suspensão sempre entrega um movimento dentro de um limite físico (a saída fica sempre dentro de uma faixa).

3.3 A fórmula, com números pequenos para você ver funcionando

$$g(z) = \frac{1}{1 + e^{-z}}$$

z é o número que você coloca na máquina; e é só uma constante ($\approx 2,718$). Testando:

Entrada (z)	Cálculo	Saída ($g(z)$)
0	$\frac{1}{1+e^0} = \frac{1}{1+1}$	0,500 $\rightarrow$ 50,0%
-3	$\frac{1}{1+e^3} = \frac{1}{1+20,1}$	0,047 $\rightarrow$ 4,7%
+3	$\frac{1}{1+e^{-3}} = \frac{1}{1+0,05}$	0,953 $\rightarrow$ 95,3%

Repare que -3 e $+3$ deram resultados espelhados (4,7% e 95,3%, que somam 100%) — a curva é simétrica em torno do 50%.

3.4 De onde vem o “ z ” que entra nessa máquina

z não é um número solto — é uma **nota combinada**, montada somando pontos a favor e contra, um por característica do fundo:

$$z = \underbrace{-3,18}_{\text{nota base}} - \underbrace{0,18 \times (\text{tamanho})}_{\text{penalidade}} + \underbrace{0,30 \times (\text{cotistas})}_{\text{bônus}} - \underbrace{0,55 \times (\text{é FIC?})}_{\text{penalidade}}$$

Pensa assim: É a mesma lógica de um score de crédito: o banco combina renda, histórico de pagamento e dívidas — coisas em escalas completamente diferentes — numa nota única. Aqui a nota combina tamanho, cotistas e tipo de fundo numa única nota que resume o “perfil” daquele fundo para prever o peso.

3.5 Por que as características entram numa escala especial (padronização)

A pergunta: Por que não somar direto o tamanho em reais com o número de cotistas?

Tamanho é medido em reais (pode ser R\$ 70 milhões); cotistas é medido em pessoas (pode ser 100). Somar 70.000.000 + 100 diretamente não faz sentido — o tamanho dominaria tudo. A solução é colocar as duas na mesma régua antes de somar: em vez do valor bruto, você usa “quantos degraus acima ou abaixo da média esse fundo está”. Um fundo exatamente na média vale 0 nessa régua; um fundo bem maior que a média vale 1, 2, ou mais; um fundo bem menor vale negativo.

No seu projeto: isso aparece como $z(\ln PL)$ e $z(\ln Cot)$ na equação (3) do `tcc I.pdf`, Seção 3.2 — o texto descreve em palavras (“entram centradas e divididas pelo desvio padrão”), mas não escreve a fórmula por extenso; ela é $z(x) = \frac{x - \text{média de } x}{\text{desvio-padrão de } x}$.

3.6 Juntando tudo: um exemplo completo, com um fundo de verdade

Exemplo com números: um fundo **grande** (1 degrau acima da média em tamanho) e que **é FIC** (cotistas na média). Usando os coeficientes reais de janeiro de 2020:

$$z = -3,18 - 0,18 \times 1 + 0,30 \times 0 - 0,55 \times 1 = -3,91$$

$$w^* = g(-3,91) = \frac{1}{1 + e^{3,91}} \approx \frac{1}{1 + 49,9} \approx 2,0\%$$

Esse 2,0% é o **peso desejado** (o alvo) desse fundo naquele mês — não uma ordem, é uma comparação estatística: “fundos com esse perfil, naquele mês, costumavam ter cerca de 2,0%”.

No seu projeto: o `tcc I.pdf` não mostra esse exemplo de um mês isolado — ele mostra, na **Tabela 3, Seção 4.2**, a *média* dos 72 meses desses mesmos coeficientes: Intercepto= $-3,380$, $\ln(\text{patrimônio}) = -0,339$, $\ln(\text{cotistas}) = 0,469$, Fundo de cotas= $-0,732$ — bem parecidos com os do exemplo, porque os coeficientes mensais são estáveis ao longo do tempo (Seção 4.3).

3.7 Por que essa forma logística é melhor que uma reta, na prática

No seu projeto: a versão linear (uma reta simples, sem a curva em S) foi testada em paralelo e gerou previsões de peso **fora do intervalo** $[0, 1]$ em **2,51% das observações** — pesos negativos, sem sentido. A versão logística nunca faz isso, por construção. Além disso, o ajuste melhora ligeiramente (um indicador parecido com R^2 sobe de 0,152 para 0,165).

A tabela completa da regressão logística (a mesma Tabela 3, Seção 4.2, do `tcc I.pdf`), com os coeficientes de nota (z), o erro-padrão, a estatística t e o efeito parcial já traduzido para pontos percentuais (explicado na próxima subseção):

Variável	Coef. (nota z)	EP (NW)	t	Ef. parcial (p.p.)	Sig.
Intercepto	-3,380	0,150	-22,5	—	***
$\ln(\text{patrimônio})$	-0,339	0,043	-7,9	-0,68	***
$\ln(\text{cotistas})$	0,469	0,035	13,3	+1,06	***
Fundo de cotas	-0,732	0,062	-11,7	-1,94	***
Captação/patrimônio	0,078	0,183	0,4	≈ 0	n.s.

Compare essa primeira coluna com a equação do z da Seção 3 — são exatamente os mesmos quatro números ($-3,18$, $-0,18$, $+0,30$, $-0,55$ no exemplo daquela seção eram os coeficientes de *um mês* específico; aqui, a **média** dos 72 meses é ligeiramente diferente, $-3,380$, $-0,339$, $+0,469$, $-0,732$, mas a mesma lógica).

3.8 O efeito parcial médio: traduzindo a nota de volta para pontos percentuais

A pergunta: O coeficiente $-0,339$ do tamanho está na escala de “nota” (z), não em pontos percentuais de peso. Como traduzir de volta?

Para variáveis contínuas (tamanho, cotistas), a tradução usa a inclinação da curva no ponto médio: multiplica o coeficiente por $g(1 - g)$ (a inclinação da curva em S naquele ponto).

No seu projeto: isso dá, por exemplo, $-0,68$ ponto percentual para tamanho, $+1,06$ para cotistas — **Tabela 3, Seção 4.2, coluna “Ef. parcial (p.p.)”**.

O cuidado especial com a dummy FIC

A pergunta: Por que “ser FIC ou não” precisa de um cálculo diferente das outras variáveis?

Pensa assim: A tradução por inclinação (usada para tamanho e cotistas) funciona bem para *pequenos passos* ao longo da curva — como usar a velocidade instantânea de um carro para estimar a distância percorrida num segundo. Mas “ser FIC ou não” não é um passo pequeno — é um salto completo entre dois estados (é ou não é), como comparar a posição do carro no início e no fim de uma freada brusca, não só a velocidade num instante.

O cálculo certo para uma dummy é a **diferença discreta**: calcular o peso previsto fingindo que o fundo *é* FIC, calcular de novo fingindo que *não é*, e subtrair de verdade.

Exemplo com números: para um fundo típico, em janeiro de 2020: peso previsto com FIC= 0 é 4,01%; peso previsto com FIC= 1 é 2,34%. A diferença de verdade é $2,34 - 4,01 = -1,67$ pontos percentuais. O método da inclinação (usado antes de uma correção) dava só $-1,52$ — porque o coeficiente de FIC é grande, o salto entre os dois estados é longo, e a reta tangente usada pelo método da inclinação não acompanha a curvatura da curva em S ao longo de todo esse salto.

No seu projeto: agregando os 72 meses, essa diferença sistemática vira $-1,60$ (derivada, método antigo) contra $-1,94$ (diferença discreta, método corrigido) — quase 20% de diferença, **Tabela 3, Seção 4.2**, nota de rodapé.

4 Fama–MacBeth: por que rodar 72 regressões separadas

A pergunta: Por que não empilhar todos os fundos de todos os meses numa regressão só?

4.1 O problema que motiva o método

Fundos do mesmo mês tendem a se mover juntos — mesma gestora, mesmas condições de mercado naquele momento. Essa “dança em grupo” cria uma correlação entre os erros da regressão que é difícil de medir diretamente (imagine ter que estimar o quanto cada um dos 150 fundos de um mês se correlaciona com cada um dos outros 149 — um número gigante de relações).

4.2 A solução, em duas etapas

Etapa 1: em vez de uma regressão gigante, você roda **uma regressão por mês**, usando só os fundos daquele mês específico. Isso gera 72 “fotos” separadas, uma por mês — 72 vetores de coeficientes $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_{72}$.

Etapa 2: depois de ter as 72 fotos, você simplesmente tira a **média** de cada coeficiente ao longo dos 72 meses, e calcula o erro-padrão a partir de **quanto esses 72 valores variam entre si**.

Pensa assim: É como perguntar “qual é a altura média das pessoas de uma cidade” medindo um bairro de cada vez, em vez de tentar juntar todo mundo numa fila só. No fim, você tira a média dos resultados dos bairros — e a variação entre os bairros já te conta, sozinha, o quanto confiar nessa média, sem precisar saber exatamente como as pessoas de cada bairro se parecem entre si.

4.3 Por que isso é inteligente

Cada “foto” mensal ($\hat{\theta}_t$) já é, sozinha, uma função de **todos** os dados daquele mês. Então qualquer “dança em grupo” que exista dentro daquele mês já está embutida em quanto aquela foto varia de mês para mês. Você não precisa modelar a correlação entre fundos diretamente — ela aparece, de graça, na dispersão da série de 72 fotos.

4.4 A hipótese que precisa valer (e que falha no seu caso)

O truque só funciona se as 72 fotos forem **independentes umas das outras** — o coeficiente de fevereiro não pode “carregar” informação de janeiro.

No seu projeto: isso falha: a correlação de um mês para o próximo, nos seus dados, é de 0,70 a 0,84 — longe de zero. Isso é corrigido pelo Newey–West, explicado a seguir.

4.5 O resultado, no seu projeto

Esta é a tabela completa (a mesma Tabela 2, Seção 4.1, do `tcc I.pdf` — reproduzida aqui por inteiro, não só um resumo, para você não precisar alternar entre os dois documentos):

Coeficiente	Média dos 72 meses ($\bar{\beta}_k$)	Est. t (Newey–West, $L = 3$)
Intercepto	+0,0396	10,5
ln(patrimônio) por d.p.	−0,0068	−11,3
ln(cotistas) por d.p.	+0,0109	10,9
Fundo de cotas	−0,0170	−11,1
Captação/patrimônio (wins.)	+0,0018	0,4

Repare que a captação é a única linha **não** significativa ($t = 0,4$, muito menor que 1,96) — é o dado por trás da frase “a captação não ajuda a explicar o peso” que aparece várias vezes neste documento. Todas as outras quatro linhas têm $|t| > 10$, folgadoamente acima do limiar de significância a 1%.

⇒ **Tabela 2, Seção 4.1** do `tcc I.pdf`.

5 Newey–West: por que o erro-padrão simples engana

A pergunta: Por que não usar a fórmula clássica de erro-padrão (desvio-padrão da série dividido pela raiz de 72)?

Pensa assim: Imagine perguntar a opinião de 72 pessoas sobre um filme, mas 60 delas são amigas próximas que sempre concordam entre si (porque conversaram antes de responder). Se você tratar as 72 respostas como 72 opiniões totalmente independentes, você vai superestimar o quanto sabe sobre a opinião real da população — na prática, você tem muito menos que 72 “vozes” realmente distintas, porque boa parte delas está só repetindo a opinião das outras.

Os 72 coeficientes mensais são parecidos com essas 72 pessoas: como se correlacionam de 0,70 a 0,84 de um mês para o outro, tratar os 72 como 72 informações totalmente novas e independentes **superestima a precisão** da média — os erros-padrão saem pequenos demais, e as estatísticas t saem grandes demais, dando uma falsa sensação de certeza.

5.1 A correção

O Newey–West soma não só a variância de cada mês sozinho, mas também as “covariâncias” entre meses vizinhos (o quanto um mês se parece com o mês seguinte, dois meses depois, etc.), com um peso que diminui quanto mais distante a defasagem:

$$\widehat{\text{Var}}_{\text{NW}}(\bar{\beta}_k) = \frac{1}{T^2} \left[\sum_{t=1}^T \hat{u}_{k,t}^2 + 2 \sum_{\ell=1}^L \left(1 - \frac{\ell}{L+1} \right) \sum_{t=\ell+1}^T \hat{u}_{k,t} \hat{u}_{k,t-\ell} \right]$$

em que $\hat{u}_{k,t} = \beta_{k,t} - \bar{\beta}_k$ é o quanto o coeficiente daquele mês se afasta da média, e L é quantos meses vizinhos entram na soma (aqui, $L = 3$, pela regra automática). O primeiro pedaço da soma (o $\sum \hat{u}_{k,t}^2$) é a fórmula clássica, “ingênuo”; o segundo pedaço — que a fórmula clássica ignora — é exatamente a parte que captura a semelhança entre meses vizinhos. Quando essa semelhança é forte (como é o caso aqui, autocorrelação de 0,70–0,84), esse segundo pedaço é grande e **positivo**, então a variância corrigida sai maior — o erro-padrão (raiz da variância) cresce, e a estatística t (que divide o coeficiente pelo erro-padrão) cai.

No seu projeto: o efeito prático, coeficiente por coeficiente:

Coeficiente	t ingênuo (sem correção)	t Newey–West ($L = 3$)	Fator de aumento do EP
ln(patrimônio)	≈ -19	$-11,3$	$\times 1,7$
ln(cotistas)	$\approx +19$	$+10,9$	$\times 1,7$
Fundo de cotas	≈ -19	$-11,1$	$\times 1,7$

As conclusões (todas as características, exceto a captação, são significativas) sobrevivem, mas os números “bonitos demais” de antes ($|t| \approx 19$ – 21) eram uma ilusão de precisão criada por ignorar que os 72 meses não são 72 informações independentes. $\Rightarrow$ **Seção 3.3 e Tabela 2, Seção 4.1.**

6 A dinâmica do fator: os coeficientes mudam de mês para mês, e o filtro de Kalman

6.1 O que a Etapa 1 do Fama–MacBeth já te deu, sem você perceber

Antes mesmo de calcular a média (Etapa 2), você já tinha 72 números separados — uma **série temporal** de coeficientes. É essa série, e só ela, que alimenta tudo que vem nesta seção. O filtro de Kalman nunca olha para os dados originais de fundo por fundo — só para essa sequência já resumida mês a mês.

6.2 Por que essa série é “barulhenta”

Cada coeficiente mensal $\hat{\theta}_t$ não é o valor “verdadeiro” daquele mês — é o valor verdadeiro mais um erro de amostragem (cada mês usa uma amostra diferente de ~ 150 fundos, e amostra finita sempre erra um pouco). O filtro de Kalman parte de duas equações, uma para o que *observamos* e outra para o que *achamos que existe por trás*:

$$\underbrace{\hat{\theta}_t = \mu_t + \varepsilon_t}_{\text{equação de medida: o que vemos}} \qquad \underbrace{\mu_t = \mu_{t-1} + \eta_t}_{\text{equação de estado: como o “verdadeiro” se move}}$$

A primeira equação diz: o número que a regressão de FM devolve num mês ($\hat{\theta}_t$) é o fator estrutural verdadeiro daquele mês (μ_t , que nunca observamos diretamente) mais um erro de amostragem (ε_t , com variância R). A segunda equação diz como o próprio μ_t se move de mês para mês: como um passeio aleatório, dando um passo aleatório η_t (com variância Q) a cada mês, sem tendência de subir ou descer sistematicamente. É a combinação dessas duas equações — uma quantidade real que se move devagar, escondida atrás de uma medição ruidosa — que dá nome ao modelo: **nível local** (*local level*).

A Figura 1 mostra exatamente essa série barulhenta, uma por característica, ao longo dos 72 meses — é o que entra no filtro, característica por característica, de forma totalmente independente (um filtro de Kalman diferente é rodado para cada uma das cinco séries).




Figura 1: As cinco séries de coeficientes, mês a mês, 2016–2021 — exatamente os $\hat{\theta}_t$ que alimentam o filtro de Kalman. Repare que nenhum painel é ruído puro em torno de zero: há uma trajetória visível, com uma reconfiguração perceptível por volta de 2018, sobretudo nos painéis de tamanho, cotistas e fundo de cotas.

Mesma figura que a Figura 1, Seção 4.3, do tcc I.pdf. Fonte: elaboração própria (script R/29).

6.3 Antes do Kalman: como saber se a série “sempre volta ao mesmo lugar” ou “pode se afastar para sempre”? O teste de Dickey–Fuller

A pergunta: Antes de decidir como prever os coeficientes, precisamos saber: eles têm um “centro de gravidade” para onde sempre voltam, ou podem se afastar dele permanentemente?

Pensa assim: Pensa numa bolinha de gude. Se você solta ela dentro de uma tigela funda, não importa de onde você solte, ela sempre rola de volta para o fundo — existe um “centro de gravidade”. Isso é **reversão à média**. Agora imagina soltar a mesma bolinha numa mesa completamente plana e sem atrito: ela fica exatamente onde parou, e qualquer empurrãozinho a leva para um lugar novo, **permanentemente** — não existe centro de gravidade nenhum. Isso é **passeio aleatório** (também

chamado de “raiz unitária”).

Por que isso importa aqui: se os coeficientes θ_t fossem um passeio aleatório puro, a melhor previsão de amanhã seria simplesmente o valor de hoje (não haveria nenhum “centro” para o qual a série tende a voltar). Se eles reverterem à média, faz sentido usar um modelo (como o Kalman) que capture essa tendência de retorno.

Como o teste funciona, por dentro

A ideia é reescrever a pergunta “a série reverte à média?” como uma regressão: a **mudança** da série de um mês para o outro é explicada por **onde a série estava** no mês anterior.

- Se o coeficiente dessa relação for **zero**: a mudança de amanhã não depende de onde você está hoje — é a mesa plana, passeio aleatório.
- Se for **negativo** (e claramente diferente de zero): quando a série está longe do centro, ela tende a se mover de volta — é a tigela, reversão à média.

A pegadinha: por que não usar a tabela de significância comum

A pergunta: Por que esse teste usa um valor crítico diferente ($-2,9$) em vez do $-1,65$ ou $-1,96$ de um teste comum?

Aqui está o detalhe sutil: **debaixo da hipótese que está sendo testada** (passeio aleatório), a própria variável usada para explicar a mudança não tem “chão” — ela pode vagar para qualquer lugar, sem limite. Isso quebra uma suposição matemática que os testes comuns precisam (que a variável explicativa se comporte de um jeito “bem-comportado”), e a distribuição da estatística do teste fica deslocada — por isso o valor crítico é mais exigente ($\approx -2,9$ a 5% de significância, não $-1,65$).

No seu projeto: rodando esse teste nas 5 séries de coeficientes (72 meses cada), quatro delas rejeitam passeio aleatório puro — intercepto, tamanho e FIC claramente reverterem à média (o teste dá valores mais negativos que $-2,9$); cotistas fica bem no limite ($-2,70$, quase lá, mas tecnicamente não rejeita a 5%); fluxo é a menos persistente de todas, quase ruído puro. Esse resultado — as séries reverterem, mas devagar — é exatamente a evidência que justifica usar o filtro de Kalman em vez de tratar a série como puro ruído ou puro passeio aleatório. $\Rightarrow$ **Seção 4.3, Tabela 4, “Dinâmica dos coeficientes”.**

6.4 Duas formas diferentes de lidar com essa série barulhenta

Caminho 1 (Fama–MacBeth, Etapa 2): tira uma média única dos 72 valores — ótimo para “em média, ao longo de todo o período, essa característica importa?”, mas descarta a ordem temporal.

Caminho 2 (filtro de Kalman): percorre a série mês a mês, tentando reconstruir a trajetória “verdadeira” que está por trás dos 72 valores ruidosos, permitindo que ela realmente se mova ao longo do tempo.

Pensa assim: Pensa nos 72 $\hat{\theta}_t$ como 72 fotos de algo que se move devagar, cada foto um pouco embaçada. O Fama–MacBeth (Caminho 1) sobrepõe as 72 fotos numa imagem composta só — boa para dizer “na média, foi assim”, mas perde o movimento. O Kalman (Caminho 2) monta um *vídeo*: reconstrói a trajetória suave mais provável por trás daquela sequência de fotos embaçadas.

6.5 Como o filtro decide quanto confiar em cada mês novo

A pergunta: Toda vez que chega um novo $\hat{\theta}_t$ (uma nova “foto”), o filtro precisa decidir: confio nele, ou confio mais no que eu já sabia até o mês passado? Como essa decisão é tomada, de verdade, número por número?

O filtro faz exatamente dois passos, repetidos mês a mês. Chame de a_t a melhor estimativa do estado μ_t e de P_t a incerteza (variância) dessa estimativa.

Passo 1 — Previsão (“o que eu esperava, antes de ver o mês novo”). Como o estado segue passeio aleatório (equação de estado acima), a melhor previsão para o mês novo é simplesmente a estimativa que sobrou do mês anterior — mas com um pouco mais de incerteza somada (porque o estado deu um passo aleatório η_t desde então):

$$a_{t|t-1} = a_{t-1}, \quad P_{t|t-1} = P_{t-1} + Q$$

Passo 2 — Atualização (“agora que vi o mês novo, o que eu acho?”). Compara-se a previsão com o valor observado $\hat{\theta}_t$; a diferença entre os dois, $v_t = \hat{\theta}_t - a_{t|t-1}$, é o quanto o mês novo “surpreendeu”. O **ganho de Kalman** K_t decide que fração dessa surpresa vira correção:

$$K_t = \frac{P_{t|t-1}}{P_{t|t-1} + R}, \quad a_t = a_{t|t-1} + K_t v_t, \quad P_t = (1 - K_t) P_{t|t-1}$$

Q e R são estimados, para cada uma das cinco séries, por máxima verossimilhança — o programa procura os valores de Q e R que tornam a sequência observada de 72 valores a mais “provável” possível, sob o modelo de nível local (mesma lógica de estimação usada, por exemplo, no MQO — só que aqui em vez de minimizar erro ao quadrado, maximiza-se a verossimilhança da trajetória inteira).

- Se o ruído de medida domina ($R \gg Q$): $K_t \rightarrow 0$, o filtro quase ignora o mês novo — vira uma média longa, praticamente “fica parado” no que já sabia.
- Se o estado se move muito ($Q \gg R$): $K_t \rightarrow 1$, o filtro quase copia o valor novo — vira “repetir o último valor”, como se cada mês fosse informação inteiramente nova e confiável.

Pensa assim: É a mesma lógica de ajustar o volume de um rádio mal sintonizado: se você sabe que a estação (o sinal verdadeiro) muda de frequência devagar mas a estática é forte, você reage pouco a cada chiado novo (ganho baixo, $K \rightarrow 0$). Se a estação pula de frequência com frequência mas o aparelho é preciso, você reage rápido a cada leitura nova (ganho alto, $K \rightarrow 1$). O filtro de Kalman calcula, sozinho, o ponto de equilíbrio certo entre essas duas situações, a partir dos próprios dados.

6.6 Um exemplo de verdade, passo a passo, com os números do seu projeto

Exemplo com números: vamos seguir a série do coeficiente de **fundo de cotas** (a mesma variável FIC da Tabela 2) ao redor da “reconfiguração de 2018” que a Figura 1 mostra visualmente. O programa (script **R/18**) estima, por máxima verossimilhança, $Q = 0,0000067$ e $R = 0,0000137$ para essa série — ou seja, o **ruído de medida é cerca do dobro do tamanho do passo real do estado**, um sinal de que o filtro deve confiar de forma moderada em cada mês novo, nem ignorá-lo, nem copiá-lo cegamente.

Mês	Previsão $a_{t t-1}$	Observado $\hat{\theta}_t$	Ganho K_t	Estimativa a_t
jan/2018	-0,0262	-0,0315	0,496	-0,0288
fev/2018	-0,0288	-0,0204	0,496	-0,0246
mar/2018	-0,0246	-0,0272	0,496	-0,0259
abr/2018	-0,0259	-0,0308	0,496	-0,0283

Confira a conta de fevereiro, à mão, com a fórmula do Passo 2: a surpresa daquele mês é $v = \hat{\theta}_t - a_{t|t-1} = -0,0204 - (-0,0288) = 0,0084$. A correção aplicada é $K_t \times v = 0,496 \times 0,0084 \approx 0,0042$. A nova estimativa é $a_t = -0,0288 + 0,0042 = -0,0246$ — exatamente o valor da tabela.

O momento "ahá": O ganho $K_t \approx 0,496$ significa que o filtro dá **quase o mesmo peso** ao que já sabia (a previsão) e ao que acabou de ver (o valor novo de fevereiro) — nem ignora o mês novo, nem copia ele inteiro. Repare também que a **estimativa filtrada** (a_t , coluna da direita) é sempre mais suave que a série **observada** ($\hat{\theta}_t$, coluna do meio): ela vai de $-0,0288$ a $-0,0283$ ao longo dos quatro meses, um movimento de $0,0005$; enquanto o observado pula de $-0,0315$ para $-0,0308$, passando por $-0,0204$ no meio do caminho — uma oscilação bem mais violenta. É exatamente esse “alisamento com memória” que diferencia o Kalman de uma média simples (que ignoraria a ordem temporal) e de “usar o valor cru de cada mês” (que copiaria cada solução da amostra).

No seu projeto: por que faz sentido usar Kalman em vez de só a média: a autocorrelação de $0,70$ a $0,84$ (Seção 4) mostra que a série **não é só ruído em torno de uma média fixa** — ela realmente se move, com uma reconfiguração visível em torno de 2018. Se fosse só ruído, a média já seria a melhor descrição possível; como não é, vale a pena reconstruir a trajetória, e é isso que o filtro faz.

7 Previsão: os quatro modelos e por que a ingênua vence

A pergunta: As características explicam bem o peso contemporâneo — será que também ajudam a prever o peso do mês seguinte?

Quatro modelos competem, todos avaliados fora da amostra (só com informação disponível até o momento da previsão):

- **M0 (ingênua):** $\hat{w}_{t+1} = w_t$ — simplesmente repete o último peso. É a régua contra a qual todos os outros precisam ganhar.
- **M1 (efeito fixo):** $\hat{w}_{t+1} = \bar{w}_i$ — usa a média histórica *do próprio fundo*. Testa se o peso reverte a um nível característico daquele fundo.
- **M2 (efeito fixo + Kalman):** soma ao nível do fundo o desvio que as características sugerem, usando o fator suavizado pelo Kalman.
- **M3 (variação):** prevê diretamente a *mudança* do peso, usando o fluxo e outras características.

7.1 O resultado, e por que ele é revelador

A tabela completa (mesma Tabela 5, Seção 4.4, do `tcc I.pdf`), com as oito células testadas — dois universos de fundos, dois horizontes, quatro modelos — em erro quadrático médio (RMSE; menor é melhor, e o menor de cada linha está em negrito):

Universo	Horizonte	M0 ingênua	M1 EF	M2 EF+Kalman	M3 variação
Todos os fundos	$h = 1$ mês	0,0156	0,0240	0,0255	0,0156
Todos os fundos	$h = 3$ meses	0,0207	0,0262	0,0273	0,0210
Só fundos de ações	$h = 1$ mês	0,0197	0,0310	0,0383	0,0198
Só fundos de ações	$h = 3$ meses	0,0266	0,0337	0,0385	0,0270

⇒ **Tabela 5, Seção 4.4** (RMSE, menor é melhor). Note que a ingênua vence **nas oito células**, e que restringir aos fundos de ações (posições maiores e mais ativas) amplia as diferenças sem mudar a ordem — o padrão não é um acaso de um universo específico.

A ingênua vence todos. O resultado mais revelador é **M1 perder de M0**: se existisse reversão à média histórica do próprio fundo, M1 venceria M0. Ele não vence — significa que **não há reversão detectável ao nível do fundo no curto prazo**: o peso se comporta quase como um *martingale* (um processo em que a melhor previsão do amanhã é simplesmente o valor de hoje, sem nenhuma tendência de retorno a média nenhuma). M3 empatar com M0 diz que nem o fluxo antecipa mudanças de peso.

Pensa assim: É como tentar prever se vai chover amanhã usando “a média histórica de chuva desse mês” contra “choveu ou não choveu hoje”. Se “choveu hoje” prevê melhor que a média histórica, isso diz que o clima tem inércia de curto prazo forte — é basicamente o que acontece aqui com o peso das carteiras.

8 A margem extensiva: antes de “quanto”, existe “tem ou não tem”

A pergunta: Até agora, olhamos só fundos que *já têm* VALE3, perguntando “quanto”. Mas existe uma pergunta anterior a essa: o fundo tem VALE3 na carteira ou não?

Pensa assim: É a diferença entre perguntar “quanto alguém gasta com viagens” (só faz sentido perguntar para quem viaja) e perguntar “essa pessoa viaja ou não” (pergunta que vale para todo mundo, inclusive quem nunca viajou na vida). A primeira pergunta é a **margem intensiva** (quanto, condicional a ter); a segunda é a **margem extensiva** (ter ou não).

8.1 Como se monta essa análise

Até aqui, a amostra só incluía fundos que detêm VALE3. Para estudar a margem extensiva, é preciso um painel diferente: **todos** os fundos de ações do Itaú, inclusive os que não têm VALE3 nenhuma (para esses, o peso registrado é simplesmente zero). Sobre esse painel maior, roda-se um **logit binário** — o mesmo tipo de curva em S da Seção 3, só que agora a variável explicada é “tem VALE3? sim ou não” (não mais “quanto”), explicada pelas mesmas características.

8.2 O achado mais bonito do trabalho

O momento “ahá”: As duas margens têm **sinais opostos**. Fundos grandes e fundos de cotas são *mais* propensos a ter VALE3 (margem extensiva positiva) — mas quando têm, carregam um peso *menor* (margem intensiva negativa, o que você já viu nas seções anteriores).

Pensa assim: Pensa numa pessoa rica montando uma coleção de vinhos: quanto mais rica, mais tipos diferentes de vinho ela tende a ter na adega (mais provável ter *qualquer* rótulo específico) —

mas cada rótulo individual ocupa uma fatia pequena da coleção total, porque ela está espalhando entre muitas opções, não concentrando numa só.

Essa é a assinatura de **diversificação**: um fundo grande, ou um fundo de cotas (que investe via outros fundos), tende a “ter um pouco de tudo” — inclusive VALE3 — mas cada posição individual fica diluída porque a carteira está espalhada por muitos ativos.

8.3 A posse também é bastante persistente

Assim como o peso (Seção 7), a decisão de “ter ou não ter” muda pouco de um mês para o outro — a posse muda em só 1,3% dos casos. Prever “continua igual” acerta 98,7% das vezes, contra $\approx 87\%$ de um modelo que usa as características — de novo, características explicam bem, mas a inércia domina a previsão de curto prazo.

O logit da margem extensiva (10.286 observações, 260 fundos de ações, dos quais 86% têm VALE3) — mesma Tabela 6, Seção 4.5:

Variável	Estimativa	Erro padrão	Estatística z	Sig.
Intercepto	−2,809	0,275	−10,2	***
ln(patrimônio)	0,232	0,015	15,1	***
ln(cotistas)	−0,034	0,012	−2,8	**
Fundo de cotas	1,311	0,075	17,5	***

Repare no **sinal do coeficiente de patrimônio**: +0,232, **positivo** — fundos maiores são *mais* propensos a ter VALE3. Compare com o sinal do mesmo tamanho na margem intensiva (Tabela 2, Seção 4.1): −0,0068, **negativo**. É o mesmo tamanho de fundo, duas perguntas diferentes, dois sinais opostos — resumido na tabela a seguir (mesma Tabela 7, Seção 4.5):

Característica	Ter ou não a ação	Quanto carregar
Tamanho do fundo	mais provável ter (+)	peso menor (−)
Fundo de cotas	mais provável ter (+)	peso menor (−)
Número de cotistas	menos provável, fraco (−)	peso maior (+)

⇒ Seção 4.5 “As duas margens”, Tabelas 6 e 7 do tcc I.pdf.

9 O modelo de ajuste parcial: o alvo, a distância, e por que o cálculo direto engana

Esta é a parte mais elaborada do trabalho. Vamos construir cada peça devagar.

9.1 Relembrando o alvo

Na Seção 3, você viu como calcular w^* — o peso desejado de um fundo, dado seu perfil. Ele é recalculado **todo mês**, para **cada fundo**, porque tanto as características do fundo quanto os coeficientes θ_t daquele mês mudam com o tempo.

9.2 A equação do ajuste parcial

A hipótese: o fundo não salta direto para o peso desejado — ele se move só uma fração λ do caminho a cada mês.

$$w_{i,t+1} = (1 - \lambda) w_{i,t} + \lambda w_{i,t}^* + u_{i,t+1}$$

Reescrevendo, chamando a distância de $d_{i,t} \equiv w_{i,t}^* - w_{i,t}$:

$$\underbrace{w_{i,t+1} - w_{i,t}}_{\text{variação do peso}} = \lambda \times \underbrace{d_{i,t}}_{\text{distância ao alvo}} + u_{i,t+1}$$

$\Rightarrow$ **Seção 3.6, equação (5)** do **tcc I.pdf**. λ é o que queremos descobrir: $\lambda = 1$ significa ajuste instantâneo; $\lambda = 0$ significa que o fundo nunca se move na direção do alvo.

9.3 Por que medir isso diretamente (MQO) não funciona: Problema 1

A pergunta: Por que a distância calculada não é confiável?

Pensa assim: Imagine tentar descobrir se “fazer mais exercício” causa “perder mais peso”, mas em vez de medir o exercício com um relógio inteligente (preciso), você pede para as pessoas **lembrarem de cabeça** quantas horas se exercitaram. A memória erra — às vezes chuta pra mais, às vezes pra menos, aleatoriamente. Quando você usa esse número “de memória” (com erro) numa análise, a relação estimada aparece **mais fraca** do que a relação real — o erro aleatório borra o sinal, como uma foto tremida.

O alvo w^* não é medido direto — é **estimado** por uma regressão com uma amostra de ~ 150 fundos daquele mês. Se a amostra fosse ligeiramente diferente, o alvo calculado sairia um pouco diferente. Esse “tremor” entra dentro da distância $d = w^* - w$, e pela mesma lógica do exercício: usar essa distância tremida para prever a variação faz a relação estimada sair **mais fraca do que a real** — **empurra λ para baixo**.

9.4 Por que medir isso diretamente (MQO) não funciona: Problema 2

A pergunta: Por que existe um segundo problema, além do erro de medida no alvo?

Pensa assim: Imagine pesar uma pessoa numa balança com uma pequena imprecisão — às vezes marca mais, às vezes menos, por roupa, hora do dia, etc., nada a ver com mudança real de peso. Se num mês a balança marcar, por acaso, mais alto que o normal, no mês seguinte a leitura volta ao normal — e vai parecer, nos seus dados, que a pessoa “emagreceu”, quando não teve perda real nenhuma.

Exemplo com números: vamos inventar um fundo cujo peso **verdadeiro** nunca muda — fica travado em 1,5% sempre, e o alvo dele também é 1,5% (não deveria haver ajuste nenhum, a distância verdadeira é zero). Só que a gente nunca vê o peso verdadeiro — vê o peso **registrado**, que tem uma pequena imprecisão de medição:

	Peso verdadeiro (ninguém vê)	Peso registrado (o que está nos dados)
Mês 1	1,5%	1,8% (imprecisão pra cima)
Mês 2	1,5%	1,5% (imprecisão sumiu)

Calculando com os números **registrados** (os únicos que existem nos dados):

$$d_1 = \text{alvo} - \text{peso registrado} = 1,5\% - 1,8\% = -0,3 \text{ p.p.}$$

$$\Delta w = \text{peso registrado mês 2} - \text{peso registrado mês 1} = 1,5\% - 1,8\% = -0,3 \text{ p.p.}$$

O momento "ahá": Se você dividir Δw por d — essencialmente o que uma regressão simples faz —, dá $\frac{-0,3}{-0,3} = 1,0$: pareceria um ajuste **perfeito e instantâneo**! Mas a gente **sabe**, porque inventamos o exemplo, que não houve ajuste nenhum — o peso verdadeiro nunca mudou. O $\lambda = 1,0$ é inteiramente uma ilusão, criada pela imprecisão do mês 1 se corrigindo sozinha no mês 2.

O motivo estrutural: o **mesmo** peso registrado do mês 1 é usado duas vezes — uma para calcular a distância, outra para calcular a variação. Qualquer solução aleatório nele cria uma correlação artificial entre os dois lados, **empurrando λ para cima**, mesmo sem ajuste real nenhum.

9.5 Os dois problemas competem

O Problema 1 empurra λ estimado **para baixo**; o Problema 2 empurra **para cima**. Rodando só a medição direta (MQO), você não sabe qual dos dois venceu — só descobre comparando com um método que corrige os dois. É isso que os métodos a seguir fazem, cada um a sua maneira.

10 Os quatro métodos de estimar a velocidade de ajuste

10.1 Método 1 — Mínimos Quadrados (MQO): a medição direta, sabendo que vem torta

A pergunta: Por que rodar um método que já sabemos que está contaminado?

Ele serve de **termômetro**: sozinho, o número não é confiável, mas comparado com os métodos seguintes, revela qual dos dois problemas pesou mais.

⇒ **Resultado:** $\hat{\lambda}^{MQO} = 0,0976$ — **Tabela 8, Seção 4.6, primeira linha**. Como saiu relativamente alto, isso sugere que o Problema 2 (vazamento mecânico) pesou mais que o Problema 1 (erro de medida) no seu caso.

10.2 Método 2 — Variável Instrumental: usando “ontem” como pista mais limpa

A pergunta: Como corrigir os dois problemas ao mesmo tempo?

Pensa assim: Em vez de perguntar “onde você está exatamente agora?” (pergunta contaminada por ruído momentâneo), você pergunta “para onde você estava indo no mês passado?”. A segunda pergunta é uma pista um pouco desatualizada, mas mais limpa — não carrega o ruído específico de hoje.

Como funciona, em dois passos (2SLS — mínimos quadrados em duas etapas):

1. **Primeiro estágio.** Regride-se a distância de hoje na distância de ontem,

$$d_{i,t} = \pi_0 + \pi_1 d_{i,t-1} + \text{erro},$$

e guarda-se só a parte **prevista**, $\hat{d}_{i,t} = \hat{\pi}_0 + \hat{\pi}_1 d_{i,t-1}$ — a parte de d_t que já era conhecida desde ontem, sem nenhum ruído de hoje embutido.

No seu projeto: $\hat{\pi}_1 \approx 0,9$ (quase 90% da distância de hoje já era esperada desde ontem) — “primeiro estágio”, mencionado na Seção 4.6.

2. **Segundo estágio.** Regride-se a variação do peso **não** na distância bruta $d_{i,t}$, mas na sua versão “limpa” $\hat{d}_{i,t}$:

$$w_{i,t+1} - w_{i,t} = \lambda \hat{d}_{i,t} + u_{i,t+1}$$

Exemplo com números: imagine um fundo com $d_{t-1} = 0,40$ p.p. (distância de ontem). Pela reta do primeiro estágio ($\hat{\pi}_0 \approx 0$, $\hat{\pi}_1 \approx 0,9$ neste exemplo simplificado), a previsão é $\hat{d}_t = 0,9 \times 0,40 = 0,36$ p.p. Suponha que a distância *bruta* observada hoje seja $d_t = 0,55$ p.p. — maior que o previsto, porque, digamos, um soluço de amostragem tornou o alvo daquele mês artificialmente distante (o Problema 1). O segundo estágio usa 0,36, não 0,55: o excesso de 0,19 p.p. (o soluço) é descartado antes de estimar λ , exatamente porque ele não existia ainda ontem — não pode ser coisa que o fundo já sabia e estava corrigindo.

Como o mês passado não sabe nada sobre o erro de medida de hoje nem sobre a oscilação passageira do peso de hoje, os dois problemas somem juntos.

$\Rightarrow$ **Resultado:** $\hat{\lambda}^{VI} = 0,0413$, $t = 6,6$ — **Tabela 8, segunda linha.** Bem menor que o MQO, confirmando que boa parte do que o MQO media era vazamento mecânico (Problema 2), não velocidade real.

10.3 Uma pausa importante: o $t = 6,6$ da VI é confiável de verdade?

Antes de seguir para o Método 3, vale parar numa correção que, no fim das contas, é tão importante quanto os quatro métodos juntos.

A pergunta: A estatística $t = 6,6$ do Método 2 (VI) parece muito forte. Ela é confiável?

Pensa assim: Imagine perguntar a opinião de 300 pessoas sobre um filme, mas 50 delas assistiram juntas, na mesma sessão de cinema, e conversaram sobre o filme enquanto assistiam. As respostas dessas 50 não são realmente 50 opiniões independentes — é mais como uma única opinião, contaminada e repetida 50 vezes. Se você trata como se fossem 300 vozes totalmente independentes, está **superestimando sua certeza** sobre a opinião real do público.

O problema: fundos no mesmo mês não são independentes

O erro-padrão do Método 2, na forma como foi calculado inicialmente, é “agrupado por fundo” (um jeito de dizer: ele permite que os erros de um *mesmo* fundo, ao longo do tempo, sejam correlacionados entre si, mas assume que fundos *diferentes* são independentes uns dos outros). O problema: isso não é verdade. Todos os fundos que têm VALE3 são afetados, no mesmo mês, pelo mesmo “clima de mercado” — em particular, se o preço de VALE3 sobe mais que o resto da carteira num mês, o peso de **todo mundo** que tem a ação sobe um pouco, mecanicamente, sem ninguém precisar negociar nada. Isso é um choque **comum a todos os fundos daquele mês**, e o erro-padrão “agrupado por fundo” não enxerga essa correlação entre fundos diferentes.

O que acontece quando você conserta isso

O momento "ahá": Recalculando o erro-padrão de um jeito que *também* captura a correlação entre fundos dentro do mesmo mês (agrupando por mês, em vez de por fundo), a estatística t despenca de 6,6 para 1,8–1,9 — praticamente no limiar da significância! O mesmo $\hat{\lambda} = 0,041$, só que agora parece muito menos confiável.

A correção de verdade: atacar a causa, não só alargar o erro-padrão

Simplesmente trocar o jeito de agrupar o erro-padrão é tratar o **sintoma** (a incerteza maior), não a **causa** (o choque comum em si, que ainda está lá, contaminando a estimativa de outras formas). A correção adotada foi diferente: incluir, na própria equação, um **efeito de tempo** — um ajuste específico para cada mês que absorve tudo que afeta igualmente todos os fundos naquele mês (inclusive o efeito mecânico do preço), *antes* de estimar λ .

Pensa assim: É a diferença entre “alargar sua margem de erro porque você sabe que a balança está imprecisa” (tratar o sintoma) e “consertar a balança antes de pesar” (tratar a causa). A segunda opção é sempre melhor, quando possível.

O momento "ahá": Com essa correção, a significância **volta forte**: $t = 6,9$, quase idêntica à estimativa original por fundo. Isso é uma notícia boa: a fragilidade não estava no fenômeno em si (a reversão ao alvo existe de verdade) — estava em como o choque comum do mês era tratado no cálculo do erro-padrão.

⇒ **Tabela 8, linha “VI + efeito de tempo δ_t ”, Seção 4.6 do tcc I.pdf** — essa linha está em destaque na tabela porque, junto com o teste de Diebold–Mariano (Seção 11.3 deste documento), é uma das duas correções mais importantes desta versão do trabalho.

10.4 Método 3 — Efeito-fixo de fundo: existe um terceiro problema

A pergunta: A pista de “ontem” resolve tudo?

Quase — falta um terceiro problema. Imagine um fundo que, por cultura interna (não capturada pelas características), **sempre** carregue mais ou menos VALE3 do que o modelo prevê — um “jeito de ser” permanente, não um soluço passageiro. Para esse fundo, a distância vai aparecer artificialmente alta ou baixa **todo mês**, inclusive no mês passado — então até a pista “limpa” do Método 2 carrega esse viés permanente.

Pensa assim: É como tentar corrigir a imprecisão de várias balanças diferentes comparando uma pessoa pesada nelas com uma pessoa magra pesada nelas — a diferença entre as pessoas atrapalha a comparação. A solução: pesar a **mesma** pessoa, na mesma balança, em momentos diferentes, e olhar só a variação dela mesma.

A correção: em vez de comparar fundos diferentes entre si, você compara **cada fundo com a própria história dele** — subtrai a média histórica de cada fundo (tanto da distância quanto da variação) antes de aplicar o Método 2:

$$(w_{i,t+1} - w_{i,t}) - \overline{\Delta w_i} = \lambda [\widehat{d}_{i,t} - \widehat{d_i}] + \text{erro}$$

em que $\overline{\Delta w_i}$ e $\widehat{d_i}$ são as médias, ao longo de todos os meses, *daquele fundo específico*. Isso cancela o “jeito de ser” permanente automaticamente, porque um valor constante subtraído da própria média vira zero.

Exemplo com números: um fundo que, todo mês, carrega em média 0,30 p.p. a mais de VALE3 do que o modelo prevê (seu “jeito de ser”, $\widehat{d_i} = 0,30$). Num mês em que a distância prevista é $\widehat{d}_{i,t} = 0,45$, o Método 2 (sem efeito-fixo) usaria 0,45 inteiro. O Método 3 usa só $0,45 - 0,30 = 0,15$ — a parte que é *desvio daquele mês em particular*, não o “jeito de ser” que já é constante em todos os meses e não representa ajuste algum.

⇒ **Resultado:** $\widehat{\lambda}^{FE+VI} = 0,1853$, $t = 9,5$ — **Tabela 8, linha “FE de fundo + VI”**. Quase

quatro vezes maior! Isso revela que o 0,041 agregado misturava fundos com desvio **permanente** (que nunca fecham, puxando a média para baixo) com desvios **passageiros** (que se fecham bem mais rápido). Isolando só a segunda parte, a velocidade real é maior.

10.5 Método 4 — Arellano-Bond: o mesmo problema, atacado de outro jeito

A pergunta: Existe outra forma de remover o “jeito de ser” do fundo, além de subtrair a média?

Sim: em vez de subtrair a média histórica, você pode **subtrair um período do período seguinte** (a equação de hoje menos a de ontem). Como o “jeito de ser” é constante no tempo, ele desaparece nessa subtração também (constante menos ela mesma é zero).

A equação também é reescrita de um jeito mais flexível, sem travar a soma dos coeficientes em 1:

$$w_{i,t} = \rho \cdot w_{i,t-1} + \lambda \cdot w_{i,t-1}^* + u_{i,t}$$

E, em vez de usar só uma pista antiga (o Método 2 usa só d_{t-1}), esse método usa **todas** as pistas suficientemente antigas ao mesmo tempo ($w_{t-2}, w_{t-3}, \dots$).

A pergunta: O que deu errado no seu caso?

Esse método foi desenhado para painéis com **muitos indivíduos e poucos períodos de tempo** (por exemplo, milhares de empresas, 5 anos de dados). O seu painel é o oposto — 307 fundos, mas 72 meses. Isso faz o número de “pistas antigas” disponíveis crescer demais (chegou a **2.484 pistas para só 307 fundos!**), deixando a estimativa instável.

⇒ **Resultado: instável.** Com todas as pistas, $\hat{\lambda} = +0,2923$; com a correção padrão para excesso de pistas (usar menos, de um jeito mais eficiente), $\hat{\lambda} = -0,3312$ — o sinal **inverte**. ⇒ **Tabela 8, duas últimas linhas; discussão no parágrafo “Quarta, e mais importante...”, Seção 4.6.** Isso não significa que o fenômeno seja falso — significa que essa ferramenta específica não serve para esse formato de painel.

10.6 Resumo dos quatro métodos

Método	O que corrige, além do anterior	Result.	Confiável aqui?
MQO	Nada (é a referência)	0,098	Não, sabidamente viésado
VI	Erro de medida + vazamento mecânico	0,041	Sim, especificação central
Efeito-fixo + VI	Além disso, o “jeito de ser” do fundo	0,185	Sim, mais rápido (dentro do fundo)
Arellano-Bond	O mesmo, por outro caminho	+0,29 −0,33	Não, instável nesse formato

Essa é uma versão simplificada, para fixar a ideia central. A tabela cheia — a mesma Tabela 8, Seção 4.6, do **tcc I.pdf** — traz **todas** as dez especificações realmente estimadas, incluindo variações de robustez que não couberam no resumo acima (cluster por mês, cluster *two-way*, instrumento mais defasado, horizonte de 3 meses):

Especificação	Estim. $\hat{\lambda}$	EP	t	Nota
MQO (enviesado)	0,0976	0,0096	10,2	viés misto (Problemas 1+2)
VI, cluster por fundo (original)	0,0413	0,0063	6,6	especificação-base
VI, cluster por mês	0,0413	0,0226	1,8	choque comum do mês
VI, cluster <i>two-way</i>	0,0413	0,0220	1,9	idem
VI + efeito de tempo δ_t	0,0409	0,0059	6,9	corrige a causa
FE de fundo + VI	0,1853	0,0194	9,5	dentro do fundo
VI, instrumento d_{t-2}	0,0210	0,0049	4,3	robustez
VI, horizonte 3 meses	0,0858	0,0114	7,5	robustez
Arellano–Bond, instr. completos	0,2923	0,0431	6,8	Sargan não-informativo
Arellano–Bond, instr. colapsados	−0,3312	0,0535	−6,2	sinal instável




Figura 2: Velocidade de ajuste $\hat{\lambda}$ por especificação (azul: sinal positivo robusto; cinza: MQO enviesado, referência; vermelho: Arellano–Bond, sinal instável). Mesma Figura 2, Seção 4.6, do `tcc I.pdf`.

Olhando a tabela cheia, duas linhas de robustez merecem nota rápida: o instrumento mais defasado (d_{t-2} em vez de d_{t-1}) dá $\lambda = 0,021$, menor ainda que a especificação central — esperado, porque uma pista mais antiga carrega menos informação sobre o ajuste recente. O horizonte de 3 meses dá $\lambda = 0,086$, maior — também esperado, porque a variação de peso ao longo de 3 meses acumula mais ajuste do que a variação de 1 mês.

11 Como interpretar os números

11.1 Da fração para algo intuitivo: a meia-vida

A pergunta: “ $\lambda = 0,041$ ” é difícil de sentir no dia a dia. Como traduzir?

Pergunte: quantos meses até o fundo fechar **metade** da distância original?

$$h_{1/2} = \frac{\ln(0,5)}{\ln(1 - \lambda)}$$

Com $\lambda = 0,041$: cerca de **16 meses e meio**. Com $\lambda = 0,185$ (efeito-fixo): cerca de **3,4 meses**.

É bem mais fácil comunicar assim: “um fundo típico leva de 3 a 16 meses para fechar metade do desvio, dependendo de qual parte da heterogeneidade entre fundos você está olhando”. (*Este cálculo específico não aparece no tcc I.pdf; está detalhado no tudo explicado.pdf, Seção “O modelo de ajuste parcial”.*)

11.2 Significativo não é o mesmo que importante

A estatística t responde só: “dá para descartar que λ é zero?”. Não diz nada sobre o **tamanho** do efeito. É possível (e é o que acontece aqui) ter um λ estatisticamente muito confiável e, ao mesmo tempo, pequeno demais para ser útil na prática.

11.3 O teste de Diebold–Mariano: a vitória do ajuste parcial é real, ou é sorte?

A pergunta: Você viu que o ajuste parcial dá um erro de previsão um pouco menor que a previsão ingênua (0,0216 contra 0,0220, no horizonte de três meses). Isso prova que ele é melhor, ou pode ser só coincidência daquela amostra específica?

Pensa assim: Imagine dois jogadores de dardo, cada um jogando 10 vezes. Um acerta, em média, 2mm mais perto do centro que o outro. Isso prova que ele é o jogador melhor, ou pode ser coincidência de só 10 arremessos, onde um teve alguns acertos de sorte? Você precisa de um teste estatístico formal para separar “diferença real” de “ruído de amostra pequena”.

Como o teste funciona

Para cada “origem” de previsão (cada mês em que você reestima tudo e prevê o mês seguinte), calcula-se a diferença entre o erro ao quadrado da previsão ingênua e o erro ao quadrado do ajuste parcial, $\delta_\tau = e_{\text{ingênua},\tau}^2 - e_{\text{ajuste},\tau}^2$. A estatística do teste é essa diferença média dividida pelo seu próprio erro-padrão de longo prazo (de novo, Newey–West, o mesmo princípio da Seção 5 — os δ_τ de origens vizinhas também podem estar correlacionados):

$$t_{DM} = \frac{\bar{\delta}}{\sqrt{\widehat{\text{Var}}_{NW}(\bar{\delta})}}$$

Se essa diferença for, **em média**, positiva — e grande o suficiente em relação a quanto ela varia de origem para origem (ou seja, $|t_{DM}| > 1,96$ a 5%) —, você pode dizer que a vitória é estatisticamente real, não apenas sorte daquela amostra.

Horizonte	RMSE ingênua	RMSE λ MQO	RMSE λ VI	t_{DM} (MQO)	t_{DM} (VI)
$h = 1$ (um mês)	0,0164	0,0161	0,0162	1,78	2,04
$h = 3$ (opacidade)	0,0220	0,0218	0,0216	0,04	0,92

Mesma Tabela 9, Seção 4.7.1, do tcc I.pdf. Repare no padrão: em $h = 1$, t_{DM} passa de 1,96 com a versão VI (2,04), mas fica abaixo com a versão MQO (1,78) — no limiar. Em $h = 3$, o horizonte que realmente importa (por causa da opacidade de até 90 dias na divulgação de carteiras), ambos ficam bem abaixo de 1,96 (0,04 e 0,92) — a vitória do ajuste parcial nesse horizonte é pequena demais, relativo à sua própria variabilidade, para ser declarada estatisticamente real.

O resultado, honestamente

O momento "ahá": No horizonte de **um mês**, a vitória do ajuste parcial é “quase” significativa (no limiar entre 5% e 10%). No horizonte de **três meses** — que é o horizonte que *realmente importa*, por causa da defasagem de 90 dias na divulgação das carteiras —, a diferença **não é** estatisticamente distinguível de zero.

Ou seja: o ajuste parcial nunca perde da previsão ingênua em nenhum teste, e a direção do resultado é sempre a esperada — mas a vitória dele não é forte o suficiente para afirmar, com confiança estatística, que ele bate a regra simples no horizonte que a opacidade de divulgação torna relevante na prática. Essa é a correção que mais mudou a conclusão do trabalho em relação a versões anteriores: antes, o texto afirmava com mais confiança que o ajuste parcial “supera a previsão ingênua” — o teste formal mostrou que essa afirmação precisava ser mais cautelosa.

⇒ **Seção 4.7.1 “Previsão recursiva e o teste de Diebold–Mariano”, Tabela 9 do tcc I.pdf.**

12 As extensões: NEFIN, beta do fundo, e o universo multiativo

12.1 Fatores de risco do NEFIN-USP

A pergunta: O coeficiente de preço/beta de VALE3 na regressão empilhada — será que é só exposição a risco de mercado já conhecido?

O NEFIN-USP publica, prontos, os prêmios de risco do mercado brasileiro (mercado, tamanho, valor, momento) — a mesma lógica dos fatores de Fama-French, adaptada ao Brasil. Esses fatores são **diários**; a regressão do trabalho é **mensal**. Para juntar as duas frequências, usa-se o **retorno composto** dentro do mês (multiplicar 1+ retorno de cada dia, não somar) — é a forma matematicamente correta de acumular retornos percentuais ao longo de vários dias (somar diretamente subestimaria o efeito, por ignorar juros compostos dentro do mês).

Controlando por esses fatores, os coeficientes de preço e beta de VALE3 praticamente não mudam ($0,00496 \rightarrow 0,00526$; $-0,00649 \rightarrow -0,00609$) — ou seja, o que esses regressores capturam não é, em sua maior parte, exposição a risco de mercado conhecido, catalogado na literatura; é algo mais específico à posição em VALE3. A tabela completa (mesma Tabela 10, Seção 4.8, do tcc I.pdf), com e sem os quatro fatores:

Variável	Sem fatores NEFIN	Com fatores NEFIN
Preço de VALE3 por d.p.	0,00496***	0,00526***
Beta de VALE3 por d.p.	-0,00649***	-0,00609***
Mercado ($R_m - R_f$) por d.p.	—	0,00216***
Tamanho (SMB) por d.p.	—	-0,00305***
Valor (HML) por d.p.	—	-0,00035 (n.s.)
Momento (WML) por d.p.	—	0,00019 (n.s.)
R^2	0,166	0,172

O fator de mercado e o de tamanho entram significativos por conta própria (fundos com mais VALE3 também carregam, em algum grau, mais exposição a esses dois fatores conhecidos) — mas isso não “rouba” quase nada dos coeficientes de preço e beta de VALE3, que é o achado central desta tabela: o padrão capturado por preço e beta *não é*, em sua maior parte, um proxy disfarçado para risco de mercado já catalogado.

12.2 Beta do próprio fundo

Diferente do beta de VALE3 (o risco da *ação*), esse é o beta do *fundo* — calculado com a mesma metodologia (covariância do retorno da cota do fundo com o Ibovespa), mas aplicado ao retorno da cota, não da ação. Descreve o quão “parecido com o mercado de ações” é o fundo como um todo. ⇒ Seção 4.9.

12.3 O universo multiativo: o padrão de VALE3 generaliza?

A pergunta: O que encontramos para VALE3 é uma propriedade geral de como os fundos do Itaú demandam ações, ou uma particularidade daquele papel específico?

A descoberta que quase inflou o número em mais que o dobro

Para responder essa pergunta, é preciso rodar a mesma regressão transversal (Seção 4) para **outras ações**, não só VALE3. A primeira tentativa disso contou “quase 900 ações diferentes” — só que esse número estava errado, por um motivo interessante que vale a pena entender.

A pergunta: Por que “quase 900” não batia com a B3 ter só umas 350–450 empresas listadas?

Pensa assim: Imagine catalogar quantos “produtos diferentes” uma loja vende olhando cada nota fiscal separadamente, sem perceber que a mesma calça aparece três vezes no catálogo: uma vez como “venda normal”, outra como “troca”, outra como “devolução”. Você contaria três produtos onde existe, na verdade, só um — a calça.

Foi exatamente isso que aconteceu com os dados brutos da CVM: o campo que identifica o ativo não segue a regra “uma ação, uma linha”. A **mesma** ação pode aparecer em até cinco rótulos diferentes, dependendo do tipo de **custódia** da posição, não do papel em si:

- a posição **direta** (a única usada para VALE3 desde o início do projeto);
- ações **cedidas em empréstimo** (o fundo empresta a ação para outra parte, por um contrato de aluguel de ações — ele continua tendo a exposição econômica, mas a CVM registra numa linha separada);
- ações **recebidas em empréstimo** (o inverso);
- **direitos e recibos de subscrição** (o direito de comprar ações novas — um instrumento relacionado à ação, mas tecnicamente diferente dela);
- **certificados de depósito**.

Exemplo com números: VALE3, sozinha, aparecia em **três** linhas diferentes no painel bruto: a posição direta, a posição cedida em empréstimo, e a posição recebida em empréstimo — três rótulos para o que é, na prática, uma ou duas exposições reais (a direta, mais eventualmente o que foi emprestado).

Como a correção foi feita

A pergunta: Como separar “posição direta de verdade” de “a mesma ação sob outro rótulo de custódia”, sem fazer isso na mão, ativo por ativo?

A solução usou o **sufixo numérico do ticker** (o código da ação, tipo VALE3, PETR4) como critério principal — mais confiável que o texto, porque a CVM às vezes rotula uma posição de forma

incompleta (por exemplo, só “Bradesco – BBDC1”, sem dizer explicitamente “direito de subscrição”). Pela convenção da B3, o número no fim do *ticker* já denuncia o tipo: **3** (ações ordinárias), **4 a 8** (ações preferenciais e subclasses) e **11** (*units*, cotas que combinam mais de uma classe) são posições diretas padrão; **1, 2, 9, 10** e números maiores costumam ser direitos, recibos ou bônus de subscrição. Essa regra foi testada contra *tickers* conhecidos (PETR4, VALE3, VALE5, ITUB4) e contra cerca de 30 casos duvidosos, um por um, sem nenhum erro encontrado.

O momento "ahá": Do total de valores distintos de rótulo de ativo (1.217), só **464 (38%)** eram posições diretas de verdade — as outras 753 linhas eram a mesma ação sob outro rótulo de custódia, não ações adicionais.

O resultado final, depois da correção

O que	Quantidade
Rótulos distintos no painel bruto	1.217
Posições diretas de verdade (após a limpeza)	464
Ativos com amostra suficiente para a regressão (≥ 15 fundos)	375
Ativos com série completa o bastante para comparar com VALE3 (≥ 24 meses)	207

Para cada um dos 207 ativos com histórico suficiente, calcula-se a média temporal do coeficiente de cada característica, e observa-se onde VALE3 cai dentro dessa distribuição *entre ativos*:

Coeficiente	Direção de VALE3, % dos 207 igual	Posição de VALE3 entre os 207	Percentil
ln(patrimônio)	negativo, 93,7%	3º mais negativo	1,4
ln(cotistas)	positivo, 98,1%	2º mais positivo	99,5
Fundo de cotas	negativo, 88,4%	2º mais negativo	1,0
Captação/PL	majoritariamente positivo, 70,5%	comum, sem destaque	60,9

A coluna do meio (“% dos 207 igual”) é a resposta à pergunta da **direção**: para tamanho, por exemplo, 93,7% dos 207 ativos têm coeficiente negativo, igual a VALE3 — é um padrão amplamente compartilhado, não uma peculiaridade de um único papel. A coluna do percentil é a resposta à pergunta da **magnitude**: percentil 1,4 para tamanho significa que só 1,4% dos 207 ativos têm um coeficiente de tamanho mais negativo que o de VALE3 — ou seja, VALE3 está na cauda extrema, não no meio da distribuição. As **direções** dos efeitos generalizam fortemente (88% a 98% dos 207 ativos têm o mesmo sinal que VALE3 para tamanho, cotistas e FIC). Mas a **magnitude** de VALE3 é extrema em três das quatro dimensões — ela é a 2ª ou 3ª mais extrema entre os 207 ativos, tanto em tamanho quanto em cotistas quanto em FIC (só o coeficiente de fluxo é comum, percentil 60,9, sem destaque). Isso significa: o *padrão* (a direção do efeito) generaliza para qualquer ação; a *magnitude exata* encontrada para VALE3 não deve ser extrapolada como “típica” — VALE3 é um papel grande, líquido e historicamente volátil, que puxa para o extremo em quase toda dimensão medida.

⇒ **Seção 4.10 inteira, Tabela 11 e Figura 3 do tcc I.pdf.**

Um detalhe técnico da regressão que soma todos os ativos numa conta só

A Seção 4.10.3 do tcc I.pdf traz uma checagem complementar, empilhando todas as observações de todos os ativos numa única regressão, com um “efeito-fixado de ativo e de mês”. Isso é feito por uma técnica chamada **demeaning iterativo** (ou Frisch–Waugh–Lovell): em vez de criar uma coluna extra na regressão para cada um dos 444 ativos e cada um dos 72 meses (o que seria tecnicamente




Figura 3: A distribuição dos coeficientes entre os 207 ativos, com VALE3 marcado em vermelho — repare como ele fica na cauda em três dos quatro painéis.

equivalente, mas pesado demais para calcular), o método subtrai repetidamente a média de cada ativo e a média de cada mês, até os números pararem de mudar.

Pensa assim: É parecido com tirar o “sabor de cada tempero” de uma receita, subtraindo a média de cada ingrediente repetidamente, até sobrar só o “sabor combinado” que você quer estudar, sem nenhum ingrediente específico dominando a conta.

O resultado confirma os mesmos três sinais estruturais, agora numa única regressão com quase 900 mil observações.

13 Juntando tudo: a história completa, em um parágrafo

As características de um fundo (tamanho, cotistas, tipo) explicam bem o peso de VALE3 que ele carrega, com sinais estáveis por 72 meses e que generalizam para um universo amplo de outras ações (embora VALE3, em magnitude, seja um caso extremo, não típico) — isso é a Parte 1 do trabalho, resolvida com Fama–MacBeth, Newey–West e o modelo logístico, e reforçada pela margem extensiva: fundos grandes e de cotas são mais propensos a *ter* VALE3, mas carregam *menos* dela, a assinatura de diversificação. Só que essas mesmas características **não ajudam a prever** a mudança de peso de um mês para o outro — o peso se comporta quase como um passeio aleatório no curto prazo (confirmado pelo teste de Dickey–Fuller: os fatores reverterem à média, mas devagar), e nenhum dos modelos estruturais bate a simples previsão de repetir o último valor. Ainda assim, existe uma reversão real, porém lenta, ao peso que as características sugerem — o modelo de ajuste parcial mede essa velocidade, com quatro métodos diferentes que concordam no sinal (exceto o Arellano–Bond, que não se comporta bem nesse formato específico de painel) uma vez corrigido o erro-padrão pelo efeito de tempo, mas discordam bastante na magnitude, revelando que parte

dos fundos se ajusta rápido (dentro da própria trajetória) e parte carrega um desvio permanente que nunca fecha. E mesmo essa reversão, testada formalmente pelo teste de Diebold–Mariano, só bate a previsão ingênua com confiança estatística no horizonte que não é operável na prática — a história tem um final honesto, não um final triunfante.