

# Guia consolidado do projeto

Demanda institucional por ativos: o peso de VALE3 nas carteiras dos fundos do Itaú

Documento de trabalho — o que já foi feito, o que falta fazer,  
com conceitos, equações, resultados e interpretações

João Paulo Zangrandi (orientador: Prof. Maurício Ferraresi Jr.)

30 de junho de 2026

**Como ler este documento.** Este não é a monografia que vai para a banca; é um *guia de estudo* para retomar o fio do projeto. Cada parte explica o conceito em linguagem simples, mostra a equação e interpreta o resultado. As etapas estão marcadas com **[FEITO]** (já implementado e rodado em R), **[A FAZER]** (próximo passo combinado) ou **[FUTURO]** (planejado para mais adiante). Os números vêm dos scripts do repositório `forecasting-fund-weights-vale-itaú`.

## Sumário

|          |                                                                            |          |
|----------|----------------------------------------------------------------------------|----------|
| <b>1</b> | <b>O mapa do projeto em uma página</b>                                     | <b>2</b> |
| <b>2</b> | <b>Conceitos-chave, em linguagem simples</b>                               | <b>2</b> |
| <b>3</b> | <b>Os dados <b>[FEITO]</b></b>                                             | <b>4</b> |
| <b>4</b> | <b>A metodologia, com todas as equações</b>                                | <b>4</b> |
| 4.1      | Especificação de demanda . . . . .                                         | 4        |
| 4.2      | Primeiro passo: a regressão transversal (o fator latente) . . . . .        | 5        |
| 4.3      | Erros-padrão corrigidos (Newey-West) <b>[FEITO]</b> . . . . .              | 5        |
| 4.4      | Segundo passo: dinâmica do fator e previsão <b>[FEITO]</b> . . . . .       | 5        |
| 4.5      | A decisão de ter ou não a ação (margem extensiva) <b>[FEITO]</b> . . . . . | 5        |
| 4.6      | Extensão dinâmica: o modelo de ajuste parcial <b>[A FAZER]</b> . . . . .   | 5        |
| <b>5</b> | <b>Resultados já obtidos</b>                                               | <b>6</b> |
| 5.1      | Determinantes do peso, agora com Newey-West <b>[FEITO]</b> . . . . .       | 6        |
| 5.2      | Forma logística (resposta fracionária) <b>[FEITO]</b> . . . . .            | 7        |
| 5.3      | Versão com preço e beta (dados empilhados) <b>[FEITO]</b> . . . . .        | 7        |
| 5.4      | Dinâmica do fator $\theta_t$ <b>[FEITO]</b> . . . . .                      | 8        |
| 5.5      | Previsão e a matriz de erros <b>[FEITO]</b> . . . . .                      | 8        |
| 5.6      | As duas margens <b>[FEITO]</b> . . . . .                                   | 9        |
| 5.7      | Ajuste parcial: estimando a velocidade $\lambda$ <b>[FEITO]</b> . . . . .  | 9        |

|   |                                    |    |
|---|------------------------------------|----|
| 6 | Agenda: o que falta, passo a passo | 10 |
| 7 | Síntese                            | 10 |
|   | Referências                        | 11 |

## 1 O mapa do projeto em uma página

**A pergunta.** Quando um fundo de investimento monta a carteira, ele decide *quanto* de cada ação vai carregar. Esse “quanto”, medido como **peso** (a fração da carteira na ação, um número entre 0 e 1), é uma medida de **demanda**. A pergunta do projeto é dupla:

1. **Explicação:** quais *características* de um fundo (tamanho, número de cotistas, tipo de fundo, fluxo de dinheiro) explicam o peso que ele dá a uma ação?
2. **Previsão:** esse peso pode ser *previsto* de um mês para o outro?

**O caso concreto.** Para tornar o problema tratável, fixamos uma ação, **VALE3** (posição direta), e uma gestora, o grupo **Itaú** (Asset, DTVM e Unibanco), no período **2016–2021** (72 meses). Estuda-se como o peso de VALE3 varia entre os fundos do Itaú e ao longo do tempo.

**A estratégia (em dois passos).** (i) A cada mês, regredimos o peso da ação nas características dos fundos; os coeficientes dessa regressão resumem “como as posições dependem das características” — são um **fator latente**  $\theta_t$ . (ii) Deixamos esse fator *variar no tempo* e tentamos prever o peso, comparando com a **previsão ingênua** (repetir o último peso).

**O que já sabemos.** As características *explicam bem* o peso (sinais estáveis nos 72 meses), mas *não conseguem prevê-lo* melhor do que simplesmente repetir o último valor: no nível do fundo, o peso é quase um **passeio aleatório**. Esse contraste é o eixo do trabalho.

**Para onde vamos.** A agenda combinada com o orientador refina a parte de modelagem em quatro frentes: padronização e **erros-padrão Newey-West** (passo 1, já feito); forma funcional **logística** para o peso (passo 2); o **modelo de ajuste parcial** com estimação por **variável instrumental** (passo 3); e, mais à frente, **regularização (ridge)** para a estimação dos fatores em alta dimensão (passo futuro).

## 2 Conceitos-chave, em linguagem simples

**Sistema de demanda (Koijen e Yogo, 2019).** É a ideia de tratar os preços dos ativos como o resultado das *demandas* de muitos investidores, e cada demanda é uma função das *características* dos ativos. A vantagem é trocar um problema gigante (milhares de ativos e investidores) por um número pequeno de parâmetros ligados a características. *Como nos afastamos disso:* aqui o ativo é **fixo** (VALE3) e quem varia são as características do *fundo*; estimamos a forma reduzida “pelas quantidades” (o peso), sem modelar o canal preço-demanda.

**Características do fundo e fatores latentes da ação.** Chamamos de  $x_i$  o vetor de características do fundo  $i$  (tamanho, cotistas etc.) — o “perfil” do fundo. Chamamos de  $\theta_n$  o vetor de *fatores latentes* da ação  $n$  — o quanto cada característica “puxa” a posição naquela ação. O peso desejado é, então, o produto  $x_i'\theta_n$ : o perfil do fundo vezes a sensibilidade da ação a cada traço do perfil.

**Seção transversal (cross-section) e Fama-MacBeth (1973).** “Seção transversal” é uma fotografia de um mês: todos os fundos ao mesmo tempo. Rodamos uma regressão por mês  $\rightarrow$  72 conjuntos de coeficientes. Fama-MacBeth é a receita de resumir essas 72 fotos: tira-se a *média* de cada coeficiente no tempo e mede-se a incerteza pela *variação* dele entre os meses.

**Autocorrelação e erros-padrão Newey-West.** Os 72 coeficientes mensais não são independentes: o de um mês se parece com o do mês anterior (autocorrelação de  $\approx 0,7$  a  $0,8$ ). O erro-padrão clássico de Fama-MacBeth *supõe independência* e, por isso, *subestima* a incerteza e *infla* as estatísticas  $t$ . O estimador de **Newey-West** corrige isso somando as autocovariâncias (com pesos decrescentes) — dá erros-padrão maiores e  $t$  menores, porém honestos.

**Resposta fracionária / ligação logística.** O peso vive em  $[0, 1]$ . Uma regressão linear pode prever valores negativos ou acima de 1, o que não faz sentido. A *função logística*  $g(z) = 1/(1 + e^{-z})$  espreme qualquer número para dentro de  $(0, 1)$ , respeitando o limite. É a forma funcional correta para uma fração (Papke e Wooldridge, 1996).

**Ajuste parcial.** A ideia de que o fundo não pula de uma vez para o peso desejado, mas se move só *parte* do caminho a cada mês, a uma velocidade  $\lambda$ . Se  $\lambda = 1$ , ajusta tudo na hora; se  $\lambda = 0$ , não ajusta nada (o peso fica “preso” no valor de ontem — que é justamente a previsão ingênua).

**Viés de atenuação e variável instrumental.** Quando um regressor é *medido com erro* (no nosso caso, a “distância ao alvo” é construída a partir de coeficientes *estimados*), o mínimos quadrados puxa o coeficiente *para zero* — isso é o **viés de atenuação**. Como o teste central é justamente “ $\lambda$  é diferente de zero?”, um método que empurra para zero atrapalha. A **variável instrumental** (ou correção de erros nas variáveis) conserta isso usando uma fonte de variação “limpa” do regressor.

**Por que ridge agora não, mas no futuro sim.** A *regularização ridge* encolhe coeficientes em direção a zero para estabilizá-los. Isso é *ruim* para estimar  $\lambda$  (agravaria a atenuação contra a hipótese de interesse), mas é *bom* para o primeiro passo quando o número de características crescer ou quando escalarmos para muitas ações: ali os regressores são *observados* (sem erro de medida) e o objetivo é estabilizar, não testar se algo é zero. Por isso o ridge é um **passo**

futuro, não descartado.

### 3 Os dados [FEITO]

Duas bases da Comissão de Valores Mobiliários e uma fonte de mercado:

- **Composição consolidada** (mensal): o peso de VALE3 (posição direta) em cada fundo.
- **Série histórica** (diária): patrimônio líquido, número de cotistas, e se o fundo é um **fundo de cotas** (FIC, que investe em outros fundos em vez de ações diretamente).
- **Informe Diário** (diário): captação e resgate → **fluxo líquido**.
- **Mercado**: preço e **beta** de VALE3 (beta = sensibilidade da ação ao Ibovespa, em janela de 252 pregões).

**Tratamentos.** Padronização do nome da gestora; remoção de linhas duplicadas e de pesos negativos (resíduos contábeis); exclusão de fundos exclusivos (mantendo só  $> 3$  cotistas); junção das bases pelo dia exato da competência. A captação foi validada contra a série histórica ( $> 99\%$  de coincidência ao centavo) e o preço contra o fechamento oficial da bolsa.

**Amostra.** 72 meses (2016–2021), grupo Itaú. Painel completo de quem detém a ação: 26.123 observações de fundo-mês, 623 fundos. Amostra de regressão (com  $> 3$  cotistas e fluxo): **11.413 observações, 307 fundos**, das quais  $\approx 76\%$  são fundos de cotas.

Tabela 1: Estatísticas descritivas da amostra de regressão.

| Variável                    | Média  | Desvio-padrão | Mediana | Mínimo | Máximo  |
|-----------------------------|--------|---------------|---------|--------|---------|
| Peso de VALE3 (%)           | 2,87   | 3,52          | 1,22    | 0,00   | 23,55   |
| Patrimônio líquido (R\$ mi) | 399    | 1.079         | 68,3    | 0,04   | 17.866  |
| Número de cotistas          | 10.202 | 72.039        | 105     | 4      | 696.013 |
| Captação líquida (R\$ mi)   | 5,7    | 74,1          | 0,0     | −1.522 | 1.636   |
| Preço de VALE3 (R\$)        | 54,6   | 27,2          | 50,9    | 9,94   | 114,1   |
| Beta de VALE3               | 1,04   | 0,30          | 0,97    | 0,68   | 1,73    |

Patrimônio e cotistas são muito assimétricos (média  $\gg$  mediana)  $\Rightarrow$  usamos o logaritmo. Preço e beta têm correlação de  $\approx -0,71$  (na alta de 2016–2021 o preço subiu e o beta caiu), o que dificulta separar os dois efeitos mais adiante.

## 4 A metodologia, com todas as equações

### 4.1 Especificação de demanda

O peso observado é um peso desejado mais um erro. Como o peso é uma fração, o peso desejado passa por uma ligação logística:

$$w_{i,t} = g(x'_{i,t} \theta_{n,t}) + \varepsilon_{i,t}^w, \quad g(z) = \frac{1}{1 + e^{-z}}, \quad (1)$$

em que  $x_{i,t}$  são as características do fundo e  $\theta_{n,t}$  os fatores latentes da ação. A versão *linear* ( $g(z) \approx z$ ) é usada como aproximação no passo transversal; a logística plena entra na decisão de posse e no modelo de ajuste parcial.

## 4.2 Primeiro passo: a regressão transversal (o fator latente)

Em cada mês  $t$ , com os fundos empilhados, estimamos por mínimos quadrados

$$\hat{\theta}_{n,t} = (X_t' X_t)^{-1} X_t' w_t, \quad (2)$$

ou seja, mês a mês rodamos

$$w_{i,t} = \alpha_t + \beta_t^1 z(\ln \text{PL})_{i,t} + \beta_t^2 z(\ln \text{Cot})_{i,t} + \beta_t^3 \text{FIC}_i + \beta_t^4 \left( \frac{\text{Fluxo}}{\text{PL}} \right)_{i,t} + \varepsilon_{i,t}. \quad (3)$$

As características de escala  $\ln \text{PL}$  e  $\ln \text{Cot}$  entram **padronizadas** ( $z(\cdot)$ : centradas e divididas pelo desvio-padrão), de modo que o coeficiente é o efeito de *um desvio-padrão*; FIC fica em 0/1 e o intercepto recupera o nível médio do peso. O resumo Fama-MacBeth toma a média no tempo,

$$\bar{\beta}_k = \frac{1}{T} \sum_{t=1}^T \beta_{k,t}, \quad T = 72. \quad (4)$$

## 4.3 Erros-padrão corrigidos (Newey-West) **[FEITO]**

Como os  $\beta_{k,t}$  são autocorrelacionados, a variância da média é estimada por

$$\widehat{\text{Var}}_{\text{NW}}(\bar{\beta}_k) = \frac{1}{T^2} \left[ \sum_{t=1}^T \hat{u}_{k,t}^2 + 2 \sum_{\ell=1}^L \left( 1 - \frac{\ell}{L+1} \right) \sum_{t=\ell+1}^T \hat{u}_{k,t} \hat{u}_{k,t-\ell} \right], \quad \hat{u}_{k,t} = \beta_{k,t} - \bar{\beta}_k, \quad (5)$$

com  $L = 3$  (regra  $L = \lfloor 4(T/100)^{2/9} \rfloor$  para  $T = 72$ ). Os resultados estão na Seção 5.

## 4.4 Segundo passo: dinâmica do fator e previsão **[FEITO]**

Cada coeficiente  $\theta_{k,t}$  é tratado como série temporal (passeio aleatório, AR(1) ou filtro de Kalman). A previsão do peso é  $\hat{w}_{i,t} = g(\hat{\theta}_t' x_{i,t})$ , comparada à ingênua  $\hat{w}_{i,t} = w_{i,t-1}$ . Avaliamos fora da amostra a 1 e a 3 meses (este último por causa da **opacidade**: as carteiras só são divulgadas com  $\approx 90$  dias de atraso).

## 4.5 A decisão de ter ou não a ação (margem extensiva) **[FEITO]**

Além de “quanto” (margem intensiva), estudamos “ter ou não” (margem extensiva) com um painel que inclui os zeros e uma regressão logística da probabilidade de o fundo deter VALE3.

## 4.6 Extensão dinâmica: o modelo de ajuste parcial **[A FAZER]**

O fundo move o peso parcialmente em direção ao desejado, à velocidade  $\lambda_n \in (0, 1)$ :

$$w_{i,t+1} = (1 - \lambda_n) w_{i,t} + \lambda_n w_{i,t}^* + u_{i,t+1}. \quad (6)$$

Definindo a distância ao alvo  $d_{i,t} \equiv w_{i,t}^* - w_{i,t}$ , isso vira

$$w_{i,t+1} - w_{i,t} = \lambda_n d_{i,t} + u_{i,t+1}. \quad (7)$$

A estimativa direta por mínimos quadrados,  $\hat{\lambda}_n^{\text{MQO}} = (d_n' d_n)^{-1} d_n' (\Delta w)$ , sofre **viés de atenuação**, porque  $d_{i,t} = g(x_{i,t}' \hat{\theta}_n) - w_{i,t}$  usa  $\hat{\theta}_n$  estimado (erro de medida). Por isso  $\lambda$  será estimado por **variável instrumental** / **correção de erros nas variáveis**, e *não* por ridge. O erro de previsão correspondente é

$$\hat{u}_{n,t+1} = (w_{n,t+1} - w_{n,t}) - \hat{\lambda}_n (g(X_t \hat{\theta}_n) - w_{n,t}). \quad (8)$$

## 5 Resultados já obtidos

### 5.1 Determinantes do peso, agora com Newey-West **[FEITO]**

A Tabela 2 traz a regressão mês a mês resumida à Fama-MacBeth, com os dois erros-padrão lado a lado. **Leitura dos sinais:** fundos maiores carregam *menos* VALE3 em peso; fundos com mais cotistas carregam *mais*; fundos de cotas têm posição direta *menor*; a captação do mês não explica o nível do peso. Esses sinais se repetem nos 72 meses.

Tabela 2: Cross-section mês a mês (Fama-MacBeth,  $T = 72$ ). Erros-padrão clássico vs. Newey-West ( $L = 3$ ). Coeficientes não-padronizados (por unidade de log).

| Variável              | Coef. médio | EP clássico | $t$ clássico | EP Newey-West | $t$ Newey-West |
|-----------------------|-------------|-------------|--------------|---------------|----------------|
| Intercepto            | 0,08939     | 0,00413     | 21,6         | 0,00718       | 12,5           |
| ln(patrimônio)        | -0,00376    | 0,00020     | -19,3        | 0,00034       | -11,2          |
| ln(cotistas)          | 0,00387     | 0,00020     | 19,8         | 0,00035       | 10,9           |
| Fundo de cotas        | -0,01697    | 0,00089     | -19,2        | 0,00151       | -11,3          |
| Captação / patrimônio | -0,00044    | 0,00309     | -0,14        | 0,00412       | -0,11          |

$R^2$  médio por mês = 0,152. A correção de Newey-West amplia os erros-padrão em  $\approx 1,7$ - $1,8\times$ . Fonte: R/24\_fm\_neweywest.R.

**O que a correção muda (e o que não muda).** O Newey-West **não altera os sinais nem a significância qualitativa**: as características de fundo seguem com  $p < 0,001$  e a captação segue não significativa. O que muda é a *magnitude* das estatísticas: os  $t$  caem de  $\approx 19$ - $22$  (clássico) para  $\approx 11$ - $12,5$  (Newey-West). *Observação honesta*: a versão preliminar do texto mencionava  $t$  “em torno de 19 a 22” após a correção, mas esses eram os valores *clássicos*; os corrigidos, calculados aqui, são  $\approx 11$ - $12,5$  — ainda fortemente significativos.

**Magnitudes por desvio-padrão (versão padronizada).** Padronizando lnPL e lnCot, o intercepto vira **0,0396** ( $\approx 3,96\%$ ), que é o nível médio do peso de um fundo não-FIC de tamanho médio. Os efeitos por *um* desvio-padrão são:

| Característica | Coef. por desvio-padrão | Leitura                                  |
|----------------|-------------------------|------------------------------------------|
| ln(patrimônio) | −0,00681                | +1 d.p. de tamanho → −0,68 p.p. de peso  |
| ln(cotistas)   | +0,01087                | +1 d.p. de cotistas → +1,09 p.p. de peso |
| Fundo de cotas | −0,01697                | ser FIC → −1,70 p.p. de peso             |

*Observação honesta:* os “−0,38 / +0,39 p.p.” citados na versão preliminar eram os coeficientes em log *cru* lidos como se fossem por desvio-padrão. Os verdadeiros efeitos por desvio-padrão são maiores, e o de *cotistas* (+1,09) supera o de *tamanho* (−0,68) — não são “semelhantes”. Isso reforça que dispersão de cotistas é o traço mais associado a peso direto maior.

## 5.2 Forma logística (resposta fracionária) [FEITO]

Reestimamos a mesma cross-section, agora com a ligação logística da (1) (em R, `glm` família `quasibinomial`), mês a mês. A Tabela 3 traz os coeficientes no resumo Fama-MacBeth com Newey-West.

Tabela 3: Cross-section logística (resposta fracionária), Fama-MacBeth + Newey-West. Coeficientes na escala de *log-odds*; características de escala padronizadas.

| Variável              | Coef. (log-odds) | EP Newey-West | <i>t</i> Newey-West | Meses com sinal + |
|-----------------------|------------------|---------------|---------------------|-------------------|
| Intercepto            | −3,380           | 0,150         | −22,5               | 0/72              |
| ln(patrimônio) [d.p.] | −0,339           | 0,043         | −7,9                | 0/72              |
| ln(cotistas) [d.p.]   | +0,469           | 0,035         | 13,3                | 72/72             |
| Fundo de cotas        | −0,732           | 0,062         | −11,7               | 0/72              |
| Captação / patrimônio | +0,078           | 0,183         | 0,43                | 37/72             |

Fonte: R/25\_fractional\_logit.R.

Três pontos resumem o passo:

1. **Sinais e significância são idênticos ao linear:** patrimônio e FIC negativos, cotistas positivo, captação não significativa, todos estáveis nos 72 meses.
2. **As magnitudes coincidem no centro.** O coeficiente de *log-odds* não é comparável direto ao linear, mas o **efeito parcial médio** (a derivada média de  $g$ , em pontos de peso) é: dá −0,68 p.p. (patrimônio), +1,06 p.p. (cotistas) e −1,60 p.p. (FIC), praticamente iguais aos coeficientes lineares (−0,68, +1,09, −1,70). Ou seja, *a linear era uma boa aproximação no centro* — a conclusão econômica não muda.
3. **O ganho do logit é respeitar o suporte.** O modelo linear gera previsões *fora* de  $[0, 1]$  em 287 de 11.413 casos (2,51%) — pesos negativos, sem sentido; o logit, por construção, nunca. O ajuste também melhora de leve (pseudo- $R^2$  0,165 vs 0,152). Isso é exatamente o que o orientador antecipou, e é **pré-requisito do passo 3**, em que o peso desejado  $w^* = g(x'\theta)$  precisa estar em  $[0, 1]$ .

## 5.3 Versão com preço e beta (dados empilhados) [FEITO]

Empilhando os 72 meses e acrescentando preço e beta (média do mês), os sinais de fundo se mantêm. Preço entra positivo (parte é *mecânica*: se a ação sobe, sua fração cresce sozinha); beta entra negativo (aversão a risco), mas com a ressalva da colinearidade preço-beta (−0,71): parte do

coeficiente do beta pode estar capturando o resíduo mecânico do preço.  $R^2 = 0,166$  (quase igual ao 0,152 sem preço/beta  $\Rightarrow$  as características de fundo já carregam a maior parte da informação).

Tabela 4: Regressão com todos os meses empilhados, incluindo preço e beta (11.413 observações).

| Variável                 | Estimativa | Erro padrão | $t$   | Sig. |
|--------------------------|------------|-------------|-------|------|
| Intercepto               | 0,09937    | 0,00406     | 24,5  | ***  |
| $\ln(\text{patrimônio})$ | -0,00354   | 0,00019     | -19,0 | ***  |
| $\ln(\text{cotistas})$   | 0,00388    | 0,00013     | 30,9  | ***  |
| Fundo de cotas           | -0,01682   | 0,00079     | -21,3 | ***  |
| Captação / patrimônio    | -0,00030   | 0,00034     | -0,91 | n.s. |
| Preço de VALE3           | 0,000182   | 0,000016    | 11,5  | ***  |
| Beta de VALE3            | -0,02141   | 0,00142     | -15,1 | ***  |

## 5.4 Dinâmica do fator $\theta_t$ [FEITO]

Os coeficientes são persistentes mas *revertem à média* (autocorrelação  $\approx 0,7$ – $0,8$ ; o teste de raiz unitária rejeita passeio aleatório puro). Logo, vale modelá-los por AR(1)/Kalman. A Figura 1 mostra os cinco coeficientes; note a reconfiguração comum em torno de 2018 em vários painéis.




Figura 1: Coeficientes da regressão mês a mês (2016–2021); tracejado = média de cada série.

## 5.5 Previsão e a matriz de erros [FEITO]

Fora da amostra, **nenhum** modelo estrutural supera a previsão ingênua (Tabela 5). O efeito-fixo (média histórica) perde para o último valor  $\Rightarrow$  o peso *não* reverte a uma média de fundo; é quase um passeio aleatório. A 3 meses a ingênua piora, mas ainda vence.

Tabela 5: Erro de previsão fora da amostra (raiz do erro quadrático médio), por horizonte.

| Universo           | Horizonte | Ingênua | Nível do fundo | Fator (Kalman) | Variação do peso |
|--------------------|-----------|---------|----------------|----------------|------------------|
| Todos os fundos    | 1 mês     | 0,0156  | 0,0240         | 0,0255         | 0,0156           |
| Todos os fundos    | 3 meses   | 0,0207  | 0,0262         | 0,0273         | 0,0210           |
| Só fundos de ações | 1 mês     | 0,0197  | 0,0310         | 0,0383         | 0,0198           |
| Só fundos de ações | 3 meses   | 0,0266  | 0,0337         | 0,0385         | 0,0270           |

## 5.6 As duas margens [FEITO]

Fundos maiores e fundos de cotas são *mais propensos a ter* VALE3, mas com peso *menor* quando a têm — sinais opostos entre a margem extensiva (ter) e a intensiva (quanto), padrão de diversificação. A posse também é muito persistente, e de novo a ingênua bate o modelo.

## 5.7 Ajuste parcial: estimando a velocidade $\lambda$ [FEITO]

Este é o passo dinâmico central. Construimos o peso desejado  $w_{i,t}^* = g(x'_{i,t}\hat{\theta}_t)$  (o ajustado do logit do passo 2), a distância  $d_{i,t} = w_{i,t}^* - w_{i,t}$ , e estimamos a (7) por mínimos quadrados (MQO) e por variável instrumental (VI), usando a distância defasada  $d_{i,t-1}$  como instrumento. O instrumento é fortíssimo (primeiro estágio  $d_t \sim d_{t-1}$ : coeficiente 0,895,  $F \approx 39.800$ ).

Tabela 6: Velocidade de ajuste  $\lambda$  na equação  $\Delta w_{i,t+1} = \lambda d_{i,t} + u$ . Erro-padrão agrupado por fundo.  $N = 10.570$  fundo-meses, 295 fundos, 70 meses.

| Estimador                     | $\hat{\lambda}$ | Erro padrão | $t$  | $p$     |
|-------------------------------|-----------------|-------------|------|---------|
| MQO (enviesado)               | 0,0976          | 0,0096      | 10,2 | < 0,001 |
| VI (instrumento $d_{i,t-1}$ ) | 0,0413          | 0,0063      | 6,6  | < 0,001 |

Fonte: R/26\_partial\_adjustment.R.

Três leituras, todas importantes:

1. **O viés do MQO foi para cima, não para baixo.** O orientador antecipou *atenuação* (MQO puxado para zero) por causa do  $\hat{\theta}_t$  estimado. Mas há um segundo viés: como  $w_{i,t}$  aparece em  $d_{i,t}$  e em  $\Delta w_{i,t+1}$ , o ruído transitório do peso cria uma **reversão à média mecânica** que puxa o MQO *para cima*. Aqui o efeito mecânico dominou (0,098 no MQO vs 0,041 na VI). O instrumento  $d_{i,t-1}$  corrige os *dois* vieses de uma vez, porque não compartilha  $w_{i,t}$  com o lado esquerdo nem o erro de estimação de  $\hat{\theta}_t$ ; por isso 0,041 é a estimativa limpa, qualquer que fosse o viés dominante.
2.  **$\lambda$  é diferente de zero, mas minúsculo.** A VI dá  $\hat{\lambda} = 0,041$  ( $t = 6,6$ ,  $p < 0,001$ ): o fundo fecha só  $\approx 4\%$  da distância ao alvo por mês, uma **meia-vida de  $\approx 16$  meses**. O ajuste existe, mas é lentíssimo.
3. **Isso reconcilia toda a história.** Como  $\lambda$  é próximo de zero, mês a mês o peso quase não se move em direção ao alvo — por isso a previsão ingênua vence em  $h = 1$  (Tabela 5). Mas  $\lambda \neq 0$  mostra que *existe* uma reversão real, porém lenta, ao alvo estrutural definido pelas características. O modelo de fator não é vazio: ele descreve a **âncora de longo prazo** do peso, não o seu movimento de curto prazo.

*Hipótese de identificação:* a VI supõe que  $d_{i,t-1}$  não se correlaciona com a inovação  $u_{i,t+1}$ , o que vale se o ruído transitório do peso não for serialmente correlacionado ao longo do intervalo  $t-1 \rightarrow t+1$ . Robustez futura: efeito-fixo de fundo, instrumento alternativo (características exógenas), e a versão a três meses (opacidade).

## 6 Agenda: o que falta, passo a passo

**Passo 1 — padronização + Newey-West.** [FEITO] Feito nesta rodada (Seção 5, script R/24). Resultado: a inferência fica mais honesta; conclusões qualitativas intactas; magnitudes por desvio-padrão corrigidas.

**Passo 2 — regressão logística (resposta fracionária) do peso.** [FEITO] Feito nesta rodada (Seção 5, script R/25). Confirmado: sinais e significância iguais ao linear; efeitos parciais médios praticamente idênticos (o linear era boa aproximação no centro); mas o linear viola  $[0, 1]$  em 2,51% dos casos enquanto o logit não, o que o torna a forma correta e habilita o passo 3.

**Passo 3 — modelo de ajuste parcial via variável instrumental.** [FEITO] Feito nesta rodada (Seção 5, script R/26). Resultado:  $\hat{\lambda}_{VI} = 0,041$ , diferente de zero ( $t = 6,6$ ) mas minúsculo (meia-vida  $\approx 16$  meses). O viés do MQO foi para *cima* (reversão mecânica dominou a atenuação); a VI com  $d_{t-1}$  corrige ambos. Conclusão: há reversão lenta e real ao alvo estrutural, coerente com o peso ser quase um passeio aleatório no curto prazo.

**Passo futuro — ridge na estimação dos fatores.** [FUTURO] Quando o número de características crescer ou ao escalar para muitas ações, usar **regularização ridge** no primeiro passo (estimação dos  $\theta$ ), onde ela é apropriada (regressores observados, objetivo de estabilizar). Não confundir com o passo 3, em que ridge seria inadequado.

**Higiene complementar.** [FUTURO] Tratar as caudas extremas de fluxo/patrimônio (*win-sorização*); decompor o peso em parte mecânica (preço) e ativa (decisão); modelo em duas partes para as margens; estender a outras ações e gestoras.

## 7 Síntese

O projeto tem hoje uma resposta sólida para a **explicação**: o peso de VALE3 nos fundos do Itaú depende, de forma estável, de tamanho, cotistas, tipo de fundo e beta. Para a **previsão**, a inércia do próprio fundo é um teto difícil: o peso é quase um passeio aleatório, e nenhum modelo estrutural a supera no curto prazo. Os três primeiros passos da agenda estão feitos: a inferência ficou mais honesta (Newey-West), a forma funcional virou logística (respeitando o suporte), e o modelo de ajuste parcial foi estimado por variável instrumental. O veredito do passo 3 amarra tudo: a velocidade de ajuste  $\lambda = 0,041$  é estatisticamente diferente de zero, mas tão pequena (meia-vida  $\approx 16$  meses) que, no curto prazo, repetir o último peso continua sendo a melhor previsão. Em uma frase: as características definem *para onde* o peso tende no longo prazo, mas o fundo caminha até lá tão devagar que, mês a mês, o peso parece um passeio aleatório.

## Referências

- Fama, E. F.; MacBeth, J. D. Risk, return, and equilibrium: empirical tests. *Journal of Political Economy*, 81(3):607–636, 1973.
- Gabaix, X.; Koijen, R. S. J. In search of the origins of financial fluctuations: the inelastic markets hypothesis. *NBER Working Paper* 28967, 2021.
- Harvey, A. C. *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge University Press, 1989.
- Hoerl, A. E.; Kennard, R. W. Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67, 1970.
- Koijen, R. S. J.; Yogo, M. A demand system approach to asset pricing. *Journal of Political Economy*, 127(4):1475–1515, 2019.
- Newey, W. K.; West, K. D. A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3):703–708, 1987.
- Papke, L. E.; Wooldridge, J. M. Econometric methods for fractional response variables with an application to 401(k) plan participation rates. *Journal of Applied Econometrics*, 11(6):619–632, 1996.