

Guia consolidado do projeto

Demanda institucional por ativos: o peso de VALE3 nas carteiras dos fundos do Itaú

Documento de trabalho — o que já foi feito, o que falta fazer,
com conceitos, equações, resultados e interpretações

João Paulo Zangrandi (orientador: Prof. Maurício Ferraresi Jr.)

30 de junho de 2026

Como ler este documento. Este não é a monografia que vai para a banca; é um *guia de estudo* para retomar o fio do projeto. Cada parte explica o conceito em linguagem simples, mostra a equação e interpreta o resultado. As etapas estão marcadas com **[FEITO]** (já implementado e rodado em R), **[A FAZER]** (próximo passo combinado) ou **[FUTURO]** (planejado para mais adiante). Os números vêm dos scripts do repositório `forecasting-fund-weights-vale-itaú`.

Sumário

1	O mapa do projeto em uma página	2
2	Conceitos-chave, em linguagem simples	2
3	Os dados [FEITO]	4
4	A metodologia, com todas as equações	4
4.1	Especificação de demanda	4
4.2	Primeiro passo: a regressão transversal (o fator latente)	5
4.3	Erros-padrão corrigidos (Newey-West) [FEITO]	5
4.4	Segundo passo: dinâmica do fator e previsão [FEITO]	5
4.5	A decisão de ter ou não a ação (margem extensiva) [FEITO]	5
4.6	Extensão dinâmica: o modelo de ajuste parcial [A FAZER]	5
5	Resultados já obtidos	6
5.1	Determinantes do peso, agora com Newey-West [FEITO]	6
5.2	Versão com preço e beta (dados empilhados) [FEITO]	7
5.3	Dinâmica do fator θ_t [FEITO]	7
5.4	Previsão e a matriz de erros [FEITO]	7
5.5	As duas margens [FEITO]	8
6	Agenda: o que falta, passo a passo	8

1 O mapa do projeto em uma página

A pergunta. Quando um fundo de investimento monta a carteira, ele decide *quanto* de cada ação vai carregar. Esse “quanto”, medido como **peso** (a fração da carteira na ação, um número entre 0 e 1), é uma medida de **demanda**. A pergunta do projeto é dupla:

1. **Explicação:** quais *características* de um fundo (tamanho, número de cotistas, tipo de fundo, fluxo de dinheiro) explicam o peso que ele dá a uma ação?
2. **Previsão:** esse peso pode ser *previsto* de um mês para o outro?

O caso concreto. Para tornar o problema tratável, fixamos uma ação, **VALE3** (posição direta), e uma gestora, o grupo **Itaú** (Asset, DTVM e Unibanco), no período **2016–2021** (72 meses). Estuda-se como o peso de VALE3 varia entre os fundos do Itaú e ao longo do tempo.

A estratégia (em dois passos). (i) A cada mês, regredimos o peso da ação nas características dos fundos; os coeficientes dessa regressão resumem “como as posições dependem das características” — são um **fator latente** θ_t . (ii) Deixamos esse fator *variar no tempo* e tentamos prever o peso, comparando com a **previsão ingênua** (repetir o último peso).

O que já sabemos. As características *explicam bem* o peso (sinais estáveis nos 72 meses), mas *não conseguem prevê-lo* melhor do que simplesmente repetir o último valor: no nível do fundo, o peso é quase um **passeio aleatório**. Esse contraste é o eixo do trabalho.

Para onde vamos. A agenda combinada com o orientador refina a parte de modelagem em quatro frentes: padronização e **erros-padrão Newey-West** (passo 1, já feito); forma funcional **logística** para o peso (passo 2); o **modelo de ajuste parcial** com estimação por **variável instrumental** (passo 3); e, mais à frente, **regularização (ridge)** para a estimação dos fatores em alta dimensão (passo futuro).

2 Conceitos-chave, em linguagem simples

Sistema de demanda (Koijen e Yogo, 2019). É a ideia de tratar os preços dos ativos como o resultado das *demandas* de muitos investidores, e cada demanda é uma função das *características* dos ativos. A vantagem é trocar um problema gigante (milhares de ativos e investidores) por um número pequeno de parâmetros ligados a características. *Como nos afastamos disso:* aqui o ativo é **fixo** (VALE3) e quem varia são as características do *fundo*; estimamos a forma reduzida “pelas quantidades” (o peso), sem modelar o canal preço-demanda.

Características do fundo e fatores latentes da ação. Chamamos de x_i o vetor de características do fundo i (tamanho, cotistas etc.) — o “perfil” do fundo. Chamamos de θ_n o vetor de *fatores latentes* da ação n — o quanto cada característica “puxa” a posição naquela ação. O peso desejado é, então, o produto $x_i'\theta_n$: o perfil do fundo vezes a sensibilidade da ação a cada traço do perfil.

Seção transversal (cross-section) e Fama-MacBeth (1973). “Seção transversal” é uma fotografia de um mês: todos os fundos ao mesmo tempo. Rodamos uma regressão por mês $\rightarrow$ 72 conjuntos de coeficientes. Fama-MacBeth é a receita de resumir essas 72 fotos: tira-se a *média* de cada coeficiente no tempo e mede-se a incerteza pela *variação* dele entre os meses.

Autocorrelação e erros-padrão Newey-West. Os 72 coeficientes mensais não são independentes: o de um mês se parece com o do mês anterior (autocorrelação de $\approx 0,7$ a $0,8$). O erro-padrão clássico de Fama-MacBeth *supõe independência* e, por isso, *subestima* a incerteza e *infla* as estatísticas t . O estimador de **Newey-West** corrige isso somando as autocovariâncias (com pesos decrescentes) — dá erros-padrão maiores e t menores, porém honestos.

Resposta fracionária / ligação logística. O peso vive em $[0, 1]$. Uma regressão linear pode prever valores negativos ou acima de 1, o que não faz sentido. A *função logística* $g(z) = 1/(1 + e^{-z})$ espreme qualquer número para dentro de $(0, 1)$, respeitando o limite. É a forma funcional correta para uma fração (Papke e Wooldridge, 1996).

Ajuste parcial. A ideia de que o fundo não pula de uma vez para o peso desejado, mas se move só *parte* do caminho a cada mês, a uma velocidade λ . Se $\lambda = 1$, ajusta tudo na hora; se $\lambda = 0$, não ajusta nada (o peso fica “preso” no valor de ontem — que é justamente a previsão ingênua).

Viés de atenuação e variável instrumental. Quando um regressor é *medido com erro* (no nosso caso, a “distância ao alvo” é construída a partir de coeficientes *estimados*), o mínimos quadrados puxa o coeficiente *para zero* — isso é o **viés de atenuação**. Como o teste central é justamente “ λ é diferente de zero?”, um método que empurra para zero atrapalha. A **variável instrumental** (ou correção de erros nas variáveis) conserta isso usando uma fonte de variação “limpa” do regressor.

Por que ridge agora não, mas no futuro sim. A *regularização ridge* encolhe coeficientes em direção a zero para estabilizá-los. Isso é *ruim* para estimar λ (agravaria a atenuação contra a hipótese de interesse), mas é *bom* para o primeiro passo quando o número de características crescer ou quando escalarmos para muitas ações: ali os regressores são *observados* (sem erro de medida) e o objetivo é estabilizar, não testar se algo é zero. Por isso o ridge é um **passo**

futuro, não descartado.

3 Os dados [FEITO]

Duas bases da Comissão de Valores Mobiliários e uma fonte de mercado:

- **Composição consolidada** (mensal): o peso de VALE3 (posição direta) em cada fundo.
- **Série histórica** (diária): patrimônio líquido, número de cotistas, e se o fundo é um **fundo de cotas** (FIC, que investe em outros fundos em vez de ações diretamente).
- **Informe Diário** (diário): captação e resgate → **fluxo líquido**.
- **Mercado**: preço e **beta** de VALE3 (beta = sensibilidade da ação ao Ibovespa, em janela de 252 pregões).

Tratamentos. Padronização do nome da gestora; remoção de linhas duplicadas e de pesos negativos (resíduos contábeis); exclusão de fundos exclusivos (mantendo só > 3 cotistas); junção das bases pelo dia exato da competência. A captação foi validada contra a série histórica ($> 99\%$ de coincidência ao centavo) e o preço contra o fechamento oficial da bolsa.

Amostra. 72 meses (2016–2021), grupo Itaú. Painel completo de quem detém a ação: 26.123 observações de fundo-mês, 623 fundos. Amostra de regressão (com > 3 cotistas e fluxo): **11.413 observações, 307 fundos**, das quais $\approx 76\%$ são fundos de cotas.

Tabela 1: Estatísticas descritivas da amostra de regressão.

Variável	Média	Desvio-padrão	Mediana	Mínimo	Máximo
Peso de VALE3 (%)	2,87	3,52	1,22	0,00	23,55
Patrimônio líquido (R\$ mi)	399	1.079	68,3	0,04	17.866
Número de cotistas	10.202	72.039	105	4	696.013
Captação líquida (R\$ mi)	5,7	74,1	0,0	−1.522	1.636
Preço de VALE3 (R\$)	54,6	27,2	50,9	9,94	114,1
Beta de VALE3	1,04	0,30	0,97	0,68	1,73

Patrimônio e cotistas são muito assimétricos (média $\gg$ mediana) $\Rightarrow$ usamos o logaritmo. Preço e beta têm correlação de $\approx -0,71$ (na alta de 2016–2021 o preço subiu e o beta caiu), o que dificulta separar os dois efeitos mais adiante.

4 A metodologia, com todas as equações

4.1 Especificação de demanda

O peso observado é um peso desejado mais um erro. Como o peso é uma fração, o peso desejado passa por uma ligação logística:

$$w_{i,t} = g(x'_{i,t} \theta_{n,t}) + \varepsilon_{i,t}^w, \quad g(z) = \frac{1}{1 + e^{-z}}, \quad (1)$$

em que $x_{i,t}$ são as características do fundo e $\theta_{n,t}$ os fatores latentes da ação. A versão *linear* ($g(z) \approx z$) é usada como aproximação no passo transversal; a logística plena entra na decisão de posse e no modelo de ajuste parcial.

4.2 Primeiro passo: a regressão transversal (o fator latente)

Em cada mês t , com os fundos empilhados, estimamos por mínimos quadrados

$$\hat{\theta}_{n,t} = (X_t' X_t)^{-1} X_t' w_t, \quad (2)$$

ou seja, mês a mês rodamos

$$w_{i,t} = \alpha_t + \beta_t^1 z(\ln \text{PL})_{i,t} + \beta_t^2 z(\ln \text{Cot})_{i,t} + \beta_t^3 \text{FIC}_i + \beta_t^4 \left(\frac{\text{Fluxo}}{\text{PL}} \right)_{i,t} + \varepsilon_{i,t}. \quad (3)$$

As características de escala $\ln \text{PL}$ e $\ln \text{Cot}$ entram **padronizadas** ($z(\cdot)$: centradas e divididas pelo desvio-padrão), de modo que o coeficiente é o efeito de *um desvio-padrão*; FIC fica em 0/1 e o intercepto recupera o nível médio do peso. O resumo Fama-MacBeth toma a média no tempo,

$$\bar{\beta}_k = \frac{1}{T} \sum_{t=1}^T \beta_{k,t}, \quad T = 72. \quad (4)$$

4.3 Erros-padrão corrigidos (Newey-West) **[FEITO]**

Como os $\beta_{k,t}$ são autocorrelacionados, a variância da média é estimada por

$$\widehat{\text{Var}}_{\text{NW}}(\bar{\beta}_k) = \frac{1}{T^2} \left[\sum_{t=1}^T \hat{u}_{k,t}^2 + 2 \sum_{\ell=1}^L \left(1 - \frac{\ell}{L+1} \right) \sum_{t=\ell+1}^T \hat{u}_{k,t} \hat{u}_{k,t-\ell} \right], \quad \hat{u}_{k,t} = \beta_{k,t} - \bar{\beta}_k, \quad (5)$$

com $L = 3$ (regra $L = \lfloor 4(T/100)^{2/9} \rfloor$ para $T = 72$). Os resultados estão na Seção 5.

4.4 Segundo passo: dinâmica do fator e previsão **[FEITO]**

Cada coeficiente $\theta_{k,t}$ é tratado como série temporal (passeio aleatório, AR(1) ou filtro de Kalman). A previsão do peso é $\hat{w}_{i,t} = g(\hat{\theta}_t' x_{i,t})$, comparada à ingênua $\hat{w}_{i,t} = w_{i,t-1}$. Avaliamos fora da amostra a 1 e a 3 meses (este último por causa da **opacidade**: as carteiras só são divulgadas com ≈ 90 dias de atraso).

4.5 A decisão de ter ou não a ação (margem extensiva) **[FEITO]**

Além de “quanto” (margem intensiva), estudamos “ter ou não” (margem extensiva) com um painel que inclui os zeros e uma regressão logística da probabilidade de o fundo deter VALE3.

4.6 Extensão dinâmica: o modelo de ajuste parcial **[A FAZER]**

O fundo move o peso parcialmente em direção ao desejado, à velocidade $\lambda_n \in (0, 1)$:

$$w_{i,t+1} = (1 - \lambda_n) w_{i,t} + \lambda_n w_{i,t}^* + u_{i,t+1}. \quad (6)$$

Definindo a distância ao alvo $d_{i,t} \equiv w_{i,t}^* - w_{i,t}$, isso vira

$$w_{i,t+1} - w_{i,t} = \lambda_n d_{i,t} + u_{i,t+1}. \quad (7)$$

A estimativa direta por mínimos quadrados, $\hat{\lambda}_n^{\text{MQO}} = (d_n' d_n)^{-1} d_n' (\Delta w)$, sofre **viés de atenuação**, porque $d_{i,t} = g(x_{i,t}' \hat{\theta}_n) - w_{i,t}$ usa $\hat{\theta}_n$ estimado (erro de medida). Por isso λ será estimado por **variável instrumental / correção de erros nas variáveis**, e *não* por ridge. O erro de previsão correspondente é

$$\hat{u}_{n,t+1} = (w_{n,t+1} - w_{n,t}) - \hat{\lambda}_n (g(X_t \hat{\theta}_n) - w_{n,t}). \quad (8)$$

5 Resultados já obtidos

5.1 Determinantes do peso, agora com Newey-West **[FEITO]**

A Tabela 2 traz a regressão mês a mês resumida à Fama-MacBeth, com os dois erros-padrão lado a lado. **Leitura dos sinais:** fundos maiores carregam *menos* VALE3 em peso; fundos com mais cotistas carregam *mais*; fundos de cotas têm posição direta *menor*; a captação do mês não explica o nível do peso. Esses sinais se repetem nos 72 meses.

Tabela 2: Cross-section mês a mês (Fama-MacBeth, $T = 72$). Erros-padrão clássico vs. Newey-West ($L = 3$). Coeficientes não-padronizados (por unidade de log).

Variável	Coef. médio	EP clássico	t clássico	EP Newey-West	t Newey-West
Intercepto	0,08939	0,00413	21,6	0,00718	12,5
ln(patrimônio)	-0,00376	0,00020	-19,3	0,00034	-11,2
ln(cotistas)	0,00387	0,00020	19,8	0,00035	10,9
Fundo de cotas	-0,01697	0,00089	-19,2	0,00151	-11,3
Captação / patrimônio	-0,00044	0,00309	-0,14	0,00412	-0,11

R^2 médio por mês = 0,152. A correção de Newey-West amplia os erros-padrão em $\approx 1,7$ - $1,8\times$. Fonte: R/24_fm_neweywest.R.

O que a correção muda (e o que não muda). O Newey-West **não altera os sinais nem a significância qualitativa**: as características de fundo seguem com $p < 0,001$ e a captação segue não significativa. O que muda é a *magnitude* das estatísticas: os t caem de ≈ 19 - 22 (clássico) para ≈ 11 - $12,5$ (Newey-West). *Observação honesta*: a versão preliminar do texto mencionava t “em torno de 19 a 22” após a correção, mas esses eram os valores *clássicos*; os corrigidos, calculados aqui, são ≈ 11 - $12,5$ — ainda fortemente significativos.

Magnitudes por desvio-padrão (versão padronizada). Padronizando lnPL e lnCot, o intercepto vira **0,0396** ($\approx 3,96\%$), que é o nível médio do peso de um fundo não-FIC de tamanho médio. Os efeitos por *um* desvio-padrão são:

Característica	Coef. por desvio-padrão	Leitura
ln(patrimônio)	−0,00681	+1 d.p. de tamanho → −0,68 p.p. de peso
ln(cotistas)	+0,01087	+1 d.p. de cotistas → +1,09 p.p. de peso
Fundo de cotas	−0,01697	ser FIC → −1,70 p.p. de peso

Observação honesta: os “−0,38 / +0,39 p.p.” citados na versão preliminar eram os coeficientes em log *cru* lidos como se fossem por desvio-padrão. Os verdadeiros efeitos por desvio-padrão são maiores, e o de *cotistas* (+1,09) supera o de *tamanho* (−0,68) — não são “semelhantes”. Isso reforça que dispersão de cotistas é o traço mais associado a peso direto maior.

5.2 Versão com preço e beta (dados empilhados) [FEITO]

Empilhando os 72 meses e acrescentando preço e beta (média do mês), os sinais de fundo se mantêm. Preço entra positivo (parte é *mecânica*: se a ação sobe, sua fração cresce sozinha); beta entra negativo (aversão a risco), mas com a ressalva da colinearidade preço-beta (−0,71): parte do coeficiente do beta pode estar capturando o resíduo mecânico do preço. $R^2 = 0,166$ (quase igual ao 0,152 sem preço/beta $\Rightarrow$ as características de fundo já carregam a maior parte da informação).

Tabela 3: Regressão com todos os meses empilhados, incluindo preço e beta (11.413 observações).

Variável	Estimativa	Erro padrão	t	Sig.
Intercepto	0,09937	0,00406	24,5	***
ln(patrimônio)	−0,00354	0,00019	−19,0	***
ln(cotistas)	0,00388	0,00013	30,9	***
Fundo de cotas	−0,01682	0,00079	−21,3	***
Captação / patrimônio	−0,00030	0,00034	−0,91	n.s.
Preço de VALE3	0,000182	0,000016	11,5	***
Beta de VALE3	−0,02141	0,00142	−15,1	***

5.3 Dinâmica do fator θ_t [FEITO]

Os coeficientes são persistentes mas *revertem à média* (autocorrelação $\approx 0,7$ – $0,8$; o teste de raiz unitária rejeita passeio aleatório puro). Logo, vale modelá-los por AR(1)/Kalman. A Figura 1 mostra os cinco coeficientes; note a reconfiguração comum em torno de 2018 em vários painéis.

5.4 Previsão e a matriz de erros [FEITO]

Fora da amostra, **nenhum** modelo estrutural supera a previsão ingênua (Tabela 4). O efeito-fixo (média histórica) perde para o último valor $\Rightarrow$ o peso *não* reverte a uma média de fundo; é quase um passeio aleatório. A 3 meses a ingênua piora, mas ainda vence.

Tabela 4: Erro de previsão fora da amostra (raiz do erro quadrático médio), por horizonte.

Universo	Horizonte	Ingênua	Nível do fundo	Fator (Kalman)	Variação do peso
Todos os fundos	1 mês	0,0156	0,0240	0,0255	0,0156
Todos os fundos	3 meses	0,0207	0,0262	0,0273	0,0210
Só fundos de ações	1 mês	0,0197	0,0310	0,0383	0,0198
Só fundos de ações	3 meses	0,0266	0,0337	0,0385	0,0270




Figura 1: Coeficientes da regressão mês a mês (2016–2021); tracejado = média de cada série.

5.5 As duas margens [FEITO]

Fundos maiores e fundos de cotas são *mais propensos a ter* VALE3, mas com peso *menor* quando a têm — sinais opostos entre a margem extensiva (ter) e a intensiva (quanto), padrão de diversificação. A posse também é muito persistente, e de novo a ingênua bate o modelo.

6 Agenda: o que falta, passo a passo

Passo 1 — padronização + Newey-West. [FEITO] Feito nesta rodada (Seção 5, script R/24). Resultado: a inferência fica mais honesta; conclusões qualitativas intactas; magnitudes por desvio-padrão corrigidas.

Passo 2 — regressão logística (resposta fracionária) do peso. [A FAZER] Reestimar (3) com a ligação logística da (1) (em R, `glm` com família `quasibinomial`). Objetivo: respeitar o suporte $[0, 1]$ e comparar com a versão linear; em geral muda pouco no centro da distribuição, mas evita previsões fora de $[0, 1]$.

Passo 3 — modelo de ajuste parcial via variável instrumental. [A FAZER] Construir o peso desejado $w^* = g(x'\hat{\theta})$, a distância $d_{i,t}$, e estimar λ pela (7) com **variável instrumental** (corrigindo o viés de atenuação). O teste central é λ é diferente de zero? Se $\lambda \approx 0$, confirma-se que o peso é quase um passeio aleatório (coerente com a Tabela 4); se $\lambda > 0$, há ajuste parcial detectável e o modelo passa a ter conteúdo preditivo.

Passo futuro — ridge na estimação dos fatores. [FUTURO] Quando o número de características crescer ou ao escalar para muitas ações, usar **regularização ridge** no primeiro

passo (estimação dos θ), onde ela é apropriada (regressores observados, objetivo de estabilizar). Não confundir com o passo 3, em que ridge seria inadequado.

Higiene complementar. [FUTURO] Tratar as caudas extremas de fluxo/patrimônio (*win-sorização*); decompor o peso em parte mecânica (preço) e ativa (decisão); modelo em duas partes para as margens; estender a outras ações e gestoras.

7 Síntese

O projeto tem hoje uma resposta sólida para a **explicação**: o peso de VALE3 nos fundos do Itaú depende, de forma estável, de tamanho, cotistas, tipo de fundo e beta. Para a **previsão**, a inércia do próprio fundo é um teto difícil: o peso é quase um passeio aleatório, e nenhum modelo estrutural a supera no curto prazo. A agenda agora torna a modelagem mais rigorosa (forma logística, inferência Newey-West — já feita) e ataca diretamente a pergunta dinâmica com o modelo de ajuste parcial estimado por variável instrumental, cujo teste de $\lambda \neq 0$ dirá se há, de fato, um ajuste gradual e previsível por trás da forte persistência.

Referências

- Fama, E. F.; MacBeth, J. D. Risk, return, and equilibrium: empirical tests. *Journal of Political Economy*, 81(3):607–636, 1973.
- Gabaix, X.; Koijen, R. S. J. In search of the origins of financial fluctuations: the inelastic markets hypothesis. *NBER Working Paper* 28967, 2021.
- Harvey, A. C. *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge University Press, 1989.
- Hoerl, A. E.; Kennard, R. W. Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67, 1970.
- Koijen, R. S. J.; Yogo, M. A demand system approach to asset pricing. *Journal of Political Economy*, 127(4):1475–1515, 2019.
- Newey, W. K.; West, K. D. A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3):703–708, 1987.
- Papke, L. E.; Wooldridge, J. M. Econometric methods for fractional response variables with an application to 401(k) plan participation rates. *Journal of Applied Econometrics*, 11(6):619–632, 1996.