

Guia consolidado do projeto

Demanda institucional por ativos: o peso de VALE3 nas carteiras dos fundos do Itaú

Documento de trabalho — o que já foi feito, o que falta fazer,
com conceitos, equações, resultados e interpretações

João Paulo Zangrandi (orientador: Prof. Maurício Ferraresi Jr.)

30 de junho de 2026

Como ler este documento. Este não é a monografia que vai para a banca; é um *guia de estudo* para retomar o fio do projeto. Cada parte explica o conceito em linguagem simples, mostra a equação e interpreta o resultado. As etapas estão marcadas com **[FEITO]** (já implementado e rodado em R), **[A FAZER]** (próximo passo combinado) ou **[FUTURO]** (planejado para mais adiante). Os números vêm dos scripts do repositório `forecasting-fund-weights-vale-itaú`.

Sumário

1	O mapa do projeto em uma página	2
2	Conceitos-chave, em linguagem simples	2
3	Por que estas escolhas fazem sentido (a lógica do orientador)	4
3.1	A teoria econômica de fundo	4
3.2	As quatro mudanças, e por que cada uma é correta	5
4	Os dados [FEITO]	5
5	A metodologia, com todas as equações	6
5.1	Especificação de demanda	6
5.2	Primeiro passo: a regressão transversal (o fator latente)	6
5.3	Erros-padrão corrigidos (Newey-West) [FEITO]	7
5.4	Segundo passo: dinâmica do fator e previsão [FEITO]	7
5.5	A decisão de ter ou não a ação (margem extensiva) [FEITO]	7
5.6	Extensão dinâmica: o modelo de ajuste parcial [FEITO]	7
6	Resultados já obtidos	8
6.1	Determinantes do peso, agora com Newey-West [FEITO]	8
6.2	Forma logística (resposta fracionária) [FEITO]	8
6.3	Versão com preço e beta (dados empilhados) [FEITO]	9
6.4	Dinâmica do fator θ_t [FEITO]	10

6.5	Previsão e a matriz de erros [FEITO]	10
6.6	As duas margens [FEITO]	11
6.7	Ajuste parcial: estimando a velocidade λ [FEITO]	11
6.8	Robustez do ajuste parcial [FEITO]	12
7	Agenda: o que falta, passo a passo	12
8	Síntese	13
	Referências	13

1 O mapa do projeto em uma página

A pergunta. Quando um fundo de investimento monta a carteira, ele decide *quanto* de cada ação vai carregar. Esse “quanto”, medido como **peso** (a fração da carteira na ação, um número entre 0 e 1), é uma medida de **demanda**. A pergunta do projeto é dupla:

1. **Explicação:** quais *características* de um fundo (tamanho, número de cotistas, tipo de fundo, fluxo de dinheiro) explicam o peso que ele dá a uma ação?
2. **Previsão:** esse peso pode ser *previsto* de um mês para o outro?

O caso concreto. Para tornar o problema tratável, fixamos uma ação, **VALE3** (posição direta), e uma gestora, o grupo **Itaú** (Asset, DTVM e Unibanco), no período **2016–2021** (72 meses). Estuda-se como o peso de VALE3 varia entre os fundos do Itaú e ao longo do tempo.

A estratégia (em dois passos). (i) A cada mês, regredimos o peso da ação nas características dos fundos; os coeficientes dessa regressão resumem “como as posições dependem das características” — são um **fator latente** θ_t . (ii) Deixamos esse fator *variar no tempo* e tentamos prever o peso, comparando com a **previsão ingênua** (repetir o último peso).

O que já sabemos. As características *explicam bem* o peso (sinais estáveis nos 72 meses), mas *não conseguem prevê-lo* melhor do que simplesmente repetir o último valor: no nível do fundo, o peso é quase um **passeio aleatório**. Esse contraste é o eixo do trabalho.

Para onde vamos. A agenda combinada com o orientador refina a parte de modelagem em quatro frentes: padronização e **erros-padrão Newey-West** (passo 1); forma funcional **logística** para o peso (passo 2); o **modelo de ajuste parcial** com estimação por **variável instrumental** (passo 3) — *os três já implementados e rodados* — e, mais à frente, **regularização (ridge)** para a estimação dos fatores em alta dimensão (passo futuro). A Seção 3 explica por que cada uma dessas escolhas é a correta.

2 Conceitos-chave, em linguagem simples

Sistema de demanda (Kojen e Yogo, 2019). É a ideia de tratar os preços dos ativos como o resultado das *demandas* de muitos investidores, e cada demanda é uma função das *características* dos ativos. A vantagem é trocar um problema gigante (milhares de ativos e investidores) por um número pequeno de parâmetros ligados a características. *Como nos afastamos disso:* aqui o ativo é **fixo** (VALE3) e quem varia são as características do *fundo*; estimamos a forma reduzida “pelas quantidades” (o peso), sem modelar o canal preço-demanda.

Características do fundo e fatores latentes da ação. Chamamos de x_i o vetor de características do fundo i (tamanho, cotistas etc.) — o “perfil” do fundo. Chamamos de θ_n o vetor de *fatores latentes* da ação n — o quanto cada característica “puxa” a posição naquela ação. O peso desejado é, então, o produto $x_i'\theta_n$: o perfil do fundo vezes a sensibilidade da ação a cada traço do perfil.

Seção transversal (cross-section) e Fama-MacBeth (1973). “Seção transversal” é uma fotografia de um mês: todos os fundos ao mesmo tempo. Rodamos uma regressão por mês $\rightarrow$ 72 conjuntos de coeficientes. Fama-MacBeth é a receita de resumir essas 72 fotos: tira-se a *média* de cada coeficiente no tempo e mede-se a incerteza pela *variação* dele entre os meses.

Autocorrelação e erros-padrão Newey-West. Os 72 coeficientes mensais não são independentes: o de um mês se parece com o do mês anterior (autocorrelação de $\approx 0,7$ a $0,8$). O erro-padrão clássico de Fama-MacBeth *supõe independência* e, por isso, *subestima* a incerteza e *infla* as estatísticas t . O estimador de **Newey-West** corrige isso somando as autocovariâncias (com pesos decrescentes) — dá erros-padrão maiores e t menores, porém honestos.

Resposta fracionária / ligação logística. O peso vive em $[0, 1]$. Uma regressão linear pode prever valores negativos ou acima de 1, o que não faz sentido. A *função logística* $g(z) = 1/(1 + e^{-z})$ espreme qualquer número para dentro de $(0, 1)$, respeitando o limite. É a forma funcional correta para uma fração (Papke e Wooldridge, 1996).

Ajuste parcial. A ideia de que o fundo não pula de uma vez para o peso desejado, mas se move só *parte* do caminho a cada mês, a uma velocidade λ . Se $\lambda = 1$, ajusta tudo na hora; se $\lambda = 0$, não ajusta nada (o peso fica “preso” no valor de ontem — que é justamente a previsão ingênua).

Viés de atenuação e variável instrumental. Quando um regressor é *medido com erro* (no nosso caso, a “distância ao alvo” é construída a partir de coeficientes *estimados*), o mínimos quadrados puxa o coeficiente *para zero* — isso é o **viés de atenuação**. Como o teste central é justamente “ λ é diferente de zero?”, um método que empurra para zero atrapalha. A **variável**

instrumental (ou correção de erros nas variáveis) conserta isso usando uma fonte de variação “limpa” do regressor.

Por que ridge agora não, mas no futuro sim. A *regularização ridge* encolhe coeficientes em direção a zero para estabilizá-los. Isso é *ruim* para estimar λ (agravaria a atenuação contra a hipótese de interesse), mas é *bom* para o primeiro passo quando o número de características crescer ou quando escalarmos para muitas ações: ali os regressores são *observados* (sem erro de medida) e o objetivo é estabilizar, não testar se algo é zero. Por isso o ridge é um **passo futuro**, não descartado.

3 Por que estas escolhas fazem sentido (a lógica do orientador)

Esta seção reúne, em um só lugar, a *teoria* por trás do projeto e o *porquê* de cada decisão metodológica que o orientador introduziu — e em que ela difere da primeira versão do trabalho. Nenhuma das mudanças é um detalhe técnico: cada uma conserta um problema concreto.

3.1 A teoria econômica de fundo

Por que modelar o peso como demanda? Um fundo não escolhe quanto de VALE3 carregar ao acaso. Ele responde ao **mandato** (um fundo de ações precisa ter ações; um fundo de cotas acessa ativos por meio de outros fundos), a **restrições de liquidez e de tamanho** (um fundo gigante não concentra numa única ação sem mover o preço contra si) e à **diversificação**. Essas forças ligam o peso às características observáveis do fundo — e é essa ligação que a regressão transversal mede. Em vez de modelar o canal preço $\rightarrow$ demanda (como em Koijen-Yogo), observamos diretamente a *quantidade* escolhida (o peso) e perguntamos de que perfil de fundo ela depende: é um sistema de demanda institucional “na forma reduzida”.

O que é o fator latente θ_t ? É o vetor de coeficientes da regressão de um mês. Economicamente, ele resume *quanto cada característica importa* para a demanda por VALE3 naquele mês: o sinal e o tamanho com que tamanho, número de cotistas e tipo de fundo “puxam” o peso. Chamamos de “latente” porque não é observado diretamente — é *inferido* da seção transversal. E ele **varia no tempo** porque as condições que governam a demanda (preço e risco da ação, ambiente de mercado, apetite das gestoras) mudam mês a mês; por isso tratamos θ_t como uma série temporal e, no limite, como um estado a ser filtrado (Kalman).

Por que um modelo *dinâmico* de ajuste parcial? Porque rebalancear custa: há custos de transação, de impacto de mercado e de coordenação interna da gestora. Um fundo que esteja longe do seu peso “ideal” não salta para ele de uma vez — fecha a distância aos poucos. A velocidade λ mede o *inverso* dessa fricção: λ alto significa ajuste rápido (pouca fricção); $\lambda \approx 0$ significa que a posição quase “gruda” no valor de ontem. Estimar λ é, no fundo, medir empiricamente o atrito de rebalanceamento das carteiras — e ligar a parte estática (a demanda-alvo da seção transversal) à parte dinâmica (como o fundo caminha até ela).

3.2 As quatro mudanças, e por que cada uma é correta

A Tabela 1 confronta a versão inicial do projeto com a mudança do orientador e a justificativa de cada uma.

Tabela 1: O que mudou em relação à nossa versão, e por que a mudança é a escolha certa.

Tema	Versão inicial	Mudança do orientador	Por que é a escolha certa
Forma funcional do peso	Regressão linear, $w = x'\theta + \varepsilon$	Ligação logística, $w = g(x'\theta) + \varepsilon$	O peso é fração em $[0, 1]$; o linear prevê valores impossíveis (negativos) em 2,5% dos casos; o logit respeita o suporte e é exigido pelo passo 3.
Erros-padrão na Fama-MacBeth	Clássico $sd/\sqrt{T}$ (supõe meses independentes)	Newey-West (HAC)	Os coeficientes mensais são autocorrelacionados (0,7–0,8); ignorar isso subestima a incerteza e infla os t .
Estimar a velocidade λ	<i>Ridge</i> (na anotação manuscrita)	Variável instrumental / erros nas variáveis	A distância ao alvo é medida com erro e o teste central é $\lambda \neq 0$; <i>ridge</i> encolhe para zero e sabotaria justamente esse teste — a VI corrige sem esse viés.
Papel do <i>ridge</i>	Seria usado já no λ	Reservado ao passo futuro (estimar θ em alta dimensão)	Lá os regressores são observados e o objetivo é estabilizar, não testar se algo é zero — uso legítimo da regularização.

Em todas as quatro, a direção apontada pelo orientador estava certa. Nossos números acrescentam a *magnitude* e, em dois pontos, uma *nuance honesta* que detalhamos nos resultados: (i) os t depois do Newey-West são ≈ 11 – $12,5$, não os ≈ 19 – 22 que a versão preliminar do texto citava (aqueles eram os clássicos); e (ii) no passo 3 o viés do mínimos quadrados foi para *cima* (reversão mecânica), não a atenuação para baixo que se antecipava — mas a variável instrumental corrige os dois casos, então a recomendação continua correta.

4 Os dados [FEITO]

Duas bases da Comissão de Valores Mobiliários e uma fonte de mercado:

- **Composição consolidada** (mensal): o peso de VALE3 (posição direta) em cada fundo.
- **Série histórica** (diária): patrimônio líquido, número de cotistas, e se o fundo é um **fundo de cotas** (FIC, que investe em outros fundos em vez de ações diretamente).
- **Informe Diário** (diário): captação e resgate $\rightarrow$ **fluxo líquido**.
- **Mercado**: preço e **beta** de VALE3 (beta = sensibilidade da ação ao Ibovespa, em janela de 252 pregões).

Tratamentos. Padronização do nome da gestora; remoção de linhas duplicadas e de pesos negativos (resíduos contábeis); exclusão de fundos exclusivos (mantendo só > 3 cotistas); junção das bases pelo dia exato da competência. A captação foi validada contra a série histórica ($> 99\%$ de coincidência ao centavo) e o preço contra o fechamento oficial da bolsa.

Amostra. 72 meses (2016–2021), grupo Itaú. Painel completo de quem detém a ação: 26.123 observações de fundo-mês, 623 fundos. Amostra de regressão (com > 3 cotistas e fluxo): **11.413 observações, 307 fundos**, das quais $\approx 76\%$ são fundos de cotas.

Tabela 2: Estatísticas descritivas da amostra de regressão.

Variável	Média	Desvio-padrão	Mediana	Mínimo	Máximo
Peso de VALE3 (%)	2,87	3,52	1,22	0,00	23,55
Patrimônio líquido (R\$ mi)	399	1.079	68,3	0,04	17.866
Número de cotistas	10.202	72.039	105	4	696.013
Captação líquida (R\$ mi)	5,7	74,1	0,0	−1.522	1.636
Preço de VALE3 (R\$)	54,6	27,2	50,9	9,94	114,1
Beta de VALE3	1,04	0,30	0,97	0,68	1,73

A própria tabela já orienta as escolhas de modelagem. O **peso** tem média 2,87% mas mediana 1,22% e máximo 23,55%: é fortemente assimétrico à direita e ancorado perto de zero — distribuição típica de uma fração, que motiva a forma logística do passo 2 (e torna a hipótese de normalidade do resíduo inadequada). **Patrimônio e cotistas** são ainda mais assimétricos (média $\gg$ mediana), por isso entram em **logaritmo**. A **captação** tem mediana exatamente zero e caudas enormes ($-1,5$ a $+1,6$ bi), o que, ao dividir pelo patrimônio de fundos pequenos, gera valores extremos (daí a winsorização ficar na agenda). E **preço e beta** têm correlação $\approx -0,71$ (na alta de 2016–2021 o preço subiu e o beta caiu), o que dificultará separar os dois efeitos mais adiante.

5 A metodologia, com todas as equações

5.1 Especificação de demanda

O peso observado é um peso desejado mais um erro. Como o peso é uma fração, o peso desejado passa por uma ligação logística:

$$w_{i,t} = g(x'_{i,t} \theta_{n,t}) + \varepsilon_{i,t}^w, \quad g(z) = \frac{1}{1 + e^{-z}}, \quad (1)$$

em que $x_{i,t}$ são as características do fundo e $\theta_{n,t}$ os fatores latentes da ação. A versão *linear* ($g(z) \approx z$) é usada como aproximação no passo transversal; a logística plena entra na decisão de posse e no modelo de ajuste parcial.

5.2 Primeiro passo: a regressão transversal (o fator latente)

Em cada mês t , com os fundos empilhados, estimamos por mínimos quadrados

$$\hat{\theta}_{n,t} = (X'_t X_t)^{-1} X'_t w_t, \quad (2)$$

ou seja, mês a mês rodamos

$$w_{i,t} = \alpha_t + \beta_t^1 z(\ln \text{PL})_{i,t} + \beta_t^2 z(\ln \text{Cot})_{i,t} + \beta_t^3 \text{FIC}_i + \beta_t^4 \left(\frac{\text{Fluxo}}{\text{PL}} \right)_{i,t} + \varepsilon_{i,t}. \quad (3)$$

As características de escala $\ln \text{PL}$ e $\ln \text{Cot}$ entram **padronizadas** ($z(\cdot)$: centradas e divididas pelo desvio-padrão), de modo que o coeficiente é o efeito de *um desvio-padrão*; FIC fica em $0/1$ e o

intercepto recupera o nível médio do peso. O resumo Fama-MacBeth toma a média no tempo,

$$\bar{\beta}_k = \frac{1}{T} \sum_{t=1}^T \beta_{k,t}, \quad T = 72. \quad (4)$$

5.3 Erros-padrão corrigidos (Newey-West) **[FEITO]**

Como os $\beta_{k,t}$ são autocorrelacionados, a variância da média é estimada por

$$\widehat{\text{Var}}_{\text{NW}}(\bar{\beta}_k) = \frac{1}{T^2} \left[\sum_{t=1}^T \hat{u}_{k,t}^2 + 2 \sum_{\ell=1}^L \left(1 - \frac{\ell}{L+1}\right) \sum_{t=\ell+1}^T \hat{u}_{k,t} \hat{u}_{k,t-\ell} \right], \quad \hat{u}_{k,t} = \beta_{k,t} - \bar{\beta}_k, \quad (5)$$

com $L = 3$ (regra $L = \lfloor 4(T/100)^{2/9} \rfloor$ para $T = 72$). Os resultados estão na Seção 6.

5.4 Segundo passo: dinâmica do fator e previsão **[FEITO]**

Cada coeficiente $\theta_{k,t}$ é tratado como série temporal (passeio aleatório, AR(1) ou filtro de Kalman). A previsão do peso é $\hat{w}_{i,t} = g(\hat{\theta}'_t x_{i,t})$, comparada à ingênua $\hat{w}_{i,t} = w_{i,t-1}$. Avaliamos fora da amostra a 1 e a 3 meses (este último por causa da **opacidade**: as carteiras só são divulgadas com ≈ 90 dias de atraso).

5.5 A decisão de ter ou não a ação (margem extensiva) **[FEITO]**

Além de “quanto” (margem intensiva), estudamos “ter ou não” (margem extensiva) com um painel que inclui os zeros e uma regressão logística da probabilidade de o fundo deter VALE3.

5.6 Extensão dinâmica: o modelo de ajuste parcial **[FEITO]**

O fundo move o peso parcialmente em direção ao desejado, à velocidade $\lambda_n \in (0, 1)$:

$$w_{i,t+1} = (1 - \lambda_n) w_{i,t} + \lambda_n w_{i,t}^* + u_{i,t+1}. \quad (6)$$

Definindo a distância ao alvo $d_{i,t} \equiv w_{i,t}^* - w_{i,t}$, isso vira

$$w_{i,t+1} - w_{i,t} = \lambda_n d_{i,t} + u_{i,t+1}. \quad (7)$$

A estimativa direta por mínimos quadrados, $\hat{\lambda}_n^{\text{MQO}} = (d'_n d_n)^{-1} d'_n (\Delta w)$, sofre **viés de atenuação**, porque $d_{i,t} = g(x'_{i,t} \hat{\theta}_n) - w_{i,t}$ usa $\hat{\theta}_n$ estimado (erro de medida). Por isso λ é estimado por **variável instrumental / correção de erros nas variáveis**, e *não* por ridge (ver o resultado na Seção 6). O erro de previsão correspondente é

$$\hat{u}_{n,t+1} = (w_{n,t+1} - w_{n,t}) - \hat{\lambda}_n \left(g(X_t \hat{\theta}_n) - w_{n,t} \right). \quad (8)$$

6 Resultados já obtidos

6.1 Determinantes do peso, agora com Newey-West [FEITO]

A Tabela 3 traz a regressão mês a mês resumida à Fama-MacBeth, com os dois erros-padrão lado a lado. **Leitura dos sinais:** fundos maiores carregam *menos* VALE3 em peso; fundos com mais cotistas carregam *mais*; fundos de cotas têm posição direta *menor*; a captação do mês não explica o nível do peso. Esses sinais se repetem nos 72 meses.

Tabela 3: Cross-section mês a mês (Fama-MacBeth, $T = 72$). Erros-padrão clássico vs. Newey-West ($L = 3$). Coeficientes não-padronizados (por unidade de log).

Variável	Coef. médio	EP clássico	t clássico	EP Newey-West	t Newey-West
Intercepto	0,08939	0,00413	21,6	0,00718	12,5
$\ln(\text{patrimônio})$	-0,00376	0,00020	-19,3	0,00034	-11,2
$\ln(\text{cotistas})$	0,00387	0,00020	19,8	0,00035	10,9
Fundo de cotas	-0,01697	0,00089	-19,2	0,00151	-11,3
Captação / patrimônio	-0,00044	0,00309	-0,14	0,00412	-0,11

R^2 médio por mês = 0,152. A correção de Newey-West amplia os erros-padrão em $\approx 1,7$ - $1,8\times$. Fonte: R/24_fm_neweywest.R.

O que a correção muda (e o que não muda). O Newey-West **não altera os sinais nem a significância qualitativa**: as características de fundo seguem com $p < 0,001$ e a captação segue não significativa. O que muda é a *magnitude* das estatísticas: os t caem de ≈ 19 - 22 (clássico) para ≈ 11 - $12,5$ (Newey-West). *Observação honesta*: a versão preliminar do texto mencionava t “em torno de 19 a 22” após a correção, mas esses eram os valores *clássicos*; os corrigidos, calculados aqui, são ≈ 11 - $12,5$ — ainda fortemente significativos.

Magnitudes por desvio-padrão (versão padronizada). Padronizando $\ln PL$ e $\ln Cot$, o intercepto vira **0,0396** ($\approx 3,96\%$), que é o nível médio do peso de um fundo não-FIC de tamanho médio. Os efeitos por *um* desvio-padrão são:

Característica	Coef. por desvio-padrão		Leitura
$\ln(\text{patrimônio})$	-0,00681	+1 d.p. de tamanho $\rightarrow$	-0,68 p.p. de peso
$\ln(\text{cotistas})$	+0,01087	+1 d.p. de cotistas $\rightarrow$	+1,09 p.p. de peso
Fundo de cotas	-0,01697	ser FIC $\rightarrow$	-1,70 p.p. de peso

Observação honesta: os “-0,38 / +0,39 p.p.” citados na versão preliminar eram os coeficientes em log *cru* lidos como se fossem por desvio-padrão. Os verdadeiros efeitos por desvio-padrão são maiores, e o de *cotistas* (+1,09) supera o de *tamanho* (-0,68) — não são “semelhantes”. Isso reforça que dispersão de cotistas é o traço mais associado a peso direto maior.

6.2 Forma logística (resposta fracionária) [FEITO]

Reestimamos a mesma cross-section, agora com a ligação logística da (1) (em R, `glm` família `quasibinomial`), mês a mês. A Tabela 4 traz os coeficientes no resumo Fama-MacBeth com Newey-West.

Tabela 4: Cross-section logística (resposta fracionária), Fama-MacBeth + Newey-West. Coeficientes na escala de *log-odds*; características de escala padronizadas.

Variável	Coef. (log-odds)	EP Newey-West	<i>t</i> Newey-West	Meses com sinal +
Intercepto	−3,380	0,150	−22,5	0/72
ln(patrimônio) [d.p.]	−0,339	0,043	−7,9	0/72
ln(cotistas) [d.p.]	+0,469	0,035	13,3	72/72
Fundo de cotas	−0,732	0,062	−11,7	0/72
Captação / patrimônio	+0,078	0,183	0,43	37/72

Fonte: R/25_fractional_logit.R.

Três pontos resumem o passo:

1. **Sinais e significância são idênticos ao linear:** patrimônio e FIC negativos, cotistas positivo, captação não significativa, todos estáveis nos 72 meses.
2. **As magnitudes coincidem no centro.** O coeficiente de *log-odds* não é comparável direto ao linear, mas o **efeito parcial médio** (a derivada média de g , em pontos de peso) é: dá −0,68 p.p. (patrimônio), +1,06 p.p. (cotistas) e −1,60 p.p. (FIC), praticamente iguais aos coeficientes lineares (−0,68, +1,09, −1,70). Ou seja, *o linear era uma boa aproximação no centro* — a conclusão econômica não muda.
3. **O ganho do logit é respeitar o suporte.** O modelo linear gera previsões *fora* de $[0, 1]$ em 287 de 11.413 casos (2,51%) — pesos negativos, sem sentido; o logit, por construção, nunca. O ajuste também melhora de leve (pseudo- R^2 0,165 vs 0,152). Isso é exatamente o que o orientador antecipou, e é **pré-requisito do passo 3**, em que o peso desejado $w^* = g(x'\theta)$ precisa estar em $[0, 1]$.

6.3 Versão com preço e beta (dados empilhados) [FEITO]

Empilhando os 72 meses e acrescentando preço e beta (média do mês), os sinais de fundo se mantêm. Preço entra positivo (parte é *mecânica*: se a ação sobe, sua fração cresce sozinha); beta entra negativo (aversão a risco), mas com a ressalva da colinearidade preço-beta (−0,71): parte do coeficiente do beta pode estar capturando o resíduo mecânico do preço. $R^2 = 0,166$ (quase igual ao 0,152 sem preço/beta $\Rightarrow$ as características de fundo já carregam a maior parte da informação).

Tabela 5: Regressão com todos os meses empilhados, incluindo preço e beta (11.413 observações).

Variável	Estimativa	Erro padrão	<i>t</i>	Sig.
Intercepto	0,09937	0,00406	24,5	***
ln(patrimônio)	−0,00354	0,00019	−19,0	***
ln(cotistas)	0,00388	0,00013	30,9	***
Fundo de cotas	−0,01682	0,00079	−21,3	***
Captação / patrimônio	−0,00030	0,00034	−0,91	n.s.
Preço de VALE3	0,000182	0,000016	11,5	***
Beta de VALE3	−0,02141	0,00142	−15,1	***

6.4 Dinâmica do fator θ_t [FEITO]

Os coeficientes são persistentes mas *revertem à média* (autocorrelação $\approx 0,7$ – $0,8$; o teste de raiz unitária rejeita passeio aleatório puro). Logo, vale modelá-los por AR(1)/Kalman. A Figura 1 mostra os cinco coeficientes; note a reconfiguração comum em torno de 2018 em vários painéis.




Figura 1: Coeficientes da regressão mês a mês (2016–2021); tracejado = média de cada série.

6.5 Previsão e a matriz de erros [FEITO]

Aqui muda a pergunta: não é mais “o que explica o peso”, e sim “o que *prevê* o peso do próximo mês”. Comparamos quatro previsões fora da amostra (Tabela 6): a ingênua ($w_{i,t-1}$), o nível médio do fundo (efeito-fixo), o fator previsto por Kalman, e a variação Δw . **Nenhum modelo estrutural supera a ingênua**: a 1 mês eles erram 54 a 63% mais (RMSE 0,024–0,026 contra 0,0156).

Por que o ingênuo vence (a intuição). Duas coisas se somam. Primeiro, o *alvo* se move pouco de um mês para o outro — o fator θ_t é persistente (autocorrelação 0,7–0,8), então o peso desejado de amanhã é quase o de hoje. Segundo, o fundo *caminha devagar* em direção ao alvo (é o λ pequeno do passo 3). Com alvo quase parado e caminhada lenta, a melhor aposta para o mês que vem é simplesmente o valor de agora. Um detalhe revelador: o **efeito-fixo (média histórica do fundo) perde para o último valor**; se o peso revertisse a uma média, a média ganharia — o que se vê é o oposto, a marca de um processo próximo do passeio aleatório. A 3 meses (a opacidade de divulgação) a ingênua piora, mas ainda vence, e a distância para os modelos estruturais encolhe — coerente com o ajuste parcial acumular um pouco mais de reversão em horizontes mais longos.

Tabela 6: Erro de previsão fora da amostra (raiz do erro quadrático médio), por horizonte.

Universo	Horizonte	Ingênua	Nível do fundo	Fator (Kalman)	Variação do peso
Todos os fundos	1 mês	0,0156	0,0240	0,0255	0,0156
Todos os fundos	3 meses	0,0207	0,0262	0,0273	0,0210
Só fundos de ações	1 mês	0,0197	0,0310	0,0383	0,0198
Só fundos de ações	3 meses	0,0266	0,0337	0,0385	0,0270

6.6 As duas margens [FEITO]

Fundos maiores e fundos de cotas são *mais propensos a ter* VALE3, mas com peso *menor* quando a têm — sinais opostos entre a margem extensiva (ter) e a intensiva (quanto), padrão de diversificação. A posse também é muito persistente, e de novo a ingênua bate o modelo.

6.7 Ajuste parcial: estimando a velocidade λ [FEITO]

Este é o passo dinâmico central. Construimos o peso desejado $w_{i,t}^* = g(x'_{i,t}\hat{\theta}_t)$ (o ajustado do logit do passo 2), a distância $d_{i,t} = w_{i,t}^* - w_{i,t}$, e estimamos a (7) por mínimos quadrados (MQO) e por variável instrumental (VI), usando a distância defasada $d_{i,t-1}$ como instrumento. O instrumento é fortíssimo (primeiro estágio $d_t \sim d_{t-1}$: coeficiente 0,895, $F \approx 39.800$).

Tabela 7: Velocidade de ajuste λ na equação $\Delta w_{i,t+1} = \lambda d_{i,t} + u$. Erro-padrão agrupado por fundo. $N = 10.570$ fundo-meses, 295 fundos, 70 meses.

Estimador	$\hat{\lambda}$	Erro padrão	t	p
MQO (enviesado)	0,0976	0,0096	10,2	< 0,001
VI (instrumento $d_{i,t-1}$)	0,0413	0,0063	6,6	< 0,001

Fonte: R/26_partial_adjustment.R.

Três leituras, todas importantes:

1. **O viés do MQO foi para cima, não para baixo.** O orientador antecipou *atenuação* (MQO puxado para zero) por causa do $\hat{\theta}_t$ estimado. Mas há um segundo viés: como $w_{i,t}$ aparece em $d_{i,t}$ e em $\Delta w_{i,t+1}$, o ruído transitório do peso cria uma **reversão à média mecânica** que puxa o MQO *para cima*. Aqui o efeito mecânico dominou (0,098 no MQO vs 0,041 na VI). O instrumento $d_{i,t-1}$ corrige os *dois* vieses de uma vez, porque não compartilha $w_{i,t}$ com o lado esquerdo nem o erro de estimação de $\hat{\theta}_t$; por isso 0,041 é a estimativa limpa, qualquer que fosse o viés dominante.
2. **λ é diferente de zero, mas minúsculo.** A VI dá $\hat{\lambda} = 0,041$ ($t = 6,6$, $p < 0,001$): o fundo fecha só $\approx 4\%$ da distância ao alvo por mês, uma **meia-vida de ≈ 16 meses**. O ajuste existe, mas é lentíssimo.
3. **Isso reconcilia toda a história.** Como λ é próximo de zero, mês a mês o peso quase não se move em direção ao alvo — por isso a previsão ingênua vence em $h = 1$ (Tabela 6). Mas $\lambda \neq 0$ mostra que *existe* uma reversão real, porém lenta, ao alvo estrutural definido pelas características. O modelo de fator não é vazio: ele descreve a **âncora de longo prazo** do peso, não o seu movimento de curto prazo.

Hipótese de identificação: a VI supõe que $d_{i,t-1}$ não se correlaciona com a inovação $u_{i,t+1}$, o que vale se o ruído transitório do peso não for serialmente correlacionado ao longo do intervalo $t-1 \rightarrow t+1$. A robustez é examinada na Seção 6.8.

6.8 Robustez do ajuste parcial [FEITO]

Reestimamos λ em quatro especificações (Tabela 8): a baseline; com **efeito-fixo de fundo** (identificação só pela variação *dentro* de cada fundo); com um **instrumento alternativo**, a segunda defasagem $d_{i,t-2}$; e no **horizonte de três meses** (a opacidade de divulgação).

Tabela 8: Robustez da velocidade de ajuste λ (VI, erro-padrão agrupado por fundo).

Especificação	$\hat{\lambda}$	Erro padrão	t	Meia-vida
Baseline ($h=1$, instrumento d_{t-1})	0,041	0,006	6,6	≈ 16 meses
+ Efeito-fixo de fundo	0,185	0,019	9,5	$\approx 3,4$ meses
Instrumento alternativo d_{t-2}	0,021	0,005	4,3	≈ 33 meses
Horizonte 3 meses ($w_{t+3} - w_t$)	0,086	0,011	7,5	(acumulado)

Fonte: R/27_pa_robustness.R.

O que é robusto e o que é sensível:

1. **O sinal e a significância são robustos.** $\lambda > 0$ com t entre 4,3 e 9,5 (p minúsculo) em *todas* as especificações: a existência de uma reversão ao alvo estrutural não depende das escolhas de estimação.
2. **A magnitude é sensível.** λ vai de 0,02 a 0,19 por mês (meia-vida de ≈ 3 a ≈ 33 meses). O efeito-fixo de fundo dá o maior λ : *dentro* de um mesmo fundo, os desvios da própria trajetória revertem mais rápido ($\approx 3,4$ meses); a versão agregada e o instrumento d_{t-2} apontam reversão mais lenta. A 3 meses, $\lambda = 0,086$ é coerente com a acumulação de um ajuste mensal pequeno.
3. **Em todas, o ajuste é incompleto dentro de um trimestre.** Mesmo no caso mais rápido (efeito-fixo), boa parte da distância ao alvo ainda persiste a três meses — o que continua coerente com a previsão ingênua vencer no curto prazo (Tabela 6).

7 Agenda: o que falta, passo a passo

Passo 1 — padronização + Newey-West. [FEITO] Feito nesta rodada (Seção 6, script R/24). Resultado: a inferência fica mais honesta; conclusões qualitativas intactas; magnitudes por desvio-padrão corrigidas.

Passo 2 — regressão logística (resposta fracionária) do peso. [FEITO] Feito nesta rodada (Seção 6, script R/25). Confirmado: sinais e significância iguais ao linear; efeitos parciais médios praticamente idênticos (o linear era boa aproximação no centro); mas o linear viola $[0, 1]$ em 2,51% dos casos enquanto o logit não, o que o torna a forma correta e habilita o passo 3.

Passo 3 — modelo de ajuste parcial via variável instrumental. [FEITO] Feito nesta rodada (Seção 6, script R/26). Resultado: $\hat{\lambda}_{VI} = 0,041$, diferente de zero ($t = 6,6$) mas minúsculo (meia-vida ≈ 16 meses). O viés do MQO foi para *cima* (reversão mecânica dominou a atenuação); a VI com d_{t-1} corrige ambos. Conclusão: há reversão lenta e real ao alvo estrutural, coerente com o peso ser quase um passeio aleatório no curto prazo.

Robustez do passo 3. [FEITO] Verificada (Seção 6.8, script R/27): $\lambda > 0$ e significativo com efeito-fixo de fundo, com instrumento alternativo d_{t-2} e no horizonte de três meses. O sinal é robusto; a magnitude varia (λ de 0,02 a 0,19 por mês), mas o ajuste é sempre incompleto dentro de um trimestre.

Passo futuro — ridge na estimação dos fatores. [FUTURO] Quando o número de características crescer ou ao escalar para muitas ações, usar **regularização ridge** no primeiro passo (estimação dos θ), onde ela é apropriada (regressores observados, objetivo de estabilizar). Não confundir com o passo 3, em que ridge seria inadequado.

Higiene complementar. [FUTURO] Tratar as caudas extremas de fluxo/patrimônio (*win-sorização*); decompor o peso em parte mecânica (preço) e ativa (decisão); modelo em duas partes para as margens; estender a outras ações e gestoras.

8 Síntese

O projeto tem hoje uma resposta sólida para a **explicação**: o peso de VALE3 nos fundos do Itaú depende, de forma estável, de tamanho, cotistas, tipo de fundo e beta. Para a **previsão**, a inércia do próprio fundo é um teto difícil: o peso é quase um passeio aleatório, e nenhum modelo estrutural a supera no curto prazo. Os três primeiros passos da agenda estão feitos: a inferência ficou mais honesta (Newey-West), a forma funcional virou logística (respeitando o suporte), e o modelo de ajuste parcial foi estimado por variável instrumental. O veredito do passo 3 amarra tudo: a velocidade de ajuste $\lambda = 0,041$ é estatisticamente diferente de zero, mas tão pequena (meia-vida ≈ 16 meses) que, no curto prazo, repetir o último peso continua sendo a melhor previsão. Em uma frase: as características definem *para onde* o peso tende no longo prazo, mas o fundo caminha até lá tão devagar que, mês a mês, o peso parece um passeio aleatório.

Referências

- Fama, E. F.; MacBeth, J. D. Risk, return, and equilibrium: empirical tests. *Journal of Political Economy*, 81(3):607–636, 1973.
- Gabaix, X.; Koijen, R. S. J. In search of the origins of financial fluctuations: the inelastic markets hypothesis. *NBER Working Paper* 28967, 2021.
- Harvey, A. C. *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge University Press, 1989.
- Hoerl, A. E.; Kennard, R. W. Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67, 1970.

- Koijen, R. S. J.; Yogo, M. A demand system approach to asset pricing. *Journal of Political Economy*, 127(4):1475–1515, 2019.
- Newey, W. K.; West, K. D. A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3):703–708, 1987.
- Papke, L. E.; Wooldridge, J. M. Econometric methods for fractional response variables with an application to 401(k) plan participation rates. *Journal of Applied Econometrics*, 11(6):619–632, 1996.