

FUNDAÇÃO GETULIO VARGAS
ESCOLA DE ECONOMIA DE SÃO PAULO
Graduação em Economia

João Paulo Zangrandi

Previsão de Pesos de Fundos:
VALE3 nos Fundos do Itaú

uma abordagem de demanda baseada em características de fundos e da ação

(forecasting-fund-weights-vale-itaú — entrega parcial)

Trabalho de Conclusão de Curso apresentado à Escola de Economia de São Paulo da Fundação Getulio Vargas como requisito parcial para a obtenção do título de Bacharel em Economia.

Entrega parcial (versão preliminar).

Orientador: Prof. Maurício Ferraresi Jr.

São Paulo
2026

Resumo

Estudamos os **determinantes** e a **previsibilidade** do peso da ação VALE3 nas carteiras dos fundos da gestora Itaú, no painel mensal 2016–2021. A abordagem segue um *sistema de demanda* no espírito de Kojien e Yogo (2019): o peso de cada ação em cada fundo é explicado por um vetor de características do fundo (*investor embeddings*) ponderado por fatores latentes específicos da ação (*asset embeddings*), estimados mês a mês por uma regressão transversal cujos coeficientes formam um **fator dinâmico** θ_t . Documentamos que o peso é estruturalmente explicado por **tamanho do fundo**, **número de cotistas** e por ser **Fundo de Investimento em Cotas (FIC)**, com sinais estáveis nos 72 meses; e que a margem *extensiva* (ter ou não a ação) tem sinais **opostos** à intensiva (quanto), um padrão de diversificação. Em previsão, porém, nenhum modelo estrutural (fator dinâmico, efeito-fixo, filtro de Kalman) supera o **benchmark ingênuo** (o peso defasado): o peso é, no nível do fundo, quase um **martingale**, mesmo sob a opacidade trimestral de 90 dias. O trabalho fecha com o desenho dos próximos passos — o modelo de *ajuste parcial da carteira* com velocidade de ajuste estimada (possivelmente *ridge*) e a regra de decisão dado o *lag* de divulgação — conforme as anotações do orientador.

Palavras-chave: sistema de demanda; fundos de investimento; pesos de carteira; fator dinâmico; previsão; CVM; VALE3.

Abstract

We study the **determinants** and **predictability** of the portfolio weight of the stock VALE3 across mutual funds managed by Itaú, on a monthly 2016–2021 panel. Following a demand-system approach à la Kojien and Yogo (2019), each stock’s weight in each fund is explained by a vector of fund characteristics (*investor embeddings*) loaded on stock-specific latent factors (*asset embeddings*), estimated month by month through a cross-sectional regression whose coefficients form a **dynamic factor** θ_t . Weights are structurally driven by **fund size**, **number of shareholders** and a **fund-of-funds (FIC)** dummy, with stable signs across all 72 months; the *extensive* margin (holding the stock at all) carries signs **opposite** to the intensive one (how much), a diversification pattern. Yet, for forecasting, no structural model (dynamic factor, fixed effects, Kalman filter) beats the **naïve benchmark** (the lagged weight): the weight behaves almost as a **martingale** at the fund level, even under the 90-day disclosure opacity. We close with the design of the next steps — the *partial portfolio adjustment* model with an estimated adjustment speed (possibly *ridge*) and the decision rule given the disclosure lag.

Keywords: demand system; mutual funds; portfolio weights; dynamic factor; forecasting; CVM; VALE3.

1 Introdução

A composição das carteiras dos fundos de investimento é uma das informações mais ricas e menos exploradas do mercado de capitais brasileiro. Cada fundo, ao escolher *quanto* de cada ação carregar, revela uma demanda — e o conjunto dos fundos de uma mesma gestora forma um painel natural para perguntar: **quais características de um fundo explicam o peso que ele dá a uma ação, e esse peso é previsível?**

Este trabalho responde a essa pergunta para um caso concreto e tratável: o peso da ação **VALE3** (posição direta) nas carteiras dos fundos da gestora **Itaú** (Itaú Asset Management, Itaú DTVM e Itaú Unibanco), no período **2016–2021**. A escolha do peso como alvo — em vez do valor financeiro ou do número de ações — é deliberada: o peso é *limitado* em $[0, 1]$, comparável entre fundos de tamanhos muito diferentes, e mapeia diretamente para a noção de *demandas relativas* dos sistemas de demanda por ativos.

A estratégia empírica tem dois passos, sugeridos pelo orientador. No primeiro, uma **regressão transversal** mês a mês do peso contra características de fundo e de ação; seus coeficientes resumem, em baixa dimensão, como as posições dependem das características — são um **fator latente** θ_t . No segundo, esse fator é tratado como uma série **dinâmica no tempo** (passeio aleatório / AR(1) / filtro de Kalman), e o objetivo passa a ser **prever** o peso de meses futuros, comparando o previsto com o realizado e estudando a resultante **matriz de erros**.

Os achados são nítidos e, em parte, contra-intuitivos. *Para explicar*, as características funcionam bem: fundos maiores têm *menos* VALE3 em peso, fundos com mais cotistas têm *mais*, e FICs têm *menos* posição direta — com sinais idênticos nos 72 meses. *Para prever*, porém, nenhum modelo estrutural supera o **ingênuo** (repetir o último peso observado): o peso de VALE3 é, no nível do fundo, quase um **martingale**. A conclusão sobrevive ao refino por efeito-fixo e Kalman, à restrição aos fundos de Ações, e à **opacidade trimestral** (prever três meses à frente). Esse contraste — forte poder *explicativo*, baixo poder *preditivo* de curto prazo — é o resultado central da entrega parcial.

O restante do texto está organizado assim: a Seção 2 situa o trabalho na literatura; a Seção 3 descreve a metodologia; a Seção 4 apresenta os dados, os tratamentos e os resultados; e a Seção 5 desenha os próximos passos — a formalização do modelo de demanda com *investor/asset embeddings* e o ajuste parcial da carteira, conforme as anotações do orientador.

2 Revisão bibliográfica

Sistemas de demanda por ativos. O arcabouço de referência é o de Kojien e Yogo (2019), que tratam preços de ativos como o equilíbrio de um **sistema de demanda**: cada investidor escolhe pesos de carteira como função das **características** dos ativos, e o mercado agrega essas demandas. A demanda baseada em características reduz um problema de altíssima dimensão (milhares de ativos $\times$ milhares de investidores) a um número pequeno de *loadings*. Gabaix e Kojien (2021), na *hipótese de mercados inelásticos*,

mostram que fluxos de demanda têm efeito de preço grande, reforçando o interesse em medir diretamente a demanda dos investidores institucionais. Nossa abordagem é o “lado da quantidade” desse programa: em vez de estimar elasticidades de preço, estimamos como o **peso** de uma ação responde às características dos fundos que a detêm.

Embeddings de investidor e de ativo. A linguagem que adotamos — *investor embeddings* (o vetor de características de cada fundo) e *asset embeddings* (o vetor de fatores latentes de cada ação) — traduz a estrutura bilinear do peso: $w_{in} \approx x'_i \theta_n$. É a mesma ideia de fatorar uma matriz grande (fundos $\times$ ações) em dois conjuntos de vetores de baixa dimensão, comum em modelos de fatores latentes e em recomendação; aqui os *embeddings* do investidor são *observáveis* (características) e os do ativo são *estimados* pela regressão transversal.

Regressão transversal e fatores dinâmicos. O método de estimar coeficientes **mês a mês** e resumir sua média e variabilidade temporal é o de Fama e MacBeth (1973), padrão em *asset pricing* empírico. Tratar a sequência de coeficientes como um processo **dinâmico** e filtrá-lo recai nos modelos de **fator dinâmico** e no **filtro de Kalman** (Harvey, 1989), que separam o sinal persistente do ruído amostral das estimativas mensais.

Fluxos, demanda e negociação de fundos. A relevância dos **fluxos** (captação menos resgate) para a negociação dos fundos é documentada por Coval e Stafford (2007), que mostram vendas/compras forçadas por fluxos, e por Lou (2012), que liga fluxos à previsibilidade de retornos via demanda. Incluímos o fluxo líquido como característica justamente para testar se ele antecipa a *variação* do peso.

Previsibilidade e persistência. Por fim, a comparação contra um **benchmark ingênuo** (passeio aleatório / último valor) é a disciplina padrão da literatura de previsão: modelos só “valem” se superam a persistência. Nosso resultado — a difícil superação do ingênuo — dialoga com a vasta evidência de que muitas séries financeiras de alta frequência de divulgação são próximas de martingales no curto prazo.

3 Metodologia

Objeto. Sejam i os fundos de uma gestora M (Itaú) e n uma ação (VALE3). Para cada fundo i e mês t , o alvo é o **peso** $w_{i,t} \in [0, 1]$ de VALE3 na carteira. A leitura estrutural é que o peso observado é um *peso-alvo* w^* mais um componente estocástico:

$$w_{i,t} = w_{i,t}^* + \varepsilon_{i,t}, \quad w_{i,t}^* = x'_{i,t} \theta_{n,t}, \quad (1)$$

em que $x_{i,t}$ é o vetor de K **características do fundo** (*investor embeddings*) e $\theta_{n,t}$ é o vetor de K **fatores latentes da ação** (*asset embeddings*).

Passo 1 — regressão transversal (o fator latente). Empilhando os fundos vivos no mês t , $w_t = X_t \theta_{n,t} + \varepsilon_t$, o vetor de *loadings* é estimado por mínimos quadrados,

$$\hat{\theta}_{n,t} = (X_t' X_t)^{-1} X_t' w_t, \quad (2)$$

com as características em **z-score** (média 0, variância 1) para comparabilidade. Na prática estimamos

$$w_{i,t} = \alpha_t + \beta_t^1 \ln \text{AUM}_{i,t} + \beta_t^2 \ln \text{Cot}_{i,t} + \beta_t^3 \text{FIC}_i + \beta_t^4 \left(\frac{\text{Fluxo}}{\text{AUM}} \right)_{i,t} + \varepsilon_{i,t}, \quad (3)$$

gerando $T = 72$ vetores θ_t , resumidos no estilo **Fama–MacBeth** (média no tempo; erro-padrão pela dispersão entre meses). Preço e *beta* da ação são constantes dentro de um mês, então entram numa versão *pooled* (Modelo 2), que os identifica pela variação *entre* meses. Como o peso é limitado em $[0, 1]$, a forma correta é **não-linear**, $w = g(X\theta) + \varepsilon$ com g logística — o que motiva a versão *logit* usada na margem extensiva e prevista para os próximos passos.

Passo 2 — dinâmica do fator e previsão. Cada coeficiente $\theta_{k,t}$ é tratado como série temporal (passeio aleatório, AR(1) ou estado-espço com **filtro de Kalman**). A previsão do peso aplica o *vetor de coeficientes previsto* às características do fundo, $\hat{w}_{i,t} = \hat{\theta}_t' x_{i,t}$, e é comparada ao **benchmark ingênuo** $\hat{w}_{i,t} = w_{i,t-1}$. A diferença forma a **matriz de erros** $e_{i,t} = w_{i,t} - \hat{w}_{i,t}$, cujas propriedades (média ≈ 0 , estacionariedade) são objeto de análise. Avaliamos a previsão **fora da amostra** (treino expandido) nos horizontes $h = 1$ e $h = 3$ — este último motivado pela **opacidade trimestral**: as carteiras só são divulgadas com ≈ 90 dias de defasagem, de modo que conhecer o peso *atual* equivale a prever $t + 3$ com informação de t .

Identificação temporal (sem *look-ahead*). Cada característica é medida num momento explícito relativo ao peso de t (Tabela 1). Preço e *beta* de VALE3 têm **dois papéis**: na *explicação* usamos a **média do mês t** (o que o gestor observou *ao longo* do mês ao dimensionar a posição); na *previsão* usamos o **fim do mês $t - 1$** (predeterminado, sem *look-ahead*).

Tabela 1: Alinhamento temporal das variáveis.

Variável	Fonte	Frequência	Quando medimos (para o mês t)
Peso de VALE3 (alvo)	CONS	mensal	fim do mês t (competência)
AUM, n ^o cotistas	SH	diária	mesmo dia da competência (fim de t)
Fluxo líquido	Inf. Diário CVM	diária	soma de todo o mês t
Preço, beta VALE3	Yahoo Finance	diária	média do mês t (explicação) / fim de $t-1$ (previsão)

4 Dados e resultados

4.1 Fontes, amostra e tratamentos

As bases primárias são duas séries da CVM: a **CONS** (composição consolidada das carteiras, mensal), de onde vem o peso de VALE3 (*posição direta*, VALE ON N1 - VALE3), e a **SH** (série histórica, diária), de onde vêm AUM (patrimônio líquido), número de cotistas e a classificação FIC/FI. O **fluxo líquido** (captação — resgate) vem do **Informe Diário** da CVM — a base-mãe da SH, única com resgate, validada contra a SH (99,7% dos fundo-meses batem ao centavo). Preço e *beta* de VALE3 vêm do **Yahoo Finance**, certificados contra o fechamento oficial da B3 (diferença máxima de R\$0,00 nas datas de referência).

Os tratamentos permanentes são: normalização do nome da gestora (acento/caixa/sufixos); *dedup* de linhas exatamente duplicadas da CONS; remoção de pesos negativos residuais ($\sim -10^{-6}$); auditoria de unicidade de (*fundo, t*); e remoção de **fundos exclusivos** (filtro cotistas > 3). O *merge* SH $\times$ CONS é feito pelo **dia exato** da competência, com 100% de *match*.

Amostra. Painel fundo $\times$ mês, 2016–2021 (72 meses), gestoras Itaú, com > 3 cotistas: **11.532** observações (11.413 com fluxo) e centenas de fundos. A margem intensiva (com VALE3) tem **11.413** fundo-meses; o painel *extensivo* (fundos de Ações, incluindo zeros) tem **10.286** fundo-meses, 86% com VALE3.

Tabela 2: Estatísticas descritivas (margem intensiva, > 3 cotistas, com fluxo; $n = 11.413$).

Variável	Média	DP	Mediana	Mín	Máx
Peso VALE3 (%)	2,87	3,52	1,22	0,00	23,55
AUM (R\$ milhões)	399	1.079	68,3	0,04	17.866
Nº de cotistas	10.202	72.039	105	4	696.013
Fluxo líq. (R\$ mi)	5,7	74,1	0,0	-1.522	1.636
Preço VALE3 (R\$)	54,6	27,2	50,9	9,94	114,1
Beta VALE3	1,04	0,30	0,97	0,68	1,73

AUM e cotistas são fortemente assimétricos (média $\gg$ mediana) — daí o log. **75,7%** das observações são de FICs. Preço e beta de VALE3 são fortemente correlacionados ($-0,71$): na recuperação 2016–2021 o preço subiu e o beta caiu.

4.2 Modelo 1 — determinantes do peso (Fama–MacBeth)

A regressão transversal (3), resumida à Fama–MacBeth, dá os determinantes do *nível* do peso (Tabela 3).

R^2 médio por mês = 0,152. *** $p < 0,001$. Leitura: fundo **maior** $\rightarrow$ menos VALE3 em peso; **mais cotistas** $\rightarrow$ mais; **FIC** $\rightarrow$ menos posição direta; o **fluxo não explica o nível**. Sinais idênticos nos 72 meses $\Rightarrow$ fatores estáveis.

Tabela 3: Modelo 1 — cross-section mês a mês (Fama–MacBeth, $T = 72$).

Variável	Coef. médio	EP (FM)	t	Meses +	Sig.
Intercepto	0,08939	0,00413	21,6	72/72	***
log(AUM)	−0,00376	0,00019	−19,3	0/72	***
log(cotistas)	0,00387	0,00020	19,8	72/72	***
FIC (dummy)	−0,01697	0,00089	−19,2	0/72	***
Fluxo/AUM	−0,00044	0,00309	−0,14	39/72	n.s.

4.3 Modelo 2 — versão *pooled* (preço e beta da ação)

Empilhando os 72 meses, preço e *beta* (média do mês t) passam a ser identificados pela variação entre meses (Tabela 4).

Tabela 4: Modelo 2 — pooled com preço e beta ($n = 11.413$, $R^2 = 0,166$).

Variável	Estimativa	EP	t	Sig.
Intercepto	0,09937	0,00406	24,5	***
log(AUM)	−0,00354	0,00019	−19,0	***
log(cotistas)	0,00388	0,00013	30,9	***
FIC (dummy)	−0,01682	0,00079	−21,3	***
Fluxo/AUM	−0,00030	0,00034	−0,91	n.s.
Preço VALE3	0,000182	0,000016	11,5	***
Beta VALE3	−0,02141	0,00142	−15,1	***

Preço + (parte é *mecânica*: se a ação sobe, sua fração cresce sozinha); **Beta** − (VALE3 mais arriscada → peso menor). No piloto de 12 meses (2016) o beta saía positivo e fraco — confirmando que poucos pontos no tempo o desidentificam.

4.4 Dinâmica do fator θ_t

Cada coeficiente é persistente mas **reverte à média** (autocorrelação $\approx 0,7$ – $0,84$; Dickey–Fuller rejeita raiz unitária): não são passeios aleatórios puros (Figura 1). Isso justifica modelá-los por AR(1)/Kalman em vez de um *random walk* ingênuo nos coeficientes.

4.5 Modelo 3 — previsão e a matriz de erros

Avaliando fora da amostra, **nenhum** modelo estrutural supera o **ingênuo** (Tabela 5). Acrescentar efeito-fixo de fundo ($\hat{\mu}_i$) ou prever os fatores por Kalman **piora**; modelar a *variação* Δw apenas empata. O efeito-fixo (média histórica) ser pior que o *lag* mostra que o peso **não reverte à média no nível do fundo** — é quase um **martingale**. A matriz de erros do melhor modelo tem média ≈ 0 e é estacionária (Dickey–Fuller $t = -8,7$), como o orientador queria verificar.

A $h = 3$ o ingênuo *piora* (+33%) e a distância aos modelos estruturais encolhe, mas ele **ainda vence**. Restringir a Ações torna a conclusão mais nítida, não a inverte.




Figura 1: Coeficientes θ_t da regressão transversal (2016–2021); tracejado = média.

Tabela 5: Previsão fora da amostra (RMSE). $h = 1$ e $h = 3$ (opacidade de 90 dias).

Universo	Horizonte	M0 Ingênuo	M1 Efeito-fixo	M2 FE+Kalman	M3 Δw
Todos holders	$h = 1$	0,0156	0,0240	0,0255	0,0156
Todos holders	$h = 3$	0,0207	0,0262	0,0273	0,0210
Só Ações	$h = 1$	0,0197	0,0310	0,0383	0,0198
Só Ações	$h = 3$	0,0266	0,0337	0,0385	0,0270

4.6 Modelo 4 — margem extensiva (ter ou não ter VALE3)

Incluindo os **zeros** (fundos de Ações que não detêm VALE3), um *logit* da *posse* sobre $\ln AUM$, $\ln Cot$ e FIC revela o achado mais interessante: as duas margens têm **sinais opostos** (Tabela 6). Fundos maiores e FICs são *mais propensos a ter* VALE3, mas com *peso menor* — o padrão clássico de **diversificação**. A posse é ainda mais persistente que o peso (muda em 1,3% dos meses); prevê-la fora da amostra, o ingênuo acerta 98,7% contra 87,2% do logit.

Tabela 6: Sinais opostos entre as duas margens.

Característica	Ter ou não (extensiva, logit)	Quanto (intensiva)
Tamanho (AUM)	+ mais provável ter	– peso menor
FIC	+ mais provável ter	– peso menor
Cotistas	– (fraco)	+

4.7 Síntese dos resultados

O peso de VALE3 nos fundos Itaú é **bem explicado** pela seção transversal (tamanho, cotistas, FIC, beta) e **mal previsto** no curto prazo: é quase um martingale no nível do fundo, com inércia que nenhum modelo estrutural bate, mesmo sob a opacidade trimestral. O modelo de fator é, por ora, uma ferramenta de *compreensão*, não de previsão — o que motiva os próximos passos.

5 Próximos passos

A continuação do trabalho formaliza a abordagem de **sistema de demanda** esboçada pelo orientador, em duas frentes: o *ajuste parcial* da carteira e a *regra de decisão* sob o *lag* de divulgação.

5.1 O peso-alvo e os *embeddings* (revisão da especificação)

Voltamos à especificação (1)–(2), mas tornando-a explicitamente **não-linear** (o peso é limitado):

$$w_{i,n} = g(x'_i \theta_n) + \varepsilon_{i,n}, \quad \hat{\theta}_n = (X'X)^{-1} X' w_n, \quad (4)$$

em que x_i (z-score) são os **investor embeddings** (características dos fundos) e θ_n são os **asset embeddings** (fatores latentes da ação), e g é uma função logística. A cada mês t obtém-se um $\hat{\theta}_{n,t}$ — a base do fator dinâmico já estimado nesta entrega.

5.2 Ajuste parcial da carteira

O elo dinâmico entre meses é um modelo de **ajuste parcial**: o fundo move o peso atual em direção ao alvo, mas só parcialmente, a uma **velocidade de ajuste** $\lambda_n \in (0, 1)$:

$$w_{i,t+1} = (1 - \lambda_n) w_{i,t} + \lambda_n w_{i,t}^* + u_{i,t+1}. \quad (5)$$

Reescrevendo em termos da variação do peso e usando $\varepsilon_{i,t} = w_{i,t}^* - w_{i,t}$ (a distância ao alvo), obtém-se uma relação linear estimável:

$$\underbrace{w_{i,t+1} - w_{i,t}}_{d_{i,t+1}} = \lambda_n \varepsilon_{i,t} + u_{i,t+1}. \quad (6)$$

Ou seja, a **variação** do peso de um mês para o outro deve ser proporcional à **distância ao alvo** no mês anterior, com a constante de proporcionalidade λ_n medindo a *velocidade* com que o fundo persegue o alvo. A velocidade de ajuste é estimada regredindo a variação observada sobre a distância estimada:

$$\hat{\lambda}_n = (\hat{\varepsilon}_{n,t} \hat{\varepsilon}_{n,t})^{-1} \hat{\varepsilon}_{n,t} d_{n,t+1}. \quad (7)$$

Como $\hat{\varepsilon}$ é um regressor estimado (logo, ruidoso e possivelmente multicolinear), o orientador anota que essa etapa será feita **provavelmente por *ridge regression*** — regularizando $\hat{\lambda}_n$ para estabilizá-lo. O **erro de previsão do peso** fica, então,

$$\hat{u}_{n,t+1} = d_{n,t+1} - \hat{\lambda}_n \hat{\varepsilon}_{n,t} = (w_{n,t+1} - w_{n,t}) - \hat{\lambda}_n (X_t \hat{\theta}_n - w_{n,t}). \quad (8)$$

Empilhando no tempo, a série $\{\hat{u}_{n,t}\}$ é exatamente a **matriz de erros** preditivos que queremos caracterizar (média, variância, estacionariedade). A intuição que liga isto à entrega atual: se $\hat{\lambda}_n \approx 0$, o ajuste parcial **degenera no benchmark ingênuo** ($w_{t+1} \approx w_t$) — coerente com o que já encontramos, e o teste formal será justamente *se λ_n é estatisticamente distinto de zero*.

5.3 Série temporal e a regra de decisão (opacidade de 90 dias)

A estimação é **recursiva**: usam-se $t = 1$ e $t = 2$ para estimar os parâmetros (θ_n e λ_n) e, de $t = 3$ em diante, gera-se a série de **erros preditivos**. A regra de decisão incorpora a **opacidade trimestral**: como as carteiras só ficam visíveis ≈ 90 dias depois, qualquer decisão em t usa apenas a informação de t e $t + 1$ e mira três passos à frente. Concretamente, comparam-se os erros de previsão de **três passos** ($t+2$, $t+3$, $t+4$), e só a partir de $t + 5$ o modelo estaria em condição de **tomar uma decisão** de carteira fundamentada. Esse desenho operacionaliza a pergunta econômica final: *conhecendo as características dos fundos e a dinâmica do alvo, é possível antecipar as posições antes de elas serem divulgadas?*

5.4 Agenda complementar

Além do modelo acima, ficam encaminhados: (i) generalizar para **outras ações e gestoras** (o *pipeline* já é parametrizável); (ii) *winsorizar* o Fluxo/AUM (caudas extremas de fundos minúsculos); (iii) decompor o peso em parte **passiva** (efeito mecânico do preço) e **ativa** (decisão do gestor); e (iv) tratar formalmente a margem extensiva por um modelo *hurdle* (duas partes). O código, os dados e as decisões metodológicas estão versionados no repositório `forecasting-fund-weights-vale-ita`.

Referências

- [1] Coval, J.; Stafford, E. (2007). Asset Fire Sales (and Purchases) in Equity Markets. *Journal of Financial Economics*, 86(2), 479–512.
- [2] Fama, E. F.; MacBeth, J. D. (1973). Risk, Return, and Equilibrium: Empirical Tests. *Journal of Political Economy*, 81(3), 607–636.
- [3] Gabaix, X.; Koijen, R. S. J. (2021). In Search of the Origins of Financial Fluctuations: The Inelastic Markets Hypothesis. *NBER Working Paper* 28967.

- [4] Harvey, A. C. (1989). *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge University Press.
- [5] Hoerl, A. E.; Kennard, R. W. (1970). Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1), 55–67.
- [6] Kojen, R. S. J.; Yogo, M. (2019). A Demand System Approach to Asset Pricing. *Journal of Political Economy*, 127(4), 1475–1515.
- [7] Lou, D. (2012). A Flow-Based Explanation for Return Predictability. *Review of Financial Studies*, 25(12), 3457–3489.