

Peso de VALE3 nos fundos de investimento brasileiros:
um modelo de fator dinâmico com correção logística e ajuste
parcial

João Paulo Zangrandi

Fundação Getulio Vargas — Escola de Economia de São Paulo (FGV–EESP)

Orientador: Prof. Mauricio Ferraresi

Sumário

1	Introdução	2
2	Revisão de literatura	2
3	Dados	2
3.1	Fontes	2
3.2	Universo e período	2
3.3	Limpeza de custódia	4
3.4	Características do fundo	4
3.5	Amostra final	5
4	Metodologia	5
4.1	Etapa 1: cross-section	6
4.2	Etapa 2: ajuste parcial	6
4.3	Etapa 3: esquema fora da amostra	7
4.4	Extensões	8
5	Resultados	8
5.1	Etapa 1: cross-section	8
5.2	Etapa 2: ajuste parcial	12
5.3	Etapa 3: esquema fora da amostra	13
6	Aplicação	29
7	Conclusão	29

1 Introdução

[Seção a ser escrita por último.]

2 Revisão de literatura

[Seção a ser desenvolvida após indicação de referências pelo orientador. Áreas de inserção previstas: precificação de ativos baseada em demanda (demand-based asset pricing); comportamento de fundos de investimento e efeitos de fluxo; modelos de ajuste parcial em finanças corporativas e de portfólio.]

3 Dados

3.1 Fontes

Os dados usados neste trabalho vêm de dois registros públicos que a Comissão de Valores Mobiliários (CVM) exige de todo fundo de investimento brasileiro. O primeiro é a Composição e Diversificação de Aplicações (CDA), um extrato mensal em que cada fundo declara, ativo por ativo, o valor de mercado e a participação percentual de cada posição em sua carteira — é dele que vem a variável dependente deste trabalho, o peso de um ativo na carteira de um fundo em um determinado mês. O segundo é o Informe Diário, que traz, para cada fundo e cada dia útil, o patrimônio líquido, o número de cotistas, a captação e o resgate do dia, e o valor da cota — é dele que vêm as características do fundo usadas como variáveis explicativas.

3.2 Universo e período

O período coberto vai de janeiro de 2016 a dezembro de 2021. O universo de fundos partiu dos fundos administrados pelo grupo Itaú e foi ampliado, em etapas, para tornar os resultados mais gerais e menos sujeitos a alguma particularidade de uma única gestora. A ampliação seguiu dois eixos independentes: o primeiro amplia *quais fundos* entram na amostra — de só Itaú (308 fundos) para todo o universo CVM que já teve VALE3 em carteira em algum momento do período (2.820 fundos, agrupados em 41 grupos de gestora por marca controladora; por exemplo, os quatro rótulos que a CVM usa para a BTG Pactual são tratados como um único grupo); o segundo amplia *quais ativos* são observados dentro desses mesmos fundos — de um único papel (VALE3) para todas as ações que eles carregam.

Cada etapa dessa ampliação produz **dois** números de fundos, que não devem ser confundidos entre si. O **universo bruto** é quantos fundos entram na consideração, só pelo critério de elegibilidade (ser do grupo Itaú, ou já ter tido VALE3 em algum momento) — não depende de nenhum dado além da posição em si. A **amostra final** é quantos desses fundos sobram depois

de exigidas as cinco características do modelo (Seção 4) simultaneamente disponíveis em pelo menos um mês — um número sempre menor que o universo bruto, porque nem todo fundo tem AUM, cotistas, fluxo, indicador de FIC e beta completos ao mesmo tempo em algum mês. A Tabela 1 mostra as duas colunas lado a lado.

Tabela 1: Evolução do universo de dados ao longo do trabalho.

Etapa	Fundos		Gestoras	Ativos	Observações
	Universo	Amostra final			
Amostra inicial (só Itaú, só VALE3)	308	250	1	1	8.335
Ampliação de gestoras (todo o universo CVM, só VALE3)	2.820	2.295	41	1	71.569
Ampliação de ativos (todo o universo CVM, todas as ações)	2.820	2.347	41	501	8.268.920

Observações em fundo(-ativo)-mês. A Seção 5 organiza os resultados por etapa (Seção 4): as Etapas 1 e 2 (estimativas e erros e , u) usam a amostra inicial (250 fundos, só VALE3); a Etapa 3 (erro fora da amostra) começa nessa mesma amostra inicial e depois generaliza para a amostra amplamente expandida (última linha desta tabela).

Um detalhe da Tabela 1 merece atenção porque, à primeira vista, parece contraditório: a coluna de amostra final **cresce** da segunda para a terceira linha (de 2.295 para 2.347 fundos) mesmo com o universo bruto permanecendo **idêntico** (2.820 nos dois casos — é literalmente o mesmo conjunto de fundos). A explicação está em como a exigência das cinco características é aplicada: um fundo só entra na amostra final se tiver, em **algum** mês, todas as cinco disponíveis ao mesmo tempo. Na etapa “só VALE3”, esse “algum mês” só pode ser um mês em que o fundo carregava VALE3 — se, digamos, um fundo teve VALE3 só em janeiro e fevereiro de 2018, e o número de cotistas dele faltava no Informe Diário da CVM justamente nesses dois meses, esse fundo fica de fora da amostra final, mesmo que em outros meses (sem VALE3) ele tivesse as cinco características completas. Na etapa “todas as ações”, esse mesmo fundo ganha uma chance a mais: se ele carregava, por exemplo, Petrobras em março de 2018, e nesse mês o dado de cotistas estava completo, esse mês passa a contar, e o fundo entra na amostra final — sem que nenhum fundo novo tenha sido adicionado ao universo bruto. Olhar todas as ações que um fundo carrega, em vez de só VALE3, multiplica o número de (fundo, mês) candidatos a satisfazer as cinco exigências de dado ao mesmo tempo; por isso a amostra final cresce, mesmo partindo do mesmo universo de 2.820 fundos.

Vale perguntar, especificamente, por que 473 dos 2.820 fundos do universo bruto (todas as gestoras, todos os ativos, sem nenhum filtro por ativo específico) ficam de fora da amostra final. A resposta, verificada fundo a fundo sobre o histórico completo de cotas de 2016 a 2021 (não uma amostra): 28 fundos (5,9% dos 473) nunca têm patrimônio, cotistas, fluxo e indicador de FIC completos ao mesmo tempo em nenhum mês, independente do beta. Os outros 445 (94,1%) têm essas quatro características completas em algum mês, mas nunca chegam a ter beta — e o motivo, para a esmagadora maioria deles, é simplesmente não ter acumulado histórico de cota

suficiente dentro da janela do trabalho, não fechamento precoce: 406 desses 445 fundos (91,2%) nunca somam 252 dias de cota válida em toda a janela 2016–2021, e portanto jamais teriam beta calculável mesmo que a amostra usasse o período inteiro; dentre estes, 263 (65%) só começam a reportar cota em 2021, isto é, são fundos jovens demais para acumular um ano de histórico antes do fim da amostra (dezembro de 2021). Um grupo bem menor, 18 fundos (4,0% dos 445), tem os 252 dias acumulados sem lacunas relevantes na série, mas começa a reportar cota por volta de novembro/dezembro de 2020 — tarde o suficiente para que o primeiro beta válido só surgisse perto do fim da amostra, sem mais nenhum mês seguinte disponível para usá-lo como preditor defasado ($t-1$). Apenas os 21 fundos restantes (4,7% dos 445) têm histórico suficiente que termina antes de novembro de 2021, um padrão mais consistente com fechamento ou saída do fundo. Em suma: quase toda a perda de fundos por causa do beta (424 dos 445, ou 95,3%) reflete fundos jovens demais para a janela do trabalho, não uma limitação de dado nem fundos que encerraram atividades.

A mesma exigência simultânea das cinco características do fundo (Seção 4) também reduz a cobertura temporal de 72 para 59 meses efetivos (fevereiro de 2017 a dezembro de 2021): o beta do fundo precisa de pelo menos 252 pregões de histórico de cota (cerca de um ano) para ser calculado, o que deixa os primeiros doze meses da amostra sem fundos suficientes. Essa perda de cobertura inicial foi uma escolha deliberada, não uma limitação inesperada do dado: preferiu-se um conjunto menor de meses com as cinco características completas a um conjunto maior com características faltantes preenchidas de forma arbitrária.

3.3 Limpeza de custódia

Um mesmo ativo pode aparecer na CDA sob rótulos diferentes conforme o tipo de posição que o fundo mantém: posição direta, posição cedida ou recebida em empréstimo, ou direito de subscrição. Manter todos esses rótulos juntos infla artificialmente o peso de um ativo e mistura posições de natureza econômica distinta. Este trabalho mantém apenas a posição direta, identificada pelo sufixo numérico do código de negociação (convenção da B3: os sufixos 3, 4, 5, 6, 7, 8 e 11 correspondem a ações ordinárias, preferenciais e units; outros sufixos e palavras-chave associadas a empréstimo ou subscrição são descartados). Essa limpeza resulta em 523 ativos de posição direta e 10.603.928 linhas de fundo-ativo-mês antes dos demais filtros.

3.4 Características do fundo

Cinco características de cada fundo entram no modelo, todas medidas no último dia do mês anterior ao da observação — nenhuma delas usa informação contemporânea ao próprio mês, o que evita viés de antecipação (*look-ahead bias*): o tamanho do fundo (logaritmo do patrimônio líquido), o número de cotistas (logaritmo), um indicador de ser fundo de cotas de outro fundo (FIC), o fluxo líquido de captação menos resgate como proporção do patrimônio, e o beta do

próprio fundo — a covariância do retorno diário da cota do fundo com o retorno do Ibovespa, dividida pela variância do retorno do Ibovespa, numa janela móvel de 252 pregões, terminando no último pregão do mês anterior. As quatro primeiras características vêm do Informe Diário; a quinta é construída a partir da série de cotas do próprio fundo.

3.5 Amostra final

Depois de exigidas as cinco características simultaneamente, a amostra usada na etapa de regressão cross-section por ativo-mês (Seção 4) tem 8.268.920 observações de fundo-ativo-mês, cobrindo os 2.347 fundos e 501 ativos mencionados. A Tabela 2 resume as principais dimensões dessa amostra final.

Tabela 2: Dimensões da amostra final (base multiativo — todas as gestoras, todos os ativos).

Observações (fundo $\times$ ativo $\times$ mês)	8.268.920
Fundos	2.347
Grupos de gestora	41
Ativos (posição direta)	501
Meses (fev/2017–dez/2021)	59

Esta é a maior base do trabalho, mas **não** é usada em todas as tabelas e figuras da Seção 5 — só na parte generalizada da Etapa 3 (Seção 5.3, a partir da Figura 8). As Seções 5.1, 5.2 e o início da 5.3 usam a amostra inicial menor (VALE3–Itaú, 250 fundos, Tabela 1). Cada tabela e figura a seguir indica explicitamente qual base usa.

[Tabelas/figuras adicionais de cobertura — por exemplo, distribuição do número de fundos por gestora, ou evolução do número de fundos ativos por mês — a incluir conforme indicação do orientador na próxima reunião.]

4 Metodologia

O trabalho é organizado em três etapas sequenciais, cada uma alimentando a seguinte. A primeira etapa estima, mês a mês, o peso que cada fundo *deveria* carregar em cada ativo, dadas as características observáveis do fundo. A segunda etapa modela a velocidade com que o peso efetivamente observado converge a esse alvo. A terceira etapa testa, em dados que o modelo nunca viu durante a estimação, se essa modelagem tem valor preditivo genuíno. Em cada uma das três etapas, o erro — a diferença entre o que o modelo previu e o que de fato aconteceu — não é descartado: ele é o principal objeto de análise deste trabalho, na medida em que sua estrutura (quem erra mais, quando, e em que direção) é o que permite comparar fundos e gestoras entre si e avaliar se o modelo tem poder explicativo genuíno ou apenas se ajusta ao passado.

4.1 Etapa 1: cross-section

Para cada ativo n e cada mês t , o peso que um fundo i carrega é modelado como função logística de cinco características do fundo:

$$\text{peso}_{i,n,t} = g(x'_{i,n,t}\theta_{n,t}) + e_{i,n,t}, \quad g(z) = \frac{1}{1 + e^{-z}} \quad (1)$$

em que $x_{i,n,t}$ reúne as cinco características descritas na Seção 3 (padronizadas, exceto o indicador de fundo de cotas) e $\theta_{n,t}$ é o vetor de coeficientes daquele ativo naquele mês, estimado por máxima verossimilhança (regressão logística quase-binomial). A função $g(\cdot)$ garante que a previsão nunca saia do intervalo $[0, 1]$, respeitando o fato de que peso é, por definição, uma fração da carteira — uma regressão linear comum não teria essa garantia. A regressão é estimada separadamente para cada célula (ativo, mês) que tenha um número mínimo de fundos detentores, sem nenhuma etapa de agregação temporal por cima (não é um procedimento em dois passos como Fama–MacBeth): cada $\theta_{n,t}$ é o resultado de uma única regressão de corte transversal.

O erro dessa etapa, $e_{i,n,t} = \text{peso}_{i,n,t} - g(x'_{i,n,t}\theta_{n,t})$, mede o quanto a posição observada de um fundo se afasta do que suas próprias características explicam, *dentro* do mesmo mês. Por construção da máxima verossimilhança, a média desse erro é mecanicamente zero em cada célula — não é evidência de bom ajuste, apenas uma propriedade algébrica do estimador. O que de fato varia, e é informativo, é a **dispersão** do erro: um fundo cujo erro é consistentemente pequeno tem posições bem explicadas pelas cinco características observáveis; um fundo cujo erro é grande e disperso tem posições que fogem desse padrão — convicção própria do gestor, não captada pelas variáveis do modelo.

4.2 Etapa 2: ajuste parcial

A Etapa 1 estima um alvo, $w_{i,n,t}^* = g(x'_{i,n,t}\theta_{n,t})$, mas não diz nada sobre a *dinâmica*: quão rápido a posição real de um fundo converge a esse alvo, mês a mês. A segunda etapa modela essa dinâmica através de um mecanismo de ajuste parcial, hipótese padrão em modelos de rebalanceamento de portfólio: a cada mês, o fundo fecha uma fração λ da distância entre sua posição atual e o alvo.

$$w_{i,n,t+1} - w_{i,n,t} = \lambda d_{i,n,t} + u_{i,n,t+1}, \quad d_{i,n,t} \equiv w_{i,n,t}^* - w_{i,n,t} \quad (2)$$

λ é estimado por mínimos quadrados ordinários diretos, sem intercepto, com todos os pares de meses consecutivos agrupados (*pooled*) — um único coeficiente, a mesma velocidade de ajuste para todo fundo e todo ativo. O erro dessa etapa, $u_{i,n,t+1}$, mede o quanto a mudança de posição observada difere do que o ajuste parcial previu: valores de u próximos de zero indicam fundos cuja movimentação segue de perto a velocidade média de ajuste estimada; valores grandes indicam movimentos abruptos — apostas concentradas de curto prazo — que o modelo, por construção,

não tem como antecipar.

4.3 Etapa 3: esquema fora da amostra

As duas primeiras etapas são estimadas com a amostra inteira e, por isso, não dizem se o modelo tem valor preditivo de verdade — um coeficiente pode explicar bem o passado e não generalizar para dados novos. A terceira etapa testa isso diretamente, com um corte temporal único: o parâmetro λ (e, na generalização a seguir, λ_h para cada horizonte h) é reestimado usando **apenas** os meses de treino, anteriores a janeiro de 2020, e então aplicado, fixo, aos meses de teste, de janeiro de 2020 em diante — período que o modelo nunca viu durante a estimação.

$$\begin{aligned}\hat{w}_{i,n,t+h} &= w_{i,n,t} + \hat{\lambda}_{h,\text{treino}} d_{i,n,t} && \text{(ajuste parcial)} \\ \hat{w}_{i,n,t+h} &= w_{i,n,t} && \text{(previsão ingênua)}\end{aligned}\tag{3}$$

O erro fora da amostra, $\text{erro}_{i,n,t+h} = (w_{i,n,t+h} - w_{i,n,t}) - \hat{\lambda}_{h,\text{treino}} d_{i,n,t}$, é comparado ao erro da previsão ingênua (que simplesmente assume que nada muda) através da raiz do erro quadrático médio (RMSE). A diferença percentual entre os dois RMSEs — chamada, neste trabalho, de **margem** — responde à pergunta que interessa de fato: o ajuste parcial estimado com dados antigos ainda ajuda a prever dados novos, ou uma previsão ingênua seria tão boa quanto?

Robustez: λ fixo vs. janela expansiva. O corte único mantém λ_h congelado no valor de treino durante todo o período de teste — uma escolha deliberada de simplicidade (Seção 4), mas que levanta a dúvida óbvia: um λ_h reestimado a cada mês, incorporando os dados de teste já observados até ali (janela expansiva, sem nenhum vazamento — cada $\lambda_{h,s}$ usa só pares cujo resultado já era conhecido antes do mês s), previa melhor? A Tabela 3 responde que não, de forma consistente nas duas versões da amostra: a razão RMSE/ingênua praticamente não muda, o padrão de quais meses o ajuste parcial vence a previsão ingênua é idêntico entre as duas versões de λ , e — na base multiativo, que sustenta a maior parte desta seção de Resultados — o ranking de dificuldade de previsão por gestora tem correlação de Spearman de 1,0000 entre as duas versões. Isso valida empiricamente a simplificação: atualizar λ_h mês a mês não captura nenhuma dinâmica relevante que o valor fixo, estimado uma única vez, já não capture.

Tabela 3: λ fixo (treino único) vs. janela expansiva (reestimado mês a mês, sem vazamento), fora da amostra, $h = 1$. Colunas 3–4: razão RMSE/RMSE ingênua.

Base	Meses de teste	λ fixo	λ expansiva
VALE3–Itaú (250 fundos)	23	0,9846	0,9813
Multiativo (2.343 fundos, 501 ativos)	23	0,9837	0,9837

Em ambas as bases, o ajuste parcial vence a previsão ingênua exatamente nos mesmos meses sob as duas versões de λ (14 de 23 na base VALE3–Itaú; 23 de 23 na base multiativo).

Por que a análise do erro é o centro deste trabalho

As três etapas descritas acima poderiam ser resumidas, cada uma, num único número: um R^2 , um $\hat{\lambda}$, uma margem agregada. Mas o valor deste trabalho está em não parar nesse resumo. Agregando o erro fora da amostra por fundo, por gestora e por ativo — e comparando essa agregação entre horizontes de previsão ($h = 1, 3, 6, 12$ meses) — é possível identificar *quais* fundos e gestoras têm posições bem explicadas pelo modelo e quais têm comportamento que foge sistematicamente dele, de forma estável ao longo do tempo e não apenas como um acidente de uma única janela de teste. Essa estrutura de erro é a base de toda a Seção de Resultados deste trabalho e, potencialmente, de uma aplicação prática discutida na Seção 6.

4.4 Extensões

O procedimento descrito acima — Etapas 1 a 3 — é aplicado primeiro à ação VALE3 dentro dos fundos do grupo Itaú, e depois generalizado em dois eixos independentes, já descritos na Seção 3: para todas as gestoras do universo CVM (através de um efeito fixo de gestora somado ao preditor linear da equação (1)), e para todas as ações que essas gestoras carregam (repetindo a equação (1) célula por célula de ativo-mês, em vez de uma única regressão para VALE3). A Etapa 3 — o esquema fora da amostra — é igualmente generalizada: o índice de ativo n e o horizonte h passam a ser explícitos na equação (2), permitindo agregar o erro fora da amostra por gestora, por ativo e por horizonte de previsão simultaneamente.

5 Resultados

[Texto analítico desta seção a ser escrito após nova rodada de discussão com o orientador. Tabelas e figuras abaixo já validadas em versões anteriores do documento de trabalho v2 OFICIAL.tex; as legendas foram mantidas apenas descritivas.]

5.1 Etapa 1: cross-section

Relembrando a equação (1), $\text{peso}_{i,n,t} = g(x'_{i,n,t}\theta_{n,t}) + e_{i,n,t}$: para cada ativo n e mês t , o modelo logístico estima o peso que cada fundo i *deveria* carregar, a partir de $x_{i,n,t}$ (as cinco características do fundo) e $\theta_{n,t}$ (os coeficientes daquele ativo naquele mês). O erro $e_{i,n,t}$ é a distância entre o peso observado e essa previsão: por construção da máxima verossimilhança, sua média é mecanicamente zero em cada célula (ativo, mês) — não é evidência de bom ajuste, é uma propriedade algébrica do estimador. O que de fato varia, e é informativo, é a **dispersão** do erro: um fundo cujo erro é consistentemente pequeno tem posições bem explicadas pelas cinco características observáveis; um fundo cujo erro é grande e disperso tem posições que fogem desse padrão. As tabelas e figuras abaixo cobrem primeiro as estimativas de $\theta_{n,t}$, e em seguida a

estatística do erro e que elas produzem.

Tabela 4: Θ logístico: antes e depois do beta do fundo (mesma amostra, 59 meses, teste de significância $t = \hat{\theta}/(\text{dp}(\hat{\theta})/\sqrt{59})$). Base: VALE3–Itaú (250 fundos, 1 ativo).

Variável	Média (sem β^{fundo})	Sig.	Média (com β^{fundo})	Sig.
α	−3,1262	***	−3,8110	***
θ^{aum} (tamanho)	−0,2749	***	−0,0594	***
θ^{cot} (cotistas)	0,4429	***	0,0493	***
θ^{fic} (fundo de cotas)	−0,6669	***	−0,2149	***
θ^{flow} (captação/resgate)	0,4402	n.s.	0,1396	n.s.
θ^{bf} (beta do fundo)	—	—	1,0110	***
Pseudo- R^2 (McFadden) médio	0,164		0,614	

* $p < 5\%$, ** $p < 1\%$, *** $p < 0,1\%$.

Tabela 5: Efeito marginal médio (APE) do logit, em pontos percentuais de peso — mesma comparação sem/com beta do fundo. Base: VALE3–Itaú (250 fundos, 1 ativo).

Característica	APE (sem β^{fundo})	Sig.	APE (com β^{fundo})	Sig.
Tamanho	−0,00734	***	−0,00154	***
Cotistas	0,01271	***	0,00111	***
Fundo de cotas	−0,02222	***	−0,00580	***
Captação/resgate	0,01068	n.s.	0,00449	n.s.
Beta do fundo	—	—	0,02942	***

Tabela 6: Estatísticas do erro e , Etapa 1 (8.335 observações). Base: VALE3–Itaú (250 fundos, 1 ativo).

Estatística	Valor
Média	0,000000
Desvio-padrão	0,0227
Mediana	−0,0008
Mínimo / Máximo	−0,113 / 0,178
% de observações com $e > 0$	45,1%
Assimetria	0,39
Curtose	7,67 (normal = 3)
Previsões fora de $[0, 1]$	0 de 8.335




Figura 1: Os seis componentes de θ_t logístico (com beta do fundo) ao longo dos 59 meses, e o pseudo- R^2 de McFadden de cada regressão mensal. Base: VALE3–Itaú (250 fundos, 1 ativo).




Figura 2: Histograma do erro e (8.335 observações). A linha tracejada marca zero. Base: VALE3–Itaú (250 fundos, 1 ativo).




Figura 3: Evolução mês a mês do erro e : nuvem cinza = erro individual de cada fundo-mês; linha azul = média mensal (mecanicamente zero); linha vermelha tracejada = desvio-padrão mensal. Base: VALE3-Itaú (250 fundos, 1 ativo).

5.2 Etapa 2: ajuste parcial

Relembrando a equação (2), $w_{i,n,t+1} - w_{i,n,t} = \lambda d_{i,n,t} + u_{i,n,t+1}$, com $d_{i,n,t} \equiv w_{i,n,t}^* - w_{i,n,t}$: o alvo $w_{i,n,t}^* = g(x'_{i,n,t} \theta_{n,t})$ vem da Etapa 1 (Seção 5.1), e $d_{i,n,t}$ é a distância entre a posição atual do fundo e esse alvo. O ajuste parcial modela a mudança de posição de um mês para o outro como uma fração λ dessa distância, estimada por MQO pooled (Seção 4) — um único coeficiente para todo fundo e todo ativo. O erro $u_{i,n,t+1}$ mede o quanto a mudança de posição observada difere do que essa velocidade média de ajuste previu: valores próximos de zero indicam fundos cuja movimentação segue de perto o λ estimado; valores grandes indicam movimentos abruptos — apostas concentradas de curto prazo — que o modelo, por construção, não tem como antecipar.

Tabela 7: Estatísticas do erro u , Etapa 2 (7.987 observações, pares de meses consecutivos). Base: VALE3–Itaú (250 fundos, 1 ativo).

Estatística	Valor
Média	0,0002
Desvio-padrão	0,0151
Mediana	−0,0004
Mínimo / Máximo	−0,160 / 0,185
% de observações com $u > 0$	44,3%
Assimetria	0,59
Curtose	19,4 (normal = 3)




Figura 4: Histograma do erro u (7.987 observações). Base: VALE3–Itaú (250 fundos, 1 ativo).




Figura 5: Evolução mês a mês do erro u . Base: VALE3–Itaú (250 fundos, 1 ativo).

5.3 Etapa 3: esquema fora da amostra

Relembrando a equação (3): $\hat{w}_{i,n,t+h} = w_{i,n,t} + \hat{\lambda}_{h,\text{treino}} d_{i,n,t}$ (ajuste parcial) contra $\hat{w}_{i,n,t+h} = w_{i,n,t}$ (previsão ingênua), com λ_h estimado **apenas** nos meses de treino (anteriores a janeiro de 2020) e aplicado, fixo, aos meses de teste — dados que o modelo nunca viu durante a estimação (a robustez dessa escolha de λ fixo está discutida na Seção 4). O erro fora da amostra, $\text{erro}_{i,n,t+h} = (w_{i,n,t+h} - w_{i,n,t}) - \hat{\lambda}_{h,\text{treino}} d_{i,n,t}$, mede o quanto essa previsão — feita com um parâmetro estimado em dados que o modelo nunca viu no período de teste — erra ao prever a mudança de posição real. É esse erro que responde à pergunta central deste trabalho (Seção 4): o ajuste parcial estimado com dados antigos ainda ajuda a prever dados novos, ou uma previsão ingênua seria tão boa quanto? As tabelas e figuras a seguir cobrem primeiro o caso de base ($h = 1$, VALE3–Itaú), e depois a generalização completa — todas as gestoras, todos os ativos, quatro horizontes de previsão — que estrutura o restante desta subseção.

Tabela 8: RMSE e MAE dentro e fora da amostra, ajuste parcial vs. ingênua. Base: VALE3–Itaú (250 fundos, 1 ativo).

Amostra	Modelo	RMSE	MAE
Treino (2017–2019)	Ajuste parcial	0,01463	—
Treino (2017–2019)	Ingênua	0,01510	—
Teste (2020–2021)	Ajuste parcial	0,01560	0,00906
Teste (2020–2021)	Ingênua	0,01585	0,00847




Figura 6: RMSE dentro (treino) e fora (teste) da amostra, ajuste parcial vs. ingênua. Base: VALE3–Itaú (250 fundos, 1 ativo).




Figura 7: RMSE mês a mês no período completo (2017–2021). A linha vermelha tracejada marca o início do teste (2020-01). Base: VALE3–Itaú (250 fundos, 1 ativo).

A generalização da Etapa 3 — índice de ativo n e horizonte h explícitos na equação (2), conforme a Seção 4 — permite ir além do RMSE agregado acima e perguntar *quem* erra mais: quais fundos, gestoras e ativos têm erro fora da amostra pequeno e estável, e quais fogem sistematicamente do modelo. **A partir daqui, e até o final desta subseção, todas as tabelas e figuras usam a base multiativo** (2.343 fundos, 41 gestoras, 501 ativos) — não mais a amostra VALE3–Itaú das seções anteriores.

Um filtro adicional de qualidade de dado, específico desta análise de erro. A Tabela 2 (Seção 3) reporta 2.347 fundos e 8.268.920 observações para a amostra final multiativo — 4 fundos e 44.072 observações a mais do que os números usados nesta subseção. A diferença vem de um problema encontrado ao investigar, em detalhe, o fundo com maior RMSE fora da amostra que este trabalho havia identificado (a versão anterior da Figura 11, adiante): a soma das participações de *todas* as posições declaradas por aquele fundo, num único mês da CDA da CVM, chegava a quase 500% do patrimônio — confirmado na fonte bruta, não é erro deste trabalho, e concentrado no período em que o fundo estava em liquidação acelerada (patrimônio caindo de R\$59 milhões para R\$1,6 milhão em seis meses). Verificando a base inteira, esse tipo de inconsistência (soma de participações acima de 105% do patrimônio) aparece em 597 dos 85.788 pares fundo-mês (0,7%), espalhados por 73 fundos — raro, mas real, e capaz de distorcer o erro calculado para os fundos afetados. Esses fundo-meses foram excluídos **antes** de qualquer regressão ou cálculo de erro (Etapa 1 e Etapa 3 recalculadas do zero sobre a base já limpa), o que reduz o RMSE agregado fora da amostra em 4,45% ($h = 1$) e 3,86% ($h = 3$) — uma correção real, não cosmética, embora o ranking de dificuldade por gestora praticamente não mude (correlação de Spearman de 0,97 entre o ranking antes e depois da limpeza). O caso mais afetado, disparado, é a Vinci Partners: RMSE ($h = 1$) cai 44% com a limpeza, puxado quase inteiramente pelo fundo problemático. Uma auditoria mais ampla das duas bases (pesos negativos ou > 1 , AUM/cotistas ausentes ou negativos, beta do fundo fora de um intervalo razoável, linhas duplicadas) não encontrou outro problema dessa magnitude; o único ponto adicional — fluxo de captação/resgate acima de 200% do patrimônio no mesmo mês, em 74 fundos (0,06% das observações, tipicamente fundos quase zerados por resgates que somem quase todo o patrimônio dentro do próprio mês) — muda o RMSE agregado em apenas 0,09% se excluído, e por isso não foi removido.




Figura 8: Evolução mensal do erro médio fora da amostra ($h = 1$), para as 3 gestoras mais difíceis de prever e as 3 mais previsíveis em todos os horizontes testados (Tabelas 10 e 11). Base: multiativo (2.343 fundos, 41 gestoras, 501 ativos).




Figura 9: Erro fora da amostra ao longo do período de teste (2020–2021), agregado em todos os fundos, gestoras e ativos — nuvem cinza: erro individual de cada fundo-ativo-mês; linha azul: média mensal; linha vermelha: desvio-padrão mensal. Painel esquerdo: $h = 1$ mês; painel direito: $h = 3$ meses. Base: multiativo (2.343 fundos, 41 gestoras, 501 ativos).




Figura 10: Margem do ajuste parcial sobre a previsão ingênua, mês a mês, ao longo de todo o período de teste (2020–2021) — $h = 1$ e $h = 3$. Complementa a Tabela 11 (que resume a margem do período inteiro num único número por gestora e horizonte) mostrando se essa vantagem é estável ao longo do tempo. Base: multiativo (2.343 fundos, 41 gestoras, 501 ativos).




Figura 11: Peso real vs. peso previsto pelo ajuste parcial ($h = 3$), fundo 396303 (Guepardo Investimentos), em JSLG3 — o fundo com maior RMSE fora da amostra na base já limpa (nota acima). O modelo não antecipa o desmonte de uma posição concentrada: o fundo tinha 69,5% do patrimônio em JSLG3 em jan/2020 e reduziu para 3,8% já em fev/2020, patamar em que permaneceu; baseado no peso elevado observado em jan/2020, o ajuste parcial previa continuidade em torno de 60% para abr/2020, quando o peso real já estava perto de zero havia meses. Base: multiativo (2.343 fundos, 41 gestoras, 501 ativos) — este gráfico exibe apenas um fundo e um ativo (JSLG3) dessa base, para ilustração.




Figura 12: Viés médio mensal fora da amostra ($h = 1$, com sinal — não apenas magnitude), para as 3 gestoras com viés mais positivo e as 3 com viés mais negativo (entre gestoras com pelo menos 100 observações de teste). Pergunta diferente da magnitude do erro: quem compra ou vende sistematicamente mais do que o modelo prevê. Base: multiativo (2.343 fundos, 41 gestoras, 501 ativos).

Esta parte final da subseção segue uma cadeia de perguntas, cada uma motivada pela resposta da anterior. A Figura 12 mostrou que algumas gestoras compram (ou vendem) sistematicamente mais do que o modelo prevê — um viés. Daqui em diante, nessa ordem: esse viés é um traço real da gestora, ou coincidência da janela de teste? Se é real, dá pra corrigir a previsão com base nele? Por que essa correção ajuda tão pouco? A parte do erro que sobra — a variância — também é um traço estável da gestora, ou é ruído puro? O que explica essa variância? E, por fim, esses achados valem só para o horizonte de um mês, ou se mantêm ao tentar prever 3, 6 ou 12 meses à frente?

O viés é persistente, mas explica pouco do erro. Um viés grande e estável seria evidência de que uma gestora tem um estilo sistemático (convicção própria, mandato diferente) não capturado pelas cinco características do modelo — vale então perguntar se o padrão da Figura 12 é um traço real da gestora ou um acidente da janela de teste. Dividindo os 23 meses de teste ao meio e comparando o viés médio de cada gestora nas duas metades, a correlação é 0,80 ($R^2 = 0,63$, $p < 0,0001$): o viés é, de fato, persistente.




Figura 13: Persistência do viés por gestora: viés médio na 1ª metade do período de teste (2020-01 a 2020-12) vs. na 2ª metade (2021-01 a 2021-11), 40 gestoras com pelo menos 50 observações em cada metade. Base: multiativo (2.343 fundos, 41 gestoras, 501 ativos).

Sendo persistente, o viés poderia em princípio ser corrigido: estimando-o só na 1ª metade do teste e aplicando-o, como um ajuste fixo, às previsões da 2ª metade (que nunca entraram nessa estimativa), o RMSE agregado da 2ª metade cai de 0,005705 para 0,005701 — uma melhora de apenas 0,07%. A correção ajuda mais nas gestoras com viés mais extremo (Guepardo Investimentos, $-3,5\%$ de RMSE; Real Investor, $-3,1\%$; Núcleo Capital, $-3,1\%$), mas é irrelevante para a maioria. A razão fica clara na decomposição a seguir.

Por que o viés importa pouco: a variância domina o erro. Pense em dois arqueiros atirando num alvo, onde “erro” é a distância de cada flecha ao centro. O primeiro erra pouco, mas sempre um pouco para o mesmo lado — um desvio sistemático, fácil de corrigir (basta mirar um pouco mais para o outro lado). O segundo acerta o centro *em média*, mas cada flecha cai num lugar diferente — imprevisibilidade genuína, sem direção fixa, que nenhum ajuste simples corrige. Os dois podem ter o mesmo erro médio ao quadrado, por motivos opostos: o primeiro por **viés**, o segundo por **variância**. A identidade $\text{RMSE}^2 = \text{viés}^2 + \text{variância}$ — a mesma relação algébrica por trás da fórmula usual de variância, $\text{Var}(X) = E[X^2] - E[X]^2$ — separa essas duas fontes de erro para cada gestora, e permite medir exatamente qual das duas pesa mais.




Figura 14: Decomposição $\text{RMSE}^2 = \text{viés}^2 + \text{variância}$ do erro fora da amostra ($h = 1$), por gestora, ordenada por RMSE. Base: multiativo (2.343 fundos, 41 gestoras, 501 ativos).

Em média entre as 40 gestoras, o viés² explica só 0,65% do RMSE^2 (mediana 0,15%); mesmo a Guepardo, a mais enviesada, chega a apenas 5,70%. Somando todas as observações da base (*pooled*, em vez de médias por gestora), o viés² é essencialmente 0% do erro total. A variância — não o viés — é, de longe, a peça que domina o erro fora da amostra, o que explica por que a correção acima rende tão pouco.

A variância também é persistente. Se a variância domina o erro, vale perguntar se ela também é um traço estável da gestora ou apenas ruído ano a ano. Repetindo o teste de persistência (1ª vs. 2ª metade do teste), agora para o desvio-padrão do erro em vez da média: correlação de 0,85 ($R^2 = 0,71$, $p < 0,0001$) — quase tão persistente quanto o viés. Gestoras mais imprevisíveis continuam mais imprevisíveis de um período para o outro.




Figura 15: Persistência da dispersão do erro por gestora: desvio-padrão do erro na 1ª metade do teste vs. na 2ª metade, mesmas 40 gestoras da Figura 13. A linha tracejada é a identidade ($y = x$); a linha sólida é o ajuste linear. Base: multiativo (2.343 fundos, 41 gestoras, 501 ativos).

O que explica a variância: concentração da carteira, mais do que beta ou tamanho.

Sendo a variância a peça relevante do erro, e sendo ela previsível de uma gestora para a outra, cabe perguntar o que a determina. Cruzando o desvio-padrão do erro de cada gestora contra três características — beta médio do fundo, tamanho médio (log do PL) e concentração média da carteira (índice HHI dos pesos por ativo, dentro de cada fundo-mês) — a concentração se destaca claramente: correlação de 0,71 ($R^2 = 0,50$), contra 0,52 ($R^2 = 0,27$) do beta e apenas 0,17 ($R^2 = 0,03$) do tamanho.




Figura 16: Desvio-padrão do erro fora da amostra por gestora ($h = 1$) vs. beta médio do fundo, tamanho médio (log AUM) e concentração média da carteira (HHI), 40 gestoras. Base: multiativo (2.343 fundos, 41 gestoras, 501 ativos).

As três correlações acima são bivariadas — cada característica sozinha contra a dispersão do erro — e não dizem se elas têm efeito *independente* umas das outras, ou se estão só capturando a mesma coisa por tabela (gestoras com beta alto podem também ser, coincidentemente, mais concentradas). Para isolar o efeito de cada característica, mantendo as outras duas fixas, as três entram juntas numa única regressão linear, por gestora ($g = 1, \dots, 40$):

$$\text{dp(erro)}_g = \alpha + \beta_1 \overline{\text{beta}}_g + \beta_2 \overline{\log(\text{AUM})}_g + \beta_3 \overline{\text{HHI}}_g + u_g \quad (4)$$

Tabela 9: Regressão múltipla (equação (4)): desvio-padrão do erro fora da amostra por gestora ($h = 1$) explicado por beta médio, tamanho médio e concentração média, juntos. 40 gestoras.

Variável	Coefficiente	t	Sig.
Intercepto (α)	-0,0098	-0,87	n.s.
Beta médio do fundo (β_1)	0,0016	0,69	n.s.
Tamanho médio, log AUM (β_2)	0,0007	1,16	n.s.
Concentração média, HHI (β_3)	0,0961	4,45	***
R^2		0,53	

Variável dependente: desvio-padrão do erro fora da amostra por gestora ($h = 1$). *** $p < 0,1\%$; n.s. = não significativo a 5%.

O resultado responde à pergunta: só a concentração (β_3) continua estatisticamente significativa depois de controlar pelas outras duas — beta e tamanho, que pareciam relevantes sozinhos (Figura 16), perdem significância quando a concentração entra na mesma regressão. Isso sugere que a relação entre beta e RMSE mostrada na Figura 18 a seguir é, em boa parte, um reflexo indireto da concentração — gestoras com fundos de beta alto tendem também a manter carteiras mais concentradas, e é a concentração, não o beta em si, que parece determinar o quão imprevisível é a mudança de posição.

Concentração no nível fundo-mês: sobretudo um traço entre fundos, não dentro do fundo. O resultado acima usa uma única média de concentração por gestora — 40 pontos — e por isso não distingue duas perguntas bem diferentes. Pense em alunos de uma turma, horas de estudo por semana vs. nota da prova daquela semana: jogando os dados de *todos* os alunos numa nuvem só, aparece uma correlação forte, mas em boa parte porque existe um *tipo* de aluno — o dedicado estuda muito toda semana e tira nota alta toda semana; o relapso, o oposto. Isso é uma diferença *entre* alunos, não diz nada sobre uma semana específica. A pergunta diferente é: pegando um único aluno, nas semanas em que *ele* estudou um pouco mais do que é normal para *ele mesmo*, tirou uma nota um pouco melhor do que é normal para ele mesmo? Essa é uma pergunta sobre variação *dentro* do mesmo aluno, e pode ter uma resposta bem diferente da correlação geral. Refinando o resultado da concentração para o nível fundo-mês — a concentração da carteira de um fundo específico, num mês específico, contra o erro desse mesmo fundo nesse mesmo mês, com dezenas de milhares de pares em vez de 40 — é possível separar as duas perguntas em três versões.




Figura 17: Concentração da carteira (HHI) vs. erro fora da amostra (RMS), nível fundo-mês, em decis. (A) contemporânea: HHI do mês t vs. erro do mês t . (B) defasada: HHI do mês $t-1$ vs. erro do mês t . (C) dentro do fundo: ambos os eixos com a média de cada fundo subtraída, isolando a variação temporal dentro do mesmo fundo. Barras de erro = ± 1 erro-padrão da média por decil. Base: multiativo (2.343 fundos, 41 gestoras, 501 ativos).

Nas versões contemporânea e defasada (painéis A e B), a correlação é praticamente idêntica (0,41 e 0,43) — a concentração do mês *anterior*, que já era conhecida antes do erro acontecer, prediz o erro do mês seguinte quase tão bem quanto a concentração do próprio mês, afastando a hipótese de que a relação seja só uma coincidência dentro do mesmo mês. Já a versão dentro do fundo (painel C, que subtrai de cada fundo sua própria média de concentração e de erro, isolando a variação temporal de um mesmo fundo em relação a si mesmo) mostra uma correlação quase nula (0,06): a concentração é, quase inteiramente, um traço que diferencia fundos *entre si* — um fundo tipicamente mais concentrado do que a média tende a errar mais do que a média — e não um sinal de curto prazo de que um fundo específico está prestes a errar mais do que o normal

dele mesmo.

Como prometido, a figura a seguir mostra essa relação entre beta e RMSE diretamente:




Figura 18: Beta médio do fundo (Etapa 1) vs. RMSE fora da amostra ($h = 1$), 1.941 fundos com pelo menos 6 observações de teste, após o mesmo filtro de posição-poeira usado nas demais figuras (peso mediano da célula fundo-ativo $\geq 0,1\%$). A característica que mais explica o *peso* (Tabela 4) também explica parte de quem é mais difícil de prever *fora da amostra*: $R^2 = 0,24$. Base: multiativo (2.343 fundos, 41 gestoras, 501 ativos) — o beta do fundo usado aqui é o mesmo conceito estimado na Etapa 1, recalculado nessa base maior.

Uma pergunta diferente: o erro de um fundo específico se repete de um mês para o outro? As persistências testadas até aqui (viés e variância) comparam o comportamento *médio* de uma gestora numa metade do período de teste (cerca de 11 meses) contra a outra — um traço de longo prazo, como perguntar se um jogador de futebol abaixo da média no primeiro turno de um campeonato continua abaixo da média no segundo turno. A pergunta agora é bem diferente, e olha para um único fundo, mês a mês: depois de errar numa direção *neste* mês, esse fundo tende a errar na mesma direção *no mês seguinte* — uma “fase ruim” que se repete de um mês para o outro, como um jogador que, depois de uma partida ruim, tende a jogar mal na partida seguinte também? A figura a seguir testa isso e encontra que não — a correlação é essencialmente zero. As duas coisas não se contradizem: um fundo pode ser, de fato, geralmente mais difícil de prever (um traço estável de longo prazo, já mostrado acima) sem que um mês ruim específico avise nada sobre o mês seguinte.




Figura 19: Persistência do erro fora da amostra dentro do mesmo fundo: erro médio no mês t vs. erro médio no mês $t + 1$ (agregado por fundo-mês, 33.600 pares consecutivos, 1.917 fundos), e distribuição da autocorrelação lag-1 entre os 1.636 fundos com pelo menos 8 pares. Correlação pooled = 0,015; autocorrelação média entre fundos = $-0,077$ — sem evidência de persistência mês a mês na *direção* do erro, distinto da estabilidade de *magnitude* (RMSE) entre horizontes mostrada na Figura a seguir. Base: multiativo (2.343 fundos, 41 gestoras, 501 ativos).

Os achados valem só para $h = 1$, ou se mantêm em horizontes mais longos? Tudo até aqui usou $h = 1$ (previsão de um mês à frente). A figura a seguir verifica se o ranking de dificuldade por gestora — quem é mais difícil de prever — muda quando o horizonte de previsão aumenta para 3, 6 ou 12 meses.




Figura 20: Estabilidade do ranking de dificuldade de previsão (RMSE fora da amostra) entre os 4 horizontes testados, 40 gestoras com dado completo em todos os horizontes (exclui Legacy Capital, que só tem observação em $h = 1$). As gestoras mais extremas (destacadas) permanecem nos extremos em todos os horizontes; a correlação de Spearman entre rankings varia de 0,90 ($h = 1$ vs. $h = 12$, os mais distantes) a 0,98 ($h = 6$ vs. $h = 12$, os mais próximos). Base: multiativo (2.343 fundos, 41 gestoras, 501 ativos).

As duas tabelas a seguir trazem os números completos por trás da figura acima: RMSE e margem de todas as 41 gestoras, nos quatro horizontes.

Tabela 10: RMSE fora da amostra por gestora, todos os 430 ativos com par (treino, teste) válido em $h = 1$ — dos 501 ativos da amostra final, 71 não têm cobertura suficiente nesse horizonte — em 4 horizontes, ordenado do mais ao menos errante em $h = 1$. Base: multiativo (2.343 fundos, 41 gestoras, 501 ativos).

Gestora	Fundos ($h=1$)	RMSE $h=1$	RMSE $h=3$	RMSE $h=6$	RMSE $h=12$
Ibiuna Investimentos	7	0,01478	0,02373	0,02761	0,03372
Guepardo Investimentos	10	0,01444	0,02385	0,03553	0,06153
AZ Quest	22	0,01096	0,01462	0,01651	0,01878
Núcleo Capital	17	0,01044	0,01829	0,02488	0,03536
Squadra Investimentos	14	0,01007	0,01390	0,01680	0,02126
Forpus Capital	3	0,00951	0,01374	0,01555	0,01559
Truxt Investimentos	31	0,00809	0,01258	0,01592	0,01952
Sharp Capital	34	0,00801	0,01290	0,01699	0,02096
Legacy Capital	1	0,00798	—	—	—
ARX Investimentos	12	0,00792	0,01084	0,01262	0,01516
Kinea Investimentos	4	0,00718	0,01161	0,01516	0,01544
Constellation Asset Management	26	0,00692	0,01377	0,01844	0,02774
Opportunity	19	0,00678	0,01053	0,01353	0,01595
SPX Capital	35	0,00613	0,00916	0,01167	0,01331

continua na próxima página

(continuação)

Gestora	Fundos ($h=1$)	RMSE $h=1$	RMSE $h=3$	RMSE $h=6$	RMSE $h=12$
Atmos Capital	28	0,00612	0,00998	0,01340	0,01706
Verde Asset Management	14	0,00600	0,01021	0,01293	0,01632
Daycoval Asset Management	5	0,00582	0,00733	0,00741	0,00787
Absolute Investimentos	7	0,00562	0,00865	0,01098	0,01312
JGP	40	0,00554	0,00774	0,00893	0,01075
Kapitalo Investimentos	22	0,00538	0,00580	0,00691	0,00823
Bogari Capital	14	0,00532	0,00932	0,01210	0,01593
Credit Suisse	65	0,00503	0,00701	0,00828	0,00943
Real Investor	5	0,00485	0,00898	0,01412	0,01757
Claritas Investimentos	10	0,00481	0,00709	0,00795	0,00843
Caixa	27	0,00461	0,00681	0,00888	0,01140
Western Asset	26	0,00435	0,00697	0,00958	0,01249
Bradesco Asset Management	277	0,00430	0,00601	0,00719	0,00850
Vinci Partners	48	0,00420	0,00636	0,00745	0,00847
BB Asset Management	103	0,00413	0,00642	0,00804	0,00988
Occam Brasil	26	0,00411	0,00668	0,00764	0,01002
Santander Brasil Asset Management	70	0,00391	0,00542	0,00625	0,00729
BTG Pactual	139	0,00391	0,00586	0,00688	0,00854
Safra Asset Management	136	0,00341	0,00482	0,00573	0,00644
BNP Paribas	42	0,00300	0,00434	0,00526	0,00691
XP	87	0,00293	0,00444	0,00535	0,00742
Julius Baer Family Office	57	0,00261	0,00364	0,00452	0,00553
Itaú	440	0,00260	0,00385	0,00469	0,00551
Dahlia Capital	18	0,00247	0,00426	0,00556	0,00625
TNA Gestão Patrimonial	29	0,00151	0,00218	0,00281	0,00387
Gávea Investimentos	17	0,00144	0,00265	0,00363	0,00471
Plural	1	0,00050	0,00080	0,00105	0,00136

Tabela 11: Margem do ajuste parcial sobre a ingênua (% de redução de RMSE), por gestora, 4 horizontes — mesma ordem da Tabela 10. Negativo = ajuste parcial pior que a ingênua. Base: multiativo (2.343 fundos, 41 gestoras, 501 ativos).

Gestora	Margem $h=1$	Margem $h=3$	Margem $h=6$	Margem $h=12$
Ibiuna Investimentos	3,5%	7,4%	7,9%	14,3%
Guepardo Investimentos	-0,2%	-2,4%	-5,9%	-10,3%
AZ Quest	3,2%	6,9%	9,8%	14,9%
Núcleo Capital	-1,5%	-2,9%	-2,8%	-5,9%
Squadra Investimentos	0,7%	0,5%	-0,1%	-1,2%
Forpus Capital	1,8%	5,8%	8,9%	17,8%
Truxt Investimentos	1,7%	3,7%	6,0%	13,6%
Sharp Capital	1,6%	4,8%	8,8%	16,4%
Legacy Capital	-11,0%	—	—	—
ARX Investimentos	2,0%	4,2%	6,8%	7,5%
Kinea Investimentos	2,1%	4,0%	9,4%	11,9%
Constellation Asset Management	-0,7%	-0,0%	2,5%	3,4%
Opportunity	1,6%	3,8%	6,4%	9,2%

continua na próxima página

(continuação)

Gestora	Margem $h=1$	Margem $h=3$	Margem $h=6$	Margem $h=12$
SPX Capital	2,8%	6,8%	11,0%	18,3%
Atmos Capital	0,1%	2,8%	5,0%	11,7%
Verde Asset Management	0,6%	1,6%	3,3%	0,4%
Daycoval Asset Management	3,3%	6,0%	8,4%	13,3%
Absolute Investimentos	1,5%	4,0%	6,3%	5,9%
JGP	2,2%	4,0%	4,8%	8,1%
Kapitalo Investimentos	2,9%	6,0%	7,4%	8,2%
Bogari Capital	-0,7%	-0,2%	0,3%	-4,3%
Credit Suisse	2,4%	4,7%	7,7%	14,0%
Real Investor	-2,0%	0,6%	1,6%	7,4%
Claritas Investimentos	1,6%	5,7%	10,5%	18,5%
Caixa	1,9%	4,3%	7,0%	9,8%
Western Asset	1,2%	3,2%	5,4%	5,8%
Bradesco Asset Management	1,9%	3,6%	4,6%	4,3%
Vinci Partners	1,5%	4,3%	8,2%	18,9%
BB Asset Management	1,1%	2,6%	3,8%	4,9%
Occam Brasil	2,2%	4,8%	7,7%	9,9%
Santander Brasil Asset Management	2,0%	4,1%	5,5%	6,9%
BTG Pactual	1,7%	3,0%	4,1%	5,1%
Safra Asset Management	1,9%	3,2%	5,5%	8,8%
BNP Paribas	0,8%	0,7%	-0,5%	-1,0%
XP	-3,4%	-6,5%	-11,4%	-13,0%
Julius Baer Family Office	1,4%	2,8%	4,5%	6,6%
Itaú	1,9%	4,3%	6,2%	7,9%
Dahlia Capital	2,2%	5,4%	8,2%	10,7%
TNA Gestão Patrimonial	-0,2%	-1,5%	-1,8%	1,5%
Gávea Investimentos	2,0%	4,1%	8,0%	10,6%
Plural	-3,1%	-4,7%	-3,9%	-7,6%

Por fim, a figura a seguir junta as duas dimensões discutidas nesta subseção — dificuldade absoluta (RMSE) e se o ajuste parcial realmente ajuda (margem) — num único gráfico, uma gestora por ponto.




Figura 21: Cada ponto é uma gestora: RMSE fora da amostra em $h=1$ (eixo x , dificuldade absoluta) vs. margem sobre a ingênua em $h=1$ (eixo y , negativo = ajuste parcial piora). Base: multiativo (2.343 fundos, 41 gestoras, 501 ativos).

6 Aplicação

[Seção ainda incerta quanto à inclusão no TCC, conforme indicação do orientador. Descreve uma estratégia — apelidada internamente de “robô caça-replicantes” — que usa a estrutura do erro fora da amostra (Seção 5) para identificar pares de fundos cujo erro se move em sincronia além do que suas características observáveis explicam.]

7 Conclusão

[Seção a ser escrita após a Introdução.]