

Peso de VALE3 nos fundos de investimento brasileiros:
um modelo de fator dinâmico com correção logística e ajuste
parcial

João Paulo Zangrandi

Fundação Getulio Vargas — Escola de Economia de São Paulo (FGV–EESP)

Orientador: Prof. Mauricio Ferraresi

Sumário

1	Introdução	3
2	Revisão de literatura	3
3	Dados	3
3.1	Fontes e universo	3
3.2	Limpeza e características	4
3.3	Amostra final	4
4	Metodologia	4
4.1	Etapa 1: cross-section	5
4.2	Etapa 2: ajuste parcial	6
4.3	Etapa 3: esquema fora da amostra	6
4.4	Extensões	7
5	Resultados	7
5.1	Etapa 1: cross-section	7
5.2	Etapa 2: ajuste parcial	8
5.3	Etapa 3: esquema fora da amostra	8
6	Aplicação: robô caça-replicantes	20
6.1	Universo completo e correção de efeito mecânico	20
6.2	Etapas 1–3 no universo completo	21
6.3	Deteção de pares replicantes	22
6.4	Sinal do robô	23

6.5	O teste decisivo: fluxo previsto prediz retorno?	24
6.6	Síntese: o que está validado e o que não está	26
7	Conclusão	27

1 Introdução

[Seção a ser escrita por último.]

2 Revisão de literatura

[Seção a ser desenvolvida após indicação de referências pelo orientador. Áreas de inserção previstas: precificação de ativos baseada em demanda (demand-based asset pricing); comportamento de fundos de investimento e efeitos de fluxo; modelos de ajuste parcial em finanças corporativas e de portfólio.]

3 Dados

3.1 Fontes e universo

Os dados vêm de dois registros públicos que a CVM exige de todo fundo de investimento brasileiro: a Composição e Diversificação de Aplicações (CDA), extrato mensal de que vem o peso de cada ativo na carteira de cada fundo (a variável dependente deste trabalho), e o Informe Diário, de onde vêm patrimônio líquido, cotistas, captação e resgate (as características do fundo). O período coberto vai de janeiro de 2016 a dezembro de 2021. O universo de fundos parte de todo fundo do universo CVM que já teve VALE3 em carteira em algum momento do período (2.820 fundos, 41 grupos de gestora por marca controladora), e para esses fundos observa-se **toda ação** que carregam, não só VALE3.

Tabela 1: Evolução do universo de dados. Fonte: scripts 17–29 → `painel_multiativo_final.csv`.

Etapa	Universo	Amostra final	Gestoras	Ativos
Ampliação de gestoras (todo o universo CVM, só VALE3)	2.820	2.295	41	1
Ampliação de ativos (todo o universo CVM, todas as ações)	2.820	2.347	41	501

Amostra final = fundos com as 6 características (Seção 3) simultaneamente disponíveis em pelo menos um mês. A cobertura temporal efetiva é de 59 meses (fev/2017–dez/2021, não os 72 meses do período bruto): o beta do fundo exige 252 pregões de histórico de cota, o que exclui os primeiros 12 meses da amostra.

Dos 473 fundos do universo bruto que não entram na amostra final, 28 nunca têm as quatro características do Informe Diário completas ao mesmo tempo; os outros 445 têm essas quatro, mas nunca chegam a ter beta — 91,2% deles (406) simplesmente não acumulam 252 dias de cota válida na janela 2016–2021 (fundos jovens demais, não uma limitação de dado), 4,0% (18) acumulam mas começam tarde demais para deixar mês seguinte disponível como preditor, e só 4,7% (21) têm um padrão mais consistente com fechamento do fundo.

3.2 Limpeza e características

Um mesmo ativo pode aparecer na CDA sob rótulos diferentes conforme o tipo de posição (direta, cedida/recebida em empréstimo, direito de subscrição). Este trabalho mantém apenas a posição direta, identificada pelo sufixo numérico do código de negociação (convenção B3: sufixos 3, 4, 5, 6, 7, 8, 11) — 523 ativos de posição direta, 10.603.928 linhas de fundo-ativo-mês antes dos demais filtros.

Seis características de cada fundo entram no modelo (equação (1)), todas medidas no último dia do mês anterior ao da observação, para evitar viés de antecipação:

Tabela 2: As 6 características da Etapa 1. Fonte: Informe Diário da CVM (5 primeiras) e `painel_multiativo_final.csv` (HHI_{resto} , derivado do próprio peso defasado).

Característica	Definição
Tamanho	Logaritmo do patrimônio líquido
Cotistas	Logaritmo do número de cotistas
FIC	Indicador (0/1) de ser fundo de cotas de outro fundo
Fluxo/AUM	(Captação – resgate) sobre o patrimônio líquido
Beta do fundo	Covariância do retorno diário da cota com o Ibovespa / variância do Ibovespa, janela móvel de 252 pregões
HHI_{resto}	Concentração do restante da carteira de ações no fechamento do mês anterior , excluindo o ativo-alvo (equação (2)) — calculado sobre o sub-portfólio de ações capturado neste painel (não o NAV inteiro do fundo, que também pode incluir renda fixa e caixa não observados aqui); fundos sem dado de carteira em $t - 1$ ficam sem essa característica (2,6% das linhas)

3.3 Amostra final

Tabela 3: Dimensões da amostra final. Fonte: `painel_multiativo_final.csv`.

Observações (fundo $\times$ ativo $\times$ mês)	8.268.920
Fundos	2.347
Grupos de gestora	41
Ativos (posição direta)	501
Meses (fev/2017–dez/2021)	59

Esta é a amostra final antes da limpeza descrita na Seção 5 (597 fundo-mês com soma de peso $> 105\%$ do patrimônio, erro de reporte da CDA, excluídos antes de qualquer regressão) — a Seção 5 usa, uma única vez do início ao fim, a versão já limpa (2.343 fundos), ao contrário da versão anterior deste documento, que trocava de base entre Etapas.

4 Metodologia

O trabalho é organizado em três etapas sequenciais, cada uma alimentando a seguinte. A primeira etapa estima, mês a mês, o peso que cada fundo *deveria* carregar em cada ativo, dadas as características observáveis do fundo. A segunda etapa modela a velocidade com que o peso

efetivamente observado converge a esse alvo. A terceira etapa testa, em dados que o modelo nunca viu durante a estimação, se essa modelagem tem valor preditivo genuíno. Em cada uma das três etapas, o erro é o principal objeto de análise: sua estrutura (quem erra mais, quando, e em que direção) é o que permite comparar fundos e gestoras entre si.

4.1 Etapa 1: cross-section

Para cada ativo n e cada mês t , o peso que um fundo i carrega é modelado como função logística de seis características do fundo:

$$\text{peso}_{i,n,t} = g(x'_{i,n,t}\theta_{n,t}) + e_{i,n,t}, \quad g(z) = \frac{1}{1 + e^{-z}} \quad (1)$$

em que $x_{i,n,t}$ reúne seis características do fundo (Seção 3): tamanho (log AUM), número de cotistas (log), indicador de fundo de cotas (FIC), fluxo de captação/resgate sobre o patrimônio, beta do próprio fundo, e a concentração do restante da carteira ($\text{HHI}_{\text{resto}}$, definida na equação (2) abaixo) — todas padronizadas, exceto o indicador de FIC, e todas medidas no fechamento do mês anterior ($t - 1$), sem exceção. $\theta_{n,t}$ é o vetor de coeficientes daquele ativo naquele mês, estimado por máxima verossimilhança (regressão logística quase-binomial), separadamente para cada célula (ativo, mês) com número mínimo de fundos detentores, sem nenhuma etapa de agregação temporal por cima: cada $\theta_{n,t}$ é o resultado de uma única regressão de corte transversal.

$$\text{HHI}_{\text{resto},i,n,t} = \text{HHI}_{\text{total},i,t-1} - \text{peso}_{i,n,t-1}^2, \quad \text{HHI}_{\text{total},i,t-1} = \sum_m \text{peso}_{i,m,t-1}^2 \quad (2)$$

$\text{HHI}_{\text{resto}}$ mede a concentração da carteira de ações do fundo i no **fechamento do mês anterior**, excluindo o peso que o próprio ativo-alvo n tinha naquele mesmo fechamento — excluir n evita a circularidade óbvia de usar a concentração de uma carteira que já inclui o peso que se está tentando explicar como variável explicativa dele mesmo; defasar para $t - 1$ garante a mesma disciplina de predeterminação das outras 5 características. Fundos sem nenhum dado de carteira em $t - 1$ (fundo novo, por exemplo) ficam sem essa característica e saem da amostra — 2,6% das linhas.

Essa característica passou por uma correção de percurso que vale registrar. O piloto que motivou sua inclusão (amostra aleatória de 100 células ativo-mês, sem viés de seleção) usava o peso do **mesmo mês** t , não de $t - 1$: 77% das células com coeficiente significativo, sinal positivo em 75 das 77, ganho médio de pseudo- R^2 de 0,080. Uma auditoria posterior identificou que essa versão contemporânea contradizia a disciplina de defasagem das outras 5 características, então o teste foi refeito com a versão defasada (equação acima): a força do efeito se manteve quase idêntica (72,1% de significância contra 72,3% da versão contemporânea, 95,2% de sinal positivo nos dois casos) — evidência de que o efeito não era um artefato mecânico de usar a mesma foto

de carteira duas vezes. A versão defasada passou a ser a especificação oficial deste trabalho.

O erro dessa etapa, $e_{i,n,t} = \text{peso}_{i,n,t} - g(x'_{i,n,t}\theta_{n,t})$, mede o quanto a posição observada de um fundo se afasta do que suas próprias características explicam, *dentro* do mesmo mês. Por construção da máxima verossimilhança, a média desse erro é mecanicamente zero em cada célula — não é evidência de bom ajuste, apenas uma propriedade algébrica do estimador. O que de fato varia, e é informativo, é a dispersão do erro.

4.2 Etapa 2: ajuste parcial

A Etapa 1 estima um alvo, $w_{i,n,t}^* = g(x'_{i,n,t}\theta_{n,t})$, mas não diz nada sobre a *dinâmica*: quão rápido a posição real de um fundo converge a esse alvo, mês a mês. A segunda etapa modela essa dinâmica através de um mecanismo de ajuste parcial: a cada mês, o fundo fecha uma fração λ da distância entre sua posição atual e o alvo.

$$w_{i,n,t+1} - w_{i,n,t} = \lambda d_{i,n,t} + u_{i,n,t+1}, \quad d_{i,n,t} \equiv w_{i,n,t}^* - w_{i,n,t} \quad (3)$$

λ é estimado por mínimos quadrados ordinários diretos, sem intercepto, com todos os pares de meses consecutivos agrupados (*pooled*) — um único coeficiente, a mesma velocidade de ajuste para todo fundo e todo ativo.

4.3 Etapa 3: esquema fora da amostra

As duas primeiras etapas são estimadas com a amostra inteira e, por isso, não dizem se o modelo tem valor preditivo de verdade. A terceira etapa testa isso diretamente, com um corte temporal único: o parâmetro λ_h , para cada horizonte h , é reestimado usando **apenas** os meses de treino, anteriores a janeiro de 2020, e então aplicado, fixo, aos meses de teste, de janeiro de 2020 em diante — período que o modelo nunca viu durante a estimação.

$$\begin{aligned} \hat{w}_{i,n,t+h} &= w_{i,n,t} + \hat{\lambda}_{h,\text{treino}} d_{i,n,t} && \text{(ajuste parcial)} \\ \hat{w}_{i,n,t+h} &= w_{i,n,t} && \text{(previsão ingênua)} \end{aligned} \quad (4)$$

O erro fora da amostra, $\text{erro}_{i,n,t+h} = (w_{i,n,t+h} - w_{i,n,t}) - \hat{\lambda}_{h,\text{treino}} d_{i,n,t}$, é comparado ao erro da previsão ingênua (que simplesmente assume que nada muda) através da raiz do erro quadrático médio (RMSE). A diferença percentual entre os dois RMSEs (**margem**) responde à pergunta central: o ajuste parcial estimado com dados antigos ainda ajuda a prever dados novos, ou uma previsão ingênua seria tão boa quanto?

4.4 Extensões

O procedimento — Etapas 1 a 3 — é aplicado a todas as gestoras do universo CVM e a todas as ações que essas gestoras carregam, repetindo a equação (1) célula por célula de ativo-mês. A Etapa 3 é igualmente generalizada: o índice de ativo n e o horizonte h são explícitos na equação (3), permitindo agregar o erro fora da amostra por gestora, por ativo e por horizonte de previsão simultaneamente.

5 Resultados

Toda esta seção usa a base multiativo já limpa, em dois passos a partir dos 2.347 fundos da Tabela 3: (1) 597 fundo-mês (73 fundos) com soma de peso $> 105\%$ do patrimônio — erro de reporte identificado na CDA da CVM, não deste trabalho — excluídos antes de qualquer regressão, restando 2.343 fundos; (2) mais 211.441 linhas (2,6%, 47 fundos) sem $\text{HHI}_{\text{resto}}$ disponível (sem dado de carteira no mês anterior — tipicamente fundo novo), exigido junto com as outras 5 características. Resultado: **2.296 fundos, 40 grupos de gestora, 501 ativos, 8.013.407 observações de fundo-ativo-mês** — uma única base do início ao fim, diferente de versões anteriores deste documento. (Um grupo de gestora, Legacy Capital, tinha um único fundo cobrindo justamente o intervalo perdido pela exigência do HHI defasado, e por isso não aparece mais em nenhuma tabela desta seção.)

5.1 Etapa 1: cross-section

O modelo (equação (1)) é estimado célula a célula (ativo, mês); 13.697 células convergiram (18 não convergiram, excluídas). A Tabela 4 resume o coeficiente padronizado (log-odds) e a Tabela 5 o efeito marginal médio (APE, pontos percentuais) de cada característica, entre as 13.697 células.

Tabela 4: Coeficiente padronizado (log-odds) de cada característica, mediana e % de células com sinal positivo, entre 13.697 células (ativo, mês). Fonte: script `99_pipeline_hhi_lag_etapa1.R` → `theta_multiativo.csv`.

Característica	Mediana	% de células positivo
Tamanho (θ^{aum})	-0,0154	47,4%
Cotistas (θ^{cot})	0,1211	70,6%
Fundo de cotas (θ^{fic})	0,0171	51,4%
Fluxo/AUM (θ^{flow})	0,0534	54,0%
Beta do fundo (θ^{bf})	0,7283	85,5%
$\text{HHI}_{\text{resto}}$ (θ^{hhi})	0,4774	86,5%

Pseudo- R^2 de McFadden médio (com piso em -1 , ver nota do script): 0,525. $\text{HHI}_{\text{resto}}$ é significativo ($|t| > 1,96$) em 72,1% das células (9.874 de 13.697), com sinal positivo em 95,2% dos casos significativos — concentrar o restante da carteira no mês anterior aumenta a probabilidade de concentrar também no ativo-alvo este mês.

Tabela 5: Efeito marginal médio (APE, pontos percentuais de peso), mesma base da Tabela 4. Fonte: script 99_pipeline_hhi_lag_etapa1.R $\rightarrow$ theta_multiativo.csv.

Característica	Mediana (p.p.)	% de células positivo
Tamanho	-0,0001%	47,4%
Cotistas	0,0092%	70,6%
Fundo de cotas	0,0001%	51,4%
Fluxo/AUM	0,0032%	54,0%
Beta do fundo	0,0988%	85,5%
HHI _{resto}	0,0488%	86,5%

Tabela 6: Estatísticas do erro e , Etapa 1, 7.997.296 observações. Fonte: script 99_pipeline_hhi_lag_etapa1.R $\rightarrow$ erro_e_multiativo.csv.

Estatística	Valor
Média	0,000000
Desvio-padrão	0,0104
Mediana	-0,0003
Mínimo / Máximo	-0,660 / 0,982
% de observações com $e > 0$	26,2%
Assimetria	6,62
Curtose	396,37 (normal = 3)
Previsões fora de $[0, 1]$	0 de 7.997.296

Assimetria/curtose bem mais altas que na versão de 1 ativo (VALE3-Itaú) — esperado: a base multiativo mistura 501 ativos de liquidez e perfil muito diferentes numa única distribuição agregada.

5.2 Etapa 2: ajuste parcial

λ (equação (3)) estimado por MQO *pooled*, todos os pares de meses consecutivos, toda a amostra: $\hat{\lambda} = 0,0785$.

Tabela 7: Estatísticas do erro u , Etapa 2, 7.262.533 pares de meses consecutivos. Fonte: script 98_etapa1_etapa2_stats_multiativo.R $\rightarrow$ erro_u_multiativo.csv.

Estatística	Valor
Média	-0,00004
Desvio-padrão	0,0043
Mediana	0,0000
Mínimo / Máximo	-0,612 / 0,592
% de observações com $u > 0$	33,5%
Assimetria	0,63
Curtose	541,36 (normal = 3)

5.3 Etapa 3: esquema fora da amostra

λ_h (equação (4)) estimado só em treino ($< \text{jan}/2020$), aplicado fixo ao teste ($\text{jan}/2020\text{--dez}/2021$). A Tabela 8 traz o RMSE agregado nos 4 horizontes, e compara diretamente o modelo com 6 características (com HHI_{resto}) contra a versão anterior de 5 características.

Tabela 8: RMSE fora da amostra, ajuste parcial vs. previsão ingênua, 4 horizontes — HHI defasado (oficial) vs. as duas versões anteriores. Fonte: script 99_pipeline_hhi_lag_etapa1.R.

	$h = 1$	$h = 3$	$h = 6$	$h = 12$
RMSE ajuste parcial (6 caract., HHI defasado)	0,003817	0,005543	0,006730	0,008104
RMSE previsão ingênua	0,003882	0,005741	0,007097	0,008735
Razão ajuste/ingênua	0,9833	0,9656	0,9483	0,9278
RMSE ajuste parcial (5 características, sem HHI)	0,003859	0,005619	—	—
RMSE ajuste parcial (6 caract., HHI contemporâneo)	0,003856	0,005610	—	—
Variação, defasado vs. 5 características	-1,09%	-1,35%	—	—
Variação, defasado vs. contemporâneo	-1,01%	-1,20%	—	—

$\lambda_1 = 0,0808$, $\lambda_3 = 0,1689$, $\lambda_6 = 0,2532$, $\lambda_{12} = 0,3855$. A versão defasada de $\text{HHI}_{\text{resto}}$ não só corrige a disciplina de defasagem (Seção 4) como melhora o RMSE agregado mais que a versão contemporânea que a precedeu — esperado, já que uma característica predeterminada é mais útil para um esquema cujo objetivo final é prever fora da amostra.

Tabela 9: λ fixo (treino único) vs. janela expansiva (reestimado mês a mês, sem vazamento), fora da amostra, $h = 1$, base multiativo (6 características, HHI defasado). Fonte: script 82_etapa3_multiativo_janela_expansiva.R.

Meses de teste	λ fixo	λ expansiva
23	0,9833	0,9833

Razão RMSE/RMSE ingênua. Ambas as versões vencem a ingênua em 23 dos 23 meses; correlação de Spearman do ranking de dificuldade por gestora entre as duas versões de λ , 40 gestoras: 1,0000. Confirma a robustez do λ fixo já vista na versão anterior deste documento.




Figura 1: Evolução mensal do erro médio fora da amostra ($h = 1$), 3 gestoras mais difíceis e 3 mais previsíveis (Tabelas 11–12). Fonte: script 74_figuras_dinamica_erro_tcc.R → etapa3_multiativo_h1.csv.




Figura 2: Erro fora da amostra agregado (nuvem cinza: individual; azul: média mensal; vermelho: desvio-padrão mensal). Esquerda: $h = 1$; direita: $h = 3$. Fonte: script 74_figuras_dinamica_erro_tcc.R.




Figura 3: Margem do ajuste parcial sobre a ingênua, mês a mês ($h = 1$: média 1,61%; $h = 3$: média 3,43%). Fonte: script 75_figura_margem_dinamica.R.




Figura 4: Peso real vs. previsto ($h = 3$), fundo 396303 (Guepardo Investimentos), JSLG3 — ainda o fundo com maior RMSE fora da amostra mesmo com HHI incluído. Desmonte de posição concentrada (69,5% $\rightarrow$ 3,8% do patrimônio entre jan/2020 e fev/2020) que o modelo não antecipa. Fonte: script 92_figura_trajetoria_fundo_v2.R.




Figura 5: Viés médio mensal fora da amostra, com sinal, 3 gestoras mais positivas e 3 mais negativas (mín. 100 obs. de teste). Maior viés positivo: Guepardo (0,00364), Núcleo Capital (0,00193); maior negativo: Daycoval ($-0,00061$), Kinea ($-0,00033$). Fonte: script 77_figura_vies_dinamico_gestora.R.

Persistência do viés. Dividindo os 23 meses de teste ao meio: correlação de 0,71 ($R^2 = 0,51$) entre o viés médio de cada gestora nas duas metades (39 gestoras com ≥ 50 observações em cada

metade) — persistente, um pouco menos que na versão sem HHI (0,80), consistente com HHI absorvendo parte do que antes aparecia como viés sistemático de gestora.




Figura 6: Viés médio, 1ª metade do teste (2020) vs. 2ª metade (2021), 39 gestoras. Fonte: script 84_persistencia_vies_gestora.R.

Correção de viés. Estimando o viés na 1ª metade e aplicando-o, fixo, à 2ª: RMSE cai de 0,005642 para 0,005639 — melhora de 0,05% (era 0,07% sem HHI), irrelevante na prática.

Decomposição $\text{RMSE}^2 = \text{viés}^2 + \text{variância}$. Em média entre as 40 gestoras, viés^2 explica 0,60% do RMSE^2 (mediana 0,15%; máximo 3,87%, Real Investor). *Pooled* (todas as observações juntas): 0,001%. A variância domina.




Figura 7: Decomposição do erro fora da amostra ($h = 1$) por gestora, ordenada por RMSE. Fonte: script 86_decomposicao_e_persistencia_variancia.R.

Persistência da variância. Correlação de 0,86 ($R^2 = 0,74$) entre o desvio-padrão do erro na 1^a e na 2^a metade do teste (39 gestoras) — tão persistente quanto na versão sem HHI (0,85, $R^2 = 0,71$): HHI não absorve a persistência da variância como absorveu parte da do viés.




Figura 8: Desvio-padrão do erro, 1ª vs. 2ª metade do teste, 39 gestoras. Linha tracejada: $y = x$. Fonte: script 86_decomposicao_e_persistencia_variancia.R.

O que explica a variância. Duas construções de concentração aparecem neste trabalho: $\text{HHI}_{\text{resto}}$ (equação (2), exclui o ativo-alvo, nível fundo-ativo-mês, já dentro da Etapa 1) e $\text{HHI}_{\text{medio}}$ (inclui todos os ativos, nível gestora, usado só nesta regressão de diagnóstico — pergunta diferente: mesmo com HHI já formalmente no modelo de peso, a concentração ainda explica erro residual entre gestoras?). Correlações bivariadas contra o desvio-padrão do erro por gestora: beta 0,48 ($R^2 = 0,23$), tamanho 0,14 ($R^2 = 0,02$), $\text{HHI}_{\text{medio}}$ 0,69 ($R^2 = 0,47$) — praticamente idênticas à versão sem HHI na Etapa 1, o que já responde à pergunta: sim, ainda explica. Para isolar o efeito de cada característica, a concentração entra numa regressão múltipla junto com as 5 características não-HHI da Etapa 1, todas medidas só no período de treino (predeterminadas em relação ao dp(erro)_g , medido só no período de teste):

$$\begin{aligned} \text{dp(erro)}_g = & \alpha + \beta_1 \overline{\text{beta}}_g + \beta_2 \overline{\log(\text{AUM})}_g + \beta_3 \overline{\log(\text{cotistas})}_g \\ & + \beta_4 \overline{\% \text{FIC}}_g + \beta_5 \overline{\text{fluxo}/\text{AUM}}_g + \beta_6 \overline{\text{HHI}_{\text{medio}}}_g + u_g \end{aligned} \quad (5)$$




Figura 9: Desvio-padrão do erro por gestora vs. beta médio, tamanho médio, $HHI_{\text{médio}}$, 40 gestoras. Fonte: script 87_explica_variancia_gestora.R.

Tabela 10: Regressão múltipla (equação (5)): desvio-padrão do erro fora da amostra por gestora explicado pelas 5 características não-HHI da Etapa 1 mais $HHI_{\text{médio}}$, todas do período de treino. 40 gestoras. Fonte: script 95_regressao_completa_variancia.R.

Variável	Coefficiente	t	Sig.
Intercepto (α)	-0,0143	-1,29	n.s.
Beta médio do fundo	0,0020	0,82	n.s.
Tamanho médio, log AUM	0,0010	1,53	n.s.
Cotistas médio, log	0,000003	0,01	n.s.
% FIC	-0,0005	-0,29	n.s.
Fluxo/AUM médio	-0,0094	-1,42	n.s.
$HHI_{\text{médio}}$	0,0832	4,17	***
R^2		0,550	

*** $p < 0,1\%$; n.s. = não significativo a 5%. Praticamente idêntica à versão sem HHI na Etapa 1 ($R^2 = 0,54$, mesmo coeficiente/ t do HHI): HHI já estar na Etapa 1 não elimina seu poder explicativo aqui — são perguntas diferentes.

Concentração no nível fundo-mês. Refinando para o nível fundo-mês (não mais média por gestora): correlação contemporânea 0,42 (Spearman 0,80), defasada (mês $t - 1$) 0,44 (Spearman 0,80) — quase idênticas, afastando coincidência de mesmo mês — e dentro do fundo (demeaned) 0,06 (Spearman 0,10): a concentração é, sobretudo, um traço que diferencia fundos entre si, não um sinal de curto prazo dentro do mesmo fundo.




Figura 10: Concentração (HHI) vs. erro fora da amostra, nível fundo-mês, em decis. (A) contemporânea; (B) defasada; (C) dentro do fundo. Fonte: script 88_concentracao_mes_a_mes.R.




Figura 11: Beta médio do fundo vs. RMSE fora da amostra, 1.912 fundos (≥ 6 obs. de teste, peso mediano $\geq 0,1\%$). $R^2 = 0,23$ (coef. 0,00742, $p < 10^{-100}$). Fonte: script 78_figura_beta_vs_erro.R.




Figura 12: Estabilidade do ranking de dificuldade por gestora entre horizontes, 40 gestoras (todas com dado completo nos 4 horizontes). Spearman: 0,97 ($h1-h3$), 0,95 ($h1-h6$), 0,89 ($h1-h12$), 0,98 ($h3-h6$), 0,94 ($h3-h12$), 0,97 ($h6-h12$). Fonte: script 80_figura_ranking_horizontes.R.

Tabela 11: RMSE fora da amostra por gestora, 4 horizontes, ordenado do mais ao menos errante em $h = 1$. Fonte: script 93_gera_latex_tabelas_9_10.R → etapa3_multiativo_gestora_multihorizonte.csv.

Gestora	Fundos ($h=1$)	RMSE $h=1$	RMSE $h=3$	RMSE $h=6$	RMSE $h=12$
Ibiuna Investimentos	6	0,01461	0,02348	0,02742	0,03336
Guepardo Investimentos	10	0,01429	0,02322	0,03384	0,05699
AZ Quest	22	0,01088	0,01449	0,01630	0,01835
Núcleo Capital	17	0,01045	0,01833	0,02504	0,03588
Squadra Investimentos	14	0,01010	0,01397	0,01698	0,02165
Forpus Capital	3	0,00994	0,01291	0,01510	0,00969
Truxt Investimentos	29	0,00807	0,01254	0,01585	0,01944
Sharp Capital	34	0,00789	0,01284	0,01695	0,02112
ARX Investimentos	11	0,00785	0,01082	0,01259	0,01517
Kinea Investimentos	4	0,00708	0,01152	0,01521	0,01601
Constellation Asset Management	25	0,00696	0,01386	0,01841	0,02789
Opportunity	19	0,00680	0,01050	0,01342	0,01558
Atmos Capital	28	0,00614	0,01000	0,01338	0,01700
SPX Capital	35	0,00613	0,00911	0,01156	0,01301
Verde Asset Management	14	0,00602	0,01023	0,01299	0,01656
Absolute Investimentos	7	0,00560	0,00824	0,01049	0,01265
Daycoval Asset Management	5	0,00555	0,00724	0,00717	0,00807
JGP	40	0,00555	0,00775	0,00894	0,01072
Kapitalo Investimentos	22	0,00534	0,00577	0,00690	0,00818
Bogari Capital	14	0,00534	0,00933	0,01211	0,01612
Real Investor	5	0,00497	0,00932	0,01427	0,01783

continua na próxima página

(continuação)

Gestora	Fundos ($h=1$)	RMSE $h=1$	RMSE $h=3$	RMSE $h=6$	RMSE $h=12$
Credit Suisse	64	0,00487	0,00669	0,00795	0,00899
Claritas Investimentos	10	0,00482	0,00704	0,00789	0,00837
Caixa	27	0,00462	0,00682	0,00888	0,01140
Western Asset	26	0,00436	0,00697	0,00958	0,01246
Bradesco Asset Management	270	0,00425	0,00594	0,00708	0,00844
BB Asset Management	103	0,00415	0,00644	0,00808	0,00989
Vinci Partners	47	0,00414	0,00628	0,00741	0,00838
Occam Brasil	26	0,00412	0,00670	0,00764	0,00996
Santander Brasil Asset Management	70	0,00389	0,00539	0,00622	0,00724
BTG Pactual	136	0,00387	0,00581	0,00678	0,00846
Safra Asset Management	135	0,00331	0,00466	0,00556	0,00621
BNP Paribas	42	0,00301	0,00437	0,00538	0,00725
XP	81	0,00291	0,00435	0,00523	0,00722
Itaú	436	0,00257	0,00378	0,00459	0,00541
Julius Baer Family Office	56	0,00253	0,00348	0,00434	0,00536
Dahlia Capital	18	0,00245	0,00420	0,00545	0,00628
TNA Gestão Patrimonial	29	0,00151	0,00218	0,00282	0,00389
Gávea Investimentos	17	0,00144	0,00265	0,00363	0,00468
Plural	1	0,00050	0,00081	0,00105	0,00137

Tabela 12: Margem do ajuste parcial sobre a ingênua (% de redução de RMSE), mesma ordem da Tabela 11. Negativo = ajuste parcial pior que a ingênua. Fonte: script 93_gera_latex_tabelas_9_10.R.

Gestora	Margem $h=1$	Margem $h=3$	Margem $h=6$	Margem $h=12$
Ibiuna Investimentos	3,7%	8,1%	8,6%	15,2%
Guepardo Investimentos	0,8%	0,3%	-0,9%	-2,2%
AZ Quest	3,4%	7,5%	10,6%	16,7%
Núcleo Capital	-1,6%	-3,2%	-3,4%	-7,5%
Squadra Investimentos	0,5%	0,0%	-1,0%	-3,0%
Forpus Capital	2,4%	5,0%	8,4%	19,1%
Truxt Investimentos	1,8%	4,1%	6,4%	14,2%
Sharp Capital	1,4%	4,3%	8,6%	15,7%
ARX Investimentos	2,1%	4,4%	7,0%	7,5%
Kinea Investimentos	1,8%	4,0%	9,0%	9,9%
Constellation Asset Management	-0,9%	-0,2%	2,3%	3,3%
Opportunity	1,6%	4,0%	6,7%	10,3%
Atmos Capital	-0,0%	2,7%	5,2%	12,4%
SPX Capital	2,9%	7,3%	11,9%	20,1%
Verde Asset Management	0,4%	1,4%	2,9%	-1,1%
Absolute Investimentos	1,5%	3,3%	5,5%	4,9%
Daycoval Asset Management	3,2%	6,4%	9,2%	14,6%
JGP	2,3%	4,2%	5,0%	8,4%
Kapitalo Investimentos	3,0%	6,3%	7,5%	8,0%
Bogari Capital	-1,1%	-0,6%	-0,0%	-5,6%
Real Investor	-2,6%	-0,2%	0,6%	6,0%
Credit Suisse	2,5%	5,0%	8,5%	15,2%

continua na próxima página

(continuação)

Gestora	Margem $h=1$	Margem $h=3$	Margem $h=6$	Margem $h=12$
Claritas Investimentos	1,7%	6,3%	11,3%	19,5%
Caixa	1,8%	4,2%	7,0%	9,7%
Western Asset	1,0%	3,1%	5,5%	5,9%
Bradesco Asset Management	2,0%	3,7%	4,8%	4,3%
BB Asset Management	1,1%	2,7%	3,8%	5,0%
Vinci Partners	0,8%	3,1%	7,1%	19,5%
Occam Brasil	2,3%	4,9%	8,1%	10,7%
Santander Brasil Asset Management	2,1%	4,3%	5,7%	7,3%
BTG Pactual	1,4%	2,7%	3,9%	4,4%
Safrá Asset Management	2,0%	3,2%	5,7%	8,5%
BNP Paribas	0,0%	-1,1%	-3,4%	-7,1%
XP	-3,1%	-6,5%	-9,8%	-11,7%
Itaú	2,0%	4,6%	6,6%	8,4%
Julius Baer Family Office	1,5%	3,0%	4,5%	6,6%
Dahlia Capital	2,4%	5,7%	8,6%	10,6%
TNA Gestão Patrimonial	-0,3%	-1,8%	-2,2%	1,0%
Gávea Investimentos	2,1%	4,3%	8,5%	11,1%
Plural	-3,3%	-5,2%	-4,5%	-8,3%




Figura 13: Cada ponto é uma gestora: RMSE ($h=1$, eixo x) vs. margem sobre a ingênua ($h=1$, eixo y ; negativo = ajuste parcial piora). Fonte: script 45_fig_multihorizonte_gestora_rmse_margem.R.

6 Aplicação: robô caça-replicantes

A estrutura do erro fora da amostra (Seção 5) sugere uma aplicação direta: se dois fundos de gestoras diferentes erram de forma sincronizada, além do que suas características observáveis explicam, isso é coincidência ou um padrão real de replicação de carteira? Esta seção testa essa pergunta até o fim — incluindo a etapa final, decisiva, que esta base de resultados nunca tinha sido usada para responder: será que esse padrão, convertido em sinal de fluxo previsto, prediz retorno futuro do ativo? Um achado é validado; o outro, testado e rejeitado, honestamente relatado como tal.

Duas mudanças de desenho em relação às Etapas 1–3: (i) o universo deixa de ser ancorado em VALE3 — passa a incluir todo fundo brasileiro com posição em ações entre 2016 e 2021, não só os que já tiveram VALE3; (ii) a variação de peso é corrigida do efeito mecânico do preço (dividendos, desdobramentos), para isolar negociação ativa de valorização passiva. Por ter sido desenvolvida antes da inclusão de $\text{HHI}_{\text{resto}}$ na Etapa 1 (Seção 4), esta seção usa a especificação de 5 características, não 6.

6.1 Universo completo e correção de efeito mecânico

Tabela 13: Universo ancorado em VALE3 (Seção 3) vs. universo completo. Fonte: scripts 50–58 → `painel_universo_completo_final.csv`.

	Ancorado (VALE3)	Completo
Fundos	2.820	3.254
Ativos	501	536
Ativos com preço (cobertura)	— 519 (96,8%; 99,65% do peso)	

O peso observado mistura negociação ativa com valorização pura do preço — um fundo que não faz nada pode ver seu peso num ativo subir só porque o preço subiu mais que o resto da carteira. A correção mecânica isola esse efeito:

$$w_{i,n,t+1}^{\text{mecânico}} = w_{i,n,t} \cdot \frac{1 + r_{n,t+1}}{1 + r_{i,t+1}}, \quad dw_{\text{corrigido}} = w_{i,n,t+1} - w_{i,n,t+1}^{\text{mecânico}} \quad (6)$$

em que r_n é o retorno do ativo (preço de mercado) e r_i é o retorno da cota do fundo inteiro (naturalmente neutro a aportes/resgates, ao contrário do peso bruto).

Yahoo Finance sozinho cobre só 62,5% dos ativos — tickers “somem” em reorganizações societárias (ex.: JBS → JBSS32), não porque a empresa deixou de existir. B3 oficial (preço bruto, sem ajuste de proventos) mais 5 tickers sucessores resolvidos manualmente (KROT11→COGN3, UNID3→LCAM3, IMCH3→MEAL3, LLISE3→LLIS3, HGTX4→HGTX3) fecham a cobertura em 99,65% do peso agregado. Dois artefatos de retorno tratados antes da correção: desdobramento/grupamento de cota não ajustado em alguns fundos (ex.: fundo 332186, cota

R\$2,00→R\$0,0375 em dez/2018, volta a crescer normalmente dali — não é perda real); e retorno de fundo ou ativo com $< -90\%$ ou $> 200\%$ num único mês, excluído só da correção mecânica (não do resto da amostra).

6.2 Etapas 1–3 no universo completo

Mesma especificação da Seção 4 (equações (1), (3) e (4), 5 características, sem HHI), agora estimada no universo completo.

Tabela 14: Etapa 1: ancorado vs. completo. Fonte: script 59_cross_section_universo_completo.R → theta_universo_completo.csv.

	Ancorado	Completo
Ativos com ≥ 24 meses estimados	236	236
Beta do fundo, % mesmo sinal que VALE3	97,0%	97,5%
Pseudo- R^2 médio	0,4407	0,4473
Células (ativo, mês) estimadas	13.957	13.939

Beta do fundo continua sendo a característica que mais generaliza entre ativos — não é artefato da amostra restrita a VALE3.

Tabela 15: Etapa 2: λ (equação (3)) bruto vs. com correção mecânica, MQO *pooled*, amostra inteira. Fonte: script 61_ajuste_parcial_universo_completo.R.

	λ	R^2
Sem correção mecânica	0,0640	0,0301
Com correção mecânica	0,0639	0,0323

λ com e sem correção fica quase idêntico e R^2 **melhora** com a correção — o resultado economicamente esperado (a correção deveria remover ruído mecânico, não introduzir nenhum). Antes de tratar os 2 artefatos de retorno acima, o mesmo teste mostrava o oposto (R^2 piorando): era inteiramente artefato dos outliers, não efeito real.

Tabela 16: Etapa 3 fora da amostra: λ_h (equação (4)) treinado em $< \text{jan}/2020$, aplicado fixo ao teste. Fonte: script 62_etapa3_universo_completo.R.

	λ bruto	λ corrigido	Margem mediana	% vence ingênua
h=1, bruto	0,0642	—	1,52%	73,5%
h=1, corrigido	—	0,0659	0,99%	61,5%
h=3	0,1324	0,1324	—	—

Para VALE3 especificamente (32.164 obs. de teste), a correção **melhora** a margem (1,20%→2,13%) — o oposto do padrão mediano. Ver Figura 14.

Quebrando por fonte do preço: ativos com preço ajustado por proventos (Yahoo, 234) quase não mudam (1,32%→1,11%); ativos só com preço bruto da B3 (106) caem bem mais (2,03%→0,72%, visível como a nuvem vermelha mais abaixo da diagonal na Figura 14) — a limitação de cobertura de preço tem consequência prática mensurável. O caso mais extremo




Figura 14: Margem vs. ingênua ($h = 1$), com e sem correção mecânica, por ativo (340 elegíveis, ≥ 100 obs. de teste), colorido pela fonte do preço. Fonte: script `69_figuras_teste_estrategia.R`.

(Alpargatas ON, margem corrigida $-92,9\%$) usa preço ajustado, não é problema de dividendo: a ação sofreu volatilidade real em 2020 (queda de $\sim 30\%$ em março) que o modelo de ajuste parcial não capta — achado genuíno, não artefato.

6.3 Detecção de pares replicantes

Para cada ativo, correlação (contemporânea e defasada em 1 mês) entre a série de erro de todo par de fundos que o carrega — ativo por ativo, não portfólio inteiro, para não diluir um replicante que só copia numa posição específica:

$$u_{i,n,t} = dw_{\text{corrigido}} - \hat{\lambda} d_{i,n,t}, \quad t_{\text{corr}} = r \sqrt{\frac{n-2}{1-r^2}} \quad (7)$$

Filtro de posição-poeira (peso mediano da célula fundo-ativo $\geq 0,1\%$) aplicado antes de qualquer correlação — sem ele, o resultado fica dominado por séries quase-zero numericamente instáveis. Correção de múltiplas comparações (Benjamini–Hochberg):

$$p_{\text{ajustado},(k)} = \min_{j \geq k} \left(p_{(j)} \cdot \frac{m}{j} \right), \quad m = 31.907.281 \text{ testes} \quad (8)$$

Pela contagem bruta, Itaú domina (671 fundos, quase $3 \times$ o 2° maior) — artefato de tamanho. Normalizado (Figura 15), quem domina são **boutiques menores**: Atmos $\leftrightarrow$ TNA (taxa 3,02), Occam $\leftrightarrow$ Plural (1,91), Squadra $\leftrightarrow$ TNA (1,88) — consistente com replicação entre gestoras de estilo próximo, não só efeito de escala.

Tabela 17: Detecção de pares. Fonte: scripts 63–65 → pares_replicantes_significativos.csv.

Ativos elegíveis (pós filtro de poeira)	344
Pares com $ \text{correlação} \geq 0,6$	1.833.580
Pares significativos ($p_{\text{ajustado}} < 0,05$)	1.272.131
— mesma gestora / gestoras diferentes	463.856 (36%) / 808.275 (64%)
Pares com liderança clara (assimetria $> 0,2$)	74.596 (58.133 cross-gestora)




Figura 15: Top 10 pares de gestora por taxa normalizada (pares fundo-fundo significativos ÷ pares possíveis entre as duas gestoras). Fonte: script 69_figuras_teste_estrategia.R.

6.4 Sinal do robô

Para cada par líder→seguidor, β por regressão através da origem na amostra pareada exata (equivalente a MQO individual por par):

$$\beta = \frac{\sum_t u_{\text{líder},t} u_{\text{seguidor},t}}{\sum_t u_{\text{líder},t}^2}, \quad dw_{\text{ajustado}} = \hat{\lambda} d_{\text{seguidor},t} + \beta u_{\text{líder},t}$$

$$\text{fluxo}_{\text{R\$}} = \text{AUM}_{\text{seguidor},t} \cdot dw_{\text{ajustado}} \quad (9)$$

Onde um seguidor tem mais de um líder candidato no mesmo ativo, usa-se só o de maior força de liderança (evita somar sinais correlacionados entre si). Fluxo somado por gestora, depois net entre todas, por ativo-mês.

Tabela 18: Fonte: scripts 66–68.

	Sem ajuste	Com ajuste
RMSE (19.423 pares seguidor-ativo, 374.516 obs.)	0,00621	0,00410 (−33,9%)

Mediana do fluxo líquido perto de zero, distribuição bem assimétrica — maioria neutra, poucos ativo-mês concentram sinal forte; R\$1–2 bi/mês para uma blue chip amplamente carregada




Figura 16: Top 5 maiores pressões compradoras e vendedoras líquidas (ativo-mês), em R\$ bilhões. Maior compra: Petrobras ON, jan/2020, +R\$1,71 bi (269 fundos, 18 gestoras). Maior venda: Petrobras Distrib., mai/2021, -R\$853 mi (430 fundos, 23 gestoras). Fonte: script 69_figuras_teste_estrategia.R.

é fração pequena do patrimônio total da indústria de fundos, ordem de grandeza plausível. A melhora de RMSE de 33,9% é **dentro da amostra** (β estimado e avaliado nos mesmos dados — garantia matemática do MQO, não prova de generalização); e o fluxo reportado é só o componente “eco do líder” (pares com líder identificado), não a previsão de todos os fundos do universo — ainda não é um sinal de demanda de mercado completo.

6.5 O teste decisivo: fluxo previsto prediz retorno?

Tudo até aqui prevê *mudança de peso dos fundos*. Uma estratégia long/short aposta em *retorno do ativo*. A teoria de *demand-based asset pricing* diz que pressão de compra empurra preço para cima — mas isso nunca tinha sido testado com o sinal construído acima. Antes de falar em estratégia, o fluxo previsto precisa prever retorno de verdade:

$$\text{retorno}_{i,t+1} = \alpha + \beta_{\text{ret}} \cdot \text{fluxo_pct}_{i,t} + \varepsilon_{i,t+1}, \quad \text{fluxo_pct}_{i,t} = \frac{\text{fluxo líquido em R\$}_{i,t}}{\text{valor total da posição em } i, \text{ mês } t} \quad (10)$$

Fluxo normalizado pelo valor total da posição (não R\$ bruto) — senão o teste só capturaria “ativo grande tem fluxo grande”, não poder preditivo de verdade. Rodado em duas versões do sinal (com e sem o eco do líder) e duas amostras (completa; restrita aos 215 ativos com margem positiva na Etapa 3, de 360 elegíveis, na hipótese de que ruído dos ativos onde o modelo não funciona bem estivesse diluindo o teste).

O teste não valida a premissa de negociar em cima do sinal. O sinal com eco do líder (o produto final desta seção) sai com coeficiente *negativo* na amostra completa e não

Tabela 19: Fonte: scripts 70–71 → teste_fluxo_prediz_retorno.csv.

	Amostra completa (8.585 obs.)		Só margem > 0 (5.958 obs.)	
	Coef. (β_{ret})	p -valor	Coef. (β_{ret})	p -valor
Sinal COM eco do líder	$-8,6 \times 10^{-8}$	0,077	$-1,1 \times 10^{-7}$	0,045
Sinal SEM eco (só $\hat{\lambda}d$)	$+7,1 \times 10^{-7}$	0,032	$+6,3 \times 10^{-7}$	0,160

R^2 em todos os casos: entre 0,033% e 0,067% — estatisticamente às vezes detectável, mas economicamente irrisório.




Figura 17: Fluxo previsto (mês t) vs. retorno do ativo (mês $t+1$), amostra completa. A reta de regressão é essencialmente plana — $R^2 = 0,036\%$. Fonte: script 72_figuras_teste_retorno.R.

significativo a 5% ($p = 0,077$) — pior que o sinal mais simples (só $\hat{\lambda}d$), que ao menos tem o sinal certo e é estatisticamente detectável, mas com R^2 tão baixo (0,03–0,07%) que não sustenta uma estratégia. Restringir a ativos de margem positiva não resgata o resultado: o sinal com eco passa a ser estatisticamente significativo nessa subamostra ($p = 0,045$), mas com o sinal *errado* para a teoria (mais fluxo comprador previsto associado a retorno *menor*) e magnitude ainda irrisória — não é uma reversão do achado, é ruído com sorte estatística.

Isto é um resultado negativo genuíno, não uma limitação de dado a ser corrigida depois. O mecanismo “fundos comprem $\Rightarrow$ preço sobe” pode existir no mercado como um todo, mas **não aparece de forma detectável neste sinal, nesta amostra, neste horizonte**. O trabalho não avança para “vale a pena operar” (liquidez, custo de transação) — não faz sentido otimizar execução de um sinal sem poder preditivo demonstrado.




Figura 18: Retorno médio subsequente por quintil de fluxo previsto (Q1 = mais vendedor, Q5 = mais comprador), amostra completa vs. restrita a ativos de margem positiva. Diferença Q5–Q1: +0,52 p.p. ($p = 0,271$) na completa, +0,85 p.p. ($p = 0,137$) na restrita — nenhuma das duas significativa. Fonte: script 72_figuras_teste_retorno.R.

6.6 Síntese: o que está validado e o que não está

Achado	Status	Evidência
Beta do fundo generaliza entre ativos	Validado	97,5% mesmo sinal que VALE3
Correção mecânica de preço melhora o ajuste	Validado	R^2 melhora com a correção
Pares de fundos com erro sincronizado além das características (replicantes)	Validado	1.272.131 pares, $p < 0,05$ com Benjamini–Hochberg
Relação líder→seguidor melhora previsão de <i>peso</i>	Validado <i>dentro da amostra</i>	RMSE –33,9%
Sinal de fluxo previsto prediz <i>retorno</i> do ativo	Rejeitado	$R^2 \approx 0$, sinal inconsistente
Estratégia long/short executável	Não avaliado (depende do item anterior)	—

O núcleo que sobrevive ao escrutínio é a **detecção de replicantes em si**: existem pares de fundos, sobretudo entre gestoras de porte parecido e próximas em estilo, cujo comportamento se move em conjunto além do que tamanho, cotistas, fluxo, estrutura de fundo de cotas e beta explicam — estatisticamente robusto mesmo depois de corrigir milhões de comparações múltiplas. A tentativa de converter esse padrão em sinal de negociação foi feita de forma honesta e testada até o fim, e não passou no teste decisivo. Isso é registrado como um resultado, não escondido: um achado positivo (existe replicação) não implica automaticamente um achado positivo seguinte

(dá para lucrar com isso) — e este trabalho testou os dois, separadamente, em vez de assumir que o segundo decorre do primeiro.

Nota sobre qualidade de dado. A base desta seção (universo completo, 3.254 fundos) recebeu, em 12/08/2026, a mesma limpeza de contaminação de soma de peso $> 105\%$ já aplicada à base multiativo (Seção 5): 1.072 fundo-mês (207 fundos) excluídos antes de qualquer regressão — 98 desses fundos nunca tinham sido auditados antes, por só existirem neste universo mais amplo (fora do universo ancorado em VALE3). Todos os números desta seção já refletem a base limpa; o efeito foi pequeno e nenhuma conclusão mudou de direção em relação à análise original sobre dado contaminado.

7 Conclusão

Este trabalho modela o peso de ações em carteiras de fundos brasileiros como um fator dinâmico: uma cross-section logística estima, mês a mês, o peso que cada fundo deveria carregar dado seis características observáveis (equação (1)); um mecanismo de ajuste parcial modela a velocidade com que a posição real converge a esse alvo (equação (3)); e um esquema fora da amostra, com λ estimado só em treino e aplicado fixo ao teste (equação (4)), testa se isso tem valor preditivo genuíno em dados que o modelo nunca viu. O procedimento nasceu restrito a VALE3 e aos fundos do grupo Itaú e foi generalizado, em etapas, para o universo inteiro da CVM — 40 grupos de gestora, 501 ativos, 2.296 fundos na versão final (Seção 5).

O resultado central é que o ajuste parcial vence a previsão ingênua de forma consistente e crescente com o horizonte — razão RMSE/ingênua de 0,9833 em $h = 1$ até 0,9278 em $h = 12$ — mas o ganho é modesto, e a contribuição mais rica do trabalho não está no RMSE agregado, e sim na estrutura do erro. A variância domina o viés como fonte de erro (viés² explica só 0,001% do RMSE² *pooled*), e essa variância é, ela mesma, previsível: é persistente entre janelas de teste ($R^2 = 0,72\text{--}0,74$) e explicada, sobretudo, pela concentração da carteira — muito mais do que por beta ou tamanho do fundo (Tabela 10). Foi exatamente esse achado, obtido primeiro como diagnóstico *fora* da Etapa 1, que motivou incorporar $\text{HHI}_{\text{resto}}$ — a concentração do restante da carteira, excluindo o ativo-alvo (equação (2)) — como sexta característica formal do modelo de peso, ao lado de tamanho, cotistas, fundo de cotas, fluxo e beta.

Essa incorporação passou por uma correção de percurso que vale registrar como parte do resultado, não só do processo: a primeira versão usava a concentração do *mesmo* mês que o peso que tentava explicar, contrariando a disciplina de defasagem das demais cinco características; uma auditoria identificou a inconsistência, e o reteste com a versão defasada (mês $t - 1$) mostrou efeito quase idêntico (72,1% das células com coeficiente significativo, contra 72,3% da versão contemporânea) — e, ao final, um RMSE fora da amostra *melhor* do que a versão original, não

apenas mais correta metodologicamente. O modelo de 6 características é, hoje, o que efetivamente gera todos os resultados deste documento; a versão de 5 características aparece só como termo de comparação.

A Seção 6 testou se essa estrutura de erro serve para algo além de diagnóstico. A resposta é dupla, e as duas metades importam igualmente. Existem pares de fundos — 1.272.131 deles, entre 41 grupos de gestora, estatisticamente robustos mesmo depois de corrigir milhões de comparações múltiplas — cujo erro se move em sincronia além do que características observáveis explicam; isso é replicação de carteira genuína, não coincidência, e é o achado que mais diretamente estende a literatura de *demand-based asset pricing* para o contexto de fundos brasileiros. Mas convertido em sinal de fluxo previsto, esse padrão não prediz retorno subsequente do ativo: o teste decisivo (Seção 6.5) produz coeficientes minúsculos, de sinal inconsistente entre especificações, com R^2 entre 0,033% e 0,067%. O trabalho registra isso como um resultado negativo genuíno, não como uma limitação a ser corrigida depois — uma estratégia de negociação sobre este sinal não está justificada pelos dados desta amostra, e não faz sentido avançar para questões de execução (liquidez, custo de transação) sem poder preditivo demonstrado primeiro.

Duas limitações estruturais valem menção explícita. Primeiro, a variável dependente — peso declarado na CDA — é uma posição *direta*: um fundo que investe via cotas de outro fundo (FIC) não tem sua exposição indireta capturada, o que provavelmente explica por que ser FIC segue associado, em média, a menor peso direto observado. Segundo, o modelo é inteiramente de demanda: nenhuma característica do lado da oferta (liquidez do ativo, free float, restrições institucionais) entra na equação (1), e a Seção 6 mostrou concretamente que demanda sincronizada entre fundos não implica, sozinha, efeito de preço detectável. Futuras extensões naturais incluem testar $\text{HHI}_{\text{resto}}$ em conjunto com efeitos fixos de gestora, e revisitar o teste de fluxo-prediz-retorno com uma medida de liquidez do ativo como controle explícito, não apenas como filtro de amostra.