

Peso de ações nos fundos de investimento brasileiros:
um modelo de fator dinâmico com correção logística e ajuste
parcial

João Paulo Zangrandi

Fundação Getulio Vargas — Escola de Economia de São Paulo (FGV–EESP)

Orientador: Prof. Mauricio Ferraresi

Sumário

1	Introdução	3
2	Revisão de literatura	3
3	Dados	3
3.1	Fontes e universo	3
3.2	Limpeza e características	4
3.3	Amostra final	4
4	Metodologia	5
4.1	Etapa 1: cross-section	5
4.2	Etapa 2: ajuste parcial	6
4.3	Etapa 3: esquema fora da amostra	6
5	Resultados	6
5.1	Etapa 1: cross-section	7
5.2	Etapa 2: ajuste parcial	8
5.3	Etapa 3: esquema fora da amostra	8
6	Aplicação: robô caça-replicantes	20
6.1	Correção de efeito mecânico do preço	20
6.2	Deteção de pares replicantes	22
6.3	Sinal do robô	23
6.4	O teste decisivo: fluxo previsto prediz retorno?	24
6.5	Síntese: o que está validado e o que não está	26

1 Introdução

[Seção a ser escrita por último.]

2 Revisão de literatura

[Seção a ser desenvolvida após indicação de referências pelo orientador. Áreas de inserção previstas: precificação de ativos baseada em demanda (demand-based asset pricing); comportamento de fundos de investimento e efeitos de fluxo; modelos de ajuste parcial em finanças corporativas e de portfólio.]

3 Dados

3.1 Fontes e universo

Os dados vêm de dois registros públicos que a CVM exige de todo fundo de investimento brasileiro: a Composição e Diversificação de Aplicações (CDA), extrato mensal de que vem o peso de cada ativo na carteira de cada fundo (a variável dependente deste trabalho), e o Informe Diário, de onde vêm patrimônio líquido, cotistas, captação e resgate (as características do fundo). O período coberto vai de janeiro de 2016 a dezembro de 2021. O universo de fundos é **todo fundo do universo CVM com posição em ações no período** (3.254 fundos, 41 grupos de gestora por marca controladora, 536 ativos de posição direta) — não restrito a nenhuma gestora ou ativo específico. Esse universo bruto já reflete uma limpeza de qualidade de dado: 34 fundo-mês (23 fundos) com soma de participações $> 150\%$ do patrimônio na CDA — erro de reporte identificado na fonte, não deste trabalho — foram excluídos antes de qualquer outra etapa (o corte de 150% separa erro de dado genuíno de alavancagem legítima de fundos "Ações Livre"/"Multimercados Livre", que persistentemente ultrapassam 100% sem ser erro).

Tabela 1: Funil da amostra, do universo bruto à amostra final. Fonte: scripts 50–58 → `painel_universo_completo_final.csv`; script 101_cross_section_universo_completo_hhi.R para a etapa de $\text{HHI}_{\text{resto}}$.

Etapa	Fundos	Ativos	Gestoras
Universo bruto (posição em ações, 2016–2021)	3.254	536	41
+ 5 características do Informe Diário completas	2.576	513	41
+ $\text{HHI}_{\text{resto}}$ defasado disponível	2.507	512	41

Cobertura temporal: 60 meses (jan/2017–dez/2021, não os 72 meses do período bruto) — o beta do fundo exige 252 pregões de histórico de cota, o que exclui os primeiros 12 meses da amostra.

Dos 678 fundos do universo bruto que não entram na amostra de 5 características completas, 68 nunca têm as quatro características do Informe Diário completas ao mesmo tempo; os outros 610 têm essas quatro, mas nunca chegam a ter beta — $91,5\%$ deles (558) simplesmente não

acumulam 252 dias de cota válida na janela 2016–2021 (fundos jovens demais, não uma limitação de dado), e os 8,5% restantes (52) acumulam mas não geram beta por outro motivo (ex.: janela sem par completo com o Ibovespa, ou fundo encerrado logo em seguida).

3.2 Limpeza e características

Um mesmo ativo pode aparecer na CDA sob rótulos diferentes conforme o tipo de posição (direta, cedida/recebida em empréstimo, direito de subscrição). Este trabalho mantém apenas a posição direta, identificada pelo sufixo numérico do código de negociação (convenção B3: sufixos 3, 4, 5, 6, 7, 8, 11) — 536 ativos de posição direta, 10.818.395 linhas de fundo-ativo-mês antes dos demais filtros.

Seis características de cada fundo entram no modelo (equação (1)), todas medidas no último dia do mês anterior ao da observação, para evitar viés de antecipação:

Tabela 2: As 6 características da Etapa 1. Fonte: Informe Diário da CVM (5 primeiras) e `painel_multiativo_final.csv` (HHI_{resto} , derivado do próprio peso defasado).

Característica	Definição
Tamanho	Logaritmo do patrimônio líquido
Cotistas	Logaritmo do número de cotistas
FIC	Indicador (0/1) de ser fundo de cotas de outro fundo
Fluxo/AUM	(Captação – resgate) sobre o patrimônio líquido
Beta do fundo	Covariância do retorno diário da cota com o Ibovespa / variância do Ibovespa, janela móvel de 252 pregões
HHI_{resto}	Concentração do restante da carteira de ações no fechamento do mês anterior , excluindo o ativo-alvo (equação (2)) — calculado sobre o sub-portfólio de ações capturado neste painel (não o NAV inteiro do fundo, que também pode incluir renda fixa e caixa não observados aqui); fundos sem dado de carteira em $t - 1$ ficam sem essa característica (2,4% das linhas)

3.3 Amostra final

Tabela 3: Dimensões da amostra final. Fonte: `painel_multiativo_final.csv`.

Observações (fundo $\times$ ativo $\times$ mês)	8.212.294
Fundos	2.507
Grupos de gestora	41
Ativos (posição direta)	512
Meses (fev/2017–dez/2021)	59

Esta é a amostra final com as 6 características (Seção 3) disponíveis linha a linha, uma única base do início ao fim (Seção 5).

4 Metodologia

O trabalho é organizado em três etapas sequenciais, cada uma alimentando a seguinte. A primeira etapa estima, mês a mês, o peso que cada fundo *deveria* carregar em cada ativo, dadas as características observáveis do fundo. A segunda etapa modela a velocidade com que o peso efetivamente observado converge a esse alvo. A terceira etapa testa, em dados que o modelo nunca viu durante a estimação, se essa modelagem tem valor preditivo genuíno. Em cada uma das três etapas, o erro é o principal objeto de análise: sua estrutura (quem erra mais, quando, e em que direção) é o que permite comparar fundos e gestoras entre si.

4.1 Etapa 1: cross-section

Para cada ativo n e cada mês t , o peso que um fundo i carrega é modelado como função logística de seis características do fundo:

$$\text{peso}_{i,n,t} = g(x'_{i,n,t}\theta_{n,t}) + e_{i,n,t}, \quad g(z) = \frac{1}{1 + e^{-z}} \quad (1)$$

em que $x_{i,n,t}$ reúne seis características do fundo (Seção 3): tamanho (log AUM), número de cotistas (log), indicador de fundo de cotas (FIC), fluxo de captação/resgate sobre o patrimônio, beta do próprio fundo, e a concentração do restante da carteira ($\text{HHI}_{\text{resto}}$, definida na equação (2) abaixo) — todas padronizadas, exceto o indicador de FIC, e todas medidas no fechamento do mês anterior ($t - 1$), sem exceção. $\theta_{n,t}$ é o vetor de coeficientes daquele ativo naquele mês, estimado por máxima verossimilhança (regressão logística quase-binomial), separadamente para cada célula (ativo, mês) com número mínimo de fundos detentores, sem nenhuma etapa de agregação temporal por cima: cada $\theta_{n,t}$ é o resultado de uma única regressão de corte transversal.

$$\text{HHI}_{\text{resto},i,n,t} = \text{HHI}_{\text{total},i,t-1} - \text{peso}_{i,n,t-1}^2, \quad \text{HHI}_{\text{total},i,t-1} = \sum_m \text{peso}_{i,m,t-1}^2 \quad (2)$$

$\text{HHI}_{\text{resto}}$ mede a concentração da carteira de ações do fundo i no **fechamento do mês anterior**, excluindo o peso que o próprio ativo-alvo n tinha naquele mesmo fechamento — excluir n evita a circularidade óbvia de usar a concentração de uma carteira que já inclui o peso que se está tentando explicar como variável explicativa dele mesmo; defasar para $t - 1$ garante a mesma disciplina de predeterminação das outras 5 características. Fundos sem nenhum dado de carteira em $t - 1$ (fundo novo, por exemplo) ficam sem essa característica e saem da amostra — 2,4% das linhas.

O erro dessa etapa, $e_{i,n,t} = \text{peso}_{i,n,t} - g(x'_{i,n,t}\theta_{n,t})$, mede o quanto a posição observada de um fundo se afasta do que suas próprias características explicam, *dentro* do mesmo mês. Por construção da máxima verossimilhança, a média desse erro é mecanicamente zero em cada célula — não é evidência de bom ajuste, apenas uma propriedade algébrica do estimador. O que de

fato varia, e é informativo, é a dispersão do erro.

4.2 Etapa 2: ajuste parcial

A Etapa 1 estima um alvo, $w_{i,n,t}^* = g(x'_{i,n,t}\theta_{n,t})$, mas não diz nada sobre a *dinâmica*: quão rápido a posição real de um fundo converge a esse alvo, mês a mês. A segunda etapa modela essa dinâmica através de um mecanismo de ajuste parcial: a cada mês, o fundo fecha uma fração λ da distância entre sua posição atual e o alvo.

$$w_{i,n,t+1} - w_{i,n,t} = \lambda d_{i,n,t} + u_{i,n,t+1}, \quad d_{i,n,t} \equiv w_{i,n,t}^* - w_{i,n,t} \quad (3)$$

λ é estimado por mínimos quadrados ordinários diretos, sem intercepto, com todos os pares de meses consecutivos agrupados (*pooled*) — um único coeficiente, a mesma velocidade de ajuste para todo fundo e todo ativo.

4.3 Etapa 3: esquema fora da amostra

As duas primeiras etapas são estimadas com a amostra inteira e, por isso, não dizem se o modelo tem valor preditivo de verdade. A terceira etapa testa isso diretamente, com um corte temporal único: o parâmetro λ_h , para cada horizonte h , é reestimado usando **apenas** os meses de treino, anteriores a janeiro de 2020, e então aplicado, fixo, aos meses de teste, de janeiro de 2020 em diante — período que o modelo nunca viu durante a estimação.

$$\begin{aligned} \hat{w}_{i,n,t+h} &= w_{i,n,t} + \hat{\lambda}_{h,\text{treino}} d_{i,n,t} && \text{(ajuste parcial)} \\ \hat{w}_{i,n,t+h} &= w_{i,n,t} && \text{(previsão ingênua)} \end{aligned} \quad (4)$$

O erro fora da amostra, $\text{erro}_{i,n,t+h} = (w_{i,n,t+h} - w_{i,n,t}) - \hat{\lambda}_{h,\text{treino}} d_{i,n,t}$, é comparado ao erro da previsão ingênua (que simplesmente assume que nada muda) através da raiz do erro quadrático médio (RMSE). A diferença percentual entre os dois RMSEs (**margem**) responde à pergunta central: o ajuste parcial estimado com dados antigos ainda ajuda a prever dados novos, ou uma previsão ingênua seria tão boa quanto?

5 Resultados

Toda esta seção usa a base final da Tabela 3 (2.507 fundos, 41 grupos de gestora, 512 ativos, 8.212.294 observações, 59 meses) — uma única base do início ao fim. A Etapa 1 é estimada célula a célula (ativo, mês), com exigência mínima de 15 fundos holders por célula; com o corte de qualidade de dado mais permissivo ($\text{soma_peso} > 150\%$ em vez de $> 105\%$, Seção 3), o único fundo do grupo Legacy Capital passa a contribuir com exatamente uma célula (dez/2021), insu-

ficiente pra aparecer em qualquer tabela desta seção que agregue por gestora ao longo do tempo — Etapa 2 e 3 exigem pares de meses consecutivos, que esse fundo não tem — resultado: **2.504 fundos, 41 grupos de gestora, 430 ativos com célula estimada, 8.195.278 observações.**

5.1 Etapa 1: cross-section

O modelo (equação (1)) é estimado célula a célula (ativo, mês); 13.723 células convergiram (17 não convergiram, excluídas). A Tabela 4 resume o coeficiente padronizado (log-odds) e a Tabela 5 o efeito marginal médio (APE, pontos percentuais) de cada característica, entre as 13.723 células.

Tabela 4: Coeficiente padronizado (log-odds) de cada característica, mediana e % de células com sinal positivo, entre 13.723 células (ativo, mês). Fonte: script `99_pipeline_hhi_lag_etapa1.R` → `theta_multiativo.csv`.

Característica	Mediana	% de células positivo
Tamanho (θ^{aum})	−0,0283	44,5%
Cotistas (θ^{cot})	0,1254	72,8%
Fundo de cotas (θ^{fic})	−0,0244	48,3%
Fluxo/AUM (θ^{flow})	0,0372	53,0%
Beta do fundo (θ^{bf})	0,7830	88,2%
HHI _{resto} (θ^{hi})	0,4220	87,6%

Pseudo- R^2 de McFadden médio (com piso em -1 , ver nota do script): 0,531. HHI_{resto} é significativo ($|t| > 1,96$) em 74,4% das células (10.210 de 13.723), com sinal positivo em 95,7% dos casos significativos — concentrar o restante da carteira no mês anterior aumenta a probabilidade de concentrar também no ativo-alvo este mês.

Tabela 5: Efeito marginal médio (APE, pontos percentuais de peso), mesma base da Tabela 4. Fonte: script `99_pipeline_hhi_lag_etapa1.R` → `theta_multiativo.csv`.

Característica	Mediana (p.p.)	% de células positivo
Tamanho	−0,0007%	44,5%
Cotistas	0,0141%	72,8%
Fundo de cotas	−0,0005%	48,3%
Fluxo/AUM	0,0027%	52,9%
Beta do fundo	0,1401%	88,2%
HHI _{resto}	0,0562%	87,6%

Tabela 6: Estatísticas do erro e , Etapa 1, 8.195.278 observações. Fonte: script 99_pipeline_hhi_lag_etapa1.R $\rightarrow$ erro_e_multiativo.csv.

Estatística	Valor
Média	0,000000
Desvio-padrão	0,0117
Mediana	-0,0004
Mínimo / Máximo	-0,688 / 0,985
% de observações com $e > 0$	25,4%
Assimetria	11,96
Curtose	774,47 (normal = 3)
Previsões fora de $[0, 1]$	0 de 8.195.278

Assimetria/curtose altas por construção: a base mistura 512 ativos de liquidez e perfil muito diferentes numa única distribuição agregada, dominada por posições pequenas/residuais e algumas concentrações extremas.

5.2 Etapa 2: ajuste parcial

λ (equação (3)) estimado por MQO *pooled*, todos os pares de meses consecutivos, toda a amostra: $\hat{\lambda} = 0,0690$.

Tabela 7: Estatísticas do erro u , Etapa 2, 7.444.169 pares de meses consecutivos. Fonte: script 98_etapa1_etapa2_stats_multiativo.R $\rightarrow$ erro_u_multiativo.csv.

Estatística	Valor
Média	-0,00004
Desvio-padrão	0,0045
Mediana	0,0000
Mínimo / Máximo	-0,892 / 0,592
% de observações com $u > 0$	33,4%
Assimetria	-1,48
Curtose	892,04 (normal = 3)

5.3 Etapa 3: esquema fora da amostra

λ_h (equação (4)) estimado só em treino ($< \text{jan}/2020$), aplicado fixo ao teste ($\text{jan}/2020\text{--dez}/2021$).

A Tabela 8 traz o RMSE agregado nos 4 horizontes.

Tabela 8: RMSE fora da amostra, ajuste parcial vs. previsão ingênua, 4 horizontes. Fonte: script 99_pipeline_hhi_lag_etapa1.R.

	$h = 1$	$h = 3$	$h = 6$	$h = 12$
RMSE ajuste parcial	0,004033	0,005850	0,007097	0,008546
RMSE previsão ingênua	0,004095	0,006040	0,007454	0,009198
Razão ajuste/ingênua	0,9849	0,9685	0,9521	0,9291

$\lambda_1 = 0,0704$, $\lambda_3 = 0,1473$, $\lambda_6 = 0,2205$, $\lambda_{12} = 0,3382$ — crescente com o horizonte, como esperado (mais tempo, mais da distância ao alvo é percorrida). O ajuste parcial vence a previsão ingênua nos 4 horizontes, com margem crescente.

Tabela 9: λ fixo (treino único) vs. janela expansiva (reestimado mês a mês, sem vazamento), fora da amostra, $h = 1$. Fonte: script 82_etapa3_multiativo_janela_expansiva.R.

Meses de teste	λ fixo	λ expansiva
23	0,9848	0,9849

Razão RMSE/RMSE ingênua. Ambas as versões vencem a ingênua em 23 dos 23 meses; correlação de Spearman do ranking de dificuldade por gestora entre as duas versões de λ , 40 gestoras: 1,0000. Confirma a robustez do λ fixo.




Figura 1: Evolução mensal do erro médio fora da amostra ($h = 1$), 3 gestoras mais difíceis (Guepardo, Ibiuna, AZ Quest) e 3 mais previsíveis (TNA, Gávea, Plural) — extremos de RMSE $h = 1$ (Tabelas 11–12). Fonte: script 74_figuras_dinamica_erro_tcc.R → etapa3_multiativo_h1.csv.




Figura 2: Erro fora da amostra agregado (nuvem cinza: individual; azul: média mensal; vermelho: desvio-padrão mensal). Esquerda: $h = 1$; direita: $h = 3$. Fonte: script 74_figuras_dinamica_erro_tcc.R.




Figura 3: Margem do ajuste parcial sobre a ingênua, mês a mês ($h = 1$: média 1,48%; $h = 3$: média 3,13%). Fonte: script 75_figura_margem_dinamica.R.




Figura 4: Peso real vs. previsto ($h = 3$), fundo 406724 (Squadra Investimentos), EQTL3 — o par fundativo de maior RMSE fora da amostra entre os que têm posição de verdade (sem posição-poeira). Diferente do exemplo de "desmonte abrupto" da versão anterior deste documento: aqui o peso fica persistentemente concentrado (entre 97% e 99,9% do patrimônio) ao longo de todo o período de teste, e é justamente essa concentração extrema e permanente — não capturada plenamente pelas 6 características — que o ajuste parcial sistematicamente não acerta. Fonte: script 92_figura_trajetoria_fundo_v2.R.




Figura 5: Viés médio mensal fora da amostra, com sinal, 3 gestoras mais positivas e 3 mais negativas (mín. 100 obs. de teste). Maior viés positivo: Guepardo (0,00329), Núcleo Capital (0,00168); maior negativo: Daycoval (−0,00070), Kinea (−0,00041). Fonte: script 77_figura_vies_dinamico_gestora.R.

Persistência do viés. Dividindo os 23 meses de teste ao meio: correlação de 0,73 ($R^2 = 0,54$) entre o viés médio de cada gestora nas duas metades (40 gestoras com ≥ 50 observações em cada metade) — persistente, mas longe de perfeito.




Figura 6: Viés médio, 1ª metade do teste (2020) vs. 2ª metade (2021), 39 gestoras. Fonte: script 84_persistencia_vies_gestora.R.

Correção de viés. Estimando o viés na 1ª metade e aplicando-o, fixo, à 2ª: RMSE cai de 0,005858 para 0,005856 — melhora de 0,04%, irrelevante na prática.

Decomposição $RMSE^2 = viés^2 + variância$. Em média entre as 40 gestoras, $viés^2$ explica 0,46% do $RMSE^2$ (mediana 0,12%; máximo 2,99%, Real Investor). *Pooled* (todas as observações juntas): 0,000%. A variância domina.

Decomposição do erro: variância domina o viés




Figura 7: Decomposição do erro fora da amostra ($h = 1$) por gestora, ordenada por RMSE. Fonte: script 86_decomposicao_e_persistencia_variancia.R.

Persistência da variância. Correlação de 0,85 ($R^2 = 0,72$) entre o desvio-padrão do erro na 1ª e na 2ª metade do teste (40 gestoras) — bem mais persistente que o viés (parágrafo anterior): quem é difícil de prever numa metade do teste tende a continuar difícil na outra, de forma muito mais estável do que a direção do erro.




Figura 8: Desvio-padrão do erro, 1ª vs. 2ª metade do teste, 39 gestoras. Linha tracejada: $y = x$. Fonte: script 86_decomposicao_e_persistencia_variancia.R.

O que explica a variância. Duas construções de concentração aparecem neste trabalho: $\text{HHI}_{\text{resto}}$ (equação (2), exclui o ativo-alvo, nível fundo-ativo-mês, já dentro da Etapa 1) e $\text{HHI}_{\text{medio}}$ (inclui todos os ativos, nível gestora, usado só nesta regressão de diagnóstico — pergunta diferente: mesmo com HHI já formalmente no modelo de peso, a concentração ainda explica erro residual entre gestoras?). Correlações bivariadas contra o desvio-padrão do erro por gestora: beta 0,47 ($R^2 = 0,22$), tamanho 0,09 ($R^2 = 0,01$), $\text{HHI}_{\text{medio}}$ 0,65 ($R^2 = 0,43$) — mesmo com HHI já formalmente no modelo de peso (Etapa 1), a concentração ainda explica bastante do erro residual entre gestoras. Para isolar o efeito de cada característica, a concentração entra numa regressão múltipla junto com as 5 características não-HHI da Etapa 1, todas medidas só no período de treino (predeterminadas em relação ao dp(erro)_g , medido só no período de teste):

$$\begin{aligned} \text{dp(erro)}_g = & \alpha + \beta_1 \overline{\text{beta}}_g + \beta_2 \overline{\log(\text{AUM})}_g + \beta_3 \overline{\log(\text{cotistas})}_g \\ & + \beta_4 \overline{\% \text{FIC}}_g + \beta_5 \overline{\text{fluxo}/\text{AUM}}_g + \beta_6 \overline{\text{HHI}_{\text{medio}}}_g + u_g \end{aligned} \quad (5)$$




Figura 9: Desvio-padrão do erro por gestora vs. beta médio, tamanho médio, $\text{HHI}_{\text{médio}}$, 40 gestoras. Fonte: script 87_explica_variancia_gestora.R.

Tabela 10: Regressão múltipla (equação (5)): desvio-padrão do erro fora da amostra por gestora explicado pelas 5 características não-HHI da Etapa 1 mais $\text{HHI}_{\text{médio}}$, todas do período de treino. 40 gestoras. Fonte: script 95_regressao_completa_variancia.R.

Variável	Coefficiente	t	Sig.
Intercepto (α)	-0,0122	-1,07	n.s.
Beta médio do fundo	0,0015	0,55	n.s.
Tamanho médio, log AUM	0,0009	1,34	n.s.
Cotistas médio, log	0,0001	0,18	n.s.
% FIC	-0,0006	-0,31	n.s.
Fluxo/AUM médio	-0,0092	-1,38	n.s.
$\text{HHI}_{\text{médio}}$	0,0736	3,76	**
R^2		0,496	

** $p < 1\%$; n.s. = não significativo a 5%. HHI já estar formalmente na Etapa 1 não elimina seu poder explicativo aqui — são perguntas diferentes (a Etapa 1 explica o *peso*; esta regressão explica o *erro* de gestoras inteiras).

Concentração no nível fundo-mês. Refinando para o nível fundo-mês (não mais média por gestora): correlação contemporânea 0,48 (Spearman 0,80), defasada (mês $t - 1$) 0,49 (Spearman 0,80) — quase idênticas, afastando coincidência de mesmo mês — e dentro do fundo (demeaned) 0,07 (Spearman 0,11): a concentração é, sobretudo, um traço que diferencia fundos entre si, não um sinal de curto prazo dentro do mesmo fundo.




Figura 10: Concentração (HHI) vs. erro fora da amostra, nível fundo-mês, em decis. (A) contemporânea; (B) defasada; (C) dentro do fundo. Fonte: script 88_concentracao_mes_a_mes.R.




Figura 11: Beta médio do fundo vs. RMSE fora da amostra, 2.039 fundos (≥ 6 obs. de teste, peso mediano $\geq 0,1\%$). $R^2 = 0,20$ (coef. 0,00754, $p < 10^{-100}$). Fonte: script 78_figura_beta_vs_erro.R.




Figura 12: Estabilidade do ranking de dificuldade por gestora entre horizontes, 40 gestoras (todas com dado completo nos 4 horizontes). Spearman: 0,97 ($h1-h3$), 0,94 ($h1-h6$), 0,91 ($h1-h12$), 0,98 ($h3-h6$), 0,97 ($h3-h12$), 0,99 ($h6-h12$). Fonte: script 80_figura_ranking_horizontes.R.

Tabela 11: RMSE fora da amostra por gestora, 4 horizontes, ordenado do mais ao menos errante em $h = 1$. Fonte: script 93_gera_latex_tabelas_9_10.R → etapa3_multiativo_gestora_multihorizonte.csv.

Gestora	Fundos ($h=1$)	RMSE $h=1$	RMSE $h=3$	RMSE $h=6$	RMSE $h=12$
Guepardo Investimentos	11	0,01424	0,02305	0,03358	0,05649
Ibiuna Investimentos	7	0,01331	0,02131	0,02492	0,02848
AZ Quest	22	0,01092	0,01461	0,01650	0,01871
Squadra Investimentos	15	0,01069	0,01588	0,02090	0,03058
Núcleo Capital	22	0,01037	0,01810	0,02468	0,03538
Forpus Capital	3	0,00992	0,01436	0,01649	0,01666
Truxt Investimentos	29	0,00811	0,01263	0,01600	0,01978
Sharp Capital	34	0,00800	0,01290	0,01713	0,02134
ARX Investimentos	11	0,00785	0,01083	0,01260	0,01510
Kinea Investimentos	4	0,00709	0,01156	0,01536	0,01600
Constellation Asset Management	25	0,00691	0,01375	0,01831	0,02768
Opportunity	19	0,00681	0,01053	0,01349	0,01570
SPX Capital	35	0,00614	0,00919	0,01174	0,01338
Atmos Capital	28	0,00612	0,00999	0,01340	0,01711
Verde Asset Management	14	0,00601	0,01020	0,01297	0,01643
Absolute Investimentos	7	0,00585	0,00921	0,01220	0,01408
JGP	46	0,00559	0,00784	0,00902	0,01079
Daycoval Asset Management	6	0,00557	0,00730	0,00726	0,00827
Kapitalo Investimentos	22	0,00536	0,00580	0,00693	0,00818
Credit Suisse	65	0,00533	0,00741	0,00859	0,00974
Bogari Capital	15	0,00530	0,00925	0,01200	0,01575

continua na próxima página

(continuação)

Gestora	Fundos ($h=1$)	RMSE $h=1$	RMSE $h=3$	RMSE $h=6$	RMSE $h=12$
Real Investor	5	0,00491	0,00919	0,01401	0,01742
Caixa	31	0,00491	0,00744	0,00990	0,01275
Vinci Partners	47	0,00487	0,00682	0,00780	0,00899
Claritas Investimentos	10	0,00482	0,00706	0,00795	0,00849
Bradesco Asset Management	302	0,00445	0,00620	0,00736	0,00875
BB Asset Management	129	0,00441	0,00671	0,00838	0,01022
Western Asset	26	0,00438	0,00701	0,00963	0,01253
Occam Brasil	27	0,00430	0,00715	0,00831	0,01096
BTG Pactual	143	0,00416	0,00629	0,00743	0,00911
Safra Asset Management	155	0,00397	0,00564	0,00668	0,00763
Santander Brasil Asset Management	70	0,00394	0,00550	0,00630	0,00734
Julius Baer Family Office	62	0,00329	0,00452	0,00538	0,00642
XP	89	0,00327	0,00478	0,00565	0,00748
BNP Paribas	44	0,00324	0,00462	0,00561	0,00744
Itaú	466	0,00261	0,00385	0,00473	0,00559
Dahlia Capital	18	0,00245	0,00422	0,00549	0,00631
TNA Gestão Patrimonial	29	0,00150	0,00216	0,00278	0,00384
Gávea Investimentos	17	0,00144	0,00265	0,00365	0,00472
Plural	1	0,00050	0,00079	0,00104	0,00134

Tabela 12: Margem do ajuste parcial sobre a ingênua (% de redução de RMSE), mesma ordem da Tabela 11. Negativo = ajuste parcial pior que a ingênua. Fonte: script 93_gera_latex_tabelas_9_10.R.

Gestora	Margem $h=1$	Margem $h=3$	Margem $h=6$	Margem $h=12$
Guepardo Investimentos	1,2%	1,0%	-0,1%	-1,3%
Ibiuna Investimentos	3,1%	6,8%	8,2%	14,3%
AZ Quest	3,1%	6,7%	9,5%	15,1%
Squadra Investimentos	-5,4%	-13,7%	-24,3%	-45,6%
Núcleo Capital	-1,0%	-2,1%	-2,0%	-5,7%
Forpus Capital	2,4%	5,9%	7,7%	11,5%
Truxt Investimentos	1,7%	3,8%	5,9%	13,1%
Sharp Capital	1,8%	4,6%	8,2%	15,2%
ARX Investimentos	2,1%	4,3%	6,9%	7,9%
Kinea Investimentos	1,7%	3,7%	8,1%	10,0%
Constellation Asset Management	-0,2%	0,6%	2,8%	4,0%
Opportunity	1,6%	3,8%	6,2%	9,6%
SPX Capital	2,7%	6,5%	10,5%	17,9%
Atmos Capital	0,2%	2,9%	5,1%	11,8%
Verde Asset Management	0,6%	1,6%	3,0%	-0,3%
Absolute Investimentos	1,8%	4,0%	7,3%	11,5%
JGP	2,1%	3,9%	4,8%	7,8%
Daycoval Asset Management	2,8%	5,6%	7,9%	12,3%
Kapitalo Investimentos	2,7%	5,8%	7,1%	8,0%
Credit Suisse	2,4%	4,9%	7,8%	13,8%
Bogari Capital	-0,4%	0,3%	0,9%	-3,2%
Real Investor	-1,4%	1,2%	2,4%	8,2%

continua na próxima página

(continuação)

Gestora	Margem $h=1$	Margem $h=3$	Margem $h=6$	Margem $h=12$
Caixa	1,5%	3,6%	6,0%	8,3%
Vinci Partners	1,3%	3,0%	6,1%	16,7%
Claritas Investimentos	1,8%	6,1%	10,6%	18,4%
Bradesco Asset Management	1,9%	3,5%	4,5%	4,2%
BB Asset Management	1,0%	2,0%	3,2%	3,5%
Western Asset	1,1%	3,1%	5,2%	5,7%
Occam Brasil	1,8%	4,0%	6,8%	9,6%
BTG Pactual	1,1%	2,0%	2,9%	5,5%
Safra Asset Management	1,7%	3,4%	6,6%	14,2%
Santander Brasil Asset Management	1,9%	4,1%	5,4%	7,1%
Julius Baer Family Office	1,4%	3,7%	6,7%	10,1%
XP	-1,6%	-3,4%	-4,5%	-4,6%
BNP Paribas	0,4%	-0,1%	-1,8%	-5,7%
Itaú	1,9%	4,2%	6,2%	8,1%
Dahlia Capital	2,4%	5,3%	8,0%	10,2%
TNA Gestão Patrimonial	0,1%	-0,8%	-0,8%	2,3%
Gávea Investimentos	2,2%	4,2%	7,9%	10,4%
Plural	-2,4%	-3,7%	-2,8%	-6,1%




Figura 13: Cada ponto é uma gestora: RMSE ($h=1$, eixo x) vs. margem sobre a ingênua ($h=1$, eixo y ; negativo = ajuste parcial piora). Fonte: script 45_fig_multihorizonte_gestora_rmse_margem.R.

Squadra Investimentos é o único caso em que o ajuste parcial **piora** a previsão em relação à ingênua de forma expressiva e crescente com o horizonte ($-5,4\%$ em $h = 1$ a $-45,6\%$ em $h = 12$, Tabela 12) — puxado justamente pelo fundo 406724, o par fundo-ativo de maior RMSE de toda

a amostra (Figura 4): sua concentração extrema e persistente em EQTL3 faz o modelo prever repetidamente uma reversão à média que nunca acontece, e o erro se acumula a cada horizonte mais longo.

6 Aplicação: robô caça-replicantes

A estrutura do erro fora da amostra (Seção 5) sugere uma aplicação direta: se dois fundos de gestoras diferentes erram de forma sincronizada, além do que suas características observáveis explicam, isso é coincidência ou um padrão real de replicação de carteira? Esta seção testa essa pergunta até o fim — incluindo a etapa final, decisiva, que esta base de resultados nunca tinha sido usada para responder: será que esse padrão, convertido em sinal de fluxo previsto, prediz retorno futuro do ativo? Um achado é validado; o outro, testado e rejeitado, honestamente relatado como tal.

A base é a mesma da Seção 5 (mesma especificação de 6 características, equações (1), (2), (3) e (4)) — não há mais nada a generalizar aqui. Esta seção acrescenta uma única mudança de desenho: a variação de peso é corrigida do efeito mecânico do preço (dividendos, desdobramentos), para isolar negociação ativa de valorização passiva. Preço disponível para 519 dos 536 ativos do universo bruto (96,8%; 99,65% do peso agregado).

6.1 Correção de efeito mecânico do preço

O peso observado mistura negociação ativa com valorização pura do preço — um fundo que não faz nada pode ver seu peso num ativo subir só porque o preço subiu mais que o resto da carteira. A correção mecânica isola esse efeito:

$$w_{i,n,t+1}^{\text{mecânico}} = w_{i,n,t} \cdot \frac{1 + r_{n,t+1}}{1 + r_{i,t+1}}, \quad dw_{\text{corrigido}} = w_{i,n,t+1} - w_{i,n,t+1}^{\text{mecânico}} \quad (6)$$

em que r_n é o retorno do ativo (preço de mercado) e r_i é o retorno da cota do fundo inteiro (naturalmente neutro a aportes/resgates, ao contrário do peso bruto).

Yahoo Finance sozinho cobre só 62,5% dos ativos — tickers “somem” em reorganizações societárias (ex.: JBS → JBSS32), não porque a empresa deixou de existir. B3 oficial (preço bruto, sem ajuste de proventos) mais 5 tickers sucessores resolvidos manualmente (KROT11→COGN3, UNID3→LCAM3, IMCH3→MEAL3, LLISE3→LLIS3, HGTX4→HGTX3) fecham a cobertura em 99,65% do peso agregado. Dois artefatos de retorno tratados antes da correção: desdobramento/grupamento de cota não ajustado em alguns fundos (ex.: fundo 332186, cota R\$2,00→R\$0,0375 em dez/2018, volta a crescer normalmente dali — não é perda real); e retorno de fundo ou ativo com $< -90\%$ ou $> 200\%$ num único mês, excluído só da correção mecânica (não do resto da amostra).

Tabela 13: Etapa 2: λ (equação (3)) bruto vs. com correção mecânica, MQO *pooled*, amostra inteira.
Fonte: script 61_ajuste_parcial_universo_completo.R.

	λ	R^2
Sem correção mecânica	0,0691	0,0320
Com correção mecânica	0,0690	0,0342

λ com e sem correção fica quase idêntico e R^2 **melhora** com a correção — o resultado economicamente esperado (a correção deveria remover ruído mecânico, não introduzir nenhum). Antes de tratar os 2 artefatos de retorno acima, o mesmo teste mostrava o oposto (R^2 piorando): era inteiramente artefato dos outliers, não efeito real.

Tabela 14: Etapa 3 fora da amostra: λ_h (equação (4)) treinado em <jan/2020, aplicado fixo ao teste.
Fonte: script 62_etapa3_universo_completo.R.

	λ bruto	λ corrigido	Margem mediana	% vence ingênua
h=1, bruto	0,0704	—	1,49%	72,3%
h=1, corrigido	—	0,0715	0,62%	64,2%
h=3	0,1473	0,1469	—	—

Para VALE3 especificamente (31.929 obs. de teste), a correção **melhora** a margem (1,36%→2,31%) — o oposto do padrão mediano. Ver Figura 14.




Figura 14: Margem vs. ingênua ($h = 1$), com e sem correção mecânica, por ativo (340 elegíveis, ≥ 100 obs. de teste), colorido pela fonte do preço. Fonte: script 69_figuras_teste_estrategia.R.

Quebrando por fonte do preço: ativos com preço ajustado por proventos (Yahoo, 234) quase não mudam (1,16%→0,75%); ativos só com preço bruto da B3 (106) caem mais (1,92%→0,54%, visível como a nuvem vermelha mais abaixo da diagonal na Figura 14) — a limitação de cobertura

de preço tem consequência prática mensurável. O caso mais extremo (Alpargatas ON, margem corrigida $-77,3\%$) usa preço ajustado, não é problema de dividendo: a ação sofreu volatilidade real em 2020 (queda de $\sim 30\%$ em março) que o modelo de ajuste parcial não capta — achado genuíno, não artefato.

6.2 Detecção de pares replicantes

Para cada ativo, correlação (contemporânea e defasada em 1 mês) entre a série de erro de todo par de fundos que o carrega — ativo por ativo, não portfólio inteiro, para não diluir um replicante que só copia numa posição específica:

$$u_{i,n,t} = dw_{\text{corrigido}} - \hat{\lambda} d_{i,n,t}, \quad t_{\text{corr}} = r \sqrt{\frac{n-2}{1-r^2}} \quad (7)$$

Filtro de posição-poeira (peso mediano da célula fundo-ativo $\geq 0,1\%$) aplicado antes de qualquer correlação — sem ele, o resultado fica dominado por séries quase-zero numericamente instáveis. Correção de múltiplas comparações (Benjamini–Hochberg):

$$p_{\text{ajustado},(k)} = \min_{j \geq k} \left(p_{(j)} \cdot \frac{m}{j} \right), \quad m = 31.907.281 \text{ testes} \quad (8)$$

Tabela 15: Detecção de pares. Fonte: scripts 63–65 $\rightarrow$ pares_replicantes_significativos.csv.

Ativos elegíveis (pós filtro de poeira)	340
Pares com $ \text{correlação} \geq 0,6$	1.808.886
Pares significativos ($p_{\text{ajustado}} < 0,05$)	1.248.772
— mesma gestora / gestoras diferentes	454.840 (36%) / 793.932 (64%)
Pares com liderança clara (assimetria $> 0,2$)	79.538 (61.134 cross-gestora)

Pela contagem bruta, Itaú domina (425 fundos, quase o dobro do 2º maior) — artefato de tamanho. Normalizado (Figura 15), quem domina são **boutiques menores**: Atmos $\leftrightarrow$ TNA (taxa 2,81), Squadra $\leftrightarrow$ TNA (1,86), Julius Baer $\leftrightarrow$ SPX Capital (1,74) — consistente com replicação entre gestoras de estilo próximo, não só efeito de escala.




Figura 15: Top 10 pares de gestora por taxa normalizada (pares fundo-fundo significativos $\div$ pares possíveis entre as duas gestoras). Fonte: script 69_figuras_teste_estrategia.R.

6.3 Sinal do robô

Para cada par líder→seguidor, β por regressão através da origem na amostra pareada exata (equivalente a MQO individual por par):

$$\beta = \frac{\sum_t u_{\text{líder},t} u_{\text{seguidor},t}}{\sum_t u_{\text{líder},t}^2}, \quad dw_{\text{ajustado}} = \hat{\lambda} d_{\text{seguidor},t} + \beta u_{\text{líder},t}$$

$$\text{fluxo}_{\text{R\$}} = \text{AUM}_{\text{seguidor},t} \cdot dw_{\text{ajustado}} \quad (9)$$

Onde um seguidor tem mais de um líder candidato no mesmo ativo, usa-se só o de maior força de liderança (evita somar sinais correlacionados entre si). Fluxo somado por gestora, depois net entre todas, por ativo-mês.

Tabela 16: Fonte: scripts 66–68.

	Sem ajuste	Com ajuste
RMSE (18.752 pares seguidor-ativo, 359.861 obs.)	0,00612	0,00403 (−34,2%)

Mediana do fluxo líquido perto de zero, distribuição bem assimétrica — maioria neutra, poucos ativo-mês concentram sinal forte; R\$1–2 bi/mês para uma blue chip amplamente carregada é fração pequena do patrimônio total da indústria de fundos, ordem de grandeza plausível. A melhora de RMSE de 34,2% é **dentro da amostra** (β estimado e avaliado nos mesmos dados — garantia matemática do MQO, não prova de generalização); e o fluxo reportado é só o componente “eco do líder” (pares com líder identificado), não a previsão de todos os fundos do universo — ainda não é um sinal de demanda de mercado completo.




Figura 16: Top 5 maiores pressões compradoras e vendedoras líquidas (ativo-mês), em R\$ bilhões. Maior compra: Petrobras ON, jan/2020, +R\$2,03 bi (290 fundos, 19 gestoras). Maior venda: Petrobras Distrib., mai/2021, -R\$886 mi (439 fundos, 23 gestoras). Fonte: script 69_figuras_teste_estrategia.R.

6.4 O teste decisivo: fluxo previsto prediz retorno?

Tudo até aqui prevê *mudança de peso dos fundos*. Uma estratégia long/short aposta em *retorno do ativo*. A teoria de *demand-based asset pricing* diz que pressão de compra empurra preço para cima — mas isso nunca tinha sido testado com o sinal construído acima. Antes de falar em estratégia, o fluxo previsto precisa prever retorno de verdade:

$$\text{retorno}_{i,t+1} = \alpha + \beta_{\text{ret}} \cdot \text{fluxo_pct}_{i,t} + \varepsilon_{i,t+1}, \quad \text{fluxo_pct}_{i,t} = \frac{\text{fluxo líquido em R\$}_{i,t}}{\text{valor total da posição em } i, \text{ mês } t} \quad (10)$$

Fluxo normalizado pelo valor total da posição (não R\$ bruto) — senão o teste só capturaria “ativo grande tem fluxo grande”, não poder preditivo de verdade. Rodado em duas versões do sinal (com e sem o eco do líder) e duas amostras (completa; restrita aos 212 ativos com margem positiva na Etapa 3, de 359 elegíveis, na hipótese de que ruído dos ativos onde o modelo não funciona bem estivesse diluindo o teste).

Tabela 17: Fonte: scripts 70–71 → teste_fluxo_prediz_retorno.csv.

	Amostra completa (8.383 obs.)		Só margem > 0 (6.160 obs.)	
	Coef. (β_{ret})	p-valor	Coef. (β_{ret})	p-valor
Sinal COM eco do líder	$-5,6 \times 10^{-8}$	0,277	$+1,9 \times 10^{-8}$	0,737
Sinal SEM eco (só $\hat{\lambda}d$)	$+1,4 \times 10^{-6}$	0,0002	$+1,1 \times 10^{-6}$	0,027

R^2 em todos os casos: entre 0,002% e 0,165% — economicamente irrisório em qualquer especificação.

O teste não valida a premissa de negociar em cima do sinal. O sinal com eco do líder (o produto final desta seção) sai com coeficiente *negativo* e não significativo em nenhuma




Figura 17: Fluxo previsto (mês t) vs. retorno do ativo (mês $t+1$), amostra completa. A reta de regressão é essencialmente plana — $R^2 = 0,014\%$. Fonte: script `72_figuras_teste_retorno.R`.

das duas amostras ($p = 0,277$ completa, $p = 0,737$ restrita a margem positiva) — pior que o sinal mais simples (só $\hat{\lambda}d$), que ao menos tem o sinal certo e é estatisticamente detectável nas duas amostras ($p = 0,0002$ completa, $p = 0,027$ restrita), mas com R^2 tão baixo (0,002–0,165%) que não sustenta uma estratégia em nenhum caso. Restringir a ativos de margem positiva não resgata o sinal com eco (permanece não significativo); o sinal sem eco mantém — e até reforça — a significância estatística na subamostra restrita, mas o R^2 continua irrisório (0,079%), então a conclusão econômica não muda: significância estatística com esse tamanho de amostra não implica poder explicativo que sustente uma estratégia.

Isto é um resultado negativo genuíno, não uma limitação de dado a ser corrigida depois. O mecanismo “fundos compram $\Rightarrow$ preço sobe” pode existir no mercado como um todo, mas **não aparece de forma detectável neste sinal, nesta amostra, neste horizonte**. O trabalho não avança para “vale a pena operar” (liquidez, custo de transação) — não faz sentido otimizar execução de um sinal sem poder preditivo demonstrado.




Figura 18: Retorno médio subsequente por quintil de fluxo previsto (Q1 = mais vendedor, Q5 = mais comprador), amostra completa vs. restrita a ativos de margem positiva. Diferença Q5–Q1: +0,50 p.p. ($p = 0,301$) na completa, +0,87 p.p. ($p = 0,116$) na restrita — nenhuma das duas significativa. Fonte: script 72_figuras_teste_retorno.R.

6.5 Síntese: o que está validado e o que não está

Achado	Status	Evidência
Beta do fundo generaliza entre ativos	Validado	92,3% mesmo sinal que VALE3
Correção mecânica de preço melhora o ajuste	Validado	R^2 melhora com a correção
Pares de fundos com erro sincronizado além das características (replicantes)	Validado	1.248.772 pares, $p < 0,05$ com Benjamini–Hochberg
Relação líder→seguidor melhora previsão de <i>peso</i>	Validado <i>dentro da amostra</i>	RMSE –34,2%
Sinal de fluxo previsto prediz <i>retorno</i> do ativo	Rejeitado	$R^2 \approx 0$, sinal inconsistente
Estratégia long/short executável	Não avaliado (depende do item anterior)	—

O núcleo que sobrevive ao escrutínio é a **deteção de replicantes em si**: existem pares de fundos, sobretudo entre gestoras de porte parecido e próximas em estilo, cujo comportamento se move em conjunto além do que tamanho, cotistas, fluxo, estrutura de fundo de cotas e beta explicam — estatisticamente robusto mesmo depois de corrigir milhões de comparações múltiplas. A tentativa de converter esse padrão em sinal de negociação foi feita de forma honesta e testada até o fim, e não passou no teste decisivo. Isso é registrado como um resultado, não escondido: um achado positivo (existe replicação) não implica automaticamente um achado positivo seguinte

(dá para lucrar com isso) — e este trabalho testou os dois, separadamente, em vez de assumir que o segundo decorre do primeiro.

7 Conclusão

[Seção a ser escrita por último.]