

Tudo Explicado

O TCC inteiro, método por método, número por número:
o que cada coisa é, por que ela está aqui, como funciona por dentro,
o que encontramos, o que ainda está frágil e como corrigimos

Peso de VALE3 nos fundos do grupo Itaú, 2016–2021

João Paulo Zangrandi (FGV–EESP)

documento didático de apoio; números reproduzidos por reexecução dos scripts em 06/07/2026

Resumo

Este documento explica, com profundidade deliberadamente exagerada, tudo o que acontece no projeto: a pergunta econômica, cada base de dados e cada tratamento, cada método econométrico (regressão transversal, Fama–MacBeth, Newey–West, logit fracionário de Papke–Wooldridge, testes de Dickey–Fuller, filtro de Kalman, ajuste parcial, variáveis instrumentais, erros-padrão agrupados e efeito de tempo, painel dinâmico de Arellano–Bond, fatores de risco do NEFIN-USP, avaliação de previsão fora da amostra e teste de Diebold–Mariano), sempre no mesmo formato: *o que é* → *por que faz sentido usar aqui* → *como funciona por dentro* → *o que deu no nosso caso* → *limitações e correções*. Esta versão (09/07/2026) incorpora as correções da revisão `correções_fable.pdf` — todas implementadas, não mais pendentes — e a extensão para um universo amplo de ações (não só VALE3), o painel dinâmico de Arellano–Bond, o beta do próprio fundo e os fatores do NEFIN-USP, pedidos numa nova rodada de anotações do orientador. Todos os números citados foram reproduzidos rodando os scripts `R/14–R/36` do repositório; onde um resultado tem fragilidade — inclusive um achado nesta versão em que um estimador (Arellano–Bond) troca de sinal conforme a especificação —, ela é explicada aqui em vez de escondida.

Sumário

1	O mapa do projeto em uma página	4
2	O arcabouço econômico	4
2.1	Sistemas de demanda por ativos (Kojen–Yogo, 2019)	4
2.2	Por que o <i>peso</i> , e não o valor em reais ou o número de ações?	5
2.3	A opacidade de 90 dias	6
3	Os dados, variável por variável	6
3.1	As quatro fontes	6
3.2	Construção do painel e tratamentos (com o porquê de cada um)	6
3.3	Os números da amostra	7
4	Passo 1(a): a regressão transversal mês a mês	8
5	Fama–MacBeth	8
6	Newey–West (erros-padrão HAC)	9
7	Logit fracionário (Papke–Wooldridge)	10
8	A regressão empilhada com preço e beta	12
9	Fatores de risco do NEFIN-USP (Carhart)	12
10	Beta do próprio fundo	13
11	Passo 2(a): a dinâmica do fator θ_t	14
11.1	Autocorrelação e AR(1)	14
11.2	O teste de Dickey–Fuller, por dentro	14
12	O filtro de Kalman	15
13	Previsão fora da amostra: desenho e resultados	16
13.1	O desenho experimental	16
13.2	Os quatro modelos comparados	17
13.3	Resultados	17
14	As duas margens: ter vs. quanto ter	17
15	Extensão: a demanda por um universo amplo de ações	18
15.1	Construção do painel amplo	18
15.2	O padrão de VALE3 generaliza?	19
16	O modelo de ajuste parcial	20
16.1	A equação e sua lógica	20
16.2	Por que o MQO é enviesado aqui — os <i>dois</i> vieses, derivados	20
16.3	Variável instrumental, por dentro	21
16.4	Erros-padrão agrupados (cluster) — e o problema do choque comum	22
16.5	Resultados principais do ajuste parcial	23

17 Painel dinâmico: Arellano–Bond	23
18 A série do erro $\hat{u}$ e a regra de decisão recursiva	25
18.1 A série do erro de previsão	25
18.2 A regra de decisão sob opacidade	25
18.3 Diebold–Mariano: o teste que disciplina essa conclusão	25
19 Fragilidades transversais e o mapa de correções	26
19.1 O outlier de fluxo e a winsorização	26
19.2 Mapa geral: limitação $\rightarrow$ correção $\rightarrow$ status	27
20 Síntese final: a história completa	27
A O que cada script faz	29
B Referências	29

1 O mapa do projeto em uma página

O projeto responde a duas perguntas sobre os fundos de investimento do grupo Itaú entre 2016 e 2021, olhando para uma única ação, VALE3:

1. **Explicação:** quais características de um fundo explicam o *peso* que ele dá a VALE3 na carteira?
2. **Previsão:** esse peso pode ser previsto de um mês (ou de um trimestre) para o outro?

A arquitetura tem **dois passos**, no espírito de um sistema de demanda por ativos:

- **Passo 1 (transversal):** a cada mês t , regredimos o peso $w_{i,t}$ de cada fundo i sobre características do fundo (tamanho, cotistas, tipo, fluxo). O vetor de coeficientes $\hat{\theta}_t$ desse mês é lido como um *fator latente*: ele resume “o quanto cada característica puxa a posição em VALE3 naquele mês”. São 72 meses, logo 72 vetores $\hat{\theta}_t$. O resumo estatístico dos 72 vetores é feito no estilo **Fama–MacBeth** (Seção 5), com erros-padrão corrigidos por **Newey–West** (Seção 6), e a forma funcional correta para uma fração usa o **logit fracionário** (Seção 7).
- **Passo 2 (dinâmico):** os $\hat{\theta}_t$ viram séries temporais, cuja persistência examinamos com autocorrelações, modelos **AR(1)** e testes de **Dickey–Fuller** (Seção 11); tentamos prever o peso com **filtro de Kalman** e efeitos fixos (Seções 12–13); e, por fim, modelamos a transição de um mês para o outro com o **ajuste parcial** $\Delta w_{t+1} = \lambda d_t + u_{t+1}$, estimado por **variável instrumental** (Seção 16), gerando a série de erros $\hat{u}$ e uma regra de decisão recursiva sob a opacidade de 90 dias (Seção 18).

O resultado, em uma frase: *as características explicam bem o nível do peso (sinais estáveis nos 72 meses, e que generalizam para 92–99% de quase 900 ações), mas o peso de cada fundo é tão persistente — quase um passeio aleatório — que no curto prazo nada supera com clareza a previsão ingênua de repetir o último valor; existe uma reversão real ao “peso-alvo” definido pelas características, robusta a seis especificações de estimação diferentes (a estimativa central fecha $\approx 4\%$ da distância por mês, mas varia por um fator de dez conforme o método), e a evidência de que isso gera ganho de previsão operável é, por ora, estatisticamente fraca — testada formalmente pelo teste de Diebold–Mariano.*

Esta versão do documento acrescenta quatro peças pedidas numa nova rodada de anotações do orientador: a velocidade de ajuste estimada também por **painel dinâmico de Arellano–Bond** (Seção 17); o **beta do próprio fundo** como controle (Seção 10); os **fatores de risco do NEFIN-USP** como controle no pooled (Seção 9); e a generalização da estimação de demanda para um **universo amplo de quase 900 ações** mantidas pelos fundos do Itaú, não só VALE3 (Seção 15).

2 O arcabouço econômico

2.1 Sistemas de demanda por ativos (Kojen–Yogo, 2019)

O que é. A visão tradicional de apreçamento parte de condições de não-arbitragem e fatores de desconto. Kojen e Yogo (2019) propõem o caminho inverso, mais próximo de organização industrial: tratar o preço de cada ativo como o resultado do *equilíbrio entre demandas* de investidores heterogêneos. Cada investidor i tem uma função de demanda pelo ativo n que depende das *características* do ativo (tamanho, book-to-market, beta, etc.): $w_{i,n} = f(x_n; \theta_i)$. Com as carteiras observadas (nos EUA, via formulários 13F), estimam-se os θ_i e, agregando as demandas e impondo

que o mercado limpa (oferta = demanda), o modelo apreça os ativos e permite contrafactuais (ex.: o que acontece com os preços se um grande fundo vende tudo?).

O que é. A grande sacada é de **redução de dimensão**: em vez de estimar uma demanda por cada par (investidor, ativo) — milhões de parâmetros —, as demandas dependem de poucas características, e o problema vira estimar poucos coeficientes por investidor.

Por que usamos isso aqui? O nosso projeto usa a *lógica* de Kojien–Yogo, mas invertida em três pontos, e é importante ser preciso sobre isso porque a banca vai perguntar:

1. **Fixamos o ativo** (VALE3) e variamos o *investidor*: a demanda depende das características do *fundo* ($x_{i,t}$), não do ativo. O vetor $\theta_{n,t}$ é o “fator latente da ação”: quanto cada característica de fundo puxa a posição naquele papel.
2. **O coeficiente é comum a todos os fundos** em cada mês (varia no tempo, não no investidor).
3. **Não estimamos elasticidade-preço nem impomos equilíbrio**: trabalhamos só do lado das quantidades (forma reduzida). Não há o instrumento de Kojien–Yogo (baseado nas carteiras dos demais investidores) porque não estimamos o canal preço→demanda.

Ou seja: é um *sistema de demanda institucional na forma reduzida, em quantidades*. A justificativa econômica para o peso depender do perfil do fundo está em restrições de mandato, liquidez e diversificação: um fundo de R\$ 10 bilhões não pode ter a mesma carteira de um fundo de R\$ 10 milhões; um fundo de cotas (FIC) acessa ações via outros fundos e tende a ter pouca posição direta; um fundo com muitos cotistas tem perfil de produto de varejo.

Literatura de apoio. Gabaix e Kojien (2021) (“mercados inelásticos”) argumentam que fluxos de demanda movem preços de forma expressiva — motivação para *medir* demanda institucional, embora não estimemos esse canal. Coval e Stafford (2007) mostram que fundos sob resgate são vendedores forçados (e captações geram compras); Lou (2012) liga fluxos a previsibilidade de retornos — é por isso que o *fluxo líquido* entra como característica: se fluxos forçam negociação, poderiam antecipar variações de peso.

2.2 Por que o *peso*, e não o valor em reais ou o número de ações?

Três razões. (i) O peso $w_{i,t} \in [0, 1]$ é **comparável entre fundos** de tamanhos completamente diferentes — R\$ 1 milhão em VALE3 é enorme para um fundo pequeno e nada para um grande; o peso normaliza isso automaticamente. (ii) O peso é a variável natural de um sistema de demanda (a carteira é um vetor de pesos que soma um). (iii) O peso é *limitado*, o que disciplina a modelagem — e é exatamente essa limitação que vai exigir a forma logística (Seção 7).

O custo dessa escolha: o efeito mecânico do preço. O peso muda mesmo sem o gestor negociar. Se VALE3 rende r_v no mês e o resto da carteira rende r_o , o peso novo é

$$w' = \frac{w(1 + r_v)}{1 + w r_v + (1 - w) r_o} \approx w + w(1 - w)(r_v - r_o) \quad \text{para retornos pequenos.} \quad (1)$$

Ou seja: quando a ação sobe mais que o resto, o peso de *todos* os detentores sobe “sozinho”. Isso contamina (a) o coeficiente do preço na regressão empilhada (Seção 8), (b) a variação Δw usada no ajuste parcial (Seção 16) e (c) a inferência, porque cria um *choque comum* a todos os fundos

dentro do mês (Seção 16.4). A decomposição formal entre variação mecânica e decisão ativa está na agenda; hoje o texto trata o tema como ressalva de interpretação.

2.3 A opacidade de 90 dias

As carteiras dos fundos brasileiros são divulgadas pela CVM com defasagem de até ≈ 90 dias. Consequência prática: no fim do mês t , o público *não* conhece w_t dos fundos; conhece w_{t-3} . Então “prever o peso atual” com informação pública equivale a prever *três meses à frente* a partir do último peso divulgado. É por isso que todos os exercícios de previsão são reportados nos horizontes $h = 1$ (referência acadêmica) e $h = 3$ (o horizonte operacional realista). Vale registrar desde já uma sutileza que a revisão apontou: a rigor, $h = 1$ é *infactível* em tempo real (usa w_t , que ninguém vê em t), então conclusões operacionais devem se apoiar em $h = 3$.

3 Os dados, variável por variável

3.1 As quatro fontes

1. **CONS (CVM)** — composição consolidada mensal das carteiras. É de onde vem a variável-alvo: a linha `Nome_Ativo == "VALE ON N1 - VALE3"` de cada fundo em cada competência, com `Participação_Ativo` (o peso, já em *fração*: verificamos que o campo varia de 0 a 0,236, nunca acima de 1) e `Valor_Ativo_mil`. Usamos só a posição direta (o rótulo é estável nos 6 anos — a migração da VALE ao Novo Mercado não mudou o nome na base, fato verificado). [R/10]
2. **SH (CVM)** — série histórica diária dos fundos: patrimônio líquido (coluna em milhares, formato brasileiro “R\$ 17.842,83”), número de cotistas, gestora, classificação ANBIMA, nome. É de onde vêm as características de fundo. [R/12]
3. **Informe Diário (CVM)** — captação e resgate *diários* por fundo (`CAPTC_DIA`, `RESG_DIA`). É a única base que registra resgates; a SH só traz a captação bruta. Fluxo líquido mensal $= \sum_{\text{dias do mês}} (\text{CAPTC} - \text{RESG})$. [R/11]
4. **Yahoo Finance** — preços de VALE3.SA e do Ibovespa (BVSP), 2014–2022, para construir preço e beta. O preço de fechamento foi conferido contra o COTAHIST oficial da B3 nas datas usadas: diferença de R\$ 0,00. [R/13]

3.2 Construção do painel e tratamentos (com o porquê de cada um)

- **Identificação do Itaú:** normalizamos o campo `GESTORA` (maiúsculas, sem acento) e mantemos os fundos de *Itaú Asset Management*, *Itaú DTVM* e *Itaú Unibanco*. Motivo: o mesmo grupo aparece com três grafias/entidades.
- **Merge SH×CONS pelo dia exato:** a SH é diária e a CONS mensal; casamos a linha da SH cuja `DATA` coincide com a `Data_Competência` da CONS. Não houve perda de observações. Motivo: evita misturar o PL de um dia qualquer com a carteira de outro.
- **Deduplicação de linhas exatas da CONS** (a CVM ocasionalmente repete a mesma linha) e **remoção de pesos negativos** (resíduos contábeis da ordem de -10^{-6} , sem interpretação de participação).

- **Zero duplicatas:** verificado que não existe par (fundo, mês) repetido em nenhum dos painéis — é o teste mais importante de integridade de um painel, porque duplicata silenciosa enviesa tudo.
- **Filtro de fundos exclusivos:** mantemos só observações com `n_cotistas` > 3. Motivo: um fundo com 1–2 cotistas é o veículo de *um* investidor (a mediana de cotistas antes do filtro era 2!); o que queremos é demanda difusa. O limiar 3 é convenção; a sensibilidade a ele está prometida e ainda não foi rodada (limitação aberta).
- **Fluxo líquido:** por que não usar a SH? Porque a SH não tem resgate. Validação: a captação da SH bate com a do Informe Diário *ao centavo* em 99,4–99,8% dos pares fundo-mês em todos os anos; as divergências são revisões entre séries da própria CVM (dois padrões forenses documentados no `log_decisoes.md`), não erro nosso. 119 fundo-meses ficam sem fluxo (NA) e saem da amostra de regressão.
- **Preço e beta com dois *timings*:** para *explicar* o peso do mês t usamos a **média do mês t** (`preco_mes`, `beta_mes`) — é o que o gestor via enquanto montava a posição; para *prever* usamos o **último pregão do mês $t - 1$** (predeterminado, sem olhar o futuro). O beta é $\text{Cov}(r_{\text{VALE}}, r_{\text{Ibov}}) / \text{Var}(r_{\text{Ibov}})$ em janela móvel de 252 pregões, com retornos simples e preço ajustado por proventos *apenas* para calcular retornos (o nível de preço usado como característica é o nominal, porque o ajustado reescreve o passado a cada provento futuro — seria *look-ahead*).

3.3 Os números da amostra

Painel	Observações	Fundos
Fundos Itaú que detêm VALE3 (2016–2021, 72 meses)	26.123	623
Após filtro de cotistas (> 3)	11.532	308
Amostra de regressão (com fluxo disponível)	11.413	307
Painel extensivo (fundos de Ações, com zeros)	10.286	260

Descritivas da amostra de regressão [R/23]: peso médio 2,87%, mediana 1,22%, máximo 23,55%, com 54 zeros — distribuição fortemente assimétrica, colada em zero (motivo central para a forma logística); PL mediano R\$ 68 milhões contra média de R\$ 399 milhões (assimetria que motiva o logaritmo); cotistas de 4 a 696 mil (idem); fluxo/PL com caudas *extremas* (mínimo –6.399% do PL — ver Seção 19); 75,7% das observações são FICs; preço e beta de VALE3 (na convenção contemporânea, média do mês) com correlação –0,71 no período — o preço subiu de $\approx$ R\$ 10 para $\approx$ R\$ 114 enquanto o beta caiu de $\approx$ 1,7 para $\approx$ 0,8, e essa colinearidade vai importar na Seção 8.

Por que logaritmo de PL e de cotistas? (i) As duas variáveis são assimétricas em ordens de grandeza (PL de R\$ 35 mil a R\$ 17,9 bilhões): em nível, meia dúzia de fundos gigantes dominariam a regressão. (ii) O log torna o coeficiente uma *semi-elasticidade*: efeito de variações *proporcionais* de tamanho, que é a noção econômica certa (dobrar de tamanho, não somar R\$ 1 milhão). (iii) Resíduos mais bem-comportados.

Por que padronizar (z-score) as variáveis de escala? Escrevemos $z(\ln PL) = (\ln PL - \overline{\ln PL}) / \widehat{\sigma}_{\ln PL}$, idem cotistas. Dois motivos: (i) **comparabilidade** — “o efeito de +1 desvio-padrão de tamanho” e “+1 d.p. de cotistas” ficam na mesma régua; (ii) **intercepto interpretável** — com regressores centrados, o intercepto vira o peso previsto do fundo *médio* (não-FIC, fluxo

zero), cerca de 4%, em vez do peso previsto de um absurdo “fundo com PL de R\$ 1 e um cotista”. Ponto técnico importante: a padronização é uma transformação *afim* dos regressores; ela não muda R^2 , estatísticas t , valores ajustados nem resíduos — só muda a unidade em que o coeficiente é lido. (A *dummy* FIC e o fluxo ficam em escala natural: dummy padronizada não tem leitura.) Um erro clássico — que já aconteceu numa versão anterior dos documentos e foi corrigido — é reportar o coeficiente por *unidade de log* e lê-lo como “por desvio-padrão”: como $\hat{\sigma}_{\ln PL} \approx 1,8$, isso subestimaria o efeito por quase metade.

4 Passo 1(a): a regressão transversal mês a mês

O que é. Em cada mês t ($t = 1, \dots, 72$), com os N_t fundos vivos naquele mês, estimamos por mínimos quadrados ordinários (MQO)

$$w_{i,t} = \alpha_t + \beta_t^1 z(\ln PL)_{i,t} + \beta_t^2 z(\ln Cot)_{i,t} + \beta_t^3 FIC_i + \beta_t^4 \left(\frac{\text{Fluxo}}{PL} \right)_{i,t} + \varepsilon_{i,t}, \quad (2)$$

ou, em matriz, $\hat{\theta}_t = (X_t' X_t)^{-1} X_t' w_t$. O MQO escolhe o vetor que minimiza a soma dos quadrados dos resíduos; geometricamente, projeta w_t no espaço gerado pelas colunas de X_t .

Por que usamos isso aqui? Três razões para rodar *uma regressão por mês* em vez de empilhar tudo: (i) permite que a relação característica→peso **varie no tempo** — é justamente essa variação que o “fator dinâmico” quer capturar; (ii) prepara o resumo de Fama–MacBeth (Seção 5), que resolve elegantemente a correlação entre fundos dentro do mês; (iii) o preço e o beta da ação são *constantes dentro do mês* (todo fundo vê o mesmo preço), logo não são identificáveis na cross-section — eles só entram na versão empilhada (Seção 8), identificados pela variação *entre* meses.

Resultados no nosso projeto. Os sinais são de uma estabilidade rara: em *todos* os 72 meses, $\ln PL$ é negativo (0/72 meses positivos), $\ln Cot$ é positivo (72/72), FIC é negativo (0/72); o fluxo alterna (39/72). O R^2 médio por mês é 0,152 — modesto, como esperado para pesos individuais, mas sistemático. A leitura econômica: *fundos maiores diluem VALE3 (carteiras mais espalhadas); fundos com mais cotistas (produtos de varejo, muitas vezes fundos setoriais ou de dividendos) concentram mais; FICs quase não têm posição direta* (eles têm a ação via fundos investidos — a posição direta é residual).

5 Fama–MacBeth

O que é. Fama e MacBeth (1973) enfrentavam o problema de testar se o beta de mercado é remunerado: regressões transversais de retornos sobre betas, repetidas período a período. A inovação metodológica que ficou para a posteridade é o **estimador em duas etapas com inferência pela série temporal dos coeficientes**: (1) para cada período t , estime a cross-section e guarde $\hat{\theta}_t$; (2) o estimador final é a média temporal

$$\bar{\theta} = \frac{1}{T} \sum_{t=1}^T \hat{\theta}_t, \quad \widehat{\text{se}}(\bar{\theta}_k) = \frac{s_k}{\sqrt{T}}, \quad s_k^2 = \frac{1}{T-1} \sum_t (\hat{\theta}_{k,t} - \bar{\theta}_k)^2. \quad (3)$$

A estatística t é $\bar{\theta}_k / \widehat{\text{se}}(\bar{\theta}_k)$, comparada à distribuição t com $T - 1$ graus de liberdade.

Como funciona, em detalhe. O truque está no que a variância amostral dos $\hat{\theta}_{k,t}$ *absorve*. Cada $\hat{\theta}_t$ é uma função dos dados do mês t inteiro. Se os fundos são correlacionados *entre si dentro do mês* (e são: choques comuns de mercado, decisões da mesma mesa de gestão), essa correlação transversal infla a variância de $\hat{\theta}_t$ — mas ela está *dentro* de cada observação da série $\{\hat{\theta}_t\}$, então a dispersão observada dos $\hat{\theta}_t$ ao longo dos meses já a contém. Em outras palavras: Fama–MacBeth converte um problema de correlação transversal intratável (matriz $N \times N$ desconhecida) em um problema de série temporal com T observações. É por isso que o método é o padrão em finanças empíricas, onde a correlação dentro do período é a regra.

A **hipótese que sobra** é explícita na fórmula (3): os $\hat{\theta}_{k,t}$ precisam ser *serialmente não correlacionados*. Se $\theta_{k,t}$ é persistente (autocorrelação positiva), a série “se repete”, a variância amostral subestima a incerteza da média e os t saem inflados. Não é um detalhe: é a falha documentada no nosso caso.

Por que usamos isso aqui? É exatamente o nosso desenho: 72 cross-sections, correlação entre fundos dentro do mês quase certa (mesma gestora!), e interesse na média e na evolução dos coeficientes. A alternativa (painel empilhado com erro agrupado) esconderia a dinâmica de θ_t , que é objeto de interesse do Passo 2.

Resultados no nosso projeto. Com as variáveis de escala padronizadas [R/24]:

	Coef. médio	EP clássico	t clássico	EP Newey–West	t NW
Intercepto (nível médio)	0,0396	0,0020	19,4	0,0038	10,5
ln(PL) por d.p.	−0,0068	0,0004	−19,3	0,0006	−11,2
ln(cotistas) por d.p.	0,0109	0,0005	19,8	0,0010	10,9
Fundo de cotas (FIC)	−0,0170	0,0009	−19,2	0,0015	−11,3
Captação/PL	−0,0004	0,0031	−0,1	0,0041	−0,1

Leitura das magnitudes: +1 d.p. de tamanho $\Rightarrow$ −0,68 ponto percentual de peso; +1 d.p. de cotistas $\Rightarrow$ +1,09 p.p.; ser FIC $\Rightarrow$ −1,70 p.p. (o maior efeito); fluxo $\approx$ zero. Como o peso médio é 2,87%, esses efeitos são economicamente grandes.

Limitações e como tratamos (ou ainda vamos tratar). A autocorrelação de primeira ordem dos $\hat{\theta}_{k,t}$ é de 0,70 a 0,84 (Seção 11) — a hipótese de independência serial de (3) falha com folga.

Correção adotada: erro-padrão de longo prazo no estilo Newey–West, próxima seção (é a coluna já mostrada acima; os t caem de ≈ 19 –21 para ≈ 11). Segunda limitação, menor: cada $\hat{\theta}_t$ é estimado com erro, e a média temporal não pondera pela precisão de cada mês (meses com poucos fundos pesam igual); com N_t entre ≈ 120 e 190, o efeito é pequeno.

6 Newey–West (erros-padrão HAC)

O que é. Newey e West (1987) propuseram um estimador de variância *consistente sob heterocedasticidade e autocorrelação* (HAC) que é, por construção, sempre não negativo. No nosso uso, o alvo é a variância da *média* de uma série temporal $\{x_t\}_{t=1}^T$ (cada série de coeficiente $\hat{\theta}_{k,t}$).

Como funciona, em detalhe. Para uma série estacionária, a variância da média amostral não é γ_0/T (só valeria sob independência), e sim

$$\text{Var}(\bar{x}) = \frac{1}{T} \left(\gamma_0 + 2 \sum_{\ell=1}^{T-1} \left(1 - \frac{\ell}{T}\right) \gamma_\ell \right) \xrightarrow{T \rightarrow \infty} \frac{1}{T} \underbrace{\left(\gamma_0 + 2 \sum_{\ell=1}^{\infty} \gamma_\ell \right)}_{\text{variância de longo prazo (LRV)}}, \quad (4)$$

em que $\gamma_\ell = \text{Cov}(x_t, x_{t-\ell})$. Com autocorrelação positiva, todos os $\gamma_\ell > 0$ *somam*: a série “conta a mesma informação várias vezes” e a média é bem menos precisa do que T observações independentes sugeririam. O estimador de Newey–West trunca a soma em L defasagens e aplica os pesos de Bartlett $k(\ell) = 1 - \ell/(L+1)$, decrescentes:

$$\widehat{\text{Var}}_{NW}(\bar{x}) = \frac{1}{T^2} \left[\sum_t \hat{u}_t^2 + 2 \sum_{\ell=1}^L \left(1 - \frac{\ell}{L+1}\right) \sum_{t=\ell+1}^T \hat{u}_t \hat{u}_{t-\ell} \right], \quad \hat{u}_t = x_t - \bar{x}. \quad (5)$$

Os pesos de Bartlett têm dupla função: (i) garantem que a estimativa é *sempre* ≥ 0 (a soma ponderada equivale a uma forma quadrática com kernel positivo-definido — sem os pesos, autocovariâncias amostrais negativas em defasagens altas podem produzir “variância negativa”); (ii) reduzem o ruído das autocovariâncias de ordem alta, estimadas com poucos pares. O preço é **viés para baixo**: os pesos < 1 encolhem a contribuição verdadeira das defasagens, e tudo além de L é ignorado. A defasagem foi escolhida pela regra automática de Newey–West (1994), $L = \lfloor 4(T/100)^{2/9} \rfloor$, que com $T = 72$ dá $L = 3$.

Por que usamos isso aqui? A Seção 5 terminou com a hipótese de independência serial violada (autocorrelações de 0,7–0,8). O NW é a correção padrão: mantém o estimador pontual de Fama–MacBeth intacto e conserta só a variância.

Resultados no nosso projeto. O efeito prático foi multiplicar os erros-padrão por 1,7–1,8 (fluxo: 1,3), derrubando os t de ≈ 19 –21,6 para ≈ 11 . Nada muda de sinal nem de significância qualitativa — mas os t “bonitos” de 20 eram, sim, uma ilusão de precisão.

Limitações e como tratamos (ou ainda vamos tratar). Sejam honestos sobre o que $L = 3$ compra. Se a série fosse um AR(1) com $\rho = 0,77$ (o que os dados sugerem), a razão correta entre o EP de longo prazo e o clássico seria $\sqrt{(1+\rho)/(1-\rho)} \approx 2,8$ — e o Bartlett com $L = 3$ entrega 1,7–1,8. Sensibilidade calculada na revisão: com $L = 6$ os t ficam em 8–9; com $L = 12$, em 7–8. **Estado:** as conclusões (tudo significativo a 1%, fluxo nulo) sobrevivem com folga a qualquer L razoável, mas o texto final deve citar essa sensibilidade (correção barata, uma frase) ou usar a correção paramétrica AR(1) $\widehat{\text{Var}} \cdot \frac{1+\hat{\rho}}{1-\hat{\rho}}$.

7 Logit fracionário (Papke–Wooldridge)

O que é. O peso é uma *fração*: $w \in [0, 1]$, com massa perto de zero (mediana 1,2%, 54 zeros exatos). O modelo linear ignora o suporte: nada impede $\hat{w} < 0$ ou > 1 . Papke e Wooldridge (1996) propuseram o **modelo de resposta fracionária**: especificar apenas a média condicional

$$E[w_i | x_i] = g(x_i' \theta), \quad g(z) = \frac{1}{1 + e^{-z}} \in (0, 1), \quad (6)$$

e estimar θ por **quase-máxima verossimilhança (QMV) de Bernoulli**: maximizar

$$\sum_i \left[w_i \log g(x_i' \theta) + (1 - w_i) \log (1 - g(x_i' \theta)) \right], \quad (7)$$

exatamente a log-verossimilhança de um logit binário, só que avaliada em w_i *fracionário*.

Como funciona, em detalhe. Por que isso funciona se w não é 0/1? Porque a Bernoulli pertence à família exponencial linear, e para essa família a QMV é **consistente sempre que a média condicional estiver certa**, seja qual for a verdadeira distribuição de w em $[0, 1]$. A condição de primeira ordem de (7) é $\sum_i x_i (w_i - g(x_i' \theta)) = 0$ — um “MQO ponderado” na escala certa: o método só exige que os resíduos $w - g$ sejam ortogonais aos regressores, nada sobre a distribuição. Zeros e uns exatos entram sem qualquer ajuste (ao contrário de, por exemplo, aplicar $\log(w/(1-w))$, que explode em $w = 0$ — por isso NÃO transformamos a variável, modelamos a média). Em R, `glm(..., family=quasibinomial(link="logit"))` implementa exatamente isso; a parte “quasi” desliga a suposição de variância Bernoulli, que seria absurda aqui.

Efeitos parciais médios (APE). O coeficiente logístico vive na escala das chances logarítmicas (*log-odds*); para compará-lo ao modelo linear, calculamos o efeito na escala do peso. Como $g'(z) = g(z)(1 - g(z))$, o efeito marginal da característica k para o fundo i é $\theta_k g_i(1 - g_i)$, e o APE é a média

$$\text{APE}_k = \theta_k \cdot \frac{1}{N} \sum_i \hat{g}_i (1 - \hat{g}_i). \quad (8)$$

Intuição: perto de $w \approx 3\%$, $g(1 - g) \approx 0,029$, então um coeficiente logístico de 0,47 vira $\approx 1,4$ p.p. — o logit “aperta” as respostas perto das bordas e as espalha no meio, como a fração exige.

Por que usamos isso aqui? (i) Respeita o suporte: o modelo linear produziu previsões fora de $[0, 1]$ em 287 de 11.413 observações (2,51%) — pesos negativos, sem sentido; o logit, nunca. (ii) É o insumo correto para o **peso desejado** w^* do ajuste parcial (Seção 16), que precisa viver em $(0, 1)$. (iii) Custa pouco: estimamos o logit *mês a mês*, como o linear, e resumimos por Fama–MacBeth + Newey–West, mantendo toda a arquitetura.

Resultados no nosso projeto. [R/25]

	Coef. (log-odds)	EP (NW)	t	APE (p.p. por d.p.)
Intercepto	−3,380	0,150	−22,5	—
ln(PL)	−0,339	0,043	−7,9	−0,68
ln(cotistas)	0,469	0,035	13,3	+1,06
FIC	−0,732	0,062	−11,7	−1,60
Captação/PL	0,078	0,183	0,4	≈ 0

Os APEs (−0,68; +1,06; −1,60) praticamente coincidem com os coeficientes lineares (−0,68; +1,09; −1,70): no “miolo” da distribuição o linear era uma boa aproximação — o que valida os resultados lineares — e o pseudo- R^2 sobe um pouco (0,165 vs 0,152). A vantagem do logit é conceitual (suporte) e operacional (w^* para o passo dinâmico).

Limitações e como tratamos (ou ainda vamos tratar). (i) Para a *dummy* FIC, o APE correto é a **diferença discreta** $\overline{g(x' \theta)|_{\text{FIC}=1} - g(x' \theta)|_{\text{FIC}=0}}$, não a derivada; usamos a derivada (a

diferença prática é pequena aqui, mas é o cálculo canônico — correção pendente, trivial). (ii) A inferência é a de Fama–MacBeth sobre os coeficientes mensais, herdando as ressalvas da Seção 6. (iii) O logit fracionário modela $E[w|x]$ *incondicional à posse*; a separação “ter vs. quanto ter” é tratada à parte (Seção 14) — um modelo em duas partes (*hurdle*) unificado está na agenda.

8 A regressão empilhada com preço e beta

O que é. Empilhamos os 72 meses ($N = 11.413$) e acrescentamos duas características da *ação*, constantes dentro do mês: o preço médio do mês e o beta médio do mês (padronizados). Identificação vem da variação *temporal*: meses de preço alto vs. baixo.

Resultados no nosso projeto. [R/28] Sinais de fundo idênticos aos mensais. Preço: +0,0050 por d.p. ($t = 11,5$); beta: −0,0065 por d.p. ($t = -15,1$); $R^2 = 0,166$ (vs 0,152 sem preço/beta — o ganho é pequeno: quase toda a variação explicável já está nas características de fundo).

Limitações e como tratamos (ou ainda vamos tratar). Três, importantes. (i) **Parte do coeficiente do preço é mecânica** (eq. 1): preço alto $\Rightarrow$ peso alto sem ninguém negociar. (ii) **Colinearidade preço–beta** (−0,71): difícil separar um do outro; o beta negativo (“aversão a risco”) pode estar absorvendo o componente mecânico residual do preço. Registro honesto: num exercício preliminar só com 2016, o beta saía *positivo* e fraco — 12 meses não identificam; com 72 ele fica claramente negativo, mas a leitura causal continua contaminada. (iii) Os EPs do empilhado *não* corrigem a dependência temporal/transversal (é a mesma razão de existir o Fama–MacBeth); os t enormes dessa tabela não devem ser levados ao pé da letra — tratamos essa tabela como descritiva. **Correção estrutural na agenda:** decompor Δw em componente mecânico e ativo antes de atribuir qualquer coisa a preço/beta.

9 Fatores de risco do NEFIN-USP (Carhart)

O que é. O NEFIN (Núcleo de Economia Financeira da USP) publica, desde 2001, uma versão brasileira dos fatores de risco de Fama–French e Carhart, construída com a mesma lógica dos originais americanos: ordenar as ações da bolsa por uma característica (tamanho, valor contábil sobre mercado, retorno passado) e formar carteiras *long-short* entre os extremos. O resultado são séries **diárias** de retorno: $R_m - R_f$ (prêmio de mercado, carteira de mercado menos taxa livre de risco), SMB (*small minus big*, tamanho), HML (*high minus low*, valor), WML (*winners minus losers*, momento) e IML (iliquidez, uma adição brasileira sem equivalente direto nos fatores originais de Fama–French).

Por que usamos isso aqui? A regressão empilhada (Seção 8) já mostrou que o coeficiente de preço e de beta de VALE3 podem estar contaminados por efeito mecânico e por colinearidade entre si. Uma pergunta natural: será que esses coeficientes são, na verdade, apenas capturando exposição a **risco de mercado já catalogado**? Se o período 2016–2021 foi de forte prêmio de mercado (o que foi: o Ibovespa mais que triplicou), um regressor correlacionado com o tempo (como o preço de VALE3, que só sobe no período) pode estar “roubando” a variação que pertenceria a um fator de mercado. Controlar pelos fatores do NEFIN é o jeito padrão de testar essa hipótese: se os coeficientes de preço/beta encolherem ao entrar os fatores, era exposição a risco conhecido; se não encolherem, é algo mais específico à posição.

Como funciona, em detalhe. Os fatores são diários; a regressão pooled é mensal. Agregamos por **retorno composto** dentro do mês, não soma simples: $R^{(m)} = \prod_{d \in m} (1 + r_d) - 1$, a forma correta de acumular retornos percentuais ao longo de vários períodos (a soma simples subestimaria sistematicamente, por ignorar o efeito de juros compostos dentro do mês). Cada fator mensal, padronizado (z-score), entra como regressor adicional na regressão empilhada da Seção 8. [R/34]

Resultados no nosso projeto.

Coefficiente de VALE3	Sem fatores NEFIN	Com fatores NEFIN
Preço por d.p.	0,00496	0,00526
Beta por d.p.	-0,00649	-0,00609
R^2	0,166	0,172

Os fatores de mercado ($R_m - R_f$) e de tamanho (SMB) entram significativos por conta própria ($t = 5,4$ e $t = -7,7$, respectivamente); valor (HML) e momento (WML), não. Mas o achado central é a **estabilidade**: os coeficientes de preço e beta de VALE3 praticamente não se movem ao entrar os quatro fatores — a diferença é da ordem da terceira casa decimal. Isso é evidência de que o que esses dois regressores capturam *não é*, em sua maior parte, exposição a risco de mercado, tamanho, valor ou momento já catalogados: é algo mais específico à posição em VALE3 (plausivelmente o componente mecânico da eq. 1, que nenhum fator de risco de mercado amplo corrigiria, já que é mecânico por construção, não um prêmio de risco).

Limitações e como tratamos (ou ainda vamos tratar). Os fatores do NEFIN são construídos com todas as ações listadas na B3, não apenas as que os fundos do Itaú carregam; e a agregação mensal por retorno composto, embora correta, ainda assim colapsa a variação diária — um teste com os fatores na frequência diária (impossível aqui, dado que a variável dependente, o peso, só existe mensalmente) capturaria mais variação.

10 Beta do próprio fundo

O que é. O beta usado até aqui (Seção 8) é o beta da *ação* VALE3 contra o Ibovespa. Esta seção calcula um beta diferente: o beta do *fundo* — a covariância entre o retorno diário da cota do fundo (o quanto uma unidade do fundo rendeu) e o retorno do Ibovespa, dividida pela variância do Ibovespa, na mesma janela móvel de 252 pregões e no mesmo timing predeterminado (último pregão do mês anterior) usados para o beta de VALE3.

$$\beta_{i,t}^{\text{fundo}} = \frac{\text{Cov}_{252}(r_i^{\text{cota}}, r_{\text{Ibov}})}{\text{Var}_{252}(r_{\text{Ibov}})}. \quad (9)$$

Por que usamos isso aqui? O beta de VALE3 descreve o risco de *um ativo*; o beta do fundo descreve o risco (ou melhor, o quão “parecido com o mercado de ações” é) do *fundo como um todo*. É uma característica de fundo que ainda não estava no modelo: distinta de tamanho (PL), de estrutura (cotistas, FIC) e de fluxo — um fundo pode ser grande e ainda assim ter uma carteira predominantemente de renda fixa (beta baixo) ou predominantemente de ações (beta próximo de 1). A pergunta que motiva incluí-lo: fundos mais “parecidos com o mercado de ações” mantêm posições maiores em VALE3?

Como funciona, em detalhe. A base SH tem o campo COTA (o valor da cota do fundo, análogo ao preço de uma ação) diariamente, em formato brasileiro (vírgula decimal, sem separador de milhar — mais simples que o campo de patrimônio, que usa ponto como separador de milhar). Calculamos o retorno diário $r_{i,t}^{\text{cota}} = \text{COTA}_{i,t} / \text{COTA}_{i,t-1} - 1$ para cada um dos 307 fundos da amostra, casamos com o retorno diário do Ibovespa (mesma fonte do beta de VALE3), e aplicamos a mesma fórmula de covariância/variação móvel. [R/33]

Resultados no nosso projeto. Na amostra dos 307 fundos: beta médio 0,50, mínimo $-0,27$, máximo 1,27 — consideravelmente mais baixo, em média, que o beta de VALE3 (1,04), como esperado de uma carteira diversificada que mistura ações com outras classes de ativo. Ao entrar como regressor adicional na regressão empilhada, o coeficiente é positivo e significativo: fundos mais “equity-like” tendem a manter peso maior em VALE3, uma checagem de consistência interna tranquilizadora (o desenho da base está capturando uma dimensão de risco coerente com a intuição), mais do que uma descoberta econômica nova.

Limitações e como tratamos (ou ainda vamos tratar). A cobertura é de 73% da amostra: fundos com menos de 252 pregões de histórico de cota (fundos jovens, ou que entraram na amostra tarde) ficam sem beta — um viés de sobrevivência leve, que favorece fundos mais antigos na análise que usa esse controle.

11 Passo 2(a): a dinâmica do fator θ_t

11.1 Autocorrelação e AR(1)

O que é. Cada série de coeficientes $\{\hat{\theta}_{k,t}\}_{t=1}^{72}$ é tratada como série temporal. Dois descritores: a autocorrelação de ordem 1, $\hat{\rho}_1 = \text{corr}(\theta_t, \theta_{t-1})$, e o modelo autorregressivo de primeira ordem

$$\theta_{k,t} = c_k + \phi_k \theta_{k,t-1} + \eta_{k,t}, \quad (10)$$

em que ϕ_k mede a persistência: $\phi = 1$ é o passeio aleatório (choques permanentes, a série não tem nível de equilíbrio); $|\phi| < 1$ é reversão à média com meia-vida $\ln(0,5)/\ln|\phi|$; $\phi = 0$ é ruído.

Por que usamos isso aqui? A escolha do modelo de previsão do fator depende disso: se θ é passeio aleatório, a melhor previsão é o último valor; se reverte à média, vale usar AR(1)/Kalman. Além disso, a persistência dos θ_t é exatamente o que quebra o erro-padrão clássico de Fama–MacBeth — os números desta seção são a *evidência* que justificou o Newey–West.

11.2 O teste de Dickey–Fuller, por dentro

O que é. Queremos distinguir “ ϕ perto de 1 mas < 1 ” (reversão lenta) de “ $\phi = 1$ ” (raiz unitária). O teste de Dickey–Fuller (DF) reescreve o AR(1) subtraindo θ_{t-1} dos dois lados:

$$\Delta\theta_t = c + \pi \theta_{t-1} + \eta_t, \quad \pi = \phi - 1. \quad (11)$$

H_0 : $\pi = 0$ (raiz unitária); H_1 : $\pi < 0$ (reversão). O teste é a estatística t de $\hat{\pi}$.

Como funciona, em detalhe. A sutileza que faz o DF ser “um teste especial” e não um t comum: sob H_0 , o regressor θ_{t-1} é um passeio aleatório — não é estacionário, sua variância cresce com t —

e o Teorema Central do Limite usual não se aplica. A distribuição assintótica da estatística é um funcional de movimento browniano (a “distribuição de Dickey–Fuller”), deslocada para a esquerda: com constante e $T \approx 70$, o valor crítico de 5% é $\approx -2,90$ (contra $-1,65$ de um t unilateral normal). Usar a tabela normal aqui rejeitaria raiz unitária com enorme frequência mesmo quando ela existe. Regra prática usada no projeto: $t < -2,9 \Rightarrow$ rejeita raiz unitária $\Rightarrow$ série estacionária/reversora.

Resultados no nosso projeto. [R/16]

Série	$\hat{\rho}_1$	$\hat{\phi}$	DF (t)	leitura
Intercepto	0,77	0,77	-3,07	reverte à média
ln(PL)	0,76	0,76	-3,11	reverte à média
ln(cotistas)	0,84	0,83	-2,70	no limite (não rejeita a 5%)
FIC	0,70	0,70	-3,57	reverte à média
Captação/PL	0,37	0,38	-5,59	quase ruído

Síntese: os fatores estruturais são **persistentes mas estacionários** — variam suavemente (com uma reconfiguração visível em torno de 2018, quando preço e beta da VALE também se moveram muito), sem nunca trocar de sinal. Isso legitima tratá-los como “estado latente” que evolui devagar. O coeficiente do fluxo é quase ruído — coerente com fluxo não explicar o nível do peso.

Limitações e como tratamos (ou ainda vamos tratar). (i) Usamos o DF *simples*, sem defasagens de $\Delta\theta$ (o “A” do ADF, que branqueia autocorrelação residual do erro do teste); com $T = 72$ e resíduos pouco autocorrelacionados o risco de distorção é baixo, mas um ADF(1–2) é a versão canônica — correção pendente e barata. (ii) Poder: com 72 observações, DF tem pouco poder para distinguir $\phi = 0,95$ de $\phi = 1$; por isso a série de cotistas ($-2,70$) fica “no limite” e é honesto dizer que não sabemos. (iii) O teste é feito sobre coeficientes *estimados* (com erro de estimação mensal), o que adiciona um componente tipo erro de medida — o ruído de estimação empurra $\hat{\rho}_1$ para *baixo*, então a persistência verdadeira dos fatores pode ser ainda maior que a medida.

12 O filtro de Kalman

O que é. Cada $\hat{\theta}_{k,t}$ que observamos é “sinal + ruído”: o fator verdadeiro do mês mais o erro de estimação da cross-section daquele mês. O modelo de **nível local** formaliza isso:

$$\underbrace{y_t = \mu_t + \varepsilon_t}_{\text{equação de medida, } \varepsilon_t \sim (0, R)} \quad \underbrace{\mu_t = \mu_{t-1} + \eta_t}_{\text{equação de estado, } \eta_t \sim (0, Q)}, \quad (12)$$

em que y_t é o coeficiente estimado e μ_t é o fator “verdadeiro”, que caminha como passeio aleatório. O filtro de Kalman é o algoritmo recursivo que, a cada mês, produz a melhor estimativa linear do estado dado o passado.

Como funciona, em detalhe. Duas fases por período, partindo de a_{t-1} (estimativa do estado) e P_{t-1} (variância dessa estimativa):

$$\text{(previsão)} \quad a_{t|t-1} = a_{t-1}, \quad P_{t|t-1} = P_{t-1} + Q; \quad (13)$$

$$\begin{aligned} \text{(atualização)} \quad v_t &= y_t - a_{t|t-1}, \quad F_t = P_{t|t-1} + R, \quad K_t = \frac{P_{t|t-1}}{F_t}, \\ a_t &= a_{t|t-1} + K_t v_t, \quad P_t = (1 - K_t) P_{t|t-1}. \end{aligned} \quad (14)$$

O **ganho de Kalman** $K_t \in (0, 1)$ é o coração: ele diz quanto acreditar na observação nova (v_t é a “surpresa”). Se o ruído de medida domina ($R \gg Q$), $K \rightarrow 0$ e o filtro quase ignora o mês novo — vira uma média longa; se o estado se move muito ($Q \gg R$), $K \rightarrow 1$ e o filtro vira o passeio aleatório (“repita o último valor”). No regime estacionário, a previsão um passo à frente do nível local é exatamente uma **média móvel exponencialmente ponderada** do passado — o filtro interpola de forma ótima entre os dois extremos que já testamos (média e último valor). Os hiperparâmetros Q e R são estimados por máxima verossimilhança usando a *decomposição do erro de predição*: as inovações v_t são independentes com variância F_t , então $\log L = -\frac{1}{2} \sum_t (\log 2\pi F_t + v_t^2/F_t)$, maximizada numericamente (Nelder–Mead). [R/18, R/19]

Por que usamos isso aqui? É a resposta natural ao diagnóstico da Seção 11: fatores persistentes, observados com ruído mensal. O filtro separa o sinal do ruído *de forma causal* (a previsão de t usa apenas $y_1, \dots, y_{t-1}$), que é o que uma previsão honesta exige. Referência didática: Harvey (1989).

Resultados no nosso projeto. A previsão de peso com fator filtrado (modelo M2 da Seção 13) *não* supera nem o efeito fixo simples nem, muito menos, a previsão ingênua. O filtro faz bem o seu trabalho — suaviza θ_t —, mas o problema é outro: a variação de curto prazo do peso de cada fundo simplesmente não é explicada pelas características, então prever melhor o θ não ajuda.

Limitações e como tratamos (ou ainda vamos tratar). Apontada na revisão: Q e R são estimados por MV **na série completa** (72 meses) e depois o filtro roda causalmente. Isso é um vazamento leve de informação futura (os hiperparâmetros “viram” a amostra toda) num exercício anunciado como estritamente fora da amostra. Como o M2 *perde mesmo com essa vantagem*, a conclusão qualitativa está a salvo — mas a correção limpa (reestimar Q, R recursivamente a cada origem, ou nota de rodapé) está pendente.

13 Previsão fora da amostra: desenho e resultados

13.1 O desenho experimental

O que é. “Fora da amostra com janela expansiva” significa: para cada mês de origem t (a partir do 13º mês, para haver histórico), estimar *tudo* só com dados até t , prever o alvo em $t + h$, gravar o erro, expandir a janela e repetir. Os erros acumulados de todas as origens formam a avaliação. A métrica é a raiz do erro quadrático médio, $\text{RMSE} = \sqrt{e^2}$ (penaliza erros grandes; mesma unidade do peso), com o MAE como companheiro robusto.

Por que usamos isso aqui? Comparar modelos *dentro* da amostra premia sobreajuste. O padrão-ouro em previsão é imitar o uso real: só informação disponível na origem. E a régua contra

a qual todo modelo é comparado é a **previsão ingênua** $\hat{w}_{i,t+h} = w_{i,t}$ — na literatura de previsão, um modelo só “existe” se bate essa regra, porque para variáveis persistentes ela é terrivelmente difícil de superar (para um passeio aleatório puro, ela é *ótima*).

13.2 Os quatro modelos comparados

- **M0 ingênuo:** $\hat{w}_{i,t+h} = w_{i,t}$ (repete o último peso).
- **M1 efeito fixo:** $\hat{w}_{i,t+h} = \hat{\mu}_i$ (média histórica do próprio fundo até t). Se o peso revertesse a um nível próprio de cada fundo, M1 venceria M0.
- **M2 efeito fixo + fator/Kalman:** $\hat{w}_{i,t+h} = \hat{\mu}_i + \hat{\theta}_t^{Kal}(x_{i,t} - \bar{x}_i)$ — soma ao nível do fundo o desvio previsto pelas características, com o fator filtrado (causal).
- **M3 variação:** $\hat{w}_{i,t+h} = w_{i,t} + \delta' x_{i,t}$, em que δ vem de regredir, no treino, a variação $w_{s+h} - w_s$ nas características — testa se as características (fluxo, sobretudo) anteciparam *mudanças*.

13.3 Resultados

RMSE fora da amostra [R/19, R/21]:

Universo	Horizonte	M0 ingênuo	M1 EF	M2 EF+Kalman	M3 variação
Todos os fundos	$h = 1$	0,0156	0,0240	0,0255	0,0156
Todos os fundos	$h = 3$	0,0207	0,0262	0,0273	0,0210
Só fundos de ações	$h = 1$	0,0197	0,0310	0,0383	0,0198
Só fundos de ações	$h = 3$	0,0266	0,0337	0,0385	0,0270

Leitura, ponto a ponto. (i) **O ingênuo vence em todas as linhas**; os modelos estruturais erram 54–63% mais em $h = 1$. (ii) O resultado mais informativo é **M1 perder de M0**: se o peso revertesse à média do fundo, a média venceria o último valor; perder significa que *não há* reversão detectável ao nível do fundo no curto prazo — é a assinatura de um processo próximo do **martingale** ($E[w_{t+1} | \mathcal{F}_t] = w_t$). (iii) M3 empatar com M0 diz que as características não anteciparam mudanças (prever variação zero = repetir o peso). (iv) Em $h = 3$ todo mundo piora e o *gap* encolhe (a inércia se dilui com o horizonte), mas a ordem não muda. (v) Restringir a fundos de ações (posições maiores e mais ativas) só amplia as diferenças. A média dos erros do melhor modelo é ≈ 0 e a série mensal desses erros é estacionária (DF $-8,7$) — o erro não tem viés nem deriva.

A ponte para o ajuste parcial. Esse quadro (explica bem, não prevê) é exatamente o que um ajuste parcial com velocidade pequena produz: se o fundo fecha só uma fração λ minúscula da distância ao alvo por mês, o peso é *quase* martingale e o alvo estrutural quase não aparece no curto prazo. O passo seguinte estima esse λ diretamente.

14 As duas margens: ter vs. quanto ter

O que é. A amostra principal condiciona em *deter* VALE3 (margem intensiva). A decisão de *ter ou não* (margem extensiva) é estudada num painel à parte: todos os fundos de *ações* do Itaú vivos no mês (universo em que “não ter VALE3” é uma escolha real, não uma característica de mandato), com peso zero imputado a quem não tem: 10.286 observações, 260 fundos, 86% têm a ação; 75 entradas e 100 saídas em 6 anos — a posse muda em só 1,3% dos fundo-meses.

O logit binário, por dentro. Modelamos $\Pr(\text{tem}_{i,t} = 1) = \Lambda(\gamma_0 + \gamma_1 \ln PL + \gamma_2 \ln Cot + \gamma_3 FIC)$, com Λ a mesma logística, agora por máxima verossimilhança de verdade (a variável é 0/1). O coeficiente é o efeito nas *log-odds*: e^γ multiplica a razão de chances. Resultados [R/20]: $\gamma_{\ln PL} = 0,232$ ($z = 15,1$) — cada unidade de $\ln PL$ ($\approx$ multiplicar o PL por 2,7) multiplica as chances de ter VALE3 por $e^{0,232} \approx 1,26$; $\gamma_{FIC} = 1,311$ ($z = 17,5$) — ser FIC multiplica as chances por $\approx 3,7$; $\gamma_{\ln Cot} = -0,034$ ($z = -2,8$), efeito pequeno e negativo.

Resultados no nosso projeto. O achado que consideramos o mais bonito do trabalho: **as duas margens têm sinais opostos**. Tamanho e FIC *augmentam* a probabilidade de ter a ação, mas *diminuem* o peso condicional; cotistas, o contrário. É a assinatura clássica de **diversificação**: fundos grandes e FICs espalham a carteira por muitos papéis — é fácil “ter um pouco de tudo” (margem extensiva alta) com fatias pequenas (margem intensiva baixa). E a posse é ainda mais persistente que o peso: prever “continua como está” acerta 98,7% em $h = 1$ (e 98,3% em $h = 3$), contra $\approx 87\%$ do logit com características — de novo, características explicam, inércia prevê.

Limitações e como tratamos (ou ainda vamos tratar). (i) Os dois exercícios (nível e posse) são independentes; o tratamento conjunto canônico é um modelo em duas partes (*hurdle*: logit de posse $\times$ fracionário do peso condicional), na agenda. (ii) 12 fundo-meses têm linha de VALE3 com participação exatamente zero e contam como “tem” — convenção a documentar. (iii) A acurácia 87,5% vs 87,2% em textos diferentes vem de duas variantes do exercício (uma exige estado anterior conhecido, outra prevê $t + h$ direto); citar a fonte exata em cada menção.

15 Extensão: a demanda por um universo amplo de ações

O que é. Tudo até aqui condicionou num único ativo, VALE3. Esta seção pergunta: o padrão encontrado — fundos maiores carregam menos peso, fundos com mais cotistas carregam mais, fundos de cotas carregam menos — é uma propriedade *geral* de como os fundos do Itaú demandam ações, ou uma particularidade de VALE3? Para responder, generalizamos a regressão transversal da Seção 4 para **todos os ativos** que os fundos do Itaú carregam, não só VALE3.

Por que usamos isso aqui? Esta é, literalmente, a matriz completa que o arcabouço de Koijen–Yogo (Seção 2) prevê: uma matriz de fatores latentes θ (*asset embeddings*), um vetor por ativo e por mês, estimada a partir da matriz de características dos fundos x (*investor embeddings*). Até aqui, tínhamos uma única coluna dessa matriz (a de VALE3); esta seção estima as outras. Foi um pedido direto do orientador nesta rodada.

15.1 Construção do painel amplo

Como funciona, em detalhe. Descoberta central desta rodada: o arquivo bruto `cons_AAAA.csv` usado no projeto já vem, na origem, filtrado para linhas com `Tipo_Ativo=="Ações"` — não é a composição completa dos fundos (que teria também renda fixa, derivativos, cotas de outros fundos). Verificamos isso com um `stopifnot` no início do script: todas as 2,8 milhões de linhas de um ano testado tinham esse tipo. Essa descoberta muda a estratégia de leitura: o script original (R/10) lia o arquivo em *blocos de texto* e filtrava por `grep1` do nome de UM ativo específico (VALE3), truque de baixa memória necessário para isolar um único papel num arquivo de centenas de megabytes; para pegar *todos* os ativos, isso não faz sentido — em vez disso, lemos o arquivo inteiro com `fread`

(rápido: 2,8 milhões de linhas em 0,8 segundo) e filtramos apenas pelos códigos de fundo do Itaú. [R/31]

O painel resultante — fundo $\times$ ativo $\times$ mês — tem **1.777 ativos distintos brutos**, 906 fundos, quase 7,8 milhões de linhas (2016–2021). Após limpeza (10 linhas com nomes de "Ação de Companhia Fechada" continham vírgula que corrompia o parsing CSV bruto da CVM, e mais 3.293 linhas do mesmo tipo de ativo — fora de escopo, sem preço de mercado — foram descartadas com auditoria) e o filtro de mais de três cotistas, sobram 1,50 milhão de observações, 305 fundos, 1.129 ativos. Uma checagem de consistência forte: VALE3 tem exatamente 26.123 linhas nesse painel amplo — o mesmo número do painel original, construído por um caminho de código totalmente diferente.

Um cuidado de padronização que só aparece no painel amplo. Ao padronizar $\ln(\text{PL})$ e $\ln(\text{cotistas})$ (Seção 3), a distribuição usada para calcular média e desvio-padrão não pode vir das linhas do painel fundo-ativo-mês diretamente: um fundo que detém cinquenta ações apareceria cinquenta vezes, pesando cinquenta vezes mais na média do que um fundo que detém uma única ação. A correção é padronizar usando a distribuição de pares (fundo, mês) **únicos** (7.964 deles), não linhas do painel amplo.

15.2 O padrão de VALE3 generaliza?

Para cada par (ativo, mês) com pelo menos 15 fundos do Itaú detentores — um limiar que garante graus de liberdade suficientes para os cinco parâmetros da regressão (2) —, estimamos a mesma cross-section, célula por célula: 23.704 células, 868 ativos distintos, 1,49 milhão de observações, em 33 segundos de computação. [R/32]

Resultados no nosso projeto. Para cada ativo com pelo menos 24 meses de $\hat{\theta}_{n,t}$ estimado (361 ativos), calculamos a média temporal dos coeficientes e olhamos a distribuição *entre ativos*:

Coeficiente	Direção (VALE3)	% dos 361 ativos igual	VALE3 é típico?
$\ln(\text{PL})$	negativo	92,5%	não — percentil 1 (extremo)
$\ln(\text{cotistas})$	positivo	98,9%	sim
Fundo de cotas	negativo	92,8%	sim
Captação/PL	fraco/instável	52,6% positivo	ambíguo nos dois

A resposta é matizada, e vale ler com cuidado. As **direções** dos três efeitos estruturais generalizam fortemente: 92 a 99% dos ativos com amostra suficiente têm o mesmo sinal que VALE3 — não é uma peculiaridade de um papel, é um padrão de como os fundos do Itaú, em geral, distribuem posições em ações conforme o perfil do fundo. Mas a **magnitude** do efeito de tamanho de VALE3 é atípica: seu coeficiente médio ($-0,00566$) está no **percentil 1** da distribuição entre os 361 ativos — VALE3 é um dos papéis cujo peso reage mais fortemente ao porte do fundo, não um caso representativo. Uma checagem independente, empilhando as 1,50 milhão de observações com efeito-fixo de *ativo* e de *mês* (estimado por demeaning iterativo de Frisch–Waugh–Lovell, que subtrai repetidamente as médias por ativo e por mês até convergir — equivalente a incluir uma *dummy* para cada um dos 1.129 ativos e cada um dos 72 meses, mas computacionalmente muito mais barato), erro-padrão agrupado por fundo, confirma os três sinais com significância ($t = -3,4$; $t = 8,3$; $t = -4,0$; $t = 0,6$ para o fluxo, não significativo). [R/32]

Limitações e como tratamos (ou ainda vamos tratar). O universo bruto (1.777 ativos) é grande demais para estender a parte **dinâmica** do modelo (preço e beta próprios de cada ativo, Kalman, ajuste parcial, previsão fora da amostra) a todos os papéis nesta rodada: mapear cada nome de ativo para um *ticker* de mercado e buscar preço/beta individualmente não é confiável de fazer em massa (nomes ambíguos, BDRs, ativos pouco líquidos, limites de taxa de fontes externas). VALE3 permanece o estudo de caso aprofundado para a parte dinâmica; esta seção cobre só a camada de *explicação* transversal (o Passo 1). Estender a cobertura de preço/beta a mais ativos — por exemplo, aos mais frequentemente detidos — fica na agenda.

16 O modelo de ajuste parcial

16.1 A equação e sua lógica

O que é. A hipótese econômica: o fundo tem um peso *desejado* $w_{i,t}^* = g(x'_{i,t}\theta_t)$ (o valor ajustado do logit fracionário — é para isso que ele existia), mas não salta para ele de uma vez; por custos de transação, liquidez e governança, move-se *parcialmente*:

$$w_{i,t+1} = (1 - \lambda) w_{i,t} + \lambda w_{i,t}^* + u_{i,t+1} \iff \Delta w_{i,t+1} = \lambda d_{i,t} + u_{i,t+1}, \quad d_{i,t} \equiv w_{i,t}^* - w_{i,t}. \quad (15)$$

$\lambda \in [0, 1]$ é a **velocidade de ajuste**: fração da distância ao alvo fechada por mês. $\lambda = 1$: ajuste instantâneo. $\lambda = 0$: o peso ignora o alvo (e a melhor previsão é a ingênua). O teste central do trabalho é $\lambda \neq 0$.

Meia-vida. Iterando (15) com alvo fixo, a distância decai geometricamente: $d_{t+h} = (1 - \lambda)^h d_t$. A meia-vida resolve $(1 - \lambda)^h = \frac{1}{2}$:

$$h_{1/2} = \frac{\ln(0,5)}{\ln(1 - \lambda)}. \quad (16)$$

Com $\lambda = 0,041$: $h_{1/2} \approx 16,4$ meses. Com $\lambda = 0,185$: $\approx 3,4$ meses.

Previsão a h passos. Pela mesma iteração (alvo congelado em t , choques de média zero),

$$\hat{w}_{t+h} = w_t + [1 - (1 - \lambda)^h] d_t. \quad (17)$$

Hipóteses embutidas (importante declará-las): w^* não se move entre t e $t + h$, e $E_t[u_{t+j}] = 0$ para todo j . É uma aproximação — e os dados sugerem que ela custa algo: o λ estimado *diretamente* no horizonte de 3 meses é 0,086, *menor* que o implicado pela iteração do mensal, $1 - (1 - 0,041)^3 = 0,119$.

16.2 Por que o MQO é enviesado aqui — os *dois* vieses, derivados

O regressor $d_{i,t} = \hat{w}_{i,t}^* - w_{i,t}$ tem dois problemas, que puxam em direções opostas.

(a) Erro de medida no alvo $\Rightarrow$ atenuação (viés para baixo). O alvo usa $\hat{\theta}_t$ *estimado*: $\hat{w}^* = w^* + (\text{erro de estimação})$. É o problema clássico de erro nas variáveis: se o regressor observado é $d = d^* + e$ com ruído e não correlacionado com d^* , então

$$\text{plim } \hat{\lambda}^{MQO} = \lambda \cdot \frac{\sigma_{d^*}^2}{\sigma_{d^*}^2 + \sigma_e^2} < \lambda. \quad (18)$$

A fração é a razão sinal/(sinal+ruído): o coeficiente é “diluído” na direção de zero. Isso é letal para o nosso teste, porque empurra a estimativa exatamente para o valor da hipótese nula ($\lambda = 0$). Nota registrada nos manuscritos do orientador: uma regularização *ridge* (que também encolhe coeficientes para zero) **agravaria** esse problema em vez de corrigi-lo — ridge é para estabilizar regressores observados em alta dimensão (útil num passo futuro, ao estimar θ com muitas características), não para regressor medido com erro.

(b) $w_{i,t}$ aparece nos dois lados $\Rightarrow$ reversão mecânica (viés para cima). Suponha que o peso observado tenha um componente transitório: $w_t = \tilde{w}_t + \eta_t$ (ruído de marcação, arredondamento de data de competência, oscilação de mercado intra-mês). Então $d_t = w^* - w_t$ contém $-\eta_t$, e $\Delta w_{t+1} = w_{t+1} - w_t$ também contém $-\eta_t$. O termo comum gera $\text{Cov}(d_t, \Delta w_{t+1}) \supset \text{Var}(\eta_t) > 0$: um peso “momentaneamente alto” faz a distância parecer negativa e o peso cair no mês seguinte — reversão puramente mecânica que o MQO lê como velocidade de ajuste. Viés para *cima*.

Quem ganha? Teoria não decide; os dados decidiram: $\hat{\lambda}^{MQO} = 0,098 > \hat{\lambda}^{VI} = 0,041$, logo o viés dominante foi o mecânico (para cima). Registro honesto: a expectativa *a priori* do projeto era a atenuação dominar; o resultado veio ao contrário, e os textos foram corrigidos para apresentar os dois vieses *ex ante* em vez de só um.

16.3 Variável instrumental, por dentro

O que é. A solução para regressor correlacionado com o erro é achar um **instrumento** z : uma variável (i) correlacionada com o regressor problemático (*relevância*, $\text{Cov}(z, d) \neq 0$) e (ii) não correlacionada com o erro da equação (*exclusão*, $\text{Cov}(z, u) = 0$). Usamos a **distância defasada** $z_{i,t} = d_{i,t-1}$: a distância é persistente (relevância quase garantida), e o ruído de medida do mês corrente (η_t , erro de $\hat{\theta}_t$) não está nela.

Como funciona, em detalhe. Em dois estágios (2SLS). Primeiro estágio: projetar o regressor no instrumento, $d_{i,t} = \pi d_{i,t-1} + v_{i,t}$, e reter $\hat{d} = \hat{\pi} d_{t-1}$ — a parte de d_t que o mês anterior *já anunciava*, limpa do ruído corrente. Segundo estágio: regredir Δw_{t+1} em $\hat{d}$. No caso **exatamente identificado** (um instrumento para um regressor), o 2SLS colapsa numa razão de covariâncias (estimador de Wald):

$$\hat{\lambda}^{VI} = \frac{\sum_{i,t} d_{i,t-1} \Delta w_{i,t+1}}{\sum_{i,t} d_{i,t-1} d_{i,t}} = \frac{\widehat{\text{Cov}}(z, \Delta w)}{\widehat{\text{Cov}}(z, d)}, \quad (19)$$

consistente porque, sob exclusão, o ruído que contamina o MQO não entra em $\text{Cov}(z, \Delta w)$: o instrumento “não vê” η_t nem o erro de $\hat{\theta}_t$ — por isso a VI corrige *os dois* vieses de uma vez, qualquer que fosse o dominante.

Relevância (verificada). Primeiro estágio: $\hat{\pi} = 0,895$, $R^2 = 0,79$; estatística t do instrumento com cluster por fundo = 89,5, ou seja, F efetivo ≈ 8.000 — ordens de magnitude acima de qualquer limiar de instrumento fraco (a regra de bolso clássica é $F > 10$; os limiares modernos de Olea–Pflueger ficam em dezenas). Instrumento fraco não é a nossa preocupação. (Nota da revisão: o $F = 39.793$ impresso pelo script vem da regressão sem cluster; o número correto a citar é o clusterizado.)

Exclusão (a parte frágil — discussão completa). $\text{Cov}(d_{t-1}, u_{t+1}) = 0$ exige que nada *persistente* fique fora do modelo. O contraexemplo relevante: suponha que o fundo i tenha um gosto

permanente por VALE3 acima do que suas características explicam (um α_i de fundo). Então $d_{i,t} \approx -\alpha_i$ *tudo mês* (o alvo medido fica sistematicamente abaixo do peso), enquanto $\Delta w \approx 0$; logo $u_{t+1} = \Delta w - \lambda d_t \approx \lambda \alpha_i$ é correlacionado com $d_{t-1} \approx -\alpha_i$ — exclusão violada, com viés de $\hat{\lambda}^{VI}$ para *baixo* (o componente permanente entra no denominador mas não no numerador). E os dados gritam exatamente esse padrão:

Especificação (todas VI, EP por fundo)	$\hat{\lambda}$	EP	t	meia-vida
Baseline, instrumento d_{t-1}	0,041	0,006	6,6	≈ 16 meses
Com efeito fixo de fundo (<i>within</i>)	0,185	0,019	9,5	$\approx 3,4$ meses
Instrumento alternativo d_{t-2}	0,021	0,005	4,3	≈ 33 meses
Horizonte de 3 meses ($\Delta_3 w$)	0,086	0,011	7,5	(acumulada)

O efeito fixo *remove* o componente permanente α_i — e λ mais que quadruplica (0,185). O instrumento mais defasado d_{t-2} carrega proporcionalmente *mais* componente permanente — e λ cai pela metade (0,021). O padrão monotônico $0,021 \rightarrow 0,041 \rightarrow 0,185$ é exatamente a assinatura da heterogeneidade persistente. A leitura defensável, portanto, não é “a magnitude é sensível” e sim: *o λ agregado mistura dois regimes — entre fundos, desvios quase permanentes que nunca se fecham; dentro do fundo, desvios da própria trajetória que se fecham com meia-vida de $\approx 3-4$ meses.* A especificação com efeito fixo é a mais crível para “velocidade de ajuste” no sentido econômico.

16.4 Erros-padrão agrupados (cluster) — e o problema do choque comum

O que é. Os resíduos $u_{i,t+1}$ do mesmo fundo são autocorrelacionados (decisões graduais), então os EPs usam o estimador sanduíche agrupado por fundo:

$$\hat{V} = (X'X)^{-1} \left[\frac{G}{G-1} \sum_{g=1}^G s_g s_g' \right] (X'X)^{-1}, \quad s_g = \sum_{i,t \in \text{fundo } g} x_{it} \hat{u}_{it}, \quad (20)$$

(na versão VI, com Z no lugar de X nos “pães” do sanduíche). A soma *dentro* do cluster antes de elevar ao quadrado permite qualquer padrão de correlação dentro do fundo; a hipótese restante é independência *entre* clusters.

Limitações e como tratamos (ou ainda vamos tratar). O problema apontado na revisão: fundos **não** são independentes dentro do mês. O retorno de VALE3 move *mechanicamente* (eq. 1) o Δw de todos os detentores ao mesmo tempo — um choque comum que o cluster por fundo ignora. Recalculando o *mesmo* $\hat{\lambda}^{VI} = 0,0413$ com outros agrupamentos: EP por fundo 0,0063 ($t = 6,6$); EP por *mês* 0,0226 ($t = 1,8$); EP *two-way* (fundo e mês, fórmula de Cameron–Gelbach–Miller $V_{\text{fundo}} + V_{\text{mês}} - V_{\text{fundo} \times \text{mês}}$) 0,0220 ($t = 1,9$, $p \approx 0,06$). Ou seja: a significância “forte” do teste central, tomada ao pé da letra, dependia da escolha de cluster.

Correção implementada: efeito de tempo, não só erro-padrão maior. [R/36] Em vez de apenas alargar o erro-padrão em torno de um modelo que ignora o choque comum, incluímos um **efeito de tempo** δ_{t+1} diretamente na equação,

$$w_{i,t+1} - w_{i,t} = \delta_{t+1} + \lambda d_{i,t} + u_{i,t+1}, \quad (21)$$

estimado com um conjunto de *dummies* de mês (72 delas) via VI, erro-padrão ainda agrupado por fundo. A lógica: δ_{t+1} absorve qualquer coisa que afete *todos* os fundos igual naquele mês —

inclusive o componente mecânico do retorno de VALE3 — antes de estimar λ ; ataca a causa do problema (o choque comum em si), não o sintoma (a variância maior que ele produz). Resultado: $\hat{\lambda} = 0,0409$, erro-padrão 0,0059, $t = 6,9$ — **a significância é recuperada**, quase idêntica à do cluster por fundo original ($t = 6,6$). Isso é uma boa notícia para o achado: a fragilidade não estava no fenômeno (a reversão ao alvo), estava em como o choque comum do mês era tratado no erro-padrão. A especificação com efeito de tempo passa a ser reportada como **co-principal**, ao lado do efeito-fixo de fundo (Seção anterior) e da variável instrumental simples.

16.5 Resultados principais do ajuste parcial

[R/26] Amostra: 10.570 observações (fundo precisa existir em $t - 1$, t , $t + 1$ — leve seleção de sobreviventes, limitação documentada), 295 fundos, 70 meses.

Estimador	$\hat{\lambda}$	EP (cluster fundo)	t
MQO	0,0976	0,0096	10,2
VI (d_{t-1})	0,0413	0,0063	6,6

Síntese interpretativa: existe reversão ao alvo estrutural, ela é *lenta* (4% da distância por mês na leitura agregada; $\approx 18\%$ na leitura *within*), e isso **reconcilia todo o resto do trabalho** — com λ pequeno, o peso é quase martingale, a ingênua vence no curto prazo, e o fator estrutural descreve o *destino* de longo prazo, não o movimento de curto prazo.

17 Painel dinâmico: Arellano–Bond

O que é. A equação de ajuste parcial pode ser vista de outro ângulo: $w_{i,t} = \rho w_{i,t-1} + \lambda w_{i,t-1}^* + u_{i,t}$ — um **painel dinâmico autorregressivo de primeira ordem** com um regressor adicional (o peso desejado defasado). Arellano e Bond (1991) propuseram um estimador para exatamente esse tipo de equação, motivados por um problema de microeconometria de painéis curtos: como estimar a persistência de uma variável quando ela mesma aparece defasada do lado direito, na presença de um efeito individual não observado?

Por que usamos isso aqui? É uma verificação **independente** da variável instrumental de defasagem única usada na Seção 16.3: ataca o mesmo problema (regressor correlacionado com o erro por construção) por um caminho diferente, sem impor a restrição não-linear de que os dois coeficientes (ρ e λ) somem exatamente um. Foi pedido pelo orientador nesta rodada, como estimador adicional a MQO e VI.

Como funciona, em detalhe. Duas ideias centrais. **(1) Diferenciar remove o efeito individual.** Se existe um efeito de fundo não observado α_i na equação em nível, subtrair a equação de $t - 1$ da de t o elimina: $\Delta w_{i,t} = \rho \Delta w_{i,t-1} + \lambda \Delta w_{i,t-1}^* + \Delta u_{i,t}$. **(2) Instrumentar com níveis defasados.** O termo $\Delta w_{i,t-1}$ ainda é correlacionado com $\Delta u_{i,t}$ (ambos envolvem $u_{i,t-1}$), mas *níveis* suficientemente defasados, $w_{i,t-2}, w_{i,t-3}, \dots$, não são — desde que o erro original $u_{i,t}$ não seja serialmente correlacionado além da primeira ordem. Isso gera um conjunto de instrumentos que **cresce com o tempo**: no período t , todos os níveis até $t - 2$ são instrumentos válidos, e o painel oferece cada vez mais instrumentos à medida que t avança — o oposto da variável instrumental simples da Seção 16.3, que usa sempre um único instrumento (d_{t-1}). O estimador é GMM: minimiza uma forma quadrática dos momentos amostrais $E[w_{i,s} \Delta u_{i,t}] = 0$ para $s \leq t - 2$, ponderada pela inversa (estimada) da matriz de variância desses momentos. [R/35]

Resultados no nosso projeto. Com $T = 72$ meses e todas as defasagens disponíveis como instrumento (lag 2 a 71), o coeficiente do peso desejado defasado é $\hat{\lambda} = 0,2923$ ($t = 6,8$), e o de persistência $\hat{\rho} = 0,584$ — um ajuste *muito* mais rápido que os 0,041 da VI restrita. Mas há um problema sério nesse número: com $T = 72$ (um painel temporalmente longo para os padrões do estimador, pensado para T pequeno e N grande) e todas as defasagens como instrumento, geram-se **2.484 instrumentos para 307 fundos** — mais instrumentos que unidades, o sintoma clássico de **proliferação de instrumentos**, que torna o teste de Sargan (que checa se os instrumentos são conjuntamente válidos) não-informativo (estatística com 2.484 graus de liberdade, $p = 1$) e, segundo a literatura de painéis dinâmicos, tende a enviesar a estimativa GMM na direção do estimador ingênuo (o que poderia estar inflando esse 0,29).

A correção: colapsar os instrumentos — e o sinal inverte. A prática padrão para proliferação de instrumentos (Roodman, 2009) é **colapsar**: em vez de uma coluna de instrumento para cada combinação (defasagem, período), usar uma única coluna por defasagem *relativa*, que agrega a informação de todos os períodos. Isso reduz drasticamente a contagem de instrumentos sem descartar as defasagens distantes. Reestimando com essa correção:

Especificação	$\hat{\lambda}$ (sobre w_{t-1}^*)	t	ρ
Instrumentos completos (lag 2–71)	+0,2923	6,8	0,584
Instrumentos colapsados (Roodman)	–0,3312	–6,2	0,476

O coeficiente troca de sinal. Uma tentativa intermediária — truncar cru os instrumentos às defasagens 2 a 5, sem colapsar — produziu uma matriz de covariância computacionalmente singular (erro de estimação, não apenas imprecisão), outro sintoma de que a especificação de painel dinâmico é mal identificada neste desenho: $N = 307$ é pequeno para os padrões usuais do Arellano–Bond (que prefere N grande), e $T = 72$ é grande para os padrões usuais do mesmo estimador (que prefere T pequeno) — é, literalmente, o oposto do caso para o qual o estimador foi desenhado.

Limitações e como tratamos (ou ainda vamos tratar). **A conclusão honesta é que o Arellano–Bond, neste desenho específico, não fornece uma estimativa confiável de λ** — nem o *sinal* é estável à forma de construir os instrumentos. Isso significa que ele **não deve ser lido como uma sétima confirmação** do fenômeno de reversão ao alvo; a robustez desse achado repousa nas seis especificações de MQO, variável instrumental (em três esquemas de cluster) e efeito-fixo de fundo, que *são* consistentes em sinal (Seção 16.4) — desenhadas para o formato particular deste painel, ao contrário do Arellano–Bond. O teste de autocorrelação de segunda ordem nos resíduos diferenciados (o diagnóstico de validade mais relevante para esse estimador, que checa se os instrumentos de defasagem 2 em diante são de fato não correlacionados com o erro) não rejeita a ausência de autocorrelação de ordem 2 na versão com instrumentos completos ($p = 0,37$) — o único diagnóstico desse bloco que não levanta bandeira, mas que não resolve a instabilidade de sinal encontrada. Rotas para investigar no futuro: um desenho de Blundell–Bond (*system GMM*, que combina a equação em diferenças com a equação em nível e costuma ser mais eficiente e estável que o Arellano–Bond puro) ou colapsos intermediários de instrumento.

18 A série do erro $\hat{u}$ e a regra de decisão recursiva

18.1 A série do erro de previsão

Com λ estimado, o erro de previsão do ajuste parcial é $\hat{u}_{t+1} = \Delta w_{t+1} - \hat{\lambda} d_t$. Caracterizamos a série (média entre fundos, mês a mês) [R/30]: média do painel 0,0002 (das médias mensais, 0,0004) — sem viés; desvio-padrão do painel 0,015; autocorrelação da série mensal $-0,16$ (levemente negativa, típica de sobre-reação/microestrutura); Dickey–Fuller $-9,6$ — estacionariedade rejeitada com folga enorme. É o que se exige de um erro de previsão saudável: centrado, estável, sem memória explorável óbvia. As duas versões (λ MQO e VI) dão o mesmo quadro, porque diferem só por $(\lambda^{MQO} - \lambda^{VI}) d_t$, que é pequeno.

18.2 A regra de decisão sob opacidade

O que é. O exercício operacional: a cada origem t (a partir do mês 24), reestimar λ *só com dados até t* (MQO e VI), prever $\hat{w}_{t+h}$ pela fórmula (17) nos horizontes $h = 1$ e $h = 3$ (o da opacidade), e comparar com a ingênua. Sem *look-ahead*: verificamos linha a linha que o treino usa apenas pares concluídos até a origem (a padronização global das características não vaza porque transformação afim não muda valores ajustados de regressão com intercepto).

Resultados no nosso projeto. RMSE fora da amostra [R/30]:

Horizonte	Ingênua	Aj. parcial (λ MQO)	Aj. parcial (λ VI)
$h = 1$ ($n = 8.002$)	0,01635	0,01607	0,01624
$h = 3$ ($n = 7.456$)	0,02196	0,02177	0,02163

Diferente dos modelos M1/M2 (que *substituíam* a âncora w_t e perdiam feio), o ajuste parcial *mantém* a âncora e soma um empurrão pequeno na direção do alvo — e os números ficam do lado certo em todas as células (melhora de 0,7% a 1,8% no RMSE).

18.3 Diebold–Mariano: o teste que disciplina essa conclusão

O que é. Dois RMSEs diferentes podem ser sorte amostral. O teste de Diebold–Mariano (1995) formaliza: defina o *diferencial de perda* $\delta_t = e_{A,t}^2 - e_{B,t}^2$ (aqui, média por origem t dos quadrados dos erros da ingênua menos os do ajuste parcial); sob H_0 de igual capacidade preditiva, $E[\delta_t] = 0$; a estatística é $\bar{\delta}/\widehat{se}_{HAC}(\bar{\delta}) \rightarrow N(0, 1)$, com EP de longo prazo (Newey–West na série dos δ_t — necessário porque previsões de h passos com janelas sobrepostas geram δ_t autocorrelacionados até a ordem $h - 1$).

Resultados no nosso projeto. Calculado na revisão sobre exatamente as mesmas janelas do R/30: em $h = 1$, $t_{DM} = 1,78$ (MQO) e 2,04 (VI) — marginalmente significativo; em $h = 3$, $t_{DM} = 0,04$ (MQO) e 0,92 (VI) — **indistinguível de zero**.

Limitações e como tratamos (ou ainda vamos tratar). A conclusão honesta, portanto, é mais modesta do que “supera a ingênua”: *o ajuste parcial nunca perde da ingênua e aponta na direção certa em todas as células, mas a única vantagem estatisticamente detectável está em $h = 1$ — que é justamente o horizonte ineficaz sob opacidade —, enquanto em $h = 3$, o horizonte operacional, a diferença não é significativa*. A redação dos documentos que afirmam superação “pequena mas consistente, sobretudo a três meses” precisa ser recalibrada para isso (correção pendente; o teste

já está pronto para entrar no R/30). Duas rotas para fortalecer o resultado de verdade: usar o λ *within* (efeito fixo) na regra de decisão, e remover o componente mecânico do preço do alvo e do erro.

19 Fragilidades transversais e o mapa de correções

19.1 O outlier de fluxo e a winsorização

O que é. A razão fluxo/PL tem mínimo $-63,99$ — um fundo minúsculo com resgate de 64 vezes o PL de fim de mês (artefato de denominador: PL pequeno no dia da foto). **Winsorizar** é truncar os extremos nos percentis (aqui 1% e 99%): valores abaixo do P1 viram P1, acima do P99 viram P99 — mantém a observação, remove a alavanca. Recalculando o Fama–MacBeth com fluxo winsorizado: o coeficiente do fluxo muda de $-0,0004$ para $+0,0018$ (continua não-significativo, $t = 0,4$); os demais coeficientes não se movem na terceira casa. Ou seja: a conclusão “fluxo não explica o nível” é robusta, mas o *número* reportado para o fluxo era refém de meia dúzia de observações extremas — e o painel do fluxo na figura dos θ_t (o “vale” isolado de 2018) é o retrato disso. **Status:** implementada nesta rodada [R/36] — a captação winsorizada 1%/99% é agora a especificação **principal** em todas as tabelas de Fama–MacBeth; a versão crua fica como robustez.

19.2 Mapa geral: limitação → correção → status

Limitação	Correção	Status
EP de Fama–MacBeth assume coefs. independentes; autocorr. 0,7–0,8	Newey–West ($L = 3$) em todas as tabelas	feita (R/24)
Escala: coef. bruto lido como “por d.p.” em versão antiga	padronização z-score + tabelas/texto refeitos	feita (R/24/28/29)
Linear viola suporte $[0, 1]$ (2,5% das previsões)	logit fracionário Papke–Wooldridge	feita (R/25)
MQO enviesado no ajuste parcial (2 vieses)	VI com d_{t-1} , 1 ^o estágio verificado	feita (R/26)
Sensibilidade da VI à especificação	FE, d_{t-2} , $h = 3$	feita (R/27)
NW com $L = 3$ subcorrige sob $\rho \approx 0,77$	reportado $L = 6/12$ (t caem p/ 7–9, conclusões idem)	feita (R/36)
“Supera a ingênua” sem teste formal	Diebold–Mariano no R/30/R/36 ($h = 3$: n.s.) + reescrito	feita (R/36)
Cluster só por fundo ignora choque comum do mês	efeito de tempo δ_t (recupera $t = 6,9$)	feita (R/36)
Exclusão de d_{t-1} frágil (heterog. persistente)	FE+VI rerepresentada como co-principal	feita (R/36)
Fluxo/PL com caudas extremas (–6.399%)	winsorizar 1%/99%, agora especificação principal	feita (R/36)
APE de dummy como derivada, não diferença discreta	diferença discreta (–1,94 vs. –1,60 p.p.)	feita (R/36)
F do 1 ^o estágio sem cluster ($F = 39.793$)	F efetivo clusterizado (= 8.012, ainda fortíssimo)	feita (R/36)
Sem estimador alternativo ao MQO/VI de 1 lag	painel dinâmico de Arellano–Bond (R/35)	feita, mas instável em sinal
Estimação restrita a VALE3	painel amplo, $\theta_{n,t}$ para ≈ 900 ativos (R/31–32)	feita (só a camada explicativa)
Sem controle de risco de mercado conhecido	fatores NEFIN-USP no pooled (R/34): coefs. estáveis	feita
Sem beta do próprio fundo como controle	calculado via cota da SH (R/33)	feita
Kalman: Q, R estimados na amostra cheia	reestimar recursivamente ou nota de rodapé	pendente
Efeito mecânico do preço em Δw e no pooled	decompor variação mecânica vs. ativa	agenda
Margens tratadas separadamente	modelo em duas partes (<i>hurdle</i>)	agenda
Corte de > 3 cotistas é convenção	sensibilidade com > 1 , > 5 , > 10	agenda
Elasticidade-preço à la Kojien–Yogo não estimada	exige instrumento dos demais investidores	agenda
Preço/beta só de VALE3 no painel amplo (1.777 ativos)	priorizar ativos mais frequentes	agenda
DF sem aumento	ADF(1-2)	pendente (menor)

20 Síntese final: a história completa

O ponto de partida foi uma pergunta de sistema de demanda: *o que explica quanto de VALE3 cada fundo do Itaú carrega, e isso prevê alguma coisa?* A resposta veio em camadas.

1. **A demanda tem estrutura estável, e generaliza.** Mês após mês, por 72 meses, sem exceção: fundos maiores diluem, fundos com mais cotistas concentram, FICs não têm posição direta relevante. Isso sobrevive à forma funcional (linear vs. logística dão efeitos quase idênticos), à correção de inferência (Newey–West: $t \approx 11$; com L grande, 7–9), à winsorização

do fluxo, ao controle por fatores de risco de mercado conhecidos (NEFIN) e — achado novo desta versão — generaliza em **direção** para 92 a 99% de quase 900 outras ações que os fundos do Itaú carregam. A **magnitude** do efeito de VALE3, porém, é atípica (percentil 1 no efeito de tamanho): é um papel extremo nessa dimensão, não representativo.

2. **As duas margens se opõem** — quem tende a *ter* (grandes, FICs) tende a *ter pouco* — a assinatura de diversificação, e o achado descritivo mais interessante.
3. **Nada prevê o curto prazo.** O peso individual é quase martingale: a ingênua vence efeito fixo, fator e Kalman em todos os universos e horizontes, e a média histórica do próprio fundo perde do último valor (não há reversão ao nível do fundo detectável).
4. **Mas existe um alvo, e o peso caminha para ele — devagar, e de forma robusta a seis (não sete) estimadores.** O ajuste parcial estimado por VI dá $\lambda \approx 0,04/\text{mês}$ no agregado (meia-vida ≈ 16 meses) e $\approx 0,19/\text{mês}$ dentro do fundo (meia-vida $\approx 3\text{--}4$ meses); com efeito de tempo em vez de cluster por mês, a significância se mantém forte ($t = 6,9$). O sinal positivo é robusto a seis especificações de MQO, VI e efeito-fixo. O painel dinâmico de Arellano–Bond, a sétima tentativa, **não** confirma essa robustez — o sinal troca conforme os instrumentos são construídos, evidência de que o estimador é mal identificado neste desenho de painel (N pequeno, T grande), não uma refutação do fenômeno. O erro de previsão resultante é centrado, estável e estacionário.
5. **O ganho de previsão do ajuste parcial ainda não está demonstrado.** Ele nunca perde da ingênua, mas a vantagem só é estatisticamente detectável (Diebold–Mariano) no horizonte que a opacidade torna infactível ($h = 1$); em $h = 3$ o teste não rejeita igualdade. Com o cluster corrigido pelo efeito de tempo, o λ *within* e a decomposição mecânica/ativa, essa fronteira é o próximo passo natural do trabalho.

Em uma frase final: *as características dizem para onde o peso vai; a inércia diz onde ele está; e a distância entre as duas coisas se fecha tão lentamente que explicá-la é fácil e lucrá-la é difícil.*

A O que cada script faz

Script	Função
R/01	Carga e sanidade das bases CONS e SH (auditoria de colunas/linhas).
R/02–R/07	Piloto 2016: painel, fluxos, características, preço/beta, filtro de cotistas, primeira cross-section.
R/10	Painel 2016–2021 do peso (26.123 obs, 623 fundos; dedup, negativos, merge dia exato).
R/11	Fluxo líquido mensal via Informe Diário (validado ao centavo vs. SH em 99,4–99,8%).
R/12	Características de fundo da SH (PL, cotistas, FIC, classificação).
R/13	Preço e beta de VALE3 (Yahoo, validado vs. B3; beta móvel 252 pregões; dois <i>timings</i>).
R/14	Filtro > 3 cotistas + 72 cross-sections + pooled; salva os θ_t .
R/15	Validação global do painel multi-ano (zero erros).
R/16	Dinâmica dos θ_t : autocorrelação, AR(1), Dickey–Fuller, pseudo-OOS, figura.
R/17–R/18	Previsão do peso: fator+RW/AR1; efeito fixo; FE+Kalman; modelo de variação.
R/19	Horizontes $h = 1$ e $h = 3$ (opacidade).
R/20	Margem extensiva (painel com zeros, logit de posse, entradas/saídas).
R/21–R/22	Previsão restrita a fundos de ações; previsão da posse em $h = 1, 3$.
R/23	Estatísticas descritivas (Tabela 1) e correlações.
R/24	Padronização + Fama–MacBeth com Newey–West (clássico vs. corrigido).
R/25	Logit fracionário mês a mês + APEs + comparação com o linear.
R/26	Ajuste parcial: MQO vs. VI (d_{t-1}), 1º estágio, cluster por fundo.
R/27	Robustez do λ : efeito fixo, d_{t-2} , horizonte 3 meses.
R/28	Conferência de escala (tabelas padronizadas exatas).
R/29	Figura dos θ_t padronizados.
R/30	Série do erro $\hat{u}$ (média, DP, autocorrelação, DF) + decisão recursiva OOS.
R/31	Painel multiativo bruto (fundo $\times$ ativo $\times$ mês, todo o universo Itaú) + limpeza + características de fundo.
R/32	Cross-section $\theta_{n,t}$ por (ativo, mês); média entre ativos; pooled com efeito fixo two-way.
R/33	Beta do próprio fundo (retorno da cota da SH vs. Ibovespa, mesma janela do beta de VALE3).
R/34	Fatores de risco do NEFIN-USP agregados para mensal; controle no pooled.
R/35	Velocidade de ajuste por painel dinâmico de Arellano–Bond (instrumentos completos e colapsados).
R/36	Correções da revisão crítica: winsorização, sensibilidade do NW, cluster two-way, efeito de tempo, Diebold–Mariano, APE discreto, F efetivo.

B Referências

- Arellano, M.; Bond, S. Some tests of specification for panel data: Monte Carlo evidence and an application to employment equations. *Review of Economic Studies*, 58(2):277–297, 1991.
- Cameron, A. C.; Gelbach, J.; Miller, D. Robust inference with multiway clustering. *Journal of Business & Economic Statistics*, 29(2):238–249, 2011.
- Coval, J.; Stafford, E. Asset fire sales (and purchases) in equity markets. *Journal of Financial Economics*, 86(2):479–512, 2007.
- Dickey, D.; Fuller, W. Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74:427–431, 1979.

- Diebold, F.; Mariano, R. Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3):253–263, 1995.
- Fama, E.; MacBeth, J. Risk, return, and equilibrium: empirical tests. *Journal of Political Economy*, 81(3):607–636, 1973.
- Gabaix, X.; Koijen, R. In search of the origins of financial fluctuations: the inelastic markets hypothesis. *NBER WP* 28967, 2021.
- Harvey, A. *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge University Press, 1989.
- Koijen, R.; Yogo, M. A demand system approach to asset pricing. *Journal of Political Economy*, 127(4):1475–1515, 2019.
- Lou, D. A flow-based explanation for return predictability. *Review of Financial Studies*, 25(12):3457–3489, 2012.
- Newey, W.; West, K. A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3):703–708, 1987; e Automatic lag selection in covariance matrix estimation. *Review of Economic Studies*, 61(4):631–653, 1994.
- Núcleo de Economia Financeira (NEFIN), USP. Risk factors for the Brazilian market. <https://nefin.com.br/data/risk-factors/>, acessado em 09/07/2026.
- Papke, L.; Wooldridge, J. Econometric methods for fractional response variables with an application to 401(k) plan participation rates. *Journal of Applied Econometrics*, 11(6):619–632, 1996.
- Roodman, D. A note on the theme of too many instruments. *Oxford Bulletin of Economics and Statistics*, 71(1):135–158, 2009.