

v2 OFICIAL

Peso de VALE3 nos fundos do Itaú — versão simples, direta e objetiva
Cross-section (MQO + logit), ajuste parcial e um esquema in/out-of-sample — sem Newey–West,
sem Kalman, sem Diebold–Mariano, sem múltiplos métodos de robustez

João Paulo Zangrandi (FGV–EESP)

Resumo

Este documento retoma o projeto a partir da ideia original das anotações do orientador: uma cross-section simples que estima um fator latente θ , uma etapa logística para manter a previsão dentro de $[0, 1]$, e um modelo de ajuste parcial para a dinâmica. Cada etapa usa **um único método** (MQO ou MQO logístico), sem testes ou correções de robustez em cascata. Nesta versão, as características do fundo (inclusive o novo beta do próprio fundo) passam a ser sempre medidas no **último dia do mês anterior**, eliminando qualquer look-ahead bias.

Sumário

1	Por que esta versão existe	3
2	Etapa 1: a cross-section (MQO + logit)	3
2.1	O resultado: antes e depois do beta do fundo	4
2.2	O erro e	4
3	Etapa 2: o ajuste parcial	7
3.1	O resultado	7
3.2	O erro u	7
4	Etapa 3: um esquema in/out-of-sample	9
4.1	O resultado, fora da amostra	9
5	Resumo	10

1 Por que esta versão existe

As versões anteriores deste projeto acumularam camada sobre camada de robustez estatística (Newey–West, filtro de Kalman, variável instrumental com múltiplos esquemas de cluster, painel dinâmico de Arellano–Bond, teste de Diebold–Mariano) até o núcleo do modelo ficar difícil de enxergar por trás das correções. Esta versão volta ao desenho original discutido com o orientador: uma cross-section por mínimos quadrados que gera um fator latente θ , uma etapa logística (a única forma de robustez mantida, porque o peso é limitado a $[0, 1]$ e a reta não respeita esse limite), e um modelo de ajuste parcial estimado diretamente por MQO. Cada etapa produz um erro, examinado com estatísticas simples — média, desvio-padrão, assimetria, curtose, histograma — sem bateria de testes formais.

A base de dados (composição de carteiras da CVM, fundos do grupo Itaú, 2016–2021) é a mesma já construída e validada na versão anterior — essa parte nunca foi a fonte da complexidade.

2 Etapa 1: a cross-section (MQO + logit)

A pergunta: As características de um fundo explicam o peso de VALE3 que ele carrega? E, se sim, como transformar essa explicação numa previsão que respeite os limites de 0% a 100%?

Esta etapa une o que em versões anteriores deste documento eram duas seções separadas: a cross-section **linear** (para interpretar os coeficientes diretamente em pontos percentuais) e a cross-section **logística** (para gerar um peso previsto que nunca sai de $[0, 1]$). As duas usam as mesmas cinco características, mês a mês:

A equação estimada:

$$\text{peso}_{i,t} = \alpha_t + b_t^{aum} z(\ln AUM_i) + b_t^{cot} z(\ln \cot_i) + b_t^{fic} FIC_i + b_t^{low} \left(\frac{\text{capt} - \text{resg}}{AUM} \right)_i + b_t^{bf} z(\beta_i^{fundo}) + \text{erro}_{i,t} \quad (1)$$

$$\text{peso}_{i,t} = g(x'_{i,t} \theta_t) + e_{i,t}, \quad g(z) = \frac{1}{1 + e^{-z}} \quad (2)$$

A primeira é estimada por MQO (coeficientes em pontos percentuais, fáceis de interpretar); a segunda por máxima verossimilhança (glm quase-binomial), a única forma de robustez mantida nesta versão, porque $x'\theta$ pode sair de $[0, 1]$ mas $g(x'\theta)$ nunca sai. As duas rodam mês a mês, uma regressão por mês, sem nenhuma etapa de resumo temporal em cima (não é Fama–MacBeth).

Novidade desta versão — duas mudanças na Etapa 1:

- (a) Entra uma 5ª característica, o **beta do próprio fundo** β^{fundo} (covariância do retorno da cota com o Ibovespa, janela de 252 pregões — mesma metodologia já usada para o beta de VALE3).
- (b) **Todas** as cinco características (não só o beta do fundo) passam a ser medidas no **último dia do mês anterior** ($t - 1$), nunca no mês corrente — antes, AUM , cotistas e fluxo eram contemporâneos ao próprio mês t . Agora θ_t é 100% predeterminado: tudo que ele usa já era conhecido antes do mês t começar.

Adendo sobre a amostra: exigir as cinco características simultaneamente reduz a cobertura de 72 para **59 meses** (fev/2017 a dez/2021) — o beta do fundo exige ≥ 252 pregões de histórico de cota (quase um ano), então nenhum fundo tem essa variável disponível nos primeiros meses da amostra (jan/2016 a jan/2017 ficam sem fundos suficientes). Essa perda foi aceita conscientemente,

não é um erro: a partir daqui, todo número deste documento vem dos 8.335 fundo-meses com as cinco características completas (120 a 190 fundos por mês, média 141).

2.1 O resultado: antes e depois do beta do fundo

Para deixar claro o efeito de adicionar o beta do fundo, a tabela abaixo compara — na **mesma amostra** de 59 meses — a regressão linear com as quatro características clássicas contra a mesma regressão com o beta do fundo incluído.

Tabela 1: Θ linear: antes e depois do beta do fundo (mesma amostra, 59 meses, teste ingênuo de significância $t = \bar{\theta}/(\text{dp}(\theta)/\sqrt{59})$).

Variável	Média (sem β^{fundo})	Sig.	Média (com β^{fundo})	Sig.
α	0,04524	***	0,03554	***
b^{aum} (tamanho)	−0,00743	***	−0,00161	*
b^{cot} (cotistas)	0,01304	***	0,00179	n.s.
b^{fic} (fundo de cotas)	−0,01956	***	−0,00567	**
b^{flow} (captação/resgate)	0,00987	n.s.	−0,00339	n.s.
b^{bf} (beta do fundo)	—	—	0,02325	***
R^2 médio	0,166		0,532	

* $p < 5\%$, ** $p < 1\%$, *** $p < 0,1\%$. Fonte: elaboração própria (`scripts/13_etapa1_unificada.R`, `14_etapa1_antes_depois.R`).

Achado: O mesmo padrão que já tinha aparecido como checagem à parte na versão anterior (Tabela 11 do `tcc I.pdf`) agora é a especificação principal: com o beta do fundo na conta, tamanho perde quase toda a força ($t = -5,2 \rightarrow -2,2$), cotistas deixa de ser significativo ($t = 6,9 \rightarrow 1,9$), e só fundo de cotas e beta do fundo continuam robustos. R^2 triplica ($0,166 \rightarrow 0,532$). Leitura: parte do que tamanho e cotistas pareciam explicar era, na verdade, um proxy indireto para o quão “equity-like” é o fundo — o beta do fundo mede isso diretamente.

A versão logística mostra o mesmo padrão (tamanho e cotistas perdem significância, beta do fundo domina): $\alpha = -3,81$ (era $-3,13$), $b^{\text{aum}} = -0,06$ n.s. (era $-0,27$ ***), $b^{\text{cot}} = 0,05$ n.s. (era $0,44$ ***), $b^{\text{fic}} = -0,21$ ** (era $-0,67$ ***), $b^{\text{bf}} = 1,01$ ***.

2.2 O erro e

$e_{i,t} = \text{peso}_{i,t} - g(x'_{i,t}\theta_t)$, o erro de ajuste da regressão logística (dentro da amostra).

Tabela 2: Estatísticas do erro e (8.335 observações).

Estatística	Valor
Média	0,000000
Desvio-padrão	0,0227
Mediana	−0,0008
Mínimo / Máximo	−0,113 / 0,178
% de observações com $e > 0$	45,1%
Assimetria	0,39
Curtose	7,67 (normal = 3)
Previsões fora de $[0, 1]$	0 de 8.335

A média é zero em todo mês — mecânico (condição de primeira ordem da máxima verossimilhança com intercepto), não evidência de bom ajuste. O desvio-padrão caiu de 0,0305 (versão sem




Figura 1: Os seis componentes de θ_t linear (com beta do fundo) ao longo dos 59 meses, e o R^2 de cada regressão mensal. b^{bf} é sempre positivo, numa faixa relativamente estreita — coerente com sua significância forte e estável.

beta do fundo) para 0,0227 — o modelo ajusta melhor, coerente com o salto no R^2 .




Figura 2: Histograma do erro e (8.335 observações). A linha tracejada marca zero.




Figura 3: Evolução mês a mês do erro e : nuvem cinza = erro individual de cada fundo-mês; linha azul = média mensal (mecanicamente zero); linha vermelha tracejada = desvio-padrão mensal. Eixo y restrito a $[-0,03, 0,06]$ para facilitar a leitura das duas linhas — 843 dos 8.335 pontos individuais (10%) ficam fora e não aparecem.

3 Etapa 2: o ajuste parcial

A pergunta: O peso de um fundo se move em direção ao que as características sugerem, ou fica parado onde está?

O alvo de um fundo, num mês, é $w_{i,t}^* = g(x'_{i,t}\theta_t)$ — a mesma previsão da Etapa 1. A hipótese de ajuste parcial: o fundo fecha uma fração λ da distância ao alvo a cada mês.

A equação estimada:

$$w_{i,t+1} - w_{i,t} = \lambda d_{i,t} + u_{i,t+1}, \quad d_{i,t} \equiv w_{i,t}^* - w_{i,t} \quad (3)$$

Estimado por MQO direto, sem intercepto, pooled em todos os fundo-meses — um único método, sem instrumento, sem efeito-fixo, sem painel dinâmico.

3.1 O resultado

$$\hat{\lambda} = 0,1534 \quad (\text{erro-padrão} = 0,0075, \quad t = 20,6, \quad R^2 = 0,050, \quad n = 7.987)$$

λ subiu de 0,098 (versão anterior) para 0,153 — esperado, já que o alvo w^* agora é mais preciso (R^2 maior na Etapa 1), o que atenua menos o coeficiente pelo erro de medida clássico (Problema 1 do modelo de ajuste parcial). Em média, um fundo fecha 15,3% da distância ao alvo por mês.

3.2 O erro u

Tabela 3: Estatísticas do erro u (7.987 observações, pares de meses consecutivos).

Estatística	Valor
Média	0,0002
Desvio-padrão	0,0151
Mediana	-0,0004
Mínimo / Máximo	-0,160 / 0,185
% de observações com $u > 0$	44,3%
Assimetria	0,59
Curtose	19,4 (normal = 3)

Praticamente idêntico ao da versão anterior (dp 0,0151 nas duas) — a mudança na Etapa 1 melhorou o ajuste de e , mas o comportamento do erro do ajuste parcial em si não muda muito.




Figura 4: Histograma do erro u (7.987 observações).




Figura 5: Evolução mês a mês do erro u . Eixo y restrito a $[-0,03, 0,04]$; 369 dos 7.987 pontos individuais (4,6%) ficam fora e não aparecem.

4 Etapa 3: um esquema in/out-of-sample

A pergunta: O λ estimado serve pra prever de verdade, em dados que o modelo nunca viu?

Um único corte no tempo, dentro do período coberto pela Etapa 1 (fev/2017 a dez/2021):

- **Treino:** 2017-02 a 2019-12 (35 meses, 4.352 observações).
- **Teste:** 2020-01 a 2021-11 (23 meses, 3.635 observações).

A equação estimada: $\hat{\lambda}$ é estimado pela equação (3) só com dados de treino, depois aplicado fixo aos meses de teste:

$$\hat{w}_{i,t+1} = w_{i,t} + \hat{\lambda}_{\text{treino}} d_{i,t} \quad (\text{ajuste parcial}) \quad \text{vs.} \quad \hat{w}_{i,t+1} = w_{i,t} \quad (\text{ingênua}) \quad (4)$$

θ_t continua sendo estimado mês a mês, sem vazamento de informação futura.

$$\hat{\lambda}_{\text{treino}} = 0,1951 \quad (35 \text{ meses de treino})$$

4.1 O resultado, fora da amostra

Tabela 4: RMSE e MAE dentro e fora da amostra, ajuste parcial vs. ingênua.

Amostra	Modelo	RMSE	MAE
Treino (2017–2019)	Ajuste parcial	0,01463	—
Treino (2017–2019)	Ingênua	0,01510	—
Teste (2020–2021)	Ajuste parcial	0,01560	0,00906
Teste (2020–2021)	Ingênua	0,01585	0,00847




Figura 6: RMSE dentro (treino) e fora (teste) da amostra, ajuste parcial vs. ingênua.

O ajuste parcial vence em RMSE nas duas amostras (razão teste = 0,984) — mesmo padrão da versão anterior. Em MAE, a ingênua continua vencendo nos casos típicos (0,00847 contra 0,00906):

o ajuste parcial evita alguns erros grandes, mas erra um pouco mais em geral. Mês a mês, vence em 14 dos 23 meses de teste (61%).




Figura 7: RMSE mês a mês no período completo (2017–2021). A linha vermelha tracejada marca o início do teste (2020-01). As duas linhas seguem coladas dos dois lados do corte — a vantagem do ajuste parcial é pequena e consistente, não concentrada num único mês.

5 Resumo

1. **Etapa 1, equações (1)–(2):** θ_t mês a mês, cinco características (agora incluindo beta do fundo), todas predeterminadas ($t - 1$). Com o beta do fundo na conta, tamanho e cotistas perdem quase toda a força explicativa; só fundo de cotas e beta do fundo continuam robustos. R^2 médio 0,532 (era 0,166). Custo: cobertura cai para 59 meses (fev/2017 em diante).
2. **Etapa 2, equação (3):** $\hat{\lambda} = 0,153$ (era 0,098) — um alvo mais preciso atenua menos o coeficiente. Erro u com comportamento parecido ao da versão anterior.
3. **Etapa 3:** λ treinado em 2017–2019 vence a ingênua fora da amostra (2020–2021) em RMSE, por margem pequena mas consistente (1,6%; vence em 61% dos meses de teste) — resultado qualitativamente igual ao da versão anterior.

Nenhuma dessas conclusões depende de Newey–West, cluster, Kalman, variável instrumental ou teste de Diebold–Mariano — o preço da simplicidade é não corrigir os vieses conhecidos do MQO direto no ajuste parcial, que a versão anterior do projeto documentou e tentou corrigir. Fica registrado como decisão consciente, não como descuido.