

v2 OFICIAL

Peso de VALE3 nos fundos do Itaú — versão simples, direta e objetiva
Cross-section (MQO + logit), ajuste parcial e um esquema in/out-of-sample — sem Newey–West,
sem Kalman, sem Diebold–Mariano, sem múltiplos métodos de robustez

João Paulo Zangrandi (FGV–EESP)

Resumo

Este documento retoma o projeto a partir da ideia original das anotações do orientador: uma cross-section simples que estima um fator latente θ , uma etapa logística para manter a previsão dentro de $[0, 1]$, e um modelo de ajuste parcial para a dinâmica. Cada etapa usa **um único método** (MQO ou MQO logístico), sem testes ou correções de robustez em cascata. Nesta versão, as características do fundo (inclusive o novo beta do próprio fundo) passam a ser sempre medidas no **último dia do mês anterior**, eliminando qualquer look-ahead bias.

Sumário

1	Por que esta versão existe	3
2	Etapa 1: a cross-section (MQO + logit)	3
2.1	O resultado: antes e depois do beta do fundo	4
2.2	O erro e	5
3	Etapa 2: o ajuste parcial	8
3.1	O resultado	8
3.2	O erro u	8
4	Etapa 3: um esquema in/out-of-sample	10
4.1	O resultado, fora da amostra	10
4.2	RMSE flexível: o mesmo teste, em vários horizontes	11
5	Extensão: mais gestoras	12
5.1	Quanto cada gestora carrega, relativo ao Itaú	13
6	Extensão: todas as ações	15
6.1	Regressão por ativo e por mês: o padrão de VALE3 generaliza?	16
6.2	Checagem complementar: uma única regressão com efeito-fixo de ativo e de mês . .	19
6.3	O erro por gestora, agora com todas as ações	20
6.4	Fechando o panorama: gestora, ativo e mês juntos, nos coeficientes	24
7	Resumo	26

1 Por que esta versão existe

As versões anteriores deste projeto acumularam camada sobre camada de robustez estatística (Newey–West, filtro de Kalman, variável instrumental com múltiplos esquemas de cluster, painel dinâmico de Arellano–Bond, teste de Diebold–Mariano) até o núcleo do modelo ficar difícil de enxergar por trás das correções. Esta versão volta ao desenho original discutido com o orientador: uma cross-section por mínimos quadrados que gera um fator latente θ , uma etapa logística (a única forma de robustez mantida, porque o peso é limitado a $[0, 1]$ e a reta não respeita esse limite), e um modelo de ajuste parcial estimado diretamente por MQO. Cada etapa produz um erro, examinado com estatísticas simples — média, desvio-padrão, assimetria, curtose, histograma — sem bateria de testes formais.

A base de dados (composição de carteiras da CVM, fundos do grupo Itaú, 2016–2021) é a mesma já construída e validada na versão anterior — essa parte nunca foi a fonte da complexidade.

2 Etapa 1: a cross-section (MQO + logit)

A pergunta: As características de um fundo explicam o peso de VALE3 que ele carrega? E, se sim, como transformar essa explicação numa previsão que respeite os limites de 0% a 100%?

Esta etapa une o que em versões anteriores deste documento eram duas seções separadas: a cross-section **linear** (para interpretar os coeficientes diretamente em pontos percentuais) e a cross-section **logística** (para gerar um peso previsto que nunca sai de $[0, 1]$). As duas usam as mesmas cinco características, mês a mês:

A equação estimada:

$$\text{peso}_{i,t} = \alpha_t + \theta_t^{aum} z(\ln AUM_i) + \theta_t^{cot} z(\ln cot_i) + \theta_t^{fic} FIC_i + \theta_t^{flow} \left(\frac{\text{capt} - \text{resg}}{AUM} \right)_i + \theta_t^{bf} z(\beta_i^{fundo}) + \text{erro}_{i,t} \quad (1)$$

$$\text{peso}_{i,t} = g(x'_{i,t} \theta_t) + e_{i,t}, \quad g(z) = \frac{1}{1 + e^{-z}} \quad (2)$$

$\theta_t = (\alpha_t, \theta_t^{aum}, \theta_t^{cot}, \theta_t^{fic}, \theta_t^{flow}, \theta_t^{bf})$ é o vetor de coeficientes de **um único mês** t ; $\Theta = \{\theta_t\}_t$, o **teta grande**, é o conjunto de todos os θ_t ao longo do tempo — é esse conjunto que as tabelas e figuras a seguir resumem (média, desvio-padrão, evolução mês a mês).

A primeira é estimada por MQO (coeficientes em pontos percentuais, fáceis de interpretar); a segunda por máxima verossimilhança (glm quase-binomial), a única forma de robustez mantida nesta versão, porque $x'\theta$ pode sair de $[0, 1]$ mas $g(x'\theta)$ nunca sai. As duas rodam mês a mês, uma regressão por mês, sem nenhuma etapa de resumo temporal em cima (não é Fama–MacBeth).

Novidade desta versão — duas mudanças na Etapa 1:

- (a) Entra uma 5ª característica, o **beta do próprio fundo** β^{fundo} : mede o quanto a cota do fundo se move junto com o mercado (Ibovespa), do mesmo jeito que se mede o beta de uma ação.

A equação estimada:

$$r_{i,d} = \frac{\text{cota}_{i,d}}{\text{cota}_{i,d-1}} - 1 \quad r_{m,d} = \frac{\text{Ibovd}}{\text{Ibovd}_{-1}} - 1$$

$$\beta_{i,t}^{fundo} = \frac{\widehat{\text{Cov}}_{252}(r_i, r_m)}{\widehat{\text{Var}}_{252}(r_m)}$$

$r_{i,d}$ é o retorno diário da cota do fundo i ; $r_{m,d}$ é o retorno diário do Ibovespa; $\widehat{\text{Cov}}_{252}$ e $\widehat{\text{Var}}_{252}$ são covariância e variância amostrais numa janela móvel dos últimos 252 pregões (≈ 1 ano), terminando no último pregão do mês $t - 1$ — mesma metodologia (e mesma janela) já usada para o beta de VALE3 (mercado) no `tcc I.pdf` (v1), agora aplicada à *cota do fundo* em vez do preço da ação.

- (b) **Todas** as cinco características (não só o beta do fundo) passam a ser medidas no **último dia do mês anterior** ($t - 1$), nunca no mês corrente — antes, *AUM*, cotistas e fluxo eram contemporâneos ao próprio mês t . Agora θ_t é 100% predeterminado: tudo que ele usa já era conhecido antes do mês t começar.

Adendo sobre a amostra: exigir as cinco características simultaneamente reduz a cobertura de 72 para **59 meses** (fev/2017 a dez/2021) — o beta do fundo exige ≥ 252 pregões de histórico de cota (quase um ano), então nenhum fundo tem essa variável disponível nos primeiros meses da amostra (jan/2016 a jan/2017 ficam sem fundos suficientes). Essa perda foi aceita conscientemente, não é um erro: a partir daqui, todo número deste documento vem dos 8.335 fundo-meses com as cinco características completas (120 a 190 fundos por mês, média 141).

2.1 O resultado: antes e depois do beta do fundo

Para deixar claro o efeito de adicionar o beta do fundo, a tabela abaixo compara — na **mesma amostra** de 59 meses — a regressão **logística** (equação (2), a que de fato alimenta o erro e e todo o resto do documento a partir daqui) com as quatro características clássicas contra a mesma regressão com o beta do fundo incluído. Os coeficientes estão na escala do preditor linear $x'\theta$ (log-odds), não em pontos percentuais.

Tabela 1: Θ logístico: antes e depois do beta do fundo (mesma amostra, 59 meses, teste ingênuo de significância $t = \hat{\theta}/(\text{dp}(\theta)/\sqrt{59})$).

Variável	Média (sem β^{fundo})	Sig.	Média (com β^{fundo})	Sig.
α	−3,1262	***	−3,8110	***
θ^{aum} (tamanho)	−0,2749	***	−0,0594	***
θ^{cot} (cotistas)	0,4429	***	0,0493	***
θ^{fic} (fundo de cotas)	−0,6669	***	−0,2149	***
θ^{flow} (captação/resgate)	0,4402	n.s.	0,1396	n.s.
θ^{bf} (beta do fundo)	—	—	1,0110	***
Pseudo- R^2 (McFadden) médio	0,164		0,614	

* $p < 5\%$, ** $p < 1\%$, *** $p < 0,1\%$. Fonte: elaboração própria (`scripts/13_etapa1_unificada.R`, `14_etapa1_antes_depois.R`). **Nota de correção:** uma versão anterior deste documento reportava t errado nesta tabela (usava $\sqrt{6}$, o número de *variáveis*, em vez de $\sqrt{59}$, o número de *meses*, no denominador do teste) — os t corretos são $\approx 3,1\times$ maiores; tamanho e cotistas continuam *** significativos com o beta do fundo, não n.s./* como antes reportado.

Achado: O mesmo padrão que já tinha aparecido como checagem à parte na versão anterior (Tabela 11 do `tcc I.pdf`) agora é a especificação principal: com o beta do fundo na conta, tamanho e cotistas ficam **bem mais fracos** em magnitude de t (tamanho: $t = -15,1 \rightarrow -6,0$; cotistas: $t = 31,5 \rightarrow 4,9$) — mas **continuam estatisticamente significativos a 0,1%**, não perdem a significância. O pseudo- R^2 quase quadruplica ($0,164 \rightarrow 0,614$). Leitura: parte do que tamanho e

cotistas explicavam era, na verdade, um proxy indireto para o quão “equity-like” é o fundo — o beta do fundo mede isso diretamente e absorve boa parte (não toda) dessa força explicativa.

Tornando o logit interpretável: efeito marginal médio

Um coeficiente logístico não é “pontos percentuais” — está na escala do preditor linear $x'\theta$ (log-odds), não na escala do peso em si. Para interpretar em pontos percentuais sem abandonar o logit, uso o **efeito marginal médio** (*average partial effect*, APE): para uma característica contínua k , $APE_k = \theta_k \cdot \overline{g'(x'\theta)}$, a média (em toda a amostra) da inclinação de $g(\cdot)$ vezes o coeficiente — quanto o peso previsto se move, em média, para uma variação de 1 desvio-padrão naquela característica. Para o FIC (0/1, discreta), uso a diferença média de $g(\cdot)$ forçando FIC= 1 contra FIC= 0 em cada fundo, mantendo as demais características observadas — mais correto que a derivada para uma variável que só assume dois valores.

Tabela 2: Efeito marginal médio (APE) do logit, em pontos percentuais de peso — mesma comparação sem/com beta do fundo.

Característica	APE (sem β^{fundo})	Sig.	APE (com β^{fundo})	Sig.
Tamanho	−0,00734	***	−0,00154	***
Cotistas	0,01271	***	0,00111	***
Fundo de cotas	−0,02222	***	−0,00580	***
Captação/resgate	0,01068	n.s.	0,00449	n.s.
Beta do fundo	—	—	0,02942	***

Fonte: elaboração própria (`scripts/13_etapa1_unificada.R`, `14_etapa1_antes_depois.R`).

Achado: O APE bate de perto com o que a versão linear já dava (tamanho $-0,0074 \rightarrow -0,0016$ linear vs. $-0,00734 \rightarrow -0,00154$ via APE; cotistas $0,0130 \rightarrow 0,0018$ linear vs. $0,01271 \rightarrow 0,00111$ via APE) — não é coincidência: quando o modelo se ajusta bem, a inclinação média do logit converge para perto do coeficiente linear equivalente. A vantagem do APE é que ele vem do **próprio** modelo logístico (respeitando os limites de $[0, 1]$), não de uma regressão linear separada rodada só para efeito de leitura.

2.2 O erro e

$e_{i,t} = \text{peso}_{i,t} - g(x'_{i,t}\theta_t)$, o erro de ajuste da regressão logística (dentro da amostra).

Tabela 3: Estatísticas do erro e (8.335 observações).

Estatística	Valor
Média	0,000000
Desvio-padrão	0,0227
Mediana	−0,0008
Mínimo / Máximo	−0,113 / 0,178
% de observações com $e > 0$	45,1%
Assimetria	0,39
Curtose	7,67 (normal = 3)
Previsões fora de $[0, 1]$	0 de 8.335

A média é zero em todo mês — mecânico (condição de primeira ordem da máxima verossimilhança com intercepto), não evidência de bom ajuste. O desvio-padrão caiu de 0,0305 (versão sem beta do fundo) para 0,0227 — o modelo ajusta melhor, coerente com o salto no pseudo- R^2 .




Figura 1: Os seis componentes de θ_t logístico (com beta do fundo) ao longo dos 59 meses, e o pseudo- R^2 de McFadden de cada regressão mensal. θ^{bf} é sempre positivo, coerente com sua significância forte e estável.




Figura 2: Histograma do erro e (8.335 observações). A linha tracejada marca zero.




Figura 3: Evolução mês a mês do erro e : nuvem cinza = erro individual de cada fundo-mês; linha azul = média mensal (mecanicamente zero); linha vermelha tracejada = desvio-padrão mensal. Eixo y restrito a $[-0,03, 0,06]$ para facilitar a leitura das duas linhas — 843 dos 8.335 pontos individuais (10%) ficam fora e não aparecem.

3 Etapa 2: o ajuste parcial

A pergunta: O peso de um fundo se move em direção ao que as características sugerem, ou fica parado onde está?

O alvo de um fundo, num mês, é $w_{i,t}^* = g(x'_{i,t}\theta_t)$ — a mesma previsão da Etapa 1. A hipótese de ajuste parcial: o fundo fecha uma fração λ da distância ao alvo a cada mês.

A equação estimada:

$$w_{i,t+1} - w_{i,t} = \lambda d_{i,t} + u_{i,t+1}, \quad d_{i,t} \equiv w_{i,t}^* - w_{i,t} \quad (3)$$

Estimado por MQO direto, sem intercepto, pooled em todos os fundo-meses — um único método, sem instrumento, sem efeito-fixo, sem painel dinâmico.

3.1 O resultado

$$\hat{\lambda} = 0,1534 \quad (\text{erro-padrão} = 0,0075, \quad t = 20,6, \quad R^2 = 0,050, \quad n = 7.987)$$

λ subiu de 0,098 (versão anterior) para 0,153 — esperado, já que o alvo w^* agora é mais preciso (pseudo- R^2 maior na Etapa 1), o que atenua menos o coeficiente pelo erro de medida clássico (Problema 1 do modelo de ajuste parcial). Em média, um fundo fecha 15,3% da distância ao alvo por mês.

3.2 O erro u

Tabela 4: Estatísticas do erro u (7.987 observações, pares de meses consecutivos).

Estatística	Valor
Média	0,0002
Desvio-padrão	0,0151
Mediana	-0,0004
Mínimo / Máximo	-0,160 / 0,185
% de observações com $u > 0$	44,3%
Assimetria	0,59
Curtose	19,4 (normal = 3)

Praticamente idêntico ao da versão anterior (dp 0,0151 nas duas) — a mudança na Etapa 1 melhorou o ajuste de e , mas o comportamento do erro do ajuste parcial em si não muda muito.




Figura 4: Histograma do erro u (7.987 observações).




Figura 5: Evolução mês a mês do erro u . Eixo y restrito a $[-0,03, 0,04]$; 369 dos 7.987 pontos individuais (4,6%) ficam fora e não aparecem.

4 Etapa 3: um esquema in/out-of-sample

A pergunta: O λ estimado serve pra prever de verdade, em dados que o modelo nunca viu?

Um único corte no tempo, dentro do período coberto pela Etapa 1 (fev/2017 a dez/2021):

- **Treino:** 2017-02 a 2019-12 (35 meses, 4.352 observações).
- **Teste:** 2020-01 a 2021-11 (23 meses, 3.635 observações).

A equação estimada: $\hat{\lambda}$ é estimado pela equação (3) só com dados de treino, depois aplicado fixo aos meses de teste:

$$\hat{w}_{i,t+1} = w_{i,t} + \hat{\lambda}_{\text{treino}} d_{i,t} \quad (\text{ajuste parcial}) \quad \text{vs.} \quad \hat{w}_{i,t+1} = w_{i,t} \quad (\text{ingênua}) \quad (4)$$

θ_t continua sendo estimado mês a mês, sem vazamento de informação futura.

$$\hat{\lambda}_{\text{treino}} = 0,1951 \quad (35 \text{ meses de treino})$$

4.1 O resultado, fora da amostra

Tabela 5: RMSE e MAE dentro e fora da amostra, ajuste parcial vs. ingênua.

Amostra	Modelo	RMSE	MAE
Treino (2017–2019)	Ajuste parcial	0,01463	—
Treino (2017–2019)	Ingênua	0,01510	—
Teste (2020–2021)	Ajuste parcial	0,01560	0,00906
Teste (2020–2021)	Ingênua	0,01585	0,00847




Figura 6: RMSE dentro (treino) e fora (teste) da amostra, ajuste parcial vs. ingênua.

O ajuste parcial vence em RMSE nas duas amostras (razão teste = 0,984) — mesmo padrão da versão anterior. Em MAE, a ingênua continua vencendo nos casos típicos (0,00847 contra 0,00906):

o ajuste parcial evita alguns erros grandes, mas erra um pouco mais em geral. Mês a mês, vence em 14 dos 23 meses de teste (61%).




Figura 7: RMSE mês a mês no período completo (2017–2021). A linha vermelha tracejada marca o início do teste (2020-01). As duas linhas seguem coladas dos dois lados do corte — a vantagem do ajuste parcial é pequena e consistente, não concentrada num único mês.

4.2 RMSE flexível: o mesmo teste, em vários horizontes

A pergunta: A vantagem do ajuste parcial sobre a ingênua (Tabela 5) é específica de prever 1 mês à frente, ou se mantém prevendo 2, 3, 6, 12 meses à frente?

Mesmo esquema treino/teste da Tabela 5 (treino < 2020-01, teste ≥ 2020-01), repetido para cada horizonte $h \in \{1, 2, 3, 6, 12\}$ meses: $dw_h = w_{i,t+h} - w_{i,t}$, $\hat{\lambda}_h$ estimado por MQO só no treino, alvo $w_{i,t}^*$ sempre fixado em t (não temos características futuras para recalculá-lo). Modelo ingênuo continua prevendo zero mudança.

Tabela 6: RMSE fora da amostra (2020–2021), ajuste parcial vs. ingênua, por horizonte.

h (meses)	$\hat{\lambda}_h$	Meses teste	RMSE ajuste	RMSE ingênua	Margem	Vence
1	0,1951	23	0,01560	0,01585	1,5%	61%
2	0,2502	22	0,01904	0,01957	2,7%	59%
3	0,2604	21	0,02087	0,02175	4,1%	57%
6	0,3191	18	0,02472	0,02577	4,1%	78%
12	0,4059	12	0,02943	0,02960	0,6%	67%

“Margem” = redução percentual de RMSE do ajuste parcial sobre a ingênua; “Vence” = % dos meses de teste em que o ajuste parcial tem RMSE menor naquele mês. Fonte: elaboração própria (`scripts/36_rmse_multihorizonte.R`).

Achado: O ajuste parcial vence a ingênua em RMSE em **todos** os 5 horizontes testados — a vantagem não é um artefato de olhar só 1 mês à frente. Mas a margem não é estável: cresce de 1,5% ($h = 1$) para um pico de 4,1% ($h = 3$ e $h = 6$) e praticamente desaparece em $h = 12$ (0,6%, com apenas 12 meses de teste disponíveis — amostra pequena, ler com cautela). $\hat{\lambda}_h$ cresce com




Figura 8: RMSE fora da amostra, ajuste parcial vs. ingênua, por horizonte de previsão.

o horizonte ($0,195 \rightarrow 0,406$), mas bem mais devagar do que uma composição geométrica simples do λ_1 previria (12 aplicações sucessivas de $\lambda_1 = 0,195$ fechariam $\approx 93\%$ do hiato, não os $\approx 41\%$ observados) — sinal de que o ajuste parcial não é um processo de decaimento a taxa constante: o alvo w^* também se move no caminho, e um λ estimado separadamente para cada horizonte capta isso melhor do que projetar λ_1 para frente.

5 Extensão: mais gestoras

A pergunta: O padrão encontrado (tamanho, cotistas, fundo de cotas, beta do fundo explicam o peso) é uma particularidade dos fundos do Itaú, ou aparece em qualquer gestora? E gestoras diferentes carregam mais ou menos VALE3 do que outras, tudo o mais igual?

Até aqui, a amostra era só os fundos do grupo Itaú. Esta extensão amplia para **todos os fundos do universo CVM** que já tiveram VALE3 em algum momento (2016–2021) — 2.820 fundos, 41 grupos de gestora (agrupados por marca controladora; ex.: “BTG Pactual” junta 4 rótulos diferentes que a CVM usa para a mesma casa). A equação (2) ganha um efeito fixo de gestora — 40 variáveis de 0/1 (uma por grupo, exceto o Itaú, que fica como referência, para não haver colinearidade perfeita com o intercepto):

$$\text{peso}_{i,t} = g(x'_{i,t}\theta_t + \sum_{g \neq \text{Itaú}} \gamma_{g,t} D_{g,i}) + \text{erro}_{i,t}$$

Adendo de processo: ao rodar essa regressão pela primeira vez, todas as cinco características saíram não significativas — um resultado que parecia dizer “a identidade da gestora explica tudo, as características não importam mais”. Investigando, a causa não era o efeito fixo de gestora: era **um único fundo-mês com dado corrompido** (peso de VALE3 registrado como 1.398,5 — impossível, peso é uma fração de 0 a 1) que, sozinho, distorcia a regressão de um mês inteiro (set/2018). Removido esse ponto (junto com outro caso igual, peso = 1.087,8, e 13 fundo-meses de beta do fundo com denominador degenerado por cota irregular), o resultado abaixo é o que

sobrevive.

Tabela 7: Θ logístico, amostra de todas as gestoras (59 meses, 71.569 obs.): sem e com efeito fixo de gestora.

Variável	Média (sem FE gestora)	Sig.	Média (com FE gestora)	Sig.
α	-3,7989	***	-3,9272	***
θ^{aum} (tamanho)	-0,0120	n.s.	-0,0141	*
θ^{cot} (cotistas)	0,0462	***	0,0331	***
θ^{fic} (fundo de cotas)	-0,1641	***	-0,1559	***
θ^{flow} (captação/resgate)	-0,1583	***	-0,1254	***
θ^{bf} (beta do fundo)	0,9052	***	0,8833	***
Pseudo- R^2 (McFadden) médio	0,604		0,696	

Tabela 8: Efeito marginal médio (APE) do logit com todas as gestoras, em pontos percentuais.

Característica	APE (sem FE gestora)	Sig.	APE (com FE gestora)	Sig.
Tamanho	-0,00085	***	-0,00080	***
Cotistas	0,00123	***	0,00079	***
Fundo de cotas	-0,00455	***	-0,00424	***
Captação/resgate	-0,00377	***	-0,00251	**
Beta do fundo	0,02691	***	0,02635	***

Fonte: elaboração própria (`scripts/20_etapa1_com_gestora.R`, `23_etapa1_gestora_antes_depois.R`).

Achado: Uma diferença real em relação à versão anterior (linear): no logit, **tamanho fica bem mais fraco** — n.s. sem FE, só marginal (*) com FE, contra ***/** que a escala linear mostrava. É o coeficiente bruto (log-odds) que perde força; o APE de tamanho continua *** significativo nas duas colunas (-0,00085 e -0,00080), só que pequeno em magnitude — as duas leituras não se contradizem, só usam testes diferentes (a variação mês a mês do coeficiente bruto é maior, em termos relativos, do que a da sua tradução em pontos percentuais). Cotistas, FIC, fluxo e beta do fundo continuam robustamente significativos nas duas especificações. Pseudo- R^2 sobe de 0,604 para 0,696 com o efeito fixo de gestora: a identidade da gestora tem poder explicativo próprio, mas não “rouba” o efeito das características — o padrão da Etapa 1 generaliza para além do Itaú. Diferente da amostra só-Itaú (Tabela 1), aqui a captação/resgate é claramente significativa (*** sem FE, ** com FE) — com 71.569 observações contra 8.335, há poder estatístico para detectar um efeito de fluxo pequeno que na amostra menor não era distinguível de ruído.

5.1 Quanto cada gestora carrega, relativo ao Itaú

Cada γ_g (log-odds) é o quanto o preditor linear de um fundo da gestora g se desloca em relação a um fundo do Itaú **com as mesmas** cinco características. Como log-odds não é diretamente interpretável, a tabela também traz o **APE discreto** de cada gestora: a diferença média de $g(\cdot)$ forçando aquele fundo a ser da gestora g contra forçá-lo a ser do Itaú, para todos os fundos da amostra (mesma lógica do APE do FIC) — em pontos percentuais de peso, positivo = carrega mais VALE3 que o Itaú equivalente, negativo = carrega menos.

Adendo de processo: em 5 das 40 gestoras, o sinal do coeficiente médio (log-odds) e do APE médio **discordam**. Não é erro: dentro de cada mês, os dois sempre têm o mesmo sinal matematicamente (é uma propriedade de $g(\cdot)$ ser monótona) — a discordância aparece só na *média simples ao longo dos meses*, quando o coeficiente em log-odds tem alguns meses de magnitude

extrema (comum quando a gestora tem poucos fundos naquele mês) que dominam a média bruta mas ficam “espremidos” pela função logística ao virar APE. O caso mais claro é a Kinea: negativa e com magnitude enorme em 2017–2018 (chegando a $-12,6$ em jun/2018), mas consistentemente positiva e modesta de 2019 em diante — a média do coeficiente fica negativa (dominada pelos extremos de 2017–2018), a média do APE fica positiva (o período mais longo e mais estável de 2019–2021 pesa mais depois de passar pela função logística). Os outros 4 casos (JGP, ARX, Vinci Partners, Safra) têm APE tão perto de zero que o sinal é irrelevante na prática. Por isso a tabela é ordenada pelo **APE**, a medida mais robusta a esses extremos.

Tabela 9: Coeficiente (log-odds) e APE (pontos percentuais) de cada gestora vs. Itaú (referência), ordenado pelo APE do maior para o menor.

Gestora	Meses	Coef.	Sig.	APE	Sig.
Legacy Capital	1	+2,3422	—	+0,16960	—
Núcleo Capital	4	+1,1618	***	+0,04666	***
Occam Brasil	59	+0,6456	***	+0,02703	***
Truxt Investimentos	42	+0,3892	***	+0,02071	***
Plural	59	+0,4350	***	+0,02050	***
AZ Quest	56	+0,2826	***	+0,01437	***
Absolute Investimentos	28	+0,1246	n.s.	+0,01413	**
Sharp Capital	59	+0,2679	***	+0,01315	***
Real Investor	47	+0,2455	**	+0,01275	***
SPX Capital	59	+0,1818	*	+0,01230	***
Western Asset	59	+0,3688	***	+0,01156	***
Caixa	59	+0,3634	***	+0,01113	***
Dahlia Capital	30	+0,1551	n.s.	+0,01070	**
Claritas Investimentos	59	+0,2810	***	+0,01058	***
Opportunity	59	+0,1438	n.s.	+0,01040	***
BB Asset Management	59	+0,3277	***	+0,00909	***
Credit Suisse	59	+0,1557	**	+0,00892	***
Bradesco Asset Management	59	+0,2945	***	+0,00886	***
Santander Brasil Asset Management	59	+0,2252	***	+0,00839	***
Kinea Investimentos	54	-0,6161	*	+0,00555	*
BNP Paribas	59	+0,1602	***	+0,00505	***
Verde Asset Management	59	+0,0688	n.s.	+0,00402	**
JGP	59	-0,0275	n.s.	+0,00153	n.s.
ARX Investimentos	57	-0,4219	*	+0,00029	n.s.
Vinci Partners	59	-0,2411	**	+0,00007	n.s.
Safra Asset Management	59	-0,0973	*	+0,00000	n.s.
BTG Pactual	59	-0,0914	*	-0,00078	n.s.
Julius Baer Family Office	59	-0,0491	n.s.	-0,00140	*
Ibiuna Investimentos	45	-0,5727	*	-0,00425	n.s.
Daycoval Asset Management	57	-1,0280	***	-0,00523	***
XP	59	-0,2856	***	-0,00562	***
TNA Gestão Patrimonial	59	-0,3059	***	-0,00751	***
Squadra Investimentos	45	-0,7695	*	-0,00830	***
Atmos Capital	33	-0,4879	***	-0,01048	***
Constellation Asset Management	25	-1,9235	***	-0,01224	*
Gávea Investimentos	34	-0,9917	***	-0,01274	***
Bogari Capital	11	-0,6110	***	-0,01484	***
Kapitalo Investimentos	52	-1,7679	***	-0,01790	***
Forpus Capital	33	-2,4478	***	-0,02059	***
Guepardo Investimentos	33	-4,6030	***	-0,02944	***

“Meses” = quantos dos 59 meses aquela gestora teve dados suficientes para entrar na regressão. t e significância: teste ingênuo sobre a média mensal (do coeficiente e do APE, respectivamente), mesmo estilo das demais tabelas. Fonte: elaboração própria (`scripts/20_etapa1_com_gestora.R`, `21_coeficientes_gestora.R`).

Leitura: gestoras grandes de varejo/plataforma (Caixa, Bradesco, BB, Santander, Western Asset) carregam *mais* VALE3 que o Itaú equivalente; gestoras boutique de gestão concentrada/high-conviction (Guepardo, Forpus, Kapitalo, Bogari, Gávea) carregam *bem menos*. Não é uma medida de causalidade — é o resíduo estrutural, depois de controlar pelas 5 características, e a leitura mais plausível é filosofia de gestão: carteiras concentradas tendem a evitar “o nome que todo mundo tem” a menos que apostem nele especificamente, diferente de uma plataforma de varejo mais próxima de uma composição ampla.




Figura 9: Evolução mensal do APE de gestora (vs. Itaú, em pontos percentuais), para as 5 gestoras com APE mais positivo e as 5 com APE mais negativo **de verdade** (mesmo ranking da Tabela 9, sem filtro de cobertura). Duas delas têm pouquíssimos meses — Legacy Capital (1 mês, aparece como ponto isolado) e Nucleo Capital (4 meses) — porque são, de fato, as gestoras com o APE médio mais alto; não há “evolução” de verdade pra mostrar nesses dois casos específicos, só o valor pontual. O pico da Kapitalo em jul/2018 não é erro de dado: naquele mês, um único fundo da casa concentrava 37% em VALE3 dentro de um grupo pequeno (13 fundos), o suficiente para puxar a estimativa mensal daquele grupo — ilustra como esses coeficientes podem ser voláteis mês a mês quando o grupo tem poucos fundos.

6 Extensão: todas as ações

A pergunta: O padrão encontrado para VALE3 é uma particularidade daquele papel, ou aparece em qualquer ação que esses mesmos fundos carreguem?

Mantendo o mesmo universo de 2.820 fundos e 41 gestoras da extensão anterior, esta seção

olha **todas as ações** que eles carregam, não só VALE3. Mesma limpeza de custódia usada no `tcc I.pdf` (v1): a CVM registra a mesma ação sob rótulos diferentes conforme o tipo de posição (direta, cedida/recebida em empréstimo, direito de subscrição); só a posição direta é mantida, classificada pelo sufixo numérico do *ticker* (convenção B3). Resultado: 523 ativos de posição direta, 10.603.928 linhas fundo-ativo-mês — VALE3 reproduziu exatamente as 96.349 linhas já conhecidas, confirmando a limpeza.

Adendo de processo: a tabela de características (AUM/cotistas/fluxo) da Etapa 2 só cobria os meses em que cada fundo tinha VALE3 — 16,8% dos fundo-mês do painel multiativo (fundos que naquele mês só tinham *outras* ações) ficavam sem essas características por um motivo evitável, não por falta real de dado. Reconstruída usando o conjunto correto de fundo-mês, a cobertura subiu para 97,6%. A amostra final tem 8.268.920 linhas, 2.347 fundos, 501 ativos.

Limitação conhecida: diferente da Etapa 1/Seção 5 (onde o merge do beta do fundo desloca explicitamente para o mês $t - 1$), o painel multiativo desta seção em diante junta o beta do fundo **contemporâneo** ao mês t , não defasado — uma inconsistência com o desenho “tudo pre-determinado, sem look-ahead” descrito na Seção 2. É também por isso que este painel cobre 60 meses (jan/2017–dez/2021) contra os 59 da Etapa 1/Seção 5 (fev/2017 em diante): com o mês inicial contemporâneo, um mês a mais de beta fica disponível. Testado o impacto (regressão pooled da Seção 6.2 refeita com o beta corretamente defasado): coeficiente 0,867 (era 0,899), $t = 30,2$ (era 28,6), APE 0,00375 (era 0,00462) — mesma ordem de grandeza, mesmo sinal, significância igual ou mais forte. Como o beta do fundo varia pouco de um mês para o outro (janela móvel de 252 pregões), a defasagem de 1 mês altera pouco seu valor; nenhuma conclusão qualitativa das Seções 6.1–6.4 muda. Corrigido o merge e reprocessada a seção por completo é o próximo passo natural, mas não feito nesta rodada.

6.1 Regressão por ativo e por mês: o padrão de VALE3 generaliza?

A equação estimada:

$$\text{peso}_{i,n,t} = g(x'_{i,n,t}\theta_{n,t}) + \text{erro}$$

$$x'\theta = \alpha_{n,t} + \theta_{n,t}^{aum} z(\ln AUM_i) + \theta_{n,t}^{cot} z(\ln cot_i) + \theta_{n,t}^{fic} FIC_i + \theta_{n,t}^{flow} \left(\frac{\text{fluxo}}{AUM} \right)_i + \theta_{n,t}^{bf} z(\beta_i^{fundo})$$

uma regressão logística por **célula (ativo n , mês t)** com ≥ 15 fundos holders — mesma equação da Etapa 1 (**sem** o efeito fixo de gestora da Seção 5), agora estimada ativo a ativo. Sem gestora porque a pergunta aqui é outra: a Seção 5 pergunta “controlando por gestora, o padrão se sustenta?”; esta seção pergunta “esse mesmo padrão aparece em qualquer ação?” — para isso, já varia a regressão inteira por ativo e mês, uma partição bem mais fina do que adicionar gestora. Na prática, também não daria: com 15–20 fundos por célula, 40 dummies de gestora quebrariam a conta na maioria delas (mais parâmetros que observações). $z(\cdot)$ usa a distribuição de (fundo,mês) **únicos**, não repetida por ativo (senão um fundo com muitas posições pesaria mais na padronização). Resultado: 13.938 células estimadas (19 não convergiram, excluídas), 430 ativos, 236 com histórico suficiente (≥ 24 meses) para comparar com VALE3. Pseudo- R^2 médio de 0,441.

Adendo de processo: em 12 das 13.957 células (0,09%), o peso de todos os fundos daquele ativo-mês era essencialmente zero (posição residual/legado, ex.: Cia Hering set/2021, 17 fundos, peso = 0 para todos) — o denominador do pseudo- R^2 de McFadden colapsa nesses casos e o valor explode para $-\infty$, não por erro de ajuste, mas por degenerescência numérica de uma variável-resposta sem variância. Corrigido com um piso em -1 só nessas células (não afeta coeficiente nem

APE, só a estatística de ajuste).

A generalização é medida em dois planos, como na Seção 5: pelo **sinal do coeficiente** (log-odds) e pelo **sinal do APE** (pontos percentuais, mais robusto a extremos).

Tabela 10: Generalização do padrão de VALE3 entre os 236 ativos com histórico suficiente.

Característica	% mesmo sinal (coef.)	% mesmo sinal (APE)	Percentil de VALE3 (APE)
Tamanho	55,9%	50,8% (acaso)	5,9
Cotistas	78,0%	73,3%	95,3
Fundo de cotas	55,9%	50,8% (acaso)	5,1
Captação/resgate	30,9% (pior que o acaso)	33,5% (pior que o acaso)	5,5
Beta do fundo	97,0%	96,2%	99,6

Fonte: elaboração própria (`scripts/25b` a 30).

Achado: Pelo APE (a medida mais confiável), tamanho e fundo de cotas generalizam **no nível do acaso** (50,8%, o mesmo que uma moeda) — mais fraco do que o sinal do coeficiente bruto já sugeria (55,9%), e bem mais fraco do que a v1 encontrou (tamanho/cotistas/FIC generalizando em 88–98% dos ativos). Captação/resgate generaliza **pior que o acaso** nos dois planos. O beta do fundo é, disparado, o padrão mais universal: 96–97% dos ativos têm o mesmo sinal de VALE3, nas duas medidas. VALE3 continua extremo em quase toda dimensão do APE (percentis abaixo de 6 ou acima de 95), inclusive no beta do fundo, onde fica em 2º lugar entre os 236 ativos.




Figura 10: Distribuição do APE médio de cada característica entre os 236 ativos com histórico suficiente (linha vermelha: VALE3; linha tracejada: mediana entre ativos).

Um panorama mais completo: além da comparação com VALE3

A Tabela 10 sempre ancora a comparação em VALE3 — de propósito, já que a pergunta desta seção é se o padrão de VALE3 generaliza, não um estudo independente de demanda por todas as 236 ações. Mas os dados já dão pra um panorama mais amplo: a distribuição completa do APE entre os ativos, e quem são os outros papéis nos extremos.

Tabela 11: Distribuição do APE entre os 236 ativos (quartis), com VALE3 para referência.

Característica	Q1	Mediana	Q3	VALE3
Tamanho	−0,00026	−0,00000	0,00027	−0,00079
Cotistas	−0,00003	0,00015	0,00045	0,00122
Fundo de cotas	−0,00061	−0,00002	0,00057	−0,00457
Captação/resgate	−0,00010	0,00056	0,00169	−0,00376
Beta do fundo	0,00100	0,00242	0,00429	0,02670

Fonte: elaboração própria (`scripts/25b` a 30).

Tabela 12: Os 5 ativos mais e menos impulsionados pelo beta do fundo (APE), entre os 236 com histórico suficiente.

Mais impulsionados		
Ativo	Meses	APE
JSL ON NM - JSLG3	58	0,03204
VALE ON N1 - VALE3	60	0,02670
Petrobras PN - PETR4	60	0,02368
Itaú Unibanco PN N1 - ITUB4	60	0,02302
Bradesco PN N1 - BBDC4	60	0,02293
Menos impulsionados (ou negativo)		
Ativo	Meses	APE
Alpargatas ON N1 - ALPA3	55	−0,00037
Magnesita SA ON NM - MAGG3	25	−0,00076
Terra Santa ON NM - TESA3	55	−0,00112
Kroton UNT N2 - KROT11	33	−0,00266
Klabin S/A PN N2 - KLBN4	39	−0,08910

Fonte: elaboração própria (`scripts/25b` a 30).

Adendo de processo: o APE da Klabin PN parece um exagero (quase $30\times$ maior em magnitude que o segundo colocado) — e é. Investigando célula a célula: a **mediana** mensal do APE da Klabin é praticamente zero ($\approx -0,00001$), mas alguns meses (sobretudo 2020–2021) têm pseudo- R^2 perto de 1 (ex. 0,998 em abr/2021) — sinal de célula quase perfeitamente separada, onde o coeficiente (e o APE derivado dele) explode sem representar um efeito econômico real. A **média** simples entre os meses fica dominada por esses poucos casos extremos, o mesmo padrão já visto com a Kinea na Seção 5. Mantido na tabela por transparência, mas a leitura correta da Klabin é “sem padrão claro”, não “efeito negativo forte”.

Achado: VALE3 é o 2º mais impulsionado pelo beta do fundo entre 236 ativos — atrás só da JSL Logística, uma diferença pequena (0,032 vs. 0,027). Os outros nomes no topo (PETR4, ITUB4, BBDC4) são, como VALE3, *blue chips* muito líquidas do Ibovespa — reforça a leitura de que o beta do fundo captura o quão “equity-like”/ligado ao índice é o fundo, e isso importa mais pra decidir quanto carregar dos papéis mais representativos do mercado.

6.2 Checagem complementar: uma única regressão com efeito-fixe de ativo e de mês

Como checagem independente, uma regressão logística *pooled* com todas as 8.268.920 observações, efeito-fixe de ativo *e* de mês, erro-padrão agrupado por fundo — o coeficiente “dentro” de cada ativo-mês, líquido de qualquer nível particular daquele ativo ou choque daquele mês. O truque de demeaning (Frisch–Waugh–Lovell) usado na versão linear **não** funciona em modelos não-lineares; esta versão usa o pacote **fixest** (**feglm**), feito especificamente para efeito-fixe em GLM de forma rápida mesmo com muitos níveis — aqui, 501 ativos + 60 meses.

Adendo de processo: 13 efeitos-fixos de ativo (49 observações) foram removidos automaticamente por terem só um desfecho (*singleton*) — rotina do próprio **fixest**, não afeta o resultado. Diferente da versão linear (onde o fundo de cotas saía **exatamente** da equação, absorvido por completo pelos efeitos-fixos), aqui o FIC **sobrevive** — o logit não sofre da mesma colinearidade exata que a demeaning linear sofria, porque a estimação não depende de inverter a mesma matriz.

Tabela 13: Regressão logística pooled com efeito-fixe de ativo e de mês (8.268.871 obs., 488 ativos, 60 meses, 2.347 fundos).

Variável	Coefficiente	<i>t</i> (cluster por fundo)	Sig.	APE
Tamanho	0,0490	2,17	*	0,000252
Cotistas	0,0094	0,50	n.s.	0,000048
Fundo de cotas	0,0497	1,25	n.s.	0,000255
Captação/resgate	−0,0010	−0,82	n.s.	−0,000005
Beta do fundo	0,8994	28,60	***	0,004619

Correlação ao quadrado = 0,314 (estatística reportada pelo **fixest**, não é o pseudo- R^2 de McFadden usado nas demais tabelas). Fonte: elaboração própria (`scripts/31_pooled_fe2way_multiativo.R`).

Achado: As duas abordagens — regressão por ativo-mês e pooled com efeito-fixe — convergem para a mesma conclusão: o beta do fundo é, disparado, a característica que mais robustamente explica o peso de **qualquer** ação carregada por esses fundos ($t = 28,6$, $APE \approx 18\times$ maior que o de qualquer outra característica). Tamanho fica só marginalmente significativo ($t = 2,17$); cotistas, FIC e fluxo não são distinguíveis de zero nesta especificação — mesmo padrão qualitativo da checagem por ativo-mês (Seção 6.1): o que na v1 parecia um efeito robusto de tamanho/cotistas/FIC, testado no universo amplo de gestoras e ações com o beta do fundo como controle, perde quase toda a força. Boa parte do que pareciam explicar era, plausivelmente, um proxy indireto para o quão “equity-like” o fundo é.

Um panorama mais completo: o efeito-fixe de cada ativo

A Tabela 13 resume só os 5 coeficientes pooled — comuns a todos os ativos. Mas o modelo com efeito-fixe de ativo estima, como subproduto, um nível **próprio para cada um dos 488 ativos** (o quanto aquele papel é sobre- ou sub-pesado, líquido das 5 características e do mês). Vale a pena olhar essa distribuição.

Adendo de processo: extrair o efeito-fixe bruto direto (**fixef(f)\$ativo**) reproduz o mesmo problema já visto na Tabela 12 (Klabin): os extremos ficam dominados por ativos com peso **mediano** praticamente zero — posições residuais presentes em muitos meses mas nunca efetivamente alocadas, cujo efeito-fixe é instável sem representar demanda real (ex.: papéis com peso mediano da ordem de 10^{-7} a 10^{-9} , mesmo com 60 meses de “cobertura”). O filtro de ≥ 24 meses (usado em

toda a Seção 6) não resolve isso — meses de presença não é o mesmo que peso relevante. A tabela abaixo usa por isso um filtro adicional: peso mediano > 0,1%, o que deixa 60 dos 488 ativos.

Tabela 14: Distribuição do efeito-fixo de ativo (log-odds, escala do modelo pooled) entre os 60 ativos com posição relevante (≥ 24 meses e peso mediano > 0,1%).

Q1	Mediana	Q3	VALE3
-5,123	-4,784	-4,315	-3,407

Fonte: elaboração própria (`scripts/39_panorama_fe_ativo.R`).

Tabela 15: Os 5 ativos com efeito-fixo mais alto e mais baixo, entre os 60 com posição relevante.

Efeito-fixo mais alto (sobrepeso)			
Ativo	Efeito-fixo	Meses	Peso mediano
Döhler PN - DOHL4	-1,698	60	21,02%
Coelba ON - CEEB3	-1,957	60	5,63%
Celpe ON - CEPE3	-2,406	60	1,63%
Cosern ON - CSRN3	-2,837	60	1,82%
VALE ON N1 - VALE3	-3,407	60	1,57%
Efeito-fixo mais baixo (subpeso)			
Ativo	Efeito-fixo	Meses	Peso mediano
Gerdau Met PN N1 - GOAU4	-5,488	60	0,12%
Eletrobras ON N1 - ELET3	-5,492	60	0,12%
Eletrobras PNB N1 - ELET6	-5,569	60	0,13%
WLM Ind Com PN - WLM4	-6,079	52	0,13%
D H B PN - DHBI4	-6,586	45	0,22%

Fonte: elaboração própria (`scripts/39_panorama_fe_ativo.R`).

Achado: VALE3 fica em 5º lugar entre 60 ativos com posição relevante — no quarto superior da distribuição, mas não isolada: Döhler, Coelba, Celpe e Cosern têm efeito-fixo ainda mais alto. Nenhum nome no topo ou na base é posição residual (todos com peso mediano acima de 0,1%, alguns como a Döhler acima de 20%) — ao contrário da tentativa sem filtro, aqui os extremos refletem sobre-/sub-peso genuíno, não ruído de posições nunca alocadas.

6.3 O erro por gestora, agora com todas as ações

A pergunta: A regressão da Seção 6 cobre agora os 501 ativos, não só VALE3. Como se comporta o erro dela quando agregado por gestora — olhando a carteira inteira de ações, não só uma posição?

A equação estimada:

$$\text{erro}_{i,n,t} = \text{peso}_{i,n,t} - g(x'_{i,n,t}\theta_{n,t})$$

o resíduo (escala da resposta) da mesma regressão logística por célula (ativo n , mês t) da Seção 6 — 8.251.936 observações, 430 ativos, 2.347 fundos, 41 gestoras.

Adendo de processo: diferente de uma especificação com efeito-fixo de gestora (equação da Seção 5, onde as equações normais do MQO garantem soma-zero do resíduo dentro de cada grupo com dummy própria), aqui **cada célula tem sua própria regressão, sem dummy de gestora**. A média do erro por gestora, portanto, **não** é zero por construção — é genuinamente informativa, junto com a dispersão. Um **viés** positivo aqui não é sobre um papel só: como a regressão roda célula

a célula (um ativo por vez) e depois o erro de cada célula é agregado por gestora, um viés positivo significa que, **olhando o book de ações inteiro daquela gestora**, os fundos dela carregam sistematicamente mais peso do que as 5 características previam — um padrão que se repete ação após ação, não um desvio pontual. Viés negativo é o oposto: carregam menos do que a fórmula prevê, de forma consistente. Significância da média testada pela série **mensal** por gestora (mesmo estilo do resto do documento: $t = \bar{e}/(\text{dp}(e)/\sqrt{\text{meses}})$), não pelas 8,25 milhões de observações brutas (que tornaria qualquer diferença minúscula “significativa” só pelo tamanho da amostra).

Tabela 16: Erro médio (testado pela série mensal) e dispersão, por gestora, no universo de todas as ações — ordenado do viés mais positivo ao mais negativo.

Gestora	Obs.	Meses	Média	Sig.	dp
Guepardo Investimentos	10798	60	+0,04493	***	0,06789
Núcleo Capital	12247	60	+0,03780	***	0,02874
Ibiuna Investimentos	11381	60	+0,01854	***	0,02387
Constellation Asset Management	17423	60	+0,01471	***	0,02475
Bogari Capital	21809	60	+0,01369	***	0,01779
Real Investor	8244	60	+0,01326	***	0,02169
Squadra Investimentos	20929	60	+0,01023	***	0,02823
Sharp Capital	37399	60	+0,00975	***	0,02503
Atmos Capital	52386	60	+0,00948	***	0,02036
Kinea Investimentos	10045	60	+0,00719	***	0,02156
Verde Asset Management	26440	60	+0,00662	***	0,02089
Forpus Capital	10275	60	+0,00556	***	0,01817
Legacy Capital	203	2	+0,00537	***	0,01769
Truxt Investimentos	54176	43	+0,00537	***	0,01582
AZ Quest	49444	60	+0,00499	***	0,01590
ARX Investimentos	21290	60	+0,00495	***	0,01740
Claritas Investimentos	24505	60	+0,00471	***	0,01405
JGP	109991	60	+0,00243	***	0,01165
Absolute Investimentos	20370	29	+0,00222	***	0,01190
Vinci Partners	139937	60	+0,00208	***	0,01676
Opportunity	54794	60	+0,00172	***	0,01728
Occam Brasil	75151	60	+0,00171	***	0,01075
Gávea Investimentos	13274	60	+0,00117	***	0,00434
Western Asset	77814	60	+0,00110	***	0,01450
Plural	17821	60	+0,00094	**	0,01099
Dahlia Capital	36938	31	+0,00075	***	0,00620
Credit Suisse	250452	60	+0,00069	***	0,00925
BTG Pactual	519772	60	+0,00068	***	0,01388
SPX Capital	126811	60	+0,00052	*	0,01068
Kapitalo Investimentos	94846	60	+0,00029	*	0,00945
Safra Asset Management	561779	60	+0,00022	***	0,00871
Caixa	70924	60	+0,00006	n.s.	0,01491
BB Asset Management	338730	60	−0,00007	n.s.	0,01485
Santander Brasil Asset Management	348279	60	−0,00036	***	0,00841
Julius Baer Family Office	273717	60	−0,00039	***	0,00736
TNA Gestão Patrimonial	262921	60	−0,00040	***	0,00507
BNP Paribas	247947	60	−0,00059	***	0,01089
XP	391636	60	−0,00065	***	0,01141
Bradesco Asset Management	930672	60	−0,00095	***	0,01095
Itaú	2882582	60	−0,00120	***	0,00649
Daycoval Asset Management	15784	60	−0,00211	***	0,00944

Fonte: elaboração própria (scripts/37_erro_multiativo.R, 38_erro_multiativo_gestora.R).

Achado: 36 das 41 gestoras têm viés estatisticamente significativo a 0,1% (mais 1 a 1%, 2 a 5%, e só 2 n.s.: Caixa, BB Asset Management) — mas a maioria das magnitudes é pequena; a




Figura 11: Distribuição do erro no universo multiativo, 8.251.936 observações.

significância generalizada reflete o tamanho da amostra (8,25 milhões de obs.), não necessariamente relevância econômica. A **Guepardo** tem o viés mais positivo (+0,045), seguida de perto pela Núcleo Capital (+0,038) — olhando a carteira de ações inteira, não só VALE3, as duas sobrepesam sistematicamente o que a fórmula prevê, e a Guepardo também tem, disparada, a maior dispersão (0,068, mais que o dobro da segunda colocada). O Itaú fica com viés pequeno e negativo (−0,0012) e dispersão baixa (0,0065, abaixo da mediana de 0,0145) — relativamente “previsível” nesse universo amplo.

Achado: Viés e dispersão andam juntos: correlação de 0,88 entre $|\text{viés}|$ e dp entre as 41 gestoras. Não é um resultado óbvio a priori — uma gestora poderia ter viés grande mas consistente (erro sempre igual, dp baixo) ou viés pequeno mas errático (dp alto, média perto de zero). Na prática, as duas coisas se confundem: quem foge mais sistematicamente do que a fórmula prevê (Guepardo, Núcleo Capital, Ibiuna) também é quem tem o erro mais instável mês a mês. Isso é o material que vai orientar o desenho do robô caça-replicas — decisão ainda em aberto, tratada à parte.

Um panorama mais completo: o mesmo erro, agora por ativo

A Tabela 16 agrega o erro por gestora — a carteira inteira de um gestor, ação após ação. A mesma base (`scripts/37_erro_multiativo.R`) também permite agregar por **ativo**: qual papel tem erro mais ou menos disperso, olhando todas as gestoras que o carregam?

Aqui a média **não** é informativa — ao contrário do corte por gestora. Toda observação de um ativo vem de células (ativo, mês) indexadas por esse mesmo ativo; como cada célula é uma regressão própria, a condição de primeira ordem do MLE força a soma dos resíduos daquela célula a zero (mesma lógica de soma-zero de um efeito-fixe, mas aqui aplicada por ativo em vez de por gestora) — e como todas as observações de um ativo somam através dessas mesmas células, a média do erro **por ativo** sai ≈ 0 por construção (checado: média de VALE3 = $-3,7 \times 10^{-12}$, essencialmente zero de máquina). É o espelho do que acontece na Seção 5 com o efeito-fixe de gestora — só que




Figura 12: Cada ponto é uma gestora: erro médio (eixo x) vs. dispersão do erro (eixo y). Rótulos legíveis só nos extremos — a Tabela 16 tem os valores exatos das 41.

lá é por gestora e aqui é por ativo. Só a **dispersão** sobra como informativa, o mesmo padrão do efeito-fixo de gestora (Seção 5): soma-zero do resíduo dentro de cada grupo por construção.

Adendo de processo: sem filtro, os ativos “menos dispersos” repetem o mesmo artefato já visto na Tabela 15 e na Tabela 12 (Klabin): dominados por posições nunca efetivamente alocadas (peso mediano da ordem de 10^{-6} a 10^{-11}), cujo erro é trivialmente ≈ 0 — não porque o modelo os explica bem, mas porque não há nada a explicar. Mesmo filtro das tabelas anteriores (≥ 24 meses e peso mediano $> 0,1\%$), restando 50 dos 430 ativos.

Tabela 17: Distribuição da dispersão do erro (dp) entre os 50 ativos com posição relevante, com VALE3 para referência.

Q1	Mediana	Q3	VALE3
0,00990	0,01274	0,01629	0,02816

Fonte: elaboração própria (`scripts/40_panorama_erro_ativo.R`).

Achado: VALE3 é o 2º ativo com erro mais disperso entre os 50 com posição relevante — atrás só da Petrobras, e à frente de Equatorial, Itaú Unibanco e Bradesco: as blue chips mais líquidas do Ibovespa são justamente as menos previsíveis por essa fórmula, não as mais. Faz sentido à luz do achado central da Seção 6.2 — é o beta do fundo que domina a explicação do peso, e blue chips concentram a variação de beta entre fundos “equity-like” e “conservadores”; papéis menos líquidos (Sul América, TIM, Eletrobras, Vivara) têm posição mais parecida entre os fundos que os carregam,

Tabela 18: Os 5 ativos com erro mais e menos disperso, entre os 50 com posição relevante.

Erro mais disperso (menos previsível)			
Ativo	Obs.	Meses	dp
Petrobras PN - PETR4	73550	60	0,03064
VALE ON N1 - VALE3	73273	60	0,02816
Equatorial ON NM - EQTL3	70599	60	0,02539
Itaú Unibanco PN N1 - ITUB4	71314	60	0,02309
Bradesco PN N1 - BBDC4	71707	60	0,02226
Erro menos disperso (mais previsível)			
Ativo	Obs.	Meses	dp
Sul América UNT N2 - SULA11	50759	60	0,00783
TIM Part S/A ON NM - TIMP3	41833	46	0,00758
Eletrobras ON N1 - ELET3	62259	60	0,00747
Eletrobras PNB N1 - ELET6	60600	60	0,00696
Vivara S.A. ON NM - VIVA3	22731	27	0,00587

Fonte: elaboração própria (`scripts/40_panorama_erro_ativo.R`).

sobrando menos espaço para o erro variar.

6.4 Fechando o panorama: gestora, ativo e mês juntos, nos coeficientes

A pergunta: Até aqui, o coeficiente por gestora (Seção 5) só foi estimado com VALE3; e o painel de todas as ações (Seção 6 em diante) nunca quebrou por gestora nos **coeficientes** — só no **erro** (Seção 6.3). Controlando por ativo e por mês, como cada gestora se compara ao Itaú olhando a carteira de ações **inteira** dela, não só uma posição?

A equação estimada:

$$\text{peso}_{i,n,g,t} = g(x'_{i,n,t}\theta + \alpha_n + \delta_t + \gamma_g)$$

uma única regressão logística com todas as 8.268.920 observações e **três** efeitos-fixos simultâneos — ativo (α_n), mês (δ_t) e **gestora** (γ_g) — em vez de só ativo e mês (Seção 6.2).

Adendo de processo: a primeira tentativa colocou gestora como **dummy** comum na equação (as 40 colunas, igual à Seção 5) em vez de efeito-fixo — e estourou a memória da máquina (16GB, sobrando poucos MB livres, processo precisou ser encerrado manualmente). O motivo: o **fixest** usa um algoritmo enxuto (projeções alternadas, custo linear no número de observações) só para variáveis marcadas como efeito-fixo; uma dummy comum de 40 níveis, combinada com erro-padrão clusterizado em 2.347 fundos e mais $488 + 60$ níveis de efeito-fixo de ativo/mês, monta uma matriz densa grande demais. Corrigido tratando gestora como **terceiro** efeito-fixo — roda em 74 segundos, memória estável.

Achado: Com efeito-fixo de gestora somado, tamanho e fundo de cotas deixam de ser sequer marginalmente significativos (eram $t = 2,17$ e $t = 1,25$ na Tabela 13, sem gestora) — parte do que pareciam captar era, na verdade, o **perfil típico** de cada gestora (gestoras maiores tendem a ter fundos maiores, por exemplo), absorvido agora pela dummy de gestora. Cotistas continua *** mas cai de magnitude. O beta do fundo **não se move** ($t = 29,0$ vs. $28,6$) — reforça que é o padrão mais robusto do documento, resistente a qualquer controle adicional.

Tabela 19: As 5 características, com efeito-fixo de ativo, mês e gestora juntos.

Variável	Coeficiente	t (cluster por fundo)	Sig.	APE
Tamanho	-0,0237	-1,13	n.s.	-0,000121
Cotistas	0,0773	4,72	***	0,000396
Fundo de cotas	-0,0499	-1,49	n.s.	-0,000256
Captação/resgate	0,0007	0,56	n.s.	0,000004
Beta do fundo	0,8486	29,04	***	0,004345

Correlação ao quadrado = 0,358. Fonte: elaboração própria (`scripts/41_pooled_fe3way_gestora_multiativo.R`).

Tabela 20: Efeito-fixo de gestora (log-odds), centrado no Itaú — painel completo de 430 ativos, não só VALE3.

Gestora	Efeito-fixo	vs. Itaú
Guepardo Investimentos	1,897	+2,185
Núcleo Capital	1,567	+1,855
Bogari Capital	1,189	+1,477
Real Investor	1,151	+1,439
Ibiuna Investimentos	1,046	+1,335
Legacy Capital	1,038	+1,327
Constellation Asset Management	0,936	+1,225
Sharp Capital	0,883	+1,171
Claritas Investimentos	0,821	+1,109
Squadra Investimentos	0,812	+1,101
Atmos Capital	0,807	+1,096
Forpus Capital	0,787	+1,076
Plural	0,734	+1,022
Gávea Investimentos	0,724	+1,012
Kinea Investimentos	0,719	+1,008
Truxt Investimentos	0,681	+0,969
AZ Quest	0,656	+0,945
Verde Asset Management	0,561	+0,849
Absolute Investimentos	0,559	+0,848
ARX Investimentos	0,553	+0,842
JGP	0,470	+0,759
Vinci Partners	0,462	+0,750
Occam Brasil	0,425	+0,714
Opportunity	0,405	+0,694
Credit Suisse	0,351	+0,639
SPX Capital	0,284	+0,572
Dahlia Capital	0,282	+0,571
BTG Pactual	0,278	+0,567
Western Asset	0,232	+0,521
Safra Asset Management	0,216	+0,505
Kapitalo Investimentos	0,158	+0,447
BB Asset Management	0,112	+0,400
Caixa	0,098	+0,387
Santander Brasil Asset Management	0,039	+0,328
Bradesco Asset Management	0,000	+0,289
BNP Paribas	-0,018	+0,271
Julius Baer Family Office	-0,033	+0,256
TNA Gestão Patrimonial	-0,098	+0,190
XP	-0,227	+0,062
Daycoval Asset Management	-0,288	+0,001
Itaú	-0,289	0,000

Fonte: elaboração própria (`scripts/41_pooled_fe3way_gestora_multiativo.R`).

Achado: A ordem quase se **inverte** em relação à Seção 5: lá (só VALE3), gestoras de va-

rejo/plataforma (Caixa, BB, Santander, Western Asset) carregavam **mais** VALE3 que o Itaú, e boutiques concentradas (Guepardo, Forpus, Constellation, Bogari, Atmos, Squadra) carregavam **menos**. Aqui, olhando a carteira de ações inteira (não só VALE3), são justamente as boutiques que têm o efeito-fixo mais alto — Guepardo, Núcleo Capital e Bogari no topo — e o Itaú fica **na última posição**, junto de Daycoval. Não é uma contradição: as duas coisas podem ser verdade ao mesmo tempo — gestoras de convicção concentrada tendem a montar posições **maiores** em geral (é o estilo delas), mas em VALE3 especificamente, um blue chip mega-cap do Ibovespa, preferem ficar **abaixo** do Itaú (evitam “o nome que todo mundo tem”). Essa leitura também bate com a Seção 6.3 (Tabela 16): a mesma Guepardo e a mesma Núcleo Capital têm o viés mais positivo do erro por gestora — duas metodologias bem diferentes (coeficiente estrutural vs. resíduo agregado) chegando à mesma ordenação, o que reforça que o padrão é real, não um artefato de uma escolha de modelo específica.

7 Resumo

1. **Etapa 1, equações (1)–(2):** θ_t mês a mês, cinco características (agora incluindo beta do fundo), todas predeterminadas ($t - 1$). Com o beta do fundo na conta, tamanho e cotistas ficam bem mais fracos em magnitude de t , mas o APE (efeito marginal médio, pontos percentuais) de ambos continua *** significativo; fundo de cotas e beta do fundo continuam com a força quase intacta. Pseudo- R^2 médio 0,614 (era 0,164). Custo: cobertura cai para 59 meses (fev/2017 em diante).
2. **Etapa 2, equação (3):** $\hat{\lambda} = 0,153$ (era 0,098) — um alvo mais preciso atenua menos o coeficiente. Erro u com comportamento parecido ao da versão anterior.
3. **Etapa 3:** λ treinado em 2017–2019 vence a ingênua fora da amostra (2020–2021) em RMSE, por margem pequena mas consistente (1,5%; vence em 61% dos meses de teste) — resultado qualitativamente igual ao da versão anterior. Flexibilizando para outros horizontes ($h = 2, 3, 6, 12$ meses), a vantagem se mantém nos 5 horizontes testados, com margem maior em $h = 3-6$ ($\approx 4\%$) e quase sumindo em $h = 12$ (amostra de teste pequena, só 12 meses).
4. **Extensão de gestoras (Seção 5):** o padrão da Etapa 1 generaliza para além do Itaú — 2.820 fundos, 41 grupos de gestora, o APE das cinco características sobrevive quase intacto ao entrar o efeito fixo de gestora (pseudo- R^2 0,604 $\rightarrow$ 0,696); tamanho fica bem mais fraco no coeficiente bruto (log-odds), mas o APE continua significativo. Gestoras de varejo/plataforma carregam mais VALE3 que o Itaú equivalente; boutiques de gestão concentrada carregam bem menos.
5. **Extensão de todas as ações (Seção 6):** mesmo universo de fundos/gestoras, agora testado em 501 ativos (13.938 células ativo-mês convergidas). O beta do fundo é a característica que mais generaliza (96–97% dos ativos com o mesmo sinal de VALE3, pelo coeficiente e pelo APE) e a única que sobrevive robusta numa regressão pooled com efeito-fixo de ativo e mês ($t = 28,6$); tamanho, cotistas e fluxo generalizam bem mais fraco do que a $v1$ havia encontrado (tamanho e FIC, pelo APE, generalizam no nível do acaso). Estendendo o erro dessa mesma regressão para todas as ações (Seção 6.3, 8.251.936 obs.), 36 das 41 gestoras têm viés significativo (mas em geral pequeno) e a Guepardo tem o viés mais positivo e, disparada, a maior dispersão (mais que o dobro da segunda colocada); viés e dispersão andam juntos

(correlação 0,88) — material que vai orientar o desenho do robô caça-replicas, decisão ainda em aberto. Ainda restrito a VALE3 no ajuste parcial/in-out-of-sample desta rodada.

6. **Panorama geral, gestora e ativo juntos (Seção 6.4):** uma única regressão com efeito-*fixo* de ativo, mês *e* gestora simultâneos — a primeira vez que o coeficiente por gestora é estimado no painel completo (430 ativos), não só VALE3. Tamanho e fundo de cotas deixam de ser significativos (o efeito-*fixo* de gestora absorve boa parte do que pareciam captar); beta do fundo não se move ($t = 29,0$). A ordem das gestoras quase se **inverte** em relação à Seção 5: boutiques de gestão concentrada (Guepardo, Núcleo Capital, Bogari), que carregavam *menos* VALE3 que o Itaú, têm o efeito-*fixo* mais alto olhando a carteira inteira — montam posições maiores em geral, mas evitam especificamente o blue chip mega-cap. Essa ordenação bate com o viés do erro por gestora (Seção 6.3), duas metodologias independentes chegando à mesma conclusão.

Nenhuma dessas conclusões depende de Newey–West, cluster, Kalman, variável instrumental ou teste de Diebold–Mariano — o preço da simplicidade é não corrigir os vieses conhecidos do MQO direto no ajuste parcial, que a versão anterior do projeto documentou e tentou corrigir. Fica registrado como decisão consciente, não como descuido.