

v2 OFICIAL

Peso de VALE3 nos fundos do Itaú — versão simples, direta e objetiva
Cross-section por MQO, logit, ajuste parcial e um esquema in/out-of-sample — sem Newey–West,
sem Kalman, sem Diebold–Mariano, sem múltiplos métodos de robustez

João Paulo Zangrandi (FGV–EESP)

Resumo

Este documento retoma o projeto a partir da ideia original das anotações do orientador: uma cross-section simples que estima um fator latente θ , uma etapa logística para manter a previsão dentro de $[0, 1]$, e um modelo de ajuste parcial para a dinâmica. Cada etapa usa **um único método** (MQO ou MQO logístico), sem testes ou correções de robustez em cascata. O objetivo é ter um pipeline curto, auditável do início ao fim, e um esquema simples de avaliação fora da amostra.

Sumário

1	Por que esta versão existe	3
2	Etapa 1: a cross-section por MQO	3
2.1	O resultado	3
3	Etapa 2: a ligação logística e o erro e	5
3.1	O resultado	5
3.2	O erro e	6
4	Etapa 3: o ajuste parcial	9
4.1	O resultado	9
4.2	O erro u	9
5	Etapa 4: um esquema in/out-of-sample	11
5.1	O resultado, fora da amostra	11
6	Resumo	13

1 Por que esta versão existe

As versões anteriores deste projeto acumularam camada sobre camada de robustez estatística (Newey–West, filtro de Kalman, variável instrumental com múltiplos esquemas de cluster, painel dinâmico de Arellano–Bond, teste de Diebold–Mariano) até o núcleo do modelo ficar difícil de enxergar por trás das correções. Esta versão volta ao desenho original discutido com o orientador: uma cross-section por mínimos quadrados que gera um fator latente θ , uma etapa logística (a única forma de robustez mantida, porque o peso é limitado a $[0, 1]$ e a reta não respeita esse limite), e um modelo de ajuste parcial estimado diretamente por MQO. Cada etapa produz um erro, e cada erro é examinado com estatísticas simples — média, desvio-padrão, assimetria, curtose, e um histograma — sem bateria de testes formais.

A base de dados (composição de carteiras da CVM, filtrada para os fundos do grupo Itaú, 2016–2021, 307 fundos, 72 meses, 11.413 observações de fundo-mês) é a mesma já construída e validada na versão anterior do projeto — essa parte nunca foi a fonte da complexidade, e não foi refeita.

2 Etapa 1: a cross-section por MQO

A pergunta: As características de um fundo (tamanho, número de cotistas, se é fundo de cotas, quanto captou ou resgatou) explicam o peso de VALE3 que ele carrega?

Para cada um dos 72 meses, roda-se uma única regressão MQO, usando só os fundos daquele mês:

A equação estimada:

$$\text{peso}_{i,t} = \alpha_t + b_t^{aum} z(\ln AUM_i) + b_t^{cot} z(\ln \text{cotistas}_i) + b_t^{fic} FIC_i + b_t^{flow} \left(\frac{\text{captação} - \text{resgate}}{AUM} \right)_i + \text{erro}_{i,t} \quad (1)$$

em que $z(\cdot)$ padroniza a variável (subtrai a média, divide pelo desvio-padrão), para que tamanho e cotistas fiquem na mesma régua. FIC é uma variável de 0 ou 1 (é fundo de cotas ou não); o fluxo entra na escala original (fração do patrimônio).

O vetor $\theta_t = (\alpha_t, b_t^{aum}, b_t^{cot}, b_t^{fic}, b_t^{flow})$ é o resultado de *um único mês*. Θ é a coleção dos 72 vetores θ_t , um por mês — é o objeto central de todo o resto do documento.

2.1 O resultado

Tabela 1: Θ : média, desvio-padrão, mínimo, máximo e teste ingênuo de significância da média dos 72 θ_t mensais.

Variável	Média	Desvio-padrão	Mínimo	Máximo	t	Sig.
α (intercepto)	0,0396	0,0171	0,0080	0,0663	19,6	***
b^{aum} (tamanho)	−0,0067	0,0031	−0,0162	−0,0014	−18,3	***
b^{cot} (cotistas)	0,0108	0,0047	0,0028	0,0233	19,6	***
b^{fic} (fundo de cotas)	−0,0170	0,0075	−0,0380	−0,0031	−19,2	***
b^{flow} (captação/resgate)	−0,0004	0,0263	−0,1227	0,0878	−0,1	n.s.

R^2 médio das 72 regressões: 0,152. $N = 11.413$ fundo-meses, 307 fundos, 72 meses. $t = \bar{\theta}/(\text{dp}(\theta)/\sqrt{72})$ — teste **ingênuo** sobre a média dos 72 valores mensais, sem nenhuma correção de autocorrelação (não é Newey–West); * $p < 5\%$, ** $p < 1\%$, *** $p < 0,1\%$. Fonte: elaboração própria (`scripts/01_cross_section_theta.R`, `09_theta_significancia.R`).

A leitura direta: fundos maiores carregam menos peso ($b^{aum} < 0$); fundos com mais cotistas carregam mais ($b^{cot} > 0$); fundos de cotas carregam menos ($b^{fic} < 0$); captação não tem um efeito médio claro (b^{flow} perto de zero, com bastante variação mês a mês).




Figura 1: Os cinco componentes de θ_t ao longo dos 72 meses, e o R^2 de cada regressão mensal. Os coeficientes não são constantes — há uma mudança de patamar visível em torno de 2018 — mas mantêm o mesmo sinal na maior parte do período.




Figura 2: Os mesmos cinco componentes de θ_t , agora padronizados (z-score) e sobrepostos num único gráfico, para comparar a evolução relativa entre eles. α , b^{aum} , b^{cot} e b^{fic} se movem de forma bastante parecida ao longo do tempo (inclusive na mudança de patamar de 2018) — um indício de que compartilham boa parte da mesma dinâmica subjacente. b^{flow} é visivelmente mais ruidoso, com um pico isolado em meados de 2018 que foge do padrão das outras quatro séries.

3 Etapa 2: a ligação logística e o erro e

A pergunta: O peso é uma fração entre 0% e 100%. Por que não usar direto o θ linear da Etapa 1 para gerar uma previsão?

Porque $x'\theta$ (a combinação linear das características) pode sair fora do intervalo $[0, 1]$ — nada nas contas da Etapa 1 impede um peso previsto negativo ou maior que 100%. A correção — a única forma de robustez mantida nesta versão — é passar a combinação linear por uma função logística antes de virar previsão:

A equação estimada:

$$\text{peso}_{i,t} = g(x'_{i,t}\theta_t) + e_{i,t}, \quad g(z) = \frac{1}{1 + e^{-z}} \quad (2)$$

Como $g(z)$ nunca sai de $(0, 1)$, qualquer que seja z , a previsão nunca sai dos limites. Mas isso exige reestimar θ_t **diretamente pela equação logística** (por máxima verossimilhança, `glm` com família quase-binomial, um único método, um por mês) — o θ linear da Etapa 1 não é compatível com essa escala (perto de $z = 0$, $g(z) \approx 0,5$, enquanto o peso real gira em torno de 1–5%; usar o θ linear dentro do $g(\cdot)$ gera um erro sistemático de quase $-0,5$ — um erro de especificação encontrado e corrigido durante a construção deste documento).

3.1 O resultado

Os sinais batem com a Etapa 1 (tamanho negativo, cotistas positivo, fundo de cotas negativo), mas a variabilidade mês a mês é bem maior em unidades de log-odds — em especial b^{flow} , cujo desvio-padrão (1,20) é maior que a própria média em módulo, e cujo mínimo/máximo ($-3,52 / 5,12$) mostra uma dispersão bem mais ampla que a das outras quatro variáveis.

Tabela 2: Θ (logit): média, desvio-padrão, mínimo, máximo e teste ingênuo de significância da média dos 72 θ_t mensais.

Variável	Média	Desvio-padrão	Mínimo	Máximo	t	Sig.
α (intercepto)	-3,3641	0,6520	-4,9745	-2,6739	-43,8	***
b^{aum} (tamanho)	-0,3183	0,1677	-0,6830	-0,0570	-16,1	***
b^{cot} (cotistas)	0,4607	0,1480	0,2153	0,8033	26,4	***
b^{fic} (fundo de cotas)	-0,7317	0,3175	-1,4450	-0,1763	-19,6	***
b^{flow} (captação/resgate)	0,0779	1,2048	-3,5171	5,1177	0,6	n.s.

Mesmos sinais da Etapa 1, agora em unidades de log-odds (a escala interna da função logística $g(\cdot)$), não pontos percentuais diretos. $t = \bar{\theta}/(\text{dp}(\theta)/\sqrt{72})$ — mesmo teste ingênuo da Tabela 1, sem correção de autocorrelação; * $p < 5\%$, ** $p < 1\%$, *** $p < 0,1\%$. Fonte: elaboração própria (scripts/02_logit_erro.R, 09_theta_significancia.R).




Figura 3: Os cinco componentes de θ_t (logit), padronizados (z-score) e sobrepostos no mesmo gráfico. O padrão é mais ruidoso que o da Etapa 1 (Figura 2) — esperado, já que cada θ_t logístico é estimado por máxima verossimilhança, mês a mês, com a mesma amostra de ~ 130 – 145 fundos — mas α , b^{aum} e b^{fic} ainda mostram comovimento visível na segunda metade da série.

3.2 O erro e

$e_{i,t} = \text{peso}_{i,t} - g(x'_{i,t}\theta_t)$ é o erro de ajuste da própria regressão (dentro da amostra, não é previsão fora da amostra).

A média de e é zero em **todo** mês — mas isso é mecânico: com intercepto na equação, a condição de primeira ordem da máxima verossimilhança força isso, do mesmo jeito que o resíduo de MQO com intercepto sempre soma zero. Não é evidência de bom ajuste, só confirma que a otimização convergiu. O que de fato descreve o comportamento do erro é o desvio-padrão (3,05 pontos percentuais), a assimetria (positiva: mais erros pequenos negativos, com uma cauda de erros positivos maiores) e a curtose (mais alta que a normal — caudas mais pesadas).

Tabela 3: Estatísticas do erro e (11.413 observações).

Estatística	Valor
Média	0,000000
Desvio-padrão	0,0305
Mediana	-0,0046
Mínimo / Máximo	-0,127 / 0,155
% de observações com $e > 0$	36,2%
Assimetria	0,98
Curtose	4,76 (normal = 3)
Previsões fora de $[0, 1]$	0 de 11.413




Figura 4: Histograma do erro e da Etapa 2 (11.413 observações). A linha tracejada marca zero.




Figura 5: Evolução mês a mês do erro e : a nuvem cinza é o erro individual de **cada fundo-mês** (11.413 pontos), com a média (linha azul) e o desvio-padrão (linha vermelha tracejada) de cada mês sobrepostos. **O eixo y é restrito a $[-0,025, 0,05]$** para deixar a média e o desvio-padrão mensal mais fáceis de enxergar; 2.805 dos 11.413 pontos individuais (25%) caem fora desse intervalo e não aparecem no gráfico — a Tabela 3 já reporta o mínimo e o máximo verdadeiros ($-0,127 / 0,155$). A média fica achatada em zero em **todo** mês — mecânico, como já explicado — mas a nuvem de pontos mostra que os erros individuais estão longe de ser todos zero; é só a média entre fundos que cancela. O desvio-padrão é a série que de fato mostra evolução: sobe de $\approx 0,01$ em 2016 para um platô de $0,03\text{--}0,04$ a partir de 2018, mesma janela em que a Figura 1 mostrou a mudança de patamar dos coeficientes.

4 Etapa 3: o ajuste parcial

A pergunta: O peso de um fundo se move em direção ao que as características sugerem, ou fica parado onde está?

O peso desejado (alvo) de um fundo, num mês, é $w_{i,t}^* = g(x'_{i,t}\theta_t)$ — a mesma previsão da Etapa 2. A hipótese de ajuste parcial: o fundo não salta direto para o alvo, mas fecha uma fração λ da distância a cada mês:

A equação estimada:

$$w_{i,t+1} - w_{i,t} = \lambda d_{i,t} + u_{i,t+1}, \quad d_{i,t} \equiv w_{i,t}^* - w_{i,t} \quad (3)$$

Estimado por MQO direto, sem intercepto (a teoria não prevê nenhum), pooled em todos os fundo-meses — **um único método**, sem instrumento, sem efeito-fixo de fundo, sem painel dinâmico.

4.1 O resultado

$$\hat{\lambda} = 0,0980 \quad (\text{erro-padrão} = 0,0047, \quad t = 20,8, \quad R^2 = 0,038, \quad n = 10.972)$$

Checagem: com intercepto incluído, ele sai 0,00021 ($t = 1,4$, não significativo) — consistente com a equação (3) não prever nenhum. $\hat{\lambda} = 0,098$ significa que, em média, um fundo fecha cerca de 9,8% da distância até o alvo a cada mês.

4.2 O erro u

Tabela 4: Estatísticas do erro u (10.972 observações, pares de meses consecutivos).

Estatística	Valor
Média	0,0002
Desvio-padrão	0,0151
Mediana	-0,0009
Mínimo / Máximo	-0,172 / 0,190
% de observações com $u > 0$	37,6%
Assimetria	0,40
Curtose	19,7 (normal = 3)

Diferente do erro e , a média de u **não** é mecanicamente zero (a equação (3) não tem intercepto) — e mesmo assim sai muito perto de zero (0,0002), sem viés aparente. A curtose de 19,7 é bem mais alta que a da Etapa 2: a maior parte dos erros é pequena e concentrada perto de zero, mas alguns poucos fundo-meses têm erro grande, puxando a cauda.




Figura 6: Histograma do erro u da Etapa 3 (10.972 observações). Note o pico estreito perto de zero e as caudas longas — coerente com a curtose alta.




Figura 7: Evolução mês a mês do erro u : a nuvem cinza é o erro individual de cada par fundo-mês consecutivo (10.972 pontos), com a média (linha azul) e o desvio-padrão (linha vermelha tracejada) de cada mês sobrepostos. **O eixo y é restrito a $[-0,03, 0,04]$** para deixar a média e o desvio-padrão mensal mais fáceis de enxergar; 487 dos 10.972 pontos individuais (4,4%) caem fora desse intervalo e não aparecem no gráfico — a Tabela 4 já reporta o mínimo e o máximo verdadeiros ($-0,172 / 0,190$). Diferente do erro e da Etapa 2, a média **não** é mecanicamente zero (a equação (3) não tem intercepto) — oscila visivelmente em torno de zero, mas sem tendência clara de longo prazo. O desvio-padrão também oscila bastante mês a mês, com alguns picos isolados (o mais forte em meados de 2018) coerentes com a curtose alta reportada na Tabela 4; a nuvem de pontos mostra de onde vêm esses picos — meses com alguns poucos fundos bem fora do padrão típico, não uma mudança geral de todo mundo.

5 Etapa 4: um esquema in/out-of-sample

A pergunta: O λ estimado serve pra prever de verdade, em dados que o modelo nunca viu?

Um único corte no tempo — sem janela expansiva com muitas origens, sem múltiplos horizontes:

- **Treino:** 2016-01 a 2019-12 (48 meses, 6.428 observações).
- **Teste:** 2020-01 a 2021-11 (23 meses, 4.544 observações).

A equação estimada: $\hat{\lambda}$ é estimado pela equação (3) **só com dados de treino**. Esse valor fixo é aplicado às observações de teste para prever a variação do peso, comparado contra a previsão ingênua (Δw previsto = 0, ou seja, “o peso do mês que vem é igual ao de hoje”). θ_t continua sendo estimado mês a mês, dentro ou fora do período de treino, sem nenhum vazamento de informação futura.

$$\hat{\lambda}_{\text{treino}} = 0,1043 \quad (\text{erro-padrão} = 0,0065, t = 16,0)$$

5.1 O resultado, fora da amostra

Tabela 5: RMSE e MAE dentro e fora da amostra, ajuste parcial vs. ingênua.

Amostra	Modelo	RMSE	MAE
Treino (2016–2019)	Ajuste parcial	0,01361	—
Treino (2016–2019)	Ingênua	0,01388	—
Teste (2020–2021)	Ajuste parcial	0,01689	0,00995
Teste (2020–2021)	Ingênua	0,01721	0,00934




Figura 8: RMSE dentro (treino) e fora (teste) da amostra, ajuste parcial vs. ingênua.

O ajuste parcial vence em RMSE nas duas amostras (razão teste = 0,981, cerca de 1,9% menor) — um padrão consistente entre treino e teste, não um resultado que só aparece por acaso fora da

amostra. Em MAE, a ingênua erra menos com mais frequência (0,00934 contra 0,00995): o ajuste parcial evita alguns erros grandes (por isso vence em RMSE, que penaliza erro grande mais que proporcionalmente), mas erra um pouco mais nos casos típicos.




Figura 9: RMSE mês a mês no período de teste. As duas linhas seguem praticamente juntas — a vantagem do ajuste parcial é pequena e consistente, não concentrada num único mês.

Mês a mês, o ajuste parcial vence a ingênua em 15 dos 23 meses de teste (65%).




Figura 10: Variação do peso prevista (eixo x) vs. observada (eixo y), fora da amostra. As previsões ficam concentradas perto de zero (o modelo prevê mudanças pequenas), enquanto a variação observada tem bem mais dispersão — coerente com o R^2 baixo da equação (3) (0,038): o modelo capta uma tendência real, mas pequena parte da variação total.

6 Resumo

Quatro etapas, cada uma com um único método, uma equação e um erro examinado:

1. **Cross-section (MQO), equação (1):** θ_t mês a mês; tamanho, cotistas e fundo de cotas explicam o peso, com sinais estáveis; R^2 médio 0,152.
2. **Logística, equação (2):** θ_t reestimado por MQO logístico para gerar previsão sempre em $[0, 1]$; erro e com desvio-padrão 3,05 p.p., levemente assimétrico, sem viés (por construção).
3. **Ajuste parcial, equação (3):** $\hat{\lambda} = 0,098$ — um fundo fecha, em média, 9,8% da distância ao alvo por mês; erro u sem viés aparente, mas com caudas pesadas (curtose 19,7).
4. **In/out-of-sample:** λ treinado em 2016–2019 vence a previsão ingênua fora da amostra (2020–2021) em RMSE, por uma margem pequena mas consistente (1,9%; vence em 65% dos meses de teste).

Nenhuma dessas conclusões depende de Newey–West, cluster, Kalman, variável instrumental ou teste de Diebold–Mariano — o preço dessa simplicidade é não corrigir os vieses conhecidos do MQO direto no ajuste parcial (erro de medida no alvo; a distância e a variação do peso compartilham $w_{i,t}$), que a versão anterior do projeto documentou e tentou corrigir. Fica registrado como decisão consciente desta versão, não como descuido.