

v2 OFICIAL

Peso de VALE3 nos fundos do Itaú — versão simples, direta e objetiva
Cross-section (MQO + logit), ajuste parcial e um esquema in/out-of-sample — sem Newey–West,
sem Kalman, sem Diebold–Mariano, sem múltiplos métodos de robustez

João Paulo Zangrandi (FGV–EESP)

Resumo

Este documento retoma o projeto a partir da ideia original das anotações do orientador: uma cross-section simples que estima um fator latente θ , uma etapa logística para manter a previsão dentro de $[0, 1]$, e um modelo de ajuste parcial para a dinâmica. Cada etapa usa **um único método** (MQO ou MQO logístico), sem testes ou correções de robustez em cascata. Nesta versão, as características do fundo (inclusive o novo beta do próprio fundo) passam a ser sempre medidas no **último dia do mês anterior**, eliminando qualquer look-ahead bias.

Sumário

1	Por que esta versão existe	3
2	Etapa 1: a cross-section (MQO + logit)	3
2.1	O resultado: antes e depois do beta do fundo	4
2.2	O erro e	5
3	Etapa 2: o ajuste parcial	8
3.1	O resultado	8
3.2	O erro u	8
4	Etapa 3: um esquema in/out-of-sample	10
4.1	O resultado, fora da amostra	10
4.2	RMSE flexível: o mesmo teste, em vários horizontes	11
5	Extensão: mais gestoras	12
5.1	Quanto cada gestora carrega, relativo ao Itaú	13
6	Extensão: todas as ações	15
6.1	Regressão por ativo e por mês: o padrão de VALE3 generaliza?	16
6.2	Checagem complementar: uma única regressão com efeito-fixo de ativo e de mês . .	17
6.3	O erro por gestora, agora com todas as ações	18
7	Resumo	20

1 Por que esta versão existe

As versões anteriores deste projeto acumularam camada sobre camada de robustez estatística (Newey–West, filtro de Kalman, variável instrumental com múltiplos esquemas de cluster, painel dinâmico de Arellano–Bond, teste de Diebold–Mariano) até o núcleo do modelo ficar difícil de enxergar por trás das correções. Esta versão volta ao desenho original discutido com o orientador: uma cross-section por mínimos quadrados que gera um fator latente θ , uma etapa logística (a única forma de robustez mantida, porque o peso é limitado a $[0, 1]$ e a reta não respeita esse limite), e um modelo de ajuste parcial estimado diretamente por MQO. Cada etapa produz um erro, examinado com estatísticas simples — média, desvio-padrão, assimetria, curtose, histograma — sem bateria de testes formais.

A base de dados (composição de carteiras da CVM, fundos do grupo Itaú, 2016–2021) é a mesma já construída e validada na versão anterior — essa parte nunca foi a fonte da complexidade.

2 Etapa 1: a cross-section (MQO + logit)

A pergunta: As características de um fundo explicam o peso de VALE3 que ele carrega? E, se sim, como transformar essa explicação numa previsão que respeite os limites de 0% a 100%?

Esta etapa une o que em versões anteriores deste documento eram duas seções separadas: a cross-section **linear** (para interpretar os coeficientes diretamente em pontos percentuais) e a cross-section **logística** (para gerar um peso previsto que nunca sai de $[0, 1]$). As duas usam as mesmas cinco características, mês a mês:

A equação estimada:

$$\text{peso}_{i,t} = \alpha_t + \theta_t^{aum} z(\ln AUM_i) + \theta_t^{cot} z(\ln \cot_i) + \theta_t^{fic} FIC_i + \theta_t^{flow} \left(\frac{\text{capt} - \text{resg}}{AUM} \right)_i + \theta_t^{bf} z(\beta_i^{fundo}) + \text{erro}_{i,t} \quad (1)$$

$$\text{peso}_{i,t} = g(x'_{i,t} \theta_t) + e_{i,t}, \quad g(z) = \frac{1}{1 + e^{-z}} \quad (2)$$

$\theta_t = (\alpha_t, \theta_t^{aum}, \theta_t^{cot}, \theta_t^{fic}, \theta_t^{flow}, \theta_t^{bf})$ é o vetor de coeficientes de **um único mês** t ; $\Theta = \{\theta_t\}_t$, o **teta grande**, é o conjunto de todos os θ_t ao longo do tempo — é esse conjunto que as tabelas e figuras a seguir resumem (média, desvio-padrão, evolução mês a mês).

A primeira é estimada por MQO (coeficientes em pontos percentuais, fáceis de interpretar); a segunda por máxima verossimilhança (glm quase-binomial), a única forma de robustez mantida nesta versão, porque $x'\theta$ pode sair de $[0, 1]$ mas $g(x'\theta)$ nunca sai. As duas rodam mês a mês, uma regressão por mês, sem nenhuma etapa de resumo temporal em cima (não é Fama–MacBeth).

Novidade desta versão — duas mudanças na Etapa 1:

- (a) Entra uma 5ª característica, o **beta do próprio fundo** β^{fundo} : mede o quanto a cota do fundo se move junto com o mercado (Ibovespa), do mesmo jeito que se mede o beta de uma ação.

A equação estimada:

$$r_{i,d} = \frac{\text{cota}_{i,d}}{\text{cota}_{i,d-1}} - 1 \quad r_{m,d} = \frac{\text{Ibovd}}{\text{Ibovd}_{-1}} - 1$$

$$\beta_{i,t}^{fundo} = \frac{\widehat{\text{Cov}}_{252}(r_i, r_m)}{\widehat{\text{Var}}_{252}(r_m)}$$

$r_{i,d}$ é o retorno diário da cota do fundo i ; $r_{m,d}$ é o retorno diário do Ibovespa; $\widehat{\text{Cov}}_{252}$ e $\widehat{\text{Var}}_{252}$ são covariância e variância amostrais numa janela móvel dos últimos 252 pregões (≈ 1 ano), terminando no último pregão do mês $t - 1$ — mesma metodologia (e mesma janela) já usada para o beta de VALE3 (mercado) no `tcc I.pdf` (v1), agora aplicada à *cota do fundo* em vez do preço da ação.

- (b) **Todas** as cinco características (não só o beta do fundo) passam a ser medidas no **último dia do mês anterior** ($t - 1$), nunca no mês corrente — antes, *AUM*, cotistas e fluxo eram contemporâneos ao próprio mês t . Agora θ_t é 100% predeterminado: tudo que ele usa já era conhecido antes do mês t começar.

Adendo sobre a amostra: exigir as cinco características simultaneamente reduz a cobertura de 72 para **59 meses** (fev/2017 a dez/2021) — o beta do fundo exige ≥ 252 pregões de histórico de cota (quase um ano), então nenhum fundo tem essa variável disponível nos primeiros meses da amostra (jan/2016 a jan/2017 ficam sem fundos suficientes). Essa perda foi aceita conscientemente, não é um erro: a partir daqui, todo número deste documento vem dos 8.335 fundo-meses com as cinco características completas (120 a 190 fundos por mês, média 141).

2.1 O resultado: antes e depois do beta do fundo

Para deixar claro o efeito de adicionar o beta do fundo, a tabela abaixo compara — na **mesma amostra** de 59 meses — a regressão **logística** (equação (2), a que de fato alimenta o erro e e todo o resto do documento a partir daqui) com as quatro características clássicas contra a mesma regressão com o beta do fundo incluído. Os coeficientes estão na escala do preditor linear $x'\theta$ (log-odds), não em pontos percentuais.

Tabela 1: Θ logístico: antes e depois do beta do fundo (mesma amostra, 59 meses, teste ingênuo de significância $t = \hat{\theta}/(\text{dp}(\theta)/\sqrt{59})$).

Variável	Média (sem β^{fundo})	Sig.	Média (com β^{fundo})	Sig.
α	−3,1262	***	−3,8110	***
θ^{aum} (tamanho)	−0,2749	***	−0,0594	***
θ^{cot} (cotistas)	0,4429	***	0,0493	***
θ^{fic} (fundo de cotas)	−0,6669	***	−0,2149	***
θ^{flow} (captação/resgate)	0,4402	n.s.	0,1396	n.s.
θ^{bf} (beta do fundo)	—	—	1,0110	***
Pseudo- R^2 (McFadden) médio	0,164		0,614	

* $p < 5\%$, ** $p < 1\%$, *** $p < 0,1\%$. Fonte: elaboração própria (`scripts/13_etapa1_unificada.R`, `14_etapa1_antes_depois.R`). **Nota de correção:** uma versão anterior deste documento reportava t errado nesta tabela (usava $\sqrt{6}$, o número de *variáveis*, em vez de $\sqrt{59}$, o número de *meses*, no denominador do teste) — os t corretos são $\approx 3,1\times$ maiores; tamanho e cotistas continuam *** significativos com o beta do fundo, não n.s./* como antes reportado.

Achado: O mesmo padrão que já tinha aparecido como checagem à parte na versão anterior (Tabela 11 do `tcc I.pdf`) agora é a especificação principal: com o beta do fundo na conta, tamanho e cotistas ficam **bem mais fracos** em magnitude de t (tamanho: $t = -15,1 \rightarrow -6,0$; cotistas: $t = 31,5 \rightarrow 4,9$) — mas **continuam estatisticamente significativos a 0,1%**, não perdem a significância. O pseudo- R^2 quase quadruplica ($0,164 \rightarrow 0,614$). Leitura: parte do que tamanho e

cotistas explicavam era, na verdade, um proxy indireto para o quão “equity-like” é o fundo — o beta do fundo mede isso diretamente e absorve boa parte (não toda) dessa força explicativa.

Tornando o logit interpretável: efeito marginal médio

Um coeficiente logístico não é “pontos percentuais” — está na escala do preditor linear $x'\theta$ (log-odds), não na escala do peso em si. Para interpretar em pontos percentuais sem abandonar o logit, uso o **efeito marginal médio** (*average partial effect*, APE): para uma característica contínua k , $APE_k = \theta_k \cdot \overline{g'(x'\theta)}$, a média (em toda a amostra) da inclinação de $g(\cdot)$ vezes o coeficiente — quanto o peso previsto se move, em média, para uma variação de 1 desvio-padrão naquela característica. Para o FIC (0/1, discreta), uso a diferença média de $g(\cdot)$ forçando FIC= 1 contra FIC= 0 em cada fundo, mantendo as demais características observadas — mais correto que a derivada para uma variável que só assume dois valores.

Tabela 2: Efeito marginal médio (APE) do logit, em pontos percentuais de peso — mesma comparação sem/com beta do fundo.

Característica	APE (sem β^{fundo})	Sig.	APE (com β^{fundo})	Sig.
Tamanho	−0,00734	***	−0,00154	***
Cotistas	0,01271	***	0,00111	***
Fundo de cotas	−0,02222	***	−0,00580	***
Captação/resgate	0,01068	n.s.	0,00449	n.s.
Beta do fundo	—	—	0,02942	***

Fonte: elaboração própria (`scripts/13_etapa1_unificada.R`, `14_etapa1_antes_depois.R`).

Achado: O APE bate de perto com o que a versão linear já dava (tamanho $-0,0074 \rightarrow -0,0016$ linear vs. $-0,00734 \rightarrow -0,00154$ via APE; cotistas $0,0130 \rightarrow 0,0018$ linear vs. $0,01271 \rightarrow 0,00111$ via APE) — não é coincidência: quando o modelo se ajusta bem, a inclinação média do logit converge para perto do coeficiente linear equivalente. A vantagem do APE é que ele vem do **próprio** modelo logístico (respeitando os limites de $[0, 1]$), não de uma regressão linear separada rodada só para efeito de leitura.

2.2 O erro e

$e_{i,t} = \text{peso}_{i,t} - g(x'_{i,t}\theta_t)$, o erro de ajuste da regressão logística (dentro da amostra).

Tabela 3: Estatísticas do erro e (8.335 observações).

Estatística	Valor
Média	0,000000
Desvio-padrão	0,0227
Mediana	−0,0008
Mínimo / Máximo	−0,113 / 0,178
% de observações com $e > 0$	45,1%
Assimetria	0,39
Curtose	7,67 (normal = 3)
Previsões fora de $[0, 1]$	0 de 8.335

A média é zero em todo mês — mecânico (condição de primeira ordem da máxima verossimilhança com intercepto), não evidência de bom ajuste. O desvio-padrão caiu de 0,0305 (versão sem beta do fundo) para 0,0227 — o modelo ajusta melhor, coerente com o salto no R^2 .




Figura 1: Os seis componentes de θ_t logístico (com beta do fundo) ao longo dos 59 meses, e o pseudo- R^2 de McFadden de cada regressão mensal. θ^{bf} é sempre positivo, coerente com sua significância forte e estável.




Figura 2: Histograma do erro e (8.335 observações). A linha tracejada marca zero.




Figura 3: Evolução mês a mês do erro e : nuvem cinza = erro individual de cada fundo-mês; linha azul = média mensal (mecanicamente zero); linha vermelha tracejada = desvio-padrão mensal. Eixo y restrito a $[-0,03, 0,06]$ para facilitar a leitura das duas linhas — 843 dos 8.335 pontos individuais (10%) ficam fora e não aparecem.

3 Etapa 2: o ajuste parcial

A pergunta: O peso de um fundo se move em direção ao que as características sugerem, ou fica parado onde está?

O alvo de um fundo, num mês, é $w_{i,t}^* = g(x'_{i,t}\theta_t)$ — a mesma previsão da Etapa 1. A hipótese de ajuste parcial: o fundo fecha uma fração λ da distância ao alvo a cada mês.

A equação estimada:

$$w_{i,t+1} - w_{i,t} = \lambda d_{i,t} + u_{i,t+1}, \quad d_{i,t} \equiv w_{i,t}^* - w_{i,t} \quad (3)$$

Estimado por MQO direto, sem intercepto, pooled em todos os fundo-meses — um único método, sem instrumento, sem efeito-fixo, sem painel dinâmico.

3.1 O resultado

$$\hat{\lambda} = 0,1534 \quad (\text{erro-padrão} = 0,0075, \quad t = 20,6, \quad R^2 = 0,050, \quad n = 7.987)$$

λ subiu de 0,098 (versão anterior) para 0,153 — esperado, já que o alvo w^* agora é mais preciso (R^2 maior na Etapa 1), o que atenua menos o coeficiente pelo erro de medida clássico (Problema 1 do modelo de ajuste parcial). Em média, um fundo fecha 15,3% da distância ao alvo por mês.

3.2 O erro u

Tabela 4: Estatísticas do erro u (7.987 observações, pares de meses consecutivos).

Estatística	Valor
Média	0,0002
Desvio-padrão	0,0151
Mediana	-0,0004
Mínimo / Máximo	-0,160 / 0,185
% de observações com $u > 0$	44,3%
Assimetria	0,59
Curtose	19,4 (normal = 3)

Praticamente idêntico ao da versão anterior (dp 0,0151 nas duas) — a mudança na Etapa 1 melhorou o ajuste de e , mas o comportamento do erro do ajuste parcial em si não muda muito.




Figura 4: Histograma do erro u (7.987 observações).




Figura 5: Evolução mês a mês do erro u . Eixo y restrito a $[-0,03, 0,04]$; 369 dos 7.987 pontos individuais (4,6%) ficam fora e não aparecem.

4 Etapa 3: um esquema in/out-of-sample

A pergunta: O λ estimado serve pra prever de verdade, em dados que o modelo nunca viu?

Um único corte no tempo, dentro do período coberto pela Etapa 1 (fev/2017 a dez/2021):

- **Treino:** 2017-02 a 2019-12 (35 meses, 4.352 observações).
- **Teste:** 2020-01 a 2021-11 (23 meses, 3.635 observações).

A equação estimada: $\hat{\lambda}$ é estimado pela equação (3) só com dados de treino, depois aplicado fixo aos meses de teste:

$$\hat{w}_{i,t+1} = w_{i,t} + \hat{\lambda}_{\text{treino}} d_{i,t} \quad (\text{ajuste parcial}) \quad \text{vs.} \quad \hat{w}_{i,t+1} = w_{i,t} \quad (\text{ingênua}) \quad (4)$$

θ_t continua sendo estimado mês a mês, sem vazamento de informação futura.

$$\hat{\lambda}_{\text{treino}} = 0,1951 \quad (35 \text{ meses de treino})$$

4.1 O resultado, fora da amostra

Tabela 5: RMSE e MAE dentro e fora da amostra, ajuste parcial vs. ingênua.

Amostra	Modelo	RMSE	MAE
Treino (2017–2019)	Ajuste parcial	0,01463	—
Treino (2017–2019)	Ingênua	0,01510	—
Teste (2020–2021)	Ajuste parcial	0,01560	0,00906
Teste (2020–2021)	Ingênua	0,01585	0,00847




Figura 6: RMSE dentro (treino) e fora (teste) da amostra, ajuste parcial vs. ingênua.

O ajuste parcial vence em RMSE nas duas amostras (razão teste = 0,984) — mesmo padrão da versão anterior. Em MAE, a ingênua continua vencendo nos casos típicos (0,00847 contra 0,00906):

o ajuste parcial evita alguns erros grandes, mas erra um pouco mais em geral. Mês a mês, vence em 14 dos 23 meses de teste (61%).




Figura 7: RMSE mês a mês no período completo (2017–2021). A linha vermelha tracejada marca o início do teste (2020-01). As duas linhas seguem coladas dos dois lados do corte — a vantagem do ajuste parcial é pequena e consistente, não concentrada num único mês.

4.2 RMSE flexível: o mesmo teste, em vários horizontes

A pergunta: A vantagem do ajuste parcial sobre a ingênua (Tabela 5) é específica de prever 1 mês à frente, ou se mantém prevendo 2, 3, 6, 12 meses à frente?

Mesmo esquema treino/teste da Tabela 5 (treino < 2020-01, teste ≥ 2020-01), repetido para cada horizonte $h \in \{1, 2, 3, 6, 12\}$ meses: $dw_h = w_{i,t+h} - w_{i,t}$, $\hat{\lambda}_h$ estimado por MQO só no treino, alvo $w_{i,t}^*$ sempre fixado em t (não temos características futuras para recalculá-lo). Modelo ingênuo continua prevendo zero mudança.

Tabela 6: RMSE fora da amostra (2020–2021), ajuste parcial vs. ingênua, por horizonte.

h (meses)	$\hat{\lambda}_h$	Meses teste	RMSE ajuste	RMSE ingênua	Margem	Vence
1	0,1951	23	0,01560	0,01585	1,5%	61%
2	0,2502	22	0,01904	0,01957	2,7%	59%
3	0,2604	21	0,02087	0,02175	4,1%	57%
6	0,3191	18	0,02472	0,02577	4,1%	78%
12	0,4059	12	0,02943	0,02960	0,6%	67%

“Margem” = redução percentual de RMSE do ajuste parcial sobre a ingênua; “Vence” = % dos meses de teste em que o ajuste parcial tem RMSE menor naquele mês. Fonte: elaboração própria (`scripts/36_rmse_multihorizonte.R`).

Achado: O ajuste parcial vence a ingênua em RMSE em **todos** os 5 horizontes testados — a vantagem não é um artefato de olhar só 1 mês à frente. Mas a margem não é estável: cresce de 1,5% ($h = 1$) para um pico de 4,1% ($h = 3$ e $h = 6$) e praticamente desaparece em $h = 12$ (0,6%, com apenas 12 meses de teste disponíveis — amostra pequena, ler com cautela). $\hat{\lambda}_h$ cresce com




Figura 8: RMSE fora da amostra, ajuste parcial vs. ingênua, por horizonte de previsão.

o horizonte ($0,195 \rightarrow 0,406$), mas bem mais devagar do que uma composição geométrica simples do λ_1 previria (12 aplicações sucessivas de $\lambda_1 = 0,195$ fechariam $\approx 93\%$ do hiato, não os $\approx 41\%$ observados) — sinal de que o ajuste parcial não é um processo de decaimento a taxa constante: o alvo w^* também se move no caminho, e um λ estimado separadamente para cada horizonte capta isso melhor do que projetar λ_1 para frente.

5 Extensão: mais gestoras

A pergunta: O padrão encontrado (tamanho, cotistas, fundo de cotas, beta do fundo explicam o peso) é uma particularidade dos fundos do Itaú, ou aparece em qualquer gestora? E gestoras diferentes carregam mais ou menos VALE3 do que outras, tudo o mais igual?

Até aqui, a amostra era só os fundos do grupo Itaú. Esta extensão amplia para **todos os fundos do universo CVM** que já tiveram VALE3 em algum momento (2016–2021) — 2.820 fundos, 41 grupos de gestora (agrupados por marca controladora; ex.: “BTG Pactual” junta 4 rótulos diferentes que a CVM usa para a mesma casa). A equação (1) ganha um efeito fixo de gestora — 40 variáveis de 0/1 (uma por grupo, exceto o Itaú, que fica como referência, para não haver colinearidade perfeita com o intercepto):

$$\text{peso}_{i,t} = \alpha_t + \theta_t^{aum} z(\ln AUM_i) + \dots + \theta_t^{bf} z(\beta_i^{fundo}) + \sum_{g \neq \text{Itaú}} \gamma_{g,t} D_{g,i} + \text{erro}_{i,t}$$

Adendo de processo: ao rodar essa regressão pela primeira vez, todas as cinco características saíram não significativas — um resultado que parecia dizer “a identidade da gestora explica tudo, as características não importam mais”. Investigando, a causa não era o efeito fixo de gestora: era **um único fundo-mês com dado corrompido** (peso de VALE3 registrado como 1.398,5 — impossível, peso é uma fração de 0 a 1) que, sozinho, distorcia a regressão de um mês inteiro (set/2018). Removido esse ponto (junto com outro caso igual, peso = 1.087,8, e 13 fundo-meses de beta do fundo com denominador degenerado por cota irregular), o resultado abaixo é o que

sobrevive.

Tabela 7: Θ logístico, amostra de todas as gestoras (59 meses, 71.569 obs.): sem e com efeito fixo de gestora.

Variável	Média (sem FE gestora)	Sig.	Média (com FE gestora)	Sig.
α	-3,7989	***	-3,9272	***
θ^{aum} (tamanho)	-0,0120	n.s.	-0,0141	*
θ^{cot} (cotistas)	0,0462	***	0,0331	***
θ^{fic} (fundo de cotas)	-0,1641	***	-0,1559	***
θ^{flow} (captação/resgate)	-0,1583	***	-0,1254	***
θ^{bf} (beta do fundo)	0,9052	***	0,8833	***
Pseudo- R^2 (McFadden) médio	0,604		0,696	

Tabela 8: Efeito marginal médio (APE) do logit com todas as gestoras, em pontos percentuais.

Característica	APE (sem FE gestora)	Sig.	APE (com FE gestora)	Sig.
Tamanho	-0,00085	***	-0,00080	***
Cotistas	0,00123	***	0,00079	***
Fundo de cotas	-0,00455	***	-0,00424	***
Captação/resgate	-0,00377	***	-0,00251	**
Beta do fundo	0,02691	***	0,02635	***

Fonte: elaboração própria (`scripts/20_etapa1_com_gestora.R`, `23_etapa1_gestora_antes_depois.R`).

Achado: Uma diferença real em relação à versão anterior (linear): no logit, **tamanho fica bem mais fraco** — n.s. sem FE, só marginal (*) com FE, contra ***/** que a escala linear mostrava. É o coeficiente bruto (log-odds) que perde força; o APE de tamanho continua *** significativo nas duas colunas (-0,00085 e -0,00080), só que pequeno em magnitude — as duas leituras não se contradizem, só usam testes diferentes (a variação mês a mês do coeficiente bruto é maior, em termos relativos, do que a da sua tradução em pontos percentuais). Cotistas, FIC, fluxo e beta do fundo continuam robustamente significativos nas duas especificações. Pseudo- R^2 sobe de 0,604 para 0,696 com o efeito fixo de gestora: a identidade da gestora tem poder explicativo próprio, mas não “rouba” o efeito das características — o padrão da Etapa 1 generaliza para além do Itaú. Diferente da amostra só-Itaú (Tabela 1), aqui a captação/resgate é claramente significativa (*** sem FE, ** com FE) — com 71.569 observações contra 8.335, há poder estatístico para detectar um efeito de fluxo pequeno que na amostra menor não era distinguível de ruído.

5.1 Quanto cada gestora carrega, relativo ao Itaú

Cada γ_g (log-odds) é o quanto o preditor linear de um fundo da gestora g se desloca em relação a um fundo do Itaú **com as mesmas** cinco características. Como log-odds não é diretamente interpretável, a tabela também traz o **APE discreto** de cada gestora: a diferença média de $g(\cdot)$ forçando aquele fundo a ser da gestora g contra forçá-lo a ser do Itaú, para todos os fundos da amostra (mesma lógica do APE do FIC) — em pontos percentuais de peso, positivo = carrega mais VALE3 que o Itaú equivalente, negativo = carrega menos.

Adendo de processo: em 5 das 40 gestoras, o sinal do coeficiente médio (log-odds) e do APE médio **discordam**. Não é erro: dentro de cada mês, os dois sempre têm o mesmo sinal matematicamente (é uma propriedade de $g(\cdot)$ ser monótona) — a discordância aparece só na *média simples ao longo dos meses*, quando o coeficiente em log-odds tem alguns meses de magnitude

extrema (comum quando a gestora tem poucos fundos naquele mês) que dominam a média bruta mas ficam “espremidos” pela função logística ao virar APE. O caso mais claro é a Kinea: negativa e com magnitude enorme em 2017–2018 (chegando a $-12,6$ em jun/2018), mas consistentemente positiva e modesta de 2019 em diante — a média do coeficiente fica negativa (dominada pelos extremos de 2017–2018), a média do APE fica positiva (o período mais longo e mais estável de 2019–2021 pesa mais depois de passar pela função logística). Os outros 4 casos (JGP, ARX, Vinci Partners, Safra) têm APE tão perto de zero que o sinal é irrelevante na prática. Por isso a tabela é ordenada pelo **APE**, a medida mais robusta a esses extremos.

Tabela 9: Coeficiente (log-odds) e APE (pontos percentuais) de cada gestora vs. Itaú (referência), ordenado pelo APE do maior para o menor.

Gestora	Meses	Coef.	Sig.	APE	Sig.
Legacy Capital	1	+2,3422	—	+0,16960	—
Núcleo Capital	4	+1,1618	***	+0,04666	***
Occam Brasil	59	+0,6456	***	+0,02703	***
Truxt Investimentos	42	+0,3892	***	+0,02071	***
Plural	59	+0,4350	***	+0,02050	***
AZ Quest	56	+0,2826	***	+0,01437	***
Absolute Investimentos	28	+0,1246	n.s.	+0,01413	**
Sharp Capital	59	+0,2679	***	+0,01315	***
Real Investor	47	+0,2455	**	+0,01275	***
SPX Capital	59	+0,1818	*	+0,01230	***
Western Asset	59	+0,3688	***	+0,01156	***
Caixa	59	+0,3634	***	+0,01113	***
Dahlia Capital	30	+0,1551	n.s.	+0,01070	**
Claritas Investimentos	59	+0,2810	***	+0,01058	***
Opportunity	59	+0,1438	n.s.	+0,01040	***
BB Asset Management	59	+0,3277	***	+0,00909	***
Credit Suisse	59	+0,1557	**	+0,00892	***
Bradesco Asset Management	59	+0,2945	***	+0,00886	***
Santander Brasil Asset Management	59	+0,2252	***	+0,00839	***
Kinea Investimentos	54	-0,6161	*	+0,00555	*
BNP Paribas	59	+0,1602	***	+0,00505	***
Verde Asset Management	59	+0,0688	n.s.	+0,00402	**
JGP	59	-0,0275	n.s.	+0,00153	n.s.
ARX Investimentos	57	-0,4219	*	+0,00029	n.s.
Vinci Partners	59	-0,2411	**	+0,00007	n.s.
Safra Asset Management	59	-0,0973	*	+0,00000	n.s.
BTG Pactual	59	-0,0914	*	-0,00078	n.s.
Julius Baer Family Office	59	-0,0491	n.s.	-0,00140	*
Ibiuna Investimentos	45	-0,5727	*	-0,00425	n.s.
Daycoval Asset Management	57	-1,0280	***	-0,00523	***
XP	59	-0,2856	***	-0,00562	***
TNA Gestão Patrimonial	59	-0,3059	***	-0,00751	***
Squadra Investimentos	45	-0,7695	*	-0,00830	***
Atmos Capital	33	-0,4879	***	-0,01048	***
Constellation Asset Management	25	-1,9235	***	-0,01224	*
Gávea Investimentos	34	-0,9917	***	-0,01274	***
Bogari Capital	11	-0,6110	***	-0,01484	***
Kapitalo Investimentos	52	-1,7679	***	-0,01790	***
Forpus Capital	33	-2,4478	***	-0,02059	***
Guepardo Investimentos	33	-4,6030	***	-0,02944	***

“Meses” = quantos dos 59 meses aquela gestora teve dados suficientes para entrar na regressão. t e significância: teste ingênuo sobre a média mensal (do coeficiente e do APE, respectivamente), mesmo estilo das demais tabelas. Fonte: elaboração própria (`scripts/20_etapa1_com_gestora.R`, `21_coeficientes_gestora.R`).

Leitura: gestoras grandes de varejo/plataforma (Caixa, Bradesco, BB, Santander, Western Asset) carregam *mais* VALE3 que o Itaú equivalente; gestoras boutique de gestão concentrada/high-conviction (Guepardo, Forpus, Kapitalo, Bogari, Gávea) carregam *bem menos*. Não é uma medida de causalidade — é o resíduo estrutural, depois de controlar pelas 5 características, e a leitura mais plausível é filosofia de gestão: carteiras concentradas tendem a evitar “o nome que todo mundo tem” a menos que apostem nele especificamente, diferente de uma plataforma de varejo mais próxima de uma composição ampla.




Figura 9: Evolução mensal do APE de gestora (vs. Itaú, em pontos percentuais), para as 5 gestoras com APE mais positivo e as 5 com APE mais negativo **de verdade** (mesmo ranking da Tabela 8, sem filtro de cobertura). Duas delas têm pouquíssimos meses — Legacy Capital (1 mês, aparece como ponto isolado) e Nucleo Capital (4 meses) — porque são, de fato, as gestoras com o APE médio mais alto; não há “evolução” de verdade pra mostrar nesses dois casos específicos, só o valor pontual. O pico da Kapitalo em jul/2018 não é erro de dado: naquele mês, um único fundo da casa concentrava 37% em VALE3 dentro de um grupo pequeno (13 fundos), o suficiente para puxar a estimativa mensal daquele grupo — ilustra como esses coeficientes podem ser voláteis mês a mês quando o grupo tem poucos fundos.

6 Extensão: todas as ações

A pergunta: O padrão encontrado para VALE3 é uma particularidade daquele papel, ou aparece em qualquer ação que esses mesmos fundos carreguem?

Mantendo o mesmo universo de 2.820 fundos e 41 gestoras da extensão anterior, esta seção

olha **todas as ações** que eles carregam, não só VALE3. Mesma limpeza de custódia usada no `tcc I.pdf` (v1): a CVM registra a mesma ação sob rótulos diferentes conforme o tipo de posição (direta, cedida/recebida em empréstimo, direito de subscrição); só a posição direta é mantida, classificada pelo sufixo numérico do *ticker* (convenção B3). Resultado: 523 ativos de posição direta, 10.603.928 linhas fundo-ativo-mês — VALE3 reproduziu exatamente as 96.349 linhas já conhecidas, confirmando a limpeza.

Adendo de processo: a tabela de características (AUM/cotistas/fluxo) da Etapa 2 só cobria os meses em que cada fundo tinha VALE3 — 16,8% dos fundo-mês do painel multiativo (fundos que naquele mês só tinham *outras* ações) ficavam sem essas características por um motivo evitável, não por falta real de dado. Reconstruída usando o conjunto correto de fundo-mês, a cobertura subiu para 97,6%. A amostra final tem 8.268.920 linhas, 2.347 fundos, 501 ativos.

6.1 Regressão por ativo e por mês: o padrão de VALE3 generaliza?

A equação estimada:

$$\text{peso}_{i,n,t} = g(x'_{i,n,t}\theta_{n,t}) + \text{erro}$$

$$x'\theta = \alpha_{n,t} + \theta_{n,t}^{aum} z(\ln AUM_i) + \theta_{n,t}^{cot} z(\ln \text{cot}_i) + \theta_{n,t}^{fic} FIC_i + \theta_{n,t}^{flow} \left(\frac{\text{fluxo}}{AUM} \right)_i + \theta_{n,t}^{bf} z(\beta_i^{fundo})$$

uma regressão logística por **célula (ativo n , mês t)** com ≥ 15 fundos holders — mesma equação da Etapa 1, agora estimada ativo a ativo. $z(\cdot)$ usa a distribuição de (fundo,mês) **únicos**, não repetida por ativo (senão um fundo com muitas posições pesaria mais na padronização). Resultado: 13.938 células estimadas (19 não convergiram, excluídas), 430 ativos, 236 com histórico suficiente (≥ 24 meses) para comparar com VALE3. Pseudo- R^2 médio de 0,441.

Adendo de processo: em 12 das 13.957 células (0,09%), o peso de todos os fundos daquele ativo-mês era essencialmente zero (posição residual/legado, ex.: Cia Hering set/2021, 17 fundos, peso = 0 para todos) — o denominador do pseudo- R^2 de McFadden colapsa nesses casos e o valor explode para $-\infty$, não por erro de ajuste, mas por degenerescência numérica de uma variável-resposta sem variância. Corrigido com um piso em -1 só nessas células (não afeta coeficiente nem APE, só a estatística de ajuste).

A generalização é medida em dois planos, como na Seção 5: pelo **sinal do coeficiente** (log-odds) e pelo **sinal do APE** (pontos percentuais, mais robusto a extremos).

Tabela 10: Generalização do padrão de VALE3 entre os 236 ativos com histórico suficiente.

Característica	% mesmo sinal (coef.)	% mesmo sinal (APE)	Percentil de VALE3 (APE)
Tamanho	55,9%	50,8% (acaso)	5,9
Cotistas	78,0%	73,3%	95,3
Fundo de cotas	55,9%	50,8% (acaso)	5,1
Captação/resgate	30,9% (pior que o acaso)	33,5% (pior que o acaso)	5,5
Beta do fundo	97,0%	96,2%	99,6

Fonte: elaboração própria (`scripts/25b` a 30).

Achado: Pelo APE (a medida mais confiável), tamanho e fundo de cotas generalizam **no nível do acaso** (50,8%, o mesmo que uma moeda) — mais fraco do que o sinal do coeficiente bruto já sugeria (55,9%), e bem mais fraco do que a v1 encontrou (tamanho/cotistas/FIC generalizando em 88–98% dos ativos). Captação/resgate generaliza **pior que o acaso** nos dois planos. O beta do

fundo é, disparado, o padrão mais universal: 96–97% dos ativos têm o mesmo sinal de VALE3, nas duas medidas. VALE3 continua extremo em quase toda dimensão do APE (percentis abaixo de 6 ou acima de 95), inclusive no beta do fundo, onde fica no topo da distribuição inteira.




Figura 10: Distribuição do APE médio de cada característica entre os 236 ativos com histórico suficiente (linha vermelha: VALE3; linha tracejada: mediana entre ativos).

6.2 Checagem complementar: uma única regressão com efeito-fixo de ativo e de mês

Como checagem independente, uma regressão *pooled* com todas as 8.268.920 observações, efeito-fixo de ativo *e* de mês (via demeaning iterativo, Frisch–Waugh–Lovell), erro-padrão agrupado por fundo — o coeficiente “dentro” de cada ativo-mês, líquido de qualquer nível particular daquele ativo ou choque daquele mês.

Adendo de processo: a primeira tentativa incluiu fundo de cotas (FIC) e a matriz ficou **exatamente singular** (número de condição = ∞). Não é bug: depois de remover o efeito de ativo e de mês, o FIC não tem mais nenhuma variação residual nesta especificação específica — seu efeito já está totalmente absorvido pelos efeitos-fixos. Removido da equação (as outras quatro variáveis não têm esse problema, número de condição cai para 2,2), o resultado é:

Tabela 11: Regressão pooled com efeito-fixo de ativo e de mês (8.268.920 obs., 501 ativos, 60 meses, 2.347 fundos).

Variável	Coeficiente	<i>t</i> (cluster por fundo)	Sig.
Tamanho	−0,000058	−0,6	n.s.
Cotistas	0,000137	1,2	n.s.
Captação/resgate	0,000004	0,3	n.s.
Beta do fundo	0,005565	39,6	***

Achado: As duas abordagens — regressão por ativo-mês e pooled com efeito-fixos — convergem para a mesma conclusão: o beta do fundo é a característica que mais robustamente explica o peso de **qualquer** ação carregada por esses fundos. Tamanho, cotistas e fluxo, que na v1 pareciam generalizar fortemente, aqui perdem quase toda a força quando testados no universo amplo de gestoras e ações com o beta do fundo como controle — boa parte do que pareciam explicar era, plausivelmente, um proxy indireto para o quão “equity-like” o fundo é.

6.3 O erro por gestora, agora com todas as ações

A pergunta: A regressão da Seção 6 cobre agora os 501 ativos, não só VALE3. Como se comporta o erro dela quando agregado por gestora — olhando a carteira inteira de ações, não só uma posição?

A equação estimada:

$$\text{erro}_{i,n,t} = \text{peso}_{i,n,t} - \widehat{\text{peso}}_{i,n,t}$$

onde $\widehat{\text{peso}}_{i,n,t}$ é o valor ajustado pela mesma regressão por célula (ativo n , mês t) da Seção 6 — 8.258.930 observações, 430 ativos, 2.347 fundos, 41 gestoras.

Adendo de processo: diferente de uma especificação com efeito-fixos de gestora (equação da Seção 5, onde as equações normais do MQO garantem soma-zero do resíduo dentro de cada grupo com dummy própria), aqui **cada célula tem sua própria regressão, sem dummy de gestora**. A média do erro por gestora, portanto, **não** é zero por construção — é genuinamente informativa, junto com a dispersão. Significância da média testada pela série **mensal** por gestora (mesmo estilo do resto do documento: $t = \bar{e}/(\text{dp}(e)/\sqrt{\text{meses}})$), não pelas 8,26 milhões de observações brutas (que tornaria qualquer diferença minúscula “significativa” só pelo tamanho da amostra).

Tabela 12: Erro médio (testado pela série mensal) e dispersão, por gestora, no universo de todas as ações — ordenado do viés mais positivo ao mais negativo.

Gestora	Obs.	Meses	Média	Sig.	dp
Guepardo Investimentos	10801	60	0,04499	***	0,06997
Núcleo Capital	12247	60	0,03773	***	0,02742
Ibiuna Investimentos	11384	60	0,01798	***	0,02404
Constellation Asset Management	17430	60	0,01388	***	0,02484
Real Investor	8247	60	0,01272	***	0,02233
Bogari Capital	21809	60	0,01208	***	0,01788
Squadra Investimentos	20941	60	0,00978	***	0,02883
Sharp Capital	37416	60	0,00936	***	0,02490
Atmos Capital	52386	60	0,00923	***	0,02062
Kinea Investimentos	10050	60	0,00750	***	0,02153
Verde Asset Management	26453	60	0,00650	***	0,02068
ARX Investimentos	21290	60	0,00560	***	0,01679
Gávea Investimentos	13274	60	0,00540	***	0,00620
AZ Quest	49456	60	0,00538	***	0,01578
Forpus Capital	10279	60	0,00467	***	0,01854
Claritas Investimentos	24520	60	0,00448	***	0,01374
Truxt Investimentos	54195	43	0,00409	***	0,01592
Legacy Capital	203	2	0,00369	**	0,01654
JGP	110083	60	0,00251	***	0,01129
Occam Brasil	75166	60	0,00229	***	0,01088
Absolute Investimentos	20379	29	0,00198	***	0,01249
Vinci Partners	140046	60	0,00197	***	0,01699
Western Asset	77837	60	0,00143	***	0,01421
Plural	17826	60	0,00121	***	0,01107
Opportunity	54836	60	0,00116	***	0,01704

continua na próxima página

Tabela 11 (continuação)

Gestora	Obs.	Meses	Média	Sig.	dp
Caixa	70987	60	0,00077	***	0,01451
BTG Pactual	520203	60	0,00054	***	0,01562
Safra Asset Management	562245	60	0,00023	***	0,00858
BB Asset Management	339045	60	0,00018	n.s.	0,01465
Credit Suisse	250689	60	0,00004	n.s.	0,00915
Kapitalo Investimentos	94917	60	-0,00018	n.s.	0,00937
BNP Paribas	248171	60	-0,00024	***	0,01131
XP	392104	60	-0,00026	***	0,00711
Santander Brasil Asset Management	348573	60	-0,00030	***	0,00840
Dahlia Capital	36993	31	-0,00059	***	0,00608
Bradesco Asset Management	931323	60	-0,00063	***	0,01101
SPX Capital	126867	60	-0,00087	***	0,01071
TNA Gestão Patrimonial	263178	60	-0,00100	***	0,00539
Itaú	2885337	60	-0,00113	***	0,00617
Julius Baer Family Office	273943	60	-0,00131	***	0,00758
Daycoval Asset Management	15801	60	-0,00165	***	0,00935

Fonte: elaboração própria (scripts/37_erro_multiativo.R, 38_erro_multiativo_gestora.R).




Figura 11: Distribuição do erro no universo multiativo, 8.258.930 observações.

Achado: 37 das 41 gestoras têm viés estatisticamente significativo a 0,1% (só 3 são n.s.: BB Asset Management, Credit Suisse, Kapitalo) — mas a maioria das magnitudes é pequena; a significância generalizada reflete o tamanho da amostra (8,26 milhões de obs.), não necessariamente relevância econômica. A **Guepardo** é o extremo isolado: viés de +0,045, mais de 10× a segunda colocada (Núcleo Capital, +0,038) — olhando a carteira de ações inteira, não só VALE3, ela sobe-pesa sistematicamente o que a fórmula prevê. O Itaú fica com viés pequeno e negativo (-0,00113) e dispersão baixa (0,00617, abaixo da mediana de 0,01451) — relativamente “previsível” nesse universo amplo.

Achado: Viés e dispersão andam juntos: correlação de 0,86 entre $|\text{viés}|$ e dp entre as 41 gestoras.




Figura 12: Cada ponto é uma gestora: erro médio (eixo x) vs. dispersão do erro (eixo y). Rótulos legíveis só nos extremos — a Tabela 11 tem os valores exatos das 41.

Não é um resultado óbvio a priori — uma gestora poderia ter viés grande mas consistente (erro sempre igual, dp baixo) ou viés pequeno mas errático (dp alto, média perto de zero). Na prática, as duas coisas se confundem: quem foge mais sistematicamente do que a fórmula prevê (Guepardo, Núcleo Capital, Ibiuna) também é quem tem o erro mais instável mês a mês. Isso é o material que vai orientar o desenho do robô caça-replicantes — decisão ainda em aberto, tratada à parte.

7 Resumo

1. **Etapa 1, equações (1)–(2):** θ_t mês a mês, cinco características (agora incluindo beta do fundo), todas predeterminadas ($t - 1$). Com o beta do fundo na conta, tamanho e cotistas ficam bem mais fracos em magnitude de t , mas continuam *** significativos; fundo de cotas e beta do fundo continuam com a força quase intacta. R^2 médio 0,532 (era 0,166). Custo: cobertura cai para 59 meses (fev/2017 em diante).
2. **Etapa 2, equação (3):** $\hat{\lambda} = 0,153$ (era 0,098) — um alvo mais preciso atenua menos o coeficiente. Erro u com comportamento parecido ao da versão anterior.
3. **Etapa 3:** λ treinado em 2017–2019 vence a ingênua fora da amostra (2020–2021) em RMSE, por margem pequena mas consistente (1,5%; vence em 61% dos meses de teste) — resultado qualitativamente igual ao da versão anterior. Flexibilizando para outros horizontes ($h = 2, 3, 6, 12$ meses), a vantagem se mantém nos 5 horizontes testados, com margem maior em

$h = 3-6$ ($\approx 4\%$) e quase sumindo em $h = 12$ (amostra de teste pequena, só 12 meses).

4. **Extensão de gestoras (Seção 5):** o padrão da Etapa 1 generaliza para além do Itaú — 2.820 fundos, 41 grupos de gestora, as cinco características sobrevivem quase intactas ao entrar o efeito fixo de gestora (R^2 0,540 $\rightarrow$ 0,632). Gestoras de varejo/plataforma carregam mais VALE3 que o Itaú equivalente; boutiques de gestão concentrada carregam bem menos.
5. **Extensão de todas as ações (Seção 6):** mesmo universo de fundos/gestoras, agora testado em 501 ativos (13.957 células ativo-mês). O beta do fundo é a característica que mais generaliza (97% dos ativos com o mesmo sinal de VALE3) e a única que sobrevive robusta numa regressão pooled com efeito-fixos de ativo e mês ($t = 39,6$); tamanho, cotistas e fluxo generalizam bem mais fraco do que a v1 havia encontrado, e fundo de cotas não é sequer identificável nessa especificação pooled (efeito absorvido pelos efeitos-fixos). Estendendo o erro dessa mesma regressão para todas as ações (Seção 6.3, 8.258.930 obs.), 37 das 41 gestoras têm viés significativo (mas em geral pequeno) e a Guepardo se destaca isolada (+0,045, 10 $\times$ a segunda colocada); viés e dispersão andam juntos (correlação 0,86) — material que vai orientar o desenho do robô caça-replicantes, decisão ainda em aberto. Ainda restrito a VALE3 no ajuste parcial/in-out-of-sample desta rodada.

Nenhuma dessas conclusões depende de Newey–West, cluster, Kalman, variável instrumental ou teste de Diebold–Mariano — o preço da simplicidade é não corrigir os vieses conhecidos do MQO direto no ajuste parcial, que a versão anterior do projeto documentou e tentou corrigir. Fica registrado como decisão consciente, não como descuido.