

v2 OFICIAL

Peso de VALE3 nos fundos do Itaú — versão simples, direta e objetiva
Cross-section (MQO + logit), ajuste parcial e um esquema in/out-of-sample — sem Newey–West,
sem Kalman, sem Diebold–Mariano, sem múltiplos métodos de robustez

João Paulo Zangrandi (FGV–EESP)

Resumo

Este documento retoma o projeto a partir da ideia original das anotações do orientador: uma cross-section simples que estima um fator latente θ , uma etapa logística para manter a previsão dentro de $[0, 1]$, e um modelo de ajuste parcial para a dinâmica. Cada etapa usa **um único método** (MQO ou MQO logístico), sem testes ou correções de robustez em cascata. Nesta versão, as características do fundo (inclusive o novo beta do próprio fundo) passam a ser sempre medidas no **último dia do mês anterior**, eliminando qualquer look-ahead bias.

Sumário

1	Por que esta versão existe	3
2	Etapa 1: a cross-section (MQO + logit)	3
2.1	O resultado: antes e depois do beta do fundo	4
2.2	O erro e	4
3	Etapa 2: o ajuste parcial	7
3.1	O resultado	7
3.2	O erro u	7
4	Etapa 3: um esquema in/out-of-sample	9
4.1	O resultado, fora da amostra	9
5	Extensão: mais gestoras	10
5.1	Quanto cada gestora carrega, relativo ao Itaú	11
5.2	O erro por gestora: quem o modelo explica melhor	13
6	Extensão: todas as ações	17
6.1	Regressão por ativo e por mês: o padrão de VALE3 generaliza?	17
6.2	Checagem complementar: uma única regressão com efeito-fixo de ativo e de mês . .	18
7	Resumo	19

1 Por que esta versão existe

As versões anteriores deste projeto acumularam camada sobre camada de robustez estatística (Newey–West, filtro de Kalman, variável instrumental com múltiplos esquemas de cluster, painel dinâmico de Arellano–Bond, teste de Diebold–Mariano) até o núcleo do modelo ficar difícil de enxergar por trás das correções. Esta versão volta ao desenho original discutido com o orientador: uma cross-section por mínimos quadrados que gera um fator latente θ , uma etapa logística (a única forma de robustez mantida, porque o peso é limitado a $[0, 1]$ e a reta não respeita esse limite), e um modelo de ajuste parcial estimado diretamente por MQO. Cada etapa produz um erro, examinado com estatísticas simples — média, desvio-padrão, assimetria, curtose, histograma — sem bateria de testes formais.

A base de dados (composição de carteiras da CVM, fundos do grupo Itaú, 2016–2021) é a mesma já construída e validada na versão anterior — essa parte nunca foi a fonte da complexidade.

2 Etapa 1: a cross-section (MQO + logit)

A pergunta: As características de um fundo explicam o peso de VALE3 que ele carrega? E, se sim, como transformar essa explicação numa previsão que respeite os limites de 0% a 100%?

Esta etapa une o que em versões anteriores deste documento eram duas seções separadas: a cross-section **linear** (para interpretar os coeficientes diretamente em pontos percentuais) e a cross-section **logística** (para gerar um peso previsto que nunca sai de $[0, 1]$). As duas usam as mesmas cinco características, mês a mês:

A equação estimada:

$$\text{peso}_{i,t} = \alpha_t + b_t^{aum} z(\ln AUM_i) + b_t^{cot} z(\ln \cot_i) + b_t^{fic} FIC_i + b_t^{low} \left(\frac{\text{capt} - \text{resg}}{AUM} \right)_i + b_t^{bf} z(\beta_i^{fundo}) + \text{erro}_{i,t} \quad (1)$$

$$\text{peso}_{i,t} = g(x'_{i,t} \theta_t) + e_{i,t}, \quad g(z) = \frac{1}{1 + e^{-z}} \quad (2)$$

A primeira é estimada por MQO (coeficientes em pontos percentuais, fáceis de interpretar); a segunda por máxima verossimilhança (glm quase-binomial), a única forma de robustez mantida nesta versão, porque $x'\theta$ pode sair de $[0, 1]$ mas $g(x'\theta)$ nunca sai. As duas rodam mês a mês, uma regressão por mês, sem nenhuma etapa de resumo temporal em cima (não é Fama–MacBeth).

Novidade desta versão — duas mudanças na Etapa 1:

- (a) Entra uma 5ª característica, o **beta do próprio fundo** β^{fundo} (covariância do retorno da cota com o Ibovespa, janela de 252 pregões — mesma metodologia já usada para o beta de VALE3).
- (b) **Todas** as cinco características (não só o beta do fundo) passam a ser medidas no **último dia do mês anterior** ($t - 1$), nunca no mês corrente — antes, AUM , cotistas e fluxo eram contemporâneos ao próprio mês t . Agora θ_t é 100% determinado: tudo que ele usa já era conhecido antes do mês t começar.

Adendo sobre a amostra: exigir as cinco características simultaneamente reduz a cobertura de 72 para **59 meses** (fev/2017 a dez/2021) — o beta do fundo exige ≥ 252 pregões de histórico de cota (quase um ano), então nenhum fundo tem essa variável disponível nos primeiros meses da amostra (jan/2016 a jan/2017 ficam sem fundos suficientes). Essa perda foi aceita conscientemente,

não é um erro: a partir daqui, todo número deste documento vem dos 8.335 fundo-meses com as cinco características completas (120 a 190 fundos por mês, média 141).

2.1 O resultado: antes e depois do beta do fundo

Para deixar claro o efeito de adicionar o beta do fundo, a tabela abaixo compara — na **mesma amostra** de 59 meses — a regressão linear com as quatro características clássicas contra a mesma regressão com o beta do fundo incluído.

Tabela 1: Θ linear: antes e depois do beta do fundo (mesma amostra, 59 meses, teste ingênuo de significância $t = \bar{\theta}/(\text{dp}(\theta)/\sqrt{59})$).

Variável	Média (sem β^{fundo})	Sig.	Média (com β^{fundo})	Sig.
α	0,04524	***	0,03554	***
b^{aum} (tamanho)	−0,00743	***	−0,00161	***
b^{cot} (cotistas)	0,01304	***	0,00179	***
b^{fic} (fundo de cotas)	−0,01956	***	−0,00567	***
b^{flow} (captação/resgate)	0,00987	n.s.	−0,00339	n.s.
b^{bf} (beta do fundo)	—	—	0,02325	***
R^2 médio	0,166		0,532	

* $p < 5\%$, ** $p < 1\%$, *** $p < 0,1\%$. Fonte: elaboração própria (`scripts/13_etapa1_unificada.R`, `14_etapa1_antes_depois.R`). **Nota de correção:** uma versão anterior deste documento reportava t errado nesta tabela (usava $\sqrt{6}$, o número de *variáveis*, em vez de $\sqrt{59}$, o número de *meses*, no denominador do teste) — os t corretos são $\approx 3,1\times$ maiores; tamanho e cotistas continuam *** significativos com o beta do fundo, não n.s./ $*$ como antes reportado.

Achado: O mesmo padrão que já tinha aparecido como checagem à parte na versão anterior (Tabela 11 do `tcc I.pdf`) agora é a especificação principal: com o beta do fundo na conta, tamanho e cotistas ficam **bem mais fracos** em magnitude de t (tamanho: $t = -17,8 \rightarrow -6,7$; cotistas: $t = 23,8 \rightarrow 6,0$) — mas **continuam estatisticamente significativos a 0,1%**, não perdem a significância. R^2 triplica ($0,166 \rightarrow 0,532$). Leitura: parte do que tamanho e cotistas explicavam era, na verdade, um proxy indireto para o quão “equity-like” é o fundo — o beta do fundo mede isso diretamente e absorve boa parte (não toda) dessa força explicativa.

A versão logística mostra o mesmo padrão de enfraquecimento (beta do fundo passa a dominar, mas tamanho e cotistas continuam significativos): $\alpha = -3,81$ (era $-3,13$), $b^{\text{aum}} = -0,06$ *** (era $-0,27$ ***), $b^{\text{cot}} = 0,05$ *** (era $0,44$ ***), $b^{\text{fic}} = -0,21$ *** (era $-0,67$ ***), $b^{\text{bf}} = 1,01$ ***.

2.2 O erro e

$e_{i,t} = \text{peso}_{i,t} - g(x'_{i,t}\theta_t)$, o erro de ajuste da regressão logística (dentro da amostra).

A média é zero em todo mês — mecânico (condição de primeira ordem da máxima verossimilhança com intercepto), não evidência de bom ajuste. O desvio-padrão caiu de 0,0305 (versão sem beta do fundo) para 0,0227 — o modelo ajusta melhor, coerente com o salto no R^2 .




Figura 1: Os seis componentes de θ_t linear (com beta do fundo) ao longo dos 59 meses, e o R^2 de cada regressão mensal. b^{bf} é sempre positivo, numa faixa relativamente estreita — coerente com sua significância forte e estável.

Tabela 2: Estatísticas do erro e (8.335 observações).

Estatística	Valor
Média	0,000000
Desvio-padrão	0,0227
Mediana	-0,0008
Mínimo / Máximo	-0,113 / 0,178
% de observações com $e > 0$	45,1%
Assimetria	0,39
Curtose	7,67 (normal = 3)
Previsões fora de $[0, 1]$	0 de 8.335




Figura 2: Histograma do erro e (8.335 observações). A linha tracejada marca zero.




Figura 3: Evolução mês a mês do erro e : nuvem cinza = erro individual de cada fundo-mês; linha azul = média mensal (mecanicamente zero); linha vermelha tracejada = desvio-padrão mensal. Eixo y restrito a $[-0,03, 0,06]$ para facilitar a leitura das duas linhas — 843 dos 8.335 pontos individuais (10%) ficam fora e não aparecem.

3 Etapa 2: o ajuste parcial

A pergunta: O peso de um fundo se move em direção ao que as características sugerem, ou fica parado onde está?

O alvo de um fundo, num mês, é $w_{i,t}^* = g(x'_{i,t}\theta_t)$ — a mesma previsão da Etapa 1. A hipótese de ajuste parcial: o fundo fecha uma fração λ da distância ao alvo a cada mês.

A equação estimada:

$$w_{i,t+1} - w_{i,t} = \lambda d_{i,t} + u_{i,t+1}, \quad d_{i,t} \equiv w_{i,t}^* - w_{i,t} \quad (3)$$

Estimado por MQO direto, sem intercepto, pooled em todos os fundo-meses — um único método, sem instrumento, sem efeito-fixo, sem painel dinâmico.

3.1 O resultado

$$\hat{\lambda} = 0,1534 \quad (\text{erro-padrão} = 0,0075, \quad t = 20,6, \quad R^2 = 0,050, \quad n = 7.987)$$

λ subiu de 0,098 (versão anterior) para 0,153 — esperado, já que o alvo w^* agora é mais preciso (R^2 maior na Etapa 1), o que atenua menos o coeficiente pelo erro de medida clássico (Problema 1 do modelo de ajuste parcial). Em média, um fundo fecha 15,3% da distância ao alvo por mês.

3.2 O erro u

Tabela 3: Estatísticas do erro u (7.987 observações, pares de meses consecutivos).

Estatística	Valor
Média	0,0002
Desvio-padrão	0,0151
Mediana	-0,0004
Mínimo / Máximo	-0,160 / 0,185
% de observações com $u > 0$	44,3%
Assimetria	0,59
Curtose	19,4 (normal = 3)

Praticamente idêntico ao da versão anterior (dp 0,0151 nas duas) — a mudança na Etapa 1 melhorou o ajuste de e , mas o comportamento do erro do ajuste parcial em si não muda muito.




Figura 4: Histograma do erro u (7.987 observações).




Figura 5: Evolução mês a mês do erro u . Eixo y restrito a $[-0,03, 0,04]$; 369 dos 7.987 pontos individuais (4,6%) ficam fora e não aparecem.

4 Etapa 3: um esquema in/out-of-sample

A pergunta: O λ estimado serve pra prever de verdade, em dados que o modelo nunca viu?

Um único corte no tempo, dentro do período coberto pela Etapa 1 (fev/2017 a dez/2021):

- **Treino:** 2017-02 a 2019-12 (35 meses, 4.352 observações).
- **Teste:** 2020-01 a 2021-11 (23 meses, 3.635 observações).

A equação estimada: $\hat{\lambda}$ é estimado pela equação (3) só com dados de treino, depois aplicado fixo aos meses de teste:

$$\hat{w}_{i,t+1} = w_{i,t} + \hat{\lambda}_{\text{treino}} d_{i,t} \quad (\text{ajuste parcial}) \quad \text{vs.} \quad \hat{w}_{i,t+1} = w_{i,t} \quad (\text{ingênua}) \quad (4)$$

θ_t continua sendo estimado mês a mês, sem vazamento de informação futura.

$$\hat{\lambda}_{\text{treino}} = 0,1951 \quad (35 \text{ meses de treino})$$

4.1 O resultado, fora da amostra

Tabela 4: RMSE e MAE dentro e fora da amostra, ajuste parcial vs. ingênua.

Amostra	Modelo	RMSE	MAE
Treino (2017–2019)	Ajuste parcial	0,01463	—
Treino (2017–2019)	Ingênua	0,01510	—
Teste (2020–2021)	Ajuste parcial	0,01560	0,00906
Teste (2020–2021)	Ingênua	0,01585	0,00847




Figura 6: RMSE dentro (treino) e fora (teste) da amostra, ajuste parcial vs. ingênua.

O ajuste parcial vence em RMSE nas duas amostras (razão teste = 0,984) — mesmo padrão da versão anterior. Em MAE, a ingênua continua vencendo nos casos típicos (0,00847 contra 0,00906):

o ajuste parcial evita alguns erros grandes, mas erra um pouco mais em geral. Mês a mês, vence em 14 dos 23 meses de teste (61%).




Figura 7: RMSE mês a mês no período completo (2017–2021). A linha vermelha tracejada marca o início do teste (2020-01). As duas linhas seguem coladas dos dois lados do corte — a vantagem do ajuste parcial é pequena e consistente, não concentrada num único mês.

5 Extensão: mais gestoras

A pergunta: O padrão encontrado (tamanho, cotistas, fundo de cotas, beta do fundo explicam o peso) é uma particularidade dos fundos do Itaú, ou aparece em qualquer gestora? E gestoras diferentes carregam mais ou menos VALE3 do que outras, tudo o mais igual?

Até aqui, a amostra era só os fundos do grupo Itaú. Esta extensão amplia para **todos os fundos do universo CVM** que já tiveram VALE3 em algum momento (2016–2021) — 2.820 fundos, 41 grupos de gestora (agrupados por marca controladora; ex.: “BTG Pactual” junta 4 rótulos diferentes que a CVM usa para a mesma casa). A equação (1) ganha um efeito fixo de gestora — 40 variáveis de 0/1 (uma por grupo, exceto o Itaú, que fica como referência, para não haver colinearidade perfeita com o intercepto):

$$\text{peso}_{i,t} = \alpha_t + b_t^{\text{aum}} z(\ln AUM_i) + \dots + b_t^{\text{bf}} z(\beta_i^{\text{fundo}}) + \sum_{g \neq \text{Itaú}} \gamma_{g,t} D_{g,i} + \text{erro}_{i,t}$$

Adendo de processo: ao rodar essa regressão pela primeira vez, todas as cinco características saíram não significativas — um resultado que parecia dizer “a identidade da gestora explica tudo, as características não importam mais”. Investigando, a causa não era o efeito fixo de gestora: era **um único fundo-mês com dado corrompido** (peso de VALE3 registrado como 1.398,5 — impossível, peso é uma fração de 0 a 1) que, sozinho, distorcia a regressão de um mês inteiro (set/2018). Removido esse ponto (junto com outro caso igual, peso = 1.087,8, e 13 fundo-meses de beta do fundo com denominador degenerado por cota irregular), o resultado abaixo é o que sobrevive.

Tabela 5: Θ linear, amostra de todas as gestoras (59 meses, 71.569 obs.): sem e com efeito fixo de gestora.

Variável	Média (sem FE gestora)	Sig.	Média (com FE gestora)	Sig.
α	0,03647	***	0,03294	***
b^{aum} (tamanho)	-0,00178	***	-0,00171	***
b^{cot} (cotistas)	0,00236	***	0,00118	***
b^{fic} (fundo de cotas)	-0,00681	***	-0,00621	***
b^{flow} (captação/resgate)	-0,00446	***	-0,00312	**
b^{bf} (beta do fundo)	0,02536	***	0,02528	***
R^2 médio	0,540		0,632	

Achado: As cinco características sobrevivem quase intactas ao entrar o efeito fixo de gestora — tamanho, FIC e beta do fundo praticamente não mudam; cotistas perde metade da magnitude ($0,0024 \rightarrow 0,0012$), continuando *** significativo. R^2 sobe de 0,540 para 0,632: a identidade da gestora tem poder explicativo próprio, mas não “rouba” o efeito das características — o padrão da Etapa 1 generaliza para além do Itaú. Diferente da amostra só-Itaú (Tabela 1), aqui a captação/resgate é significativa (*** sem FE, ** com FE) — com 71.569 observações contra 8.335, há poder estatístico para detectar um efeito de fluxo pequeno que na amostra menor não era distinguível de ruído.

5.1 Quanto cada gestora carrega, relativo ao Itaú

Cada γ_g é a diferença média de peso de VALE3 entre um fundo da gestora g e um fundo do Itaú com as mesmas cinco características. Positivo = carrega mais que o Itaú equivalente; negativo = carrega menos.

Tabela 6: Coeficiente de cada gestora vs. Itaú (referência), ordenado do maior para o menor.

Gestora	Meses	Coef.	Sig.
Legacy Capital	1	+0,1288	—
Núcleo Capital	4	+0,0243	***
Occam Brasil	59	+0,0230	***
Caixa	59	+0,0179	***
Western Asset	59	+0,0179	***
AZ Quest	56	+0,0172	***
Gávea Investimentos	34	+0,0157	***
Sharp Capital	59	+0,0144	***
Truxt Investimentos	42	+0,0131	***
Kinea Investimentos	54	+0,0119	***
Bradesco Asset Management	59	+0,0113	***
Plural	59	+0,0110	***
BB Asset Management	59	+0,0103	***
Claritas Investimentos	59	+0,0094	***
Santander Brasil Asset Management	59	+0,0088	***
Absolute Investimentos	28	+0,0085	n.s.
BNP Paribas	59	+0,0078	***
Opportunity	59	+0,0076	**
SPX Capital	59	+0,0054	*
Verde Asset Management	59	+0,0047	*
Real Investor	47	+0,0038	n.s.
Credit Suisse	59	+0,0037	***
Dahlia Capital	30	+0,0032	n.s.
JGP	59	+0,0026	n.s.
Safra Asset Management	59	+0,0017	**

continua na próxima página

Tabela 6 (continuação)

Gestora	Meses	Coef.	Sig.
ARX Investimentos	57	−0,0009	n.s.
BTG Pactual	59	−0,0017	***
Vinci Partners	59	−0,0023	n.s.
XP	59	−0,0025	***
Daycoval Asset Management	57	−0,0062	***
Julius Baer Family Office	59	−0,0073	***
TNA Gestão Patrimonial	59	−0,0100	***
Kapitalo Investimentos	52	−0,0105	***
Ibiuna Investimentos	45	−0,0141	***
Squadra Investimentos	45	−0,0209	***
Atmos Capital	33	−0,0238	***
Bogari Capital	11	−0,0278	***
Constellation Asset Management	25	−0,0316	***
Forpus Capital	33	−0,0391	***
Guepardo Investimentos	33	−0,0602	***

“Meses” = quantos dos 59 meses aquela gestora teve dados suficientes para entrar na regressão (nem toda gestora tem VALE3 o período inteiro). *t* e significância: teste ingênuo sobre a média dos coeficientes mensais, mesmo estilo das demais tabelas. Fonte: elaboração própria (`scripts/20_etapa1_com_gestora.R`, `21_coeficientes_gestora.R`).

Leitura: gestoras grandes de varejo/plataforma (Caixa, Bradesco, BB, Santander, Western Asset) carregam *mais* VALE3 que o Itaú equivalente; gestoras boutique de gestão concentrada/high-conviction (Guepardo, Forpus, Constellation, Bogari, Atmos, Squadra) carregam *bem menos*. Não é uma medida de causalidade — é o resíduo estrutural, depois de controlar pelas 5 características, e a leitura mais plausível é filosofia de gestão: carteiras concentradas tendem a evitar “o nome que todo mundo tem” a menos que apostem nele especificamente, diferente de uma plataforma de varejo mais próxima de uma composição ampla.




Figura 8: Evolução mensal do coeficiente de gestora (vs. Itaú), para as 5 gestoras mais positivas e as 5 mais negativas entre as que têm cobertura de pelo menos 45 dos 59 meses. O pico isolado da Kapitalo em jul/2018 não é erro de dado: naquele mês, um único fundo da casa concentrava 37% em VALE3 dentro de um grupo pequeno (13 fundos), o suficiente para puxar a estimativa mensal daquele grupo — ilustra como esses coeficientes podem ser voláteis mês a mês quando o grupo tem poucos fundos.

5.2 O erro por gestora: quem o modelo explica melhor

A pergunta: O erro e da cross-section (Seção 2.2) é parecido entre gestoras, ou tem gestoras que o modelo explica muito melhor que outras?

Adendo de processo: a primeira tentativa comparou a *média* do erro e entre gestoras — deu essencialmente zero para todas as 40, sem exceção. Não é coincidência nem erro de cálculo: como a regressão tem uma dummy própria para cada gestora, as equações normais do MQO garantem que o resíduo soma zero **dentro** de cada grupo com dummy própria, em todo mês. Média do erro por gestora é, portanto, zero por construção, não uma medida útil. O que sobra informativo é a **dispersão** do erro dentro de cada gestora — quanto maior, mais difícil o modelo (mesmo com a dummy) explica a alocação daquele grupo em VALE3.

Tabela 7: Desvio-padrão do erro e de cada gestora, ordenado do mais disperso para o menos.

Gestora	Obs.	Meses	dp
Verde Asset Management	429	59	0,0353
Opportunity	786	59	0,0349
Vinci Partners	1492	59	0,0349
Sharp Capital	748	59	0,0346
BTG Pactual	4904	59	0,0342
Caixa	829	59	0,0341
BB Asset Management	3663	59	0,0289
Truxt Investimentos	767	42	0,0289
Bradesco Asset Management	9411	59	0,0283
Western Asset	1191	59	0,0281
Real Investor	126	47	0,0272
AZ Quest	679	56	0,0261
ARX Investimentos	422	57	0,0261
Credit Suisse	1980	59	0,0243
Kapitalo Investimentos	824	52	0,0240
Absolute Investimentos	161	28	0,0239
Safra Asset Management	4375	59	0,0226
BNP Paribas	1957	59	0,0217
Santander Brasil Asset Management	3157	59	0,0207
Julius Baer Family Office	1999	59	0,0205
Itaú	19386	59	0,0199
JGP	1748	59	0,0185
XP	2555	59	0,0180
Occam Brasil	1117	59	0,0175
SPX Capital	1474	59	0,0171
Claritas Investimentos	339	59	0,0166
Ibiuna Investimentos	256	45	0,0160
Daycoval Asset Management	145	57	0,0154
Squadra Investimentos	541	45	0,0152
Plural	204	59	0,0139
Kinea Investimentos	111	54	0,0109
Constellation Asset Management	217	25	0,0106
TNA Gestão Patrimonial	1630	59	0,0097
Gávea Investimentos	464	34	0,0092
Núcleo Capital	56	4	0,0087
Atmos Capital	845	33	0,0072
Dahlia Capital	260	30	0,0068
Bogari Capital	114	11	0,0033
Forpus Capital	82	33	0,0026
Guepardo Investimentos	124	33	0,0021

Legacy Capital fica de fora (apenas 1 observação, dp indefinido). Fonte: elaboração própria (`scripts/33_erro_por_gestora.R`, `34_erro_gestora_dispersao.R`).

Achado: O Itaú fica perto do meio da distribuição ($dp = 0,0199$, posição 21 de 40, do menos para o mais disperso). Nos extremos: gestoras *boutique* concentradas e de renda variável pura — Verde, Opportunity, Vinci Partners, Sharp, BTG — têm o erro mais disperso ($dp \approx 0,034$ – $0,035$, quase o dobro do Itaú); gestoras com mandatos mais amplos ou passivos — TNA, Kinea, Plural, Squadra, Daycoval — têm o erro bem mais concentrado ($dp \approx 0,009$ – $0,015$). Leitura: as 5 características usadas explicam melhor o comportamento de gestoras com carteiras mais diversificadas/institucionais do que o de gestoras de convicção concentrada, cuja alocação em VALE3 provavelmente depende mais de uma visão específica sobre o papel do que dos atributos genéricos do fundo.




Figura 9: Distribuição do erro e (com efeito-fixe de gestora), 71.569 observações.




Figura 10: Distribuição do desvio-padrão do erro entre as 40 gestoras (linha vermelha: Itaú).




Figura 11: Evolução mensal do desvio-padrão do erro, para as 5 gestoras mais dispersas e as 5 menos dispersas (cobertura mínima de 45 dos 59 meses). Os picos isolados (Vinci Partners em 2021, Plural em 2018) seguem o mesmo padrão já visto na evolução dos coeficientes de gestora: grupos pequenos, sensíveis a um único fundo concentrado naquele mês.

6 Extensão: todas as ações

A pergunta: O padrão encontrado para VALE3 é uma particularidade daquele papel, ou aparece em qualquer ação que esses mesmos fundos carreguem?

Mantendo o mesmo universo de 2.820 fundos e 41 gestoras da extensão anterior, esta seção olha **todas as ações** que eles carregam, não só VALE3. Mesma limpeza de custódia usada no `tcc I.pdf` (v1): a CVM registra a mesma ação sob rótulos diferentes conforme o tipo de posição (direta, cedida/recebida em empréstimo, direito de subscrição); só a posição direta é mantida, classificada pelo sufixo numérico do *ticker* (convenção B3). Resultado: 523 ativos de posição direta, 10.603.928 linhas fundo-ativo-mês — VALE3 reproduziu exatamente as 96.349 linhas já conhecidas, confirmando a limpeza.

Adendo de processo: a tabela de características (AUM/cotistas/fluxo) da Etapa 2 só cobria os meses em que cada fundo tinha VALE3 — 16,8% dos fundo-mês do painel multiativo (fundos que naquele mês só tinham *outras* ações) ficavam sem essas características por um motivo evitável, não por falta real de dado. Reconstruída usando o conjunto correto de fundo-mês, a cobertura subiu para 97,6%. A amostra final tem 8.268.920 linhas, 2.347 fundos, 501 ativos.

6.1 Regressão por ativo e por mês: o padrão de VALE3 generaliza?

A equação estimada:

$$\text{peso}_{i,n,t} = \alpha_{n,t} + b_{n,t}^{aum} z(\ln AUM_i) + b_{n,t}^{cot} z(\ln cot_i) + b_{n,t}^{fic} FIC_i + b_{n,t}^{flow} (\text{fluxo}/AUM)_i + b_{n,t}^{bf} z(\beta_i^{fundo}) + \text{erro}$$

uma regressão por **célula (ativo n , mês t)** com ≥ 15 fundos holders — mesma equação da Etapa 1, agora estimada ativo a ativo. $z(\cdot)$ usa a distribuição de (fundo,mês) **únicos**, não repetida por ativo (senão um fundo com muitas posições pesaria mais na padronização). Resultado: 13.957 células estimadas, 430 ativos, 236 com histórico suficiente (≥ 24 meses) para comparar com VALE3.

Tabela 8: Generalização do padrão de VALE3 entre os 236 ativos com histórico suficiente.

Característica	% dos ativos com mesmo sinal que VALE3	Percentil de VALE3
Tamanho	62,3%	1,7
Cotistas	78,8%	98,3
Fundo de cotas	54,2%	0,8
Captação/resgate	43,2% (pior que o acaso)	5,9
Beta do fundo	97,0%	99,6

Fonte: elaboração própria (`scripts/25b` a `30`).

Achado: Diferente do que a v1 encontrou (tamanho/cotistas/FIC generalizando em 88–98% dos ativos), aqui — com o beta do fundo na conta e o universo ampliado para 41 gestoras — tamanho e fundo de cotas generalizam bem mais fraco, e captação/resgate generaliza **pior que o acaso** (a maioria dos ativos tem sinal oposto ao de VALE3 para essa variável). O beta do fundo é, disparado, o padrão mais universal: 97% dos ativos têm o mesmo sinal de VALE3. VALE3 continua extremo em quase toda dimensão (percentis abaixo de 6 ou acima de 98), inclusive no beta do fundo, onde fica no topo da distribuição inteira.




Figura 12: Distribuição do coeficiente médio de cada característica entre os 236 ativos com histórico suficiente (linha vermelha: VALE3; linha tracejada: mediana entre ativos).

6.2 Checagem complementar: uma única regressão com efeito-fixo de ativo e de mês

Como checagem independente, uma regressão *pooled* com todas as 8.268.920 observações, efeito-fixo de ativo e de mês (via demeaning iterativo, Frisch–Waugh–Lovell), erro-padrão agrupado por fundo — o coeficiente “dentro” de cada ativo-mês, líquido de qualquer nível particular daquele ativo ou choque daquele mês.

Adendo de processo: a primeira tentativa incluiu fundo de cotas (FIC) e a matriz ficou **exatamente singular** (número de condição = ∞). Não é bug: depois de remover o efeito de ativo e de mês, o FIC não tem mais nenhuma variação residual nesta especificação específica — seu efeito já está totalmente absorvido pelos efeitos-fixos. Removido da equação (as outras quatro variáveis não têm esse problema, número de condição cai para 2,2), o resultado é:

Tabela 9: Regressão pooled com efeito-fixo de ativo e de mês (8.268.920 obs., 501 ativos, 60 meses, 2.347 fundos).

Variável	Coefficiente	t (cluster por fundo)	Sig.
Tamanho	−0,000058	−0,6	n.s.
Cotistas	0,000137	1,2	n.s.
Captação/resgate	0,000004	0,3	n.s.
Beta do fundo	0,005565	39,6	***

Achado: As duas abordagens — regressão por ativo-mês e pooled com efeito-fixo — convergem para a mesma conclusão: o beta do fundo é a característica que mais robustamente explica o peso de **qualquer** ação carregada por esses fundos. Tamanho, cotistas e fluxo, que na v1 pareciam generalizar fortemente, aqui perdem quase toda a força quando testados no universo amplo de

gestoras e ações com o beta do fundo como controle — boa parte do que pareciam explicar era, plausivelmente, um proxy indireto para o quão “equity-like” o fundo é.

7 Resumo

1. **Etapa 1, equações (1)–(2):** θ_t mês a mês, cinco características (agora incluindo beta do fundo), todas predeterminadas ($t - 1$). Com o beta do fundo na conta, tamanho e cotistas ficam bem mais fracos em magnitude de t , mas continuam *** significativos; fundo de cotas e beta do fundo continuam com a força quase intacta. R^2 médio 0,532 (era 0,166). Custo: cobertura cai para 59 meses (fev/2017 em diante).
2. **Etapa 2, equação (3):** $\hat{\lambda} = 0,153$ (era 0,098) — um alvo mais preciso atenua menos o coeficiente. Erro u com comportamento parecido ao da versão anterior.
3. **Etapa 3:** λ treinado em 2017–2019 vence a ingênua fora da amostra (2020–2021) em RMSE, por margem pequena mas consistente (1,6%; vence em 61% dos meses de teste) — resultado qualitativamente igual ao da versão anterior.
4. **Extensão de gestoras (Seção 5):** o padrão da Etapa 1 generaliza para além do Itaú — 2.820 fundos, 41 grupos de gestora, as cinco características sobrevivem quase intactas ao entrar o efeito fixo de gestora (R^2 0,540 $\rightarrow$ 0,632). Gestoras de varejo/plataforma carregam mais VALE3 que o Itaú equivalente; boutiques de gestão concentrada carregam bem menos. O erro *médio* por gestora é zero por construção (efeito-fixos absorve); a *dispersão* não é — boutiques de convicção concentrada (Verde, Opportunity, Vinci, Sharp, BTG) têm erro até o dobro mais disperso que gestoras de mandato amplo (TNA, Kinea, Plural), sinal de que as cinco características explicam pior a alocação de gestoras concentradas.
5. **Extensão de todas as ações (Seção 6):** mesmo universo de fundos/gestoras, agora testado em 501 ativos (13.957 células ativo-mês). O beta do fundo é a característica que mais generaliza (97% dos ativos com o mesmo sinal de VALE3) e a única que sobrevive robusta numa regressão pooled com efeito-fixos de ativo e mês ($t = 39,6$); tamanho, cotistas e fluxo generalizam bem mais fraco do que a v1 havia encontrado, e fundo de cotas não é sequer identificável nessa especificação pooled (efeito absorvido pelos efeitos-fixos). Ainda restrito a VALE3 no ajuste parcial/in-out-of-sample desta rodada.

Nenhuma dessas conclusões depende de Newey–West, cluster, Kalman, variável instrumental ou teste de Diebold–Mariano — o preço da simplicidade é não corrigir os vieses conhecidos do MQO direto no ajuste parcial, que a versão anterior do projeto documentou e tentou corrigir. Fica registrado como decisão consciente, não como descuido.